

Лабораторная работа: Анализ цен на жильё в Бостоне

Цель: освоить методы предобработки, визуализации, построения и оценки линейной регрессии.

Исходные данные

Датасет Boston Housing (506 строк, 13 признаков + целевая переменная MEDV — медианная стоимость жилья в тыс. \$).

`load_boston()` удалён из `scikit-learn` начиная с версии 1.2 из-за этических претензий к признаку `B` (подробнее: M. Carlisle, «Racist data destruction?», 2019). Поэтому датасет нужно загружать вручную одним из двух способов.

Способ 1 (проще) — через `fetch_openml`

```
from sklearn.datasets import fetch_openml

boston = fetch_openml(name="boston", version=1, as_frame=True)

df = boston.frame
```

Способ 2 (если недоступен OpenML) — из оригинального источника CMU

```
import pandas as pd
import numpy as np

!wget -q http://lib.stat.cmu.edu/datasets/boston -O boston.txt

raw_df = pd.read_csv("boston.txt", sep=r"\s+", skiprows=22, header=None)
data = np.hstack([raw_df.values[::2, :], raw_df.values[1::2, :2]])
target = raw_df.values[1::2, 2]

columns = ['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD',
           'TAX', 'PTRATIO', 'B', 'LSTAT']
df = pd.DataFrame(data, columns=columns)
df['MEDV'] = target
```

Задание 1: Первичный анализ

- Выведите размерность и типы данных
- Проверьте наличие пропущенных значений
- Постройте распределение MEDV (гистограмма + boxplot)
- Найдите признаки с наибольшей корреляцией с MEDV

Задание 2: Предобработка

- Разбейте данные на train/test (train_test_split, test_size=0.2, зафиксируйте random_state)
- Нормализуйте числовые признаки с помощью StandardScaler — обучайте scaler только на train, применяйте к обоим наборам
- Создайте бинарный признак: is_high_value = MEDV > 30
- Удалите выбросы по Z-score (> 3 стандартных отклонений) — только на train, чтобы не исказить оценку на тесте

Задание 3: Визуализация

- Постройте тепловую карту корреляций (seaborn.heatmap)
- Нарисуйте scatter plot RM vs MEDV (количество комнат vs цена)
- Постройте график зависимости MEDV от LSTAT (доля бедного населения)

Задание 4: Линейная регрессия

- Постройте модель линейной регрессии MEDV ~ RM + LSTAT + PTRATIO на train, оцените на test
- Выведите коэффициенты и интерпретируйте их
- Оцените качество модели: R^2 , MAE, RMSE (отдельно на train и test — сравните, есть ли переобучение)
- Посчитайте VIF (Variance Inflation Factor) для признаков модели, чтобы проверить мультиколлинеарность
- Постройте график остатков (residuals vs predicted) — проверьте, выполняются ли предпосылки линейной регрессии (гомоскедастичность, отсутствие явных паттернов)

Задание 5: NumPy-анализ вручную

Реализуйте линейную регрессию вручную через матрицы: $\beta = (X^T X)^{-1} X^T y$

- Сравните коэффициенты с результатами sklearn (на тех же train-данных)

Задание 6: Кластеризация (дополнительно)

- Масштабируйте признаки CRIM, NOX, DIS перед кластеризацией (StandardScaler)
- Примените KMeans для кластеризации районов по этим признакам (зафиксируйте random_state, обоснуйте выбор числа кластеров, например через метод локтя)
- Визуализируйте кластеры на scatter plot
- Проанализируйте среднюю цену жилья (MEDV) в каждом кластере

Сдача работы

В виде Jupyter Notebook.

В отчёте должно быть:

- Всё описанное в пунктах выше
- Выводы по корреляциям и модели
- Анализ остатков и мультиколлинеарности — что они говорят о качестве и ограничениях модели
- Возможные улучшения (полиномиальные признаки, регуляризация — Ridge/Lasso, кросс-валидация)
- Краткая рефлексия: какие признаки датасета вы бы не стали использовать в реальной модели ценообразования жилья и почему

На дополнительные баллы: модель посложнее (например, регуляризованная регрессия или ансамблевый метод) с кросс-валидацией и кратким обоснованием, почему выбранная модель лучше базовой линейной регрессии.

Вопрос на подумать (думать обязательно)

Как математически объяснить, почему мультиколлинеарность приводит к проблемам у линейной регрессии?

Подсказка: рассмотрите формулу оценки коэффициентов $\beta = (X^T X)^{-1} X^T y$ и подумайте, что происходит с матрицей $X^T X$, когда столбцы X становятся линейно зависимыми (или близки к этому).