

Лабораторная работа 1. Средние величины и показатели вариации

По имеющимся в следующей таблице данным по группе из 20 студентов необходимо:

- 1) построить интервальный ряд распределения признака и его график;
- 2) рассчитать модальное, медианное и среднее значение, установить его типичность с помощью коэффициентов вариации;
- 3) проверить распределение на нормальность с помощью коэффициентов асимметрии и эксцесса.

№ п/п	Вариант									
	1	2	3	4	5	6	7	8	9	10
	Рост, см	Вес, кг	Доход, у.е./мес.	IQ (тест Айзенка)	Тет- радь, листов	Воз- раст, лет	Соот- ношение «рост/вес»	Стаж работы, мес.	Кол-во друзей, чел.	Время решения контрольной, час.
1	159	45	430	95	24	20	3,533	26	5	8,5
2	160	61	640	115	32	25	2,623	63	7	6,2
3	161	56	610	111	24	28	2,875	94	10	6,8
4	162	48	330	97	24	19	3,375	16	4	12,0
5	162	54	420	105	60	23	3,000	49	2	7,5
6	164	58	290	98	16	20	2,828	14	6	10,0
7	166	51	480	109	90	26	3,255	78	9	7,2
8	169	62	610	120	24	19	2,726	10	5	4,2
9	170	70	840	122	48	30	2,429	130	10	3,5
10	170	72	330	92	24	20	2,361	20	3	9,5
11	171	73	560	110	16	28	2,342	86	8	7,8
12	171	64	450	102	48	21	2,672	29	4	8,0
13	172	73	350	108	32	26	2,356	75	7	6,0
14	174	68	310	100	48	21	2,559	22	4	4,8
15	176	81	380	104	64	20	2,173	32	1	8,6
16	176	84	340	104	48	19	2,095	21	5	10,0
17	178	76	660	128	90	27	2,342	96	8	4,5
18	181	90	450	106	48	26	2,011	70	9	12,5
19	183	68	540	105	32	23	2,691	59	6	10,5
20	192	95	750	117	60	27	2,021	98	4	6,5

Средние величины и показатели вариации (теория)

Имеются следующие данные о возрастном составе студентов группы заочного отделения ВУЗа (лет): 19; 19; 19; 20; 20; 20; 20; 20; 20; 20; 20; 21; 21; 21; 22; 23; 23; 24; 25; 25; 25; 26; 27; 29.

Для анализа распределения студентов по возрасту требуется: 1) построить интервальный ряд распределения и его график; 2) рассчитать модальный, медианный и средний возраст, установить его типичность с помощью коэффициентов вариации; 3) проверить распределение на нормальность с помощью коэффициентов асимметрии и эксцесса.

Решение. Для построения интервального ряда из дискретного используется формула Стерджесса, с помощью которой определяется оптимальное количество интервалов (n):

$$n = 1 + 3,322 \lg N, \quad (10)$$

где N – число величин в дискретном ряде.

В нашей задаче $n = 1 + 3,322 \lg 25 = 1 + 3,322 * 1,398 = 5,64$. Так как число интервалов не может быть дробным, то округлим его до ближайшего целого числа, т.е. до 6.

После определения оптимального количества интервалов определяем размах интервала по формуле:

$$h = H / n, \quad (11)$$

где H – размах вариации, определяемый по формуле (12).

$$H = X_{\max} - X_{\min}, \quad (12)$$

где $X_{\max}$ и $X_{\min}$ — максимальное и минимальное значения в совокупности.

В нашей задаче $h = (29 - 19)/6 = 1,67$.

Интервальная группировка данных приведена в первом столбце таблицы 1, которая содержит также алгоритм и промежуточные расчеты.

Таблица 1. Вспомогательные расчеты для решения задачи

X_i , лет	f_i	$X_{и}$	$X_{и}f_i$	$\frac{X_{и}-\bar{X}}{\bar{X}}$	$ X_{и}-\bar{X} f_i$	$(\frac{X_{и}-\bar{X}}{\bar{X}})^2$	$(\frac{X_{и}-\bar{X}}{\bar{X}})^2 f_i$	$(X_{и}-\bar{X})^3 f_i$	$(X_{и}-\bar{X})^4 f_i$
до 20,67	1 2	19,83 3	237,99 6	-2,13 4	25,602	4,552	54,623	-116,539	248,638
20,67-22,33	4	21,5	86,000	-0,46 5	1,866	0,218	0,871	-0,406	0,189
22,33-24	3 3	23,16 7	69,501	1,200	3,601	1,441	4,323	5,190	6,231
24-25,67	3	24,83 3	74,499	2,866	8,599	8,217	24,650	70,659	202,543

X_i , лет	f_i	$X_{и}$	$X_{и}f_i$	$\frac{X_{и}-\bar{X}}{\bar{X}}$	$ X_{и}-\bar{X} f_i$	$(\frac{X_{и}-\bar{X}}{\bar{X}})^2$	$(\frac{X_{и}-\bar{X}}{\bar{X}})^2 f_i$	$(X_{и}-\bar{X})^3 f_i$	$(X_{и}-\bar{X})^4 f_i$
25,67-27,33	2	26,5	53,000	4,533	9,067	20,552	41,105	186,348	844,806
более 27,33	1	28,167	28,167	6,200	6,200	38,446	38,446	238,383	1478,091
Итого	25	—	549,163	—	54,937	—	164,018	383,636	2780,498

На основе этой группировки строится график распределения возраста студентов (рис.2).




Рис.2. График распределения возраста студентов.

Мода – это наиболее часто повторяющееся значение признака. Для интервального ряда с равными интервалами величина моды определяется по формуле (13):

$$Mo = X_{Mo} + h \frac{f_{Mo} - f_{Mo-1}}{2f_{Mo} - f_{Mo-1} - f_{Mo+1}}, \quad (13)$$

где X_{Mo} – нижнее значение модального интервала; f_{Mo} – число наблюдений или объем взвешивающего признака (вес признака) в модальном интервале; f_{Mo-1} – то же для интервала, предшествующего модальному; f_{Mo+1} – то же для

интервала, следующего за модальным; h – величина интервала изменения признака в группах.

В нашей задаче чаще всего повторяется (12 раз) первый интервал возраста (до 20,67), значит, это и есть модальный интервал. Используя формулу (13), определяем точное значение модального возраста:

$$Mo = 19 + 1,667 \cdot (12 - 0) / (2 \cdot 12 - 4 - 0) = 20 \text{ (лет)}.$$

Медиана – это такое значение признака, которое приходится на середину ранжированного ряда. Таким образом, в ранжированном ряду распределения одна половина ряда имеет значения признака больше медианы, другая – меньше медианы. Для интервального ряда с равными интервалами величина медианы определяется так:

$$Me = X_{Me} + h \frac{0,5 \sum f - f'_{Me-1}}{f_{Me}}, \quad (14)$$

где X_{Me} – нижняя граница медианного интервала; h – его величина (размах); f'_{Me-1} – сумма наблюдений (или объема взвешивающего признака), накопленная до начала медианного интервала; f_{Me} – число наблюдений или объем взвешивающего признака в медианном интервале.

В нашей задаче второй интервал возраста (от 20,67 до 22,33) является медианным, так как на него приходится середина ряда распределения возраста. Используя формулу (14), определяем точное значение медианного возраста:

$$Me = 20,67 + 1,667 \cdot (12,5 - 12) / 4 = 20,878 \text{ (года)}.$$

Средняя величина – это обобщающий показатель совокупности, характеризующий уровень изучаемого явления или процесса. Средние величины могут быть *простыми* и *взвешенными*. Простая средняя рассчитывается при наличии двух и более статистических величин, расположенных в произвольном (несгруппированном) порядке, по общей формуле (15). Взвешенная средняя величина рассчитывается по сгруппированным статистическим величинам с использованием общей формулы (16).

$$\bar{X} = \sqrt[m]{\frac{\sum X_i^m}{N}}; \quad (15) \quad \bar{X} = \sqrt[m]{\frac{\sum X_i^m f_i}{\sum f_i}}. \quad (16)$$

При этом обозначено: X_i – значения отдельных статистических величин или середин группировочных интервалов; m – показатель степени, от значения которого зависят *виды* средних величин. Используя формулы (15) и (16) при разных показателях степени m , получаем частные формулы каждого вида (см. таблицу 2).

Таблица 2. Виды степенных средних и их применение

m	Название средней	Формула расчета средней		Когда применяется
		простая	взвешенная	
1	Арифметическая	$\bar{X}_{ap} = \frac{\sum X_i}{N} \quad (17)$	$\bar{X}_{ap} = \frac{\sum X_i f_i}{\sum f_i} \quad (18)$	Чаще всего, кроме тех случаев, когда должны применяться другие виды средних
-1	Гармоническая	$\bar{X}_{гм} = \frac{N}{\sum \frac{1}{X_i}} \quad (19)$	$\bar{X}_{гм} = \frac{\sum f_i}{\sum \frac{f_i}{X_i}} \quad (20)$	Для осреднения величин с дробной размерностью при наличии дополнительных данных по числителю дробной размерности
0	Геометрическая	$\bar{X}_{geom} = \sqrt[N]{\prod_{i=1}^N X_i} \quad (21)$	$\bar{X}_{geom} = \sqrt[N]{\prod_{i=1}^N X_i^{f_i}} \quad (22)$	Для осреднения цепных индексов динамики
2	Квадратическая	$\bar{X}_{кв} = \sqrt{\frac{\sum X_i^2}{N}} \quad (23)$	$\bar{X}_{кв} = \sqrt{\frac{\sum X_i^2 f_i}{\sum f_i}} \quad (24)$	Для осреднения вариации признака (расчет средних отклонений)
3	Кубическая	$\bar{X}_{куб} = \sqrt[3]{\frac{\sum X_i^3}{N}} \quad (25)$	$\bar{X}_{куб} = \sqrt[3]{\frac{\sum X_i^3 f_i}{\sum f_i}} \quad (26)$	Для расчета индексов нищеты населения
1	Хронологическая	$\bar{X}_{xp} = \frac{\frac{X_1 + X_N}{2} + \sum_{i=2}^{N-1} X_i}{N-1} \quad (27)$	$\bar{X}_{xp} = \frac{\sum (X_i + X_{i+1}) f_i}{2 \sum f_i} \quad (28)$	Для осреднения моментных статистических величин

Выбор вида формулы средней величины зависит от содержания осредняемого признака и конкретных данных, по которым ее приходится вычислять. Показатель степени m в общей формуле средней величины оказывает существенное влияние на значение средней величины: по мере увеличения степени возрастает и средняя величина (правило мажорантности средних величин), то есть $\bar{X}_{гм} < \bar{X}_{geom} < \bar{X}_{ap} < \bar{X}_{кв} < \bar{X}_{куб}$. Так, если $m \rightarrow +\infty$, то $\bar{X} \rightarrow X_{\max}$, а если $m \rightarrow -\infty$, то $\bar{X} \rightarrow X_{\min}$.

В нашей задаче, применяя формулу (18) и подставляя вместо X_i середины интервалов возраста $X_{и}$, определяем средний возраст студентов: $\bar{X}_{ap} = 549,163/25 = 21,967$ (года). Теперь осталось определить типичность или нетипичность найденной средней величины. Это осуществляется с помощью расчета показателей вариации. Чем ближе они к нулю, тем типичнее найденная средняя величина для изучаемой статистической совокупности. При этом критериальным значением коэффициента вариации служит $1/3$.

Коэффициенты вариации рассчитываются как отношение среднего отклонения к средней величине. Поскольку среднее отклонение может определяться линейным и квадратическим способами, то соответствующими могут быть и коэффициенты вариации.

Среднее линейное отклонение определяется по формулам (29) и (30):

$$L = \frac{\sum |X_i - \bar{X}|}{N} \quad \text{– простое;} \quad (29) \qquad L = \frac{\sum |X_i - \bar{X}| f_i}{\sum f_i} \quad \text{– взвешенное.} \quad (30)$$

Среднее квадратическое отклонение определяется как корень квадратный из дисперсии, то есть по формуле (31):

$$\sigma = \sqrt{D}. \quad (31)$$

Дисперсия определяется по формулам (32) или (33):

$$D = \frac{\sum (X_i - \bar{X})^2}{N} \quad \text{– простая;} \quad (32) \qquad D = \frac{\sum (X_i - \bar{X})^2 f_i}{\sum f_i} \quad \text{– взвешенная.} \quad (33)$$

В нашей задаче, применяя формулу (30), определим ее числитель и внесем в расчетную таблицу. В итоге получим среднее линейное отклонение: $L = 54,937/25 = 2,198$ (года). Разделив это значение на средний возраст, получим

линейный коэффициент вариации: $\lambda = \frac{L}{\bar{X}} = 2,198/21,967 = 0,100$. По значению этого коэффициента для рассмотренной группы студентов делаем вывод о типичности среднего возраста, т.к. расчетное значение коэффициента вариации не превышает критерияльного ($0,100 < 0,333$).

Применяя формулу (33), получим в итоге дисперсию: $D = 164,018/25 = 6,561$. Извлечем из этого числа корень и получим в результате среднее квадратическое отклонение: $\sigma = \sqrt{D} = 2,561$ (года). Разделив это значение на

средний возраст, получим квадратический коэффициент вариации: $v = \frac{\sigma}{\bar{X}} = 2,561/21,967 = 0,117$. По значению этого коэффициента для рассмотренной группы студентов можно сделать вывод о типичности среднего возраста, т.к. расчетное значение коэффициента вариации не превышает критерияльного ($0,117 < 0,333$).

В качестве показателей асимметрии используются: коэффициент асимметрии – нормированный момент третьего порядка (34) и коэффициент асимметрии Пирсона (35):

$$r_3 = \frac{\mu_3}{\sigma^3}, \quad (34)$$

$$As = \frac{\bar{X} - Mo}{\sigma}. \quad (35)$$

Если значение коэффициента асимметрии положительно, то в ряду преобладают варианты, которые больше средней (правосторонняя скошенность), если отрицательно – левосторонняя скошенность. Если коэффициент асимметрии равен 0, то вариационный ряд симметричен.

В нашей задаче $\mu_3 = \frac{\sum (x_i - \bar{x}) f_i}{\sum f_i} = 383,636/25 = 15,345$; $\sigma^3 = 2,561^3 = 16,797$;
 $r_3 = 15,345/16,797 = 0,914 > 0$, значит, распределение студентов по росту с правосторонней асимметрией. Это подтверждает и значение коэффициента асимметрии Пирсона: $As = (21,967 - 20)/2,561 = 0,768$.

Для характеристики *крутизны распределения* используется центральный момент 4-го порядка:

$$\mu_4 = \frac{\sum (x_i - \bar{x})^4 f_i}{\sum f_i} \quad (36)$$

Для образования безразмерной характеристики определяется нормированный момент 4-го порядка $r_4 = \frac{\mu_4}{\sigma^4}$, который и характеризует крутизну (заостренность) графика распределения. При измерении асимметрии эталоном служит нормальное (симметричное) распределение, для которого $r_4 = 3$. Поэтому для оценки крутизны данного распределения в сравнении с нормальным вычисляется эксцесс распределения (37):

$$Ex = \frac{\mu_4}{\sigma^4} - 3 \quad (37)$$

Для приближенного определения эксцесса может быть использована формула Линдберга (38):

$$Ex = d_{\sigma/2} - 0,3829, \quad (38)$$

где $d_{\sigma/2}$ – доля количества вариантов, лежащих в интервале, равном половине σ (в ту и другую сторону от средней величины).

В нашей задаче числитель центрального момента 4-го порядка рассчитан в последнем столбце расчетной таблицы. В итоге по формуле (37) имеем: $Ex = (2780,498/25)/2,561^4 - 3 = 111,220/43,017 - 3 = -0,415$. Так как $Ex < 0$, то распределение низковершинное. Это подтверждает и приблизительный расчет по формуле (38): в интервале $21,967 \pm 0,5 * 2,561$, то есть от 20,687 до 23,248 находится примерно 21,4% студентов. Таким образом, $Ex = 0,214 - 0,3829 = -0,169$.