Лабораторная работа 3. Многомерная линейная регрессия

По имеющимся в файле players.csv данным (характеристики футболистов) необходимо:
1) провести корреляционный анализ: построить матрицу парных корреляций Пирсона и тепловую карту (heatmap); для пары признаков с максимальной по модулю корреляцией рассчитать коэффициент частной корреляции и проверить, не обусловлена ли их связь третьим фактором;
2) разделить выборку на обучающую и тестовую части в соотношении 80/20 и стандартизировать признаки;
3) обучить модели: обычную линейную регрессию, гребневую регрессию (Ridge) и Лассо (Lasso), гиперпараметр alpha подобрать с помощью кросс-валидации; сравнить качество моделей по метрикам MSE, RMSE, MAE, R2 и оценить важность признаков;
4) провести анализ остатков лучшей модели: построить график «предсказанные значения/остатки» и Q-Q график, проверить нормальность остатков 2 любыми статистическими тестами, а гетероскедастичность — тестом Уайта.
Целевая переменная – рейтинг игрока overall. Признаки: value_eur, wage_eur, age, height_cm, weight_kg; sofifa_id – идентификатор, из анализа исключается; value_eur, wage_eur преобразовать по формуле ln(1+x).

Вариант 1	Вариант 2	Вариант 3
Обычная линейная регрессия + Ridge	Обычная линейная регрессия + Lasso	Ridge+Lasso

Первые 5 строк файла players.csv

sofifa_id	overall	value_eur	wage_eur	age	height_cm	weight_kg
158023	93	78000000.0	320000.0	34	170	72
188545	92	119500000.0	270000.0	32	185	81
20801	91	45000000.0	270000.0	36	187	83
190871	91	129000000.0	270000.0	29	175	68
192985	91	125500000.0	350000.0	30	181	70

Теория

- ### Корреляционный анализ

Коэффициент корреляции Пирсона измеряет силу и направление линейной связи двух признаков:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

Коэффициент принимает значения от –1 до +1; чем ближе |r| к единице, тем сильнее линейная связь. Корреляционная матрица содержит коэффициенты Пирсона для всех пар признаков и наглядно изображается тепловой картой (heatmap), где цвет ячейки соответствует величине связи. Сильная взаимная корреляция признаков между собой (мультиколлинеарность) делает оценки коэффициентов регрессии нестабильными.

- ### Частная корреляция

Частный коэффициент корреляции измеряет связь между признаками x и y при устранении влияния третьего фактора z:

$$r_{xy \cdot z} = \frac{r_{xy} - r_{xz} r_{yz}}{\sqrt{(1 - r_{xz}^2)(1 - r_{yz}^2)}}$$

где r_{xy}, r_{xz}, r_{yz} — парные коэффициенты Пирсона. Если частная корреляция практически совпадает с парной, связь x и y собственная; если она резко убывает к нулю — связь наведена третьим фактором. Эквивалентный способ вычисления — корреляция остатков регрессий x на z и y на z.

- ### Разделение выборки и стандартизация признаков

Выборка случайным образом делится на обучающую (train, 80%) и тестовую (test, 20%) части: модель обучается только на train, а качество оценивается на test — данных, которые модель «не видела». Признаки стандартизуются (z-преобразование):

$$x' = \frac{x - \bar{x}}{\sigma_x}$$

где $\bar{x}$ и σ_x — среднее значение и стандартное отклонение признака. Сильно скошенные признаки (value_eur, wage_eur) предварительно логарифмируются:

$$x' = \ln(1 + x)$$

- Многомерная линейная регрессия

Модель связывает целевую переменную y с p признаками:

$$y = b_0 + b_1 x_1 + b_2 x_2 + \ldots + b_p x_p + \varepsilon$$

где b_0 — свободный член (intercept), b_j — коэффициенты регрессии, ε — случайная ошибка. В матричной форме модель записывается как

$$y = Xb + \varepsilon$$

Коэффициенты оцениваются методом наименьших квадратов (МНК) — минимизацией суммы квадратов остатков; решение в матричной форме:

$$\hat{b} = (X^T X)^{-1} X^T y$$

- Гребневая регрессия (Ridge) и Лассо (Lasso)

Регуляризация добавляет к сумме квадратов остатков штраф на величину коэффициентов. Гребневая регрессия (Ridge, L2-штраф):

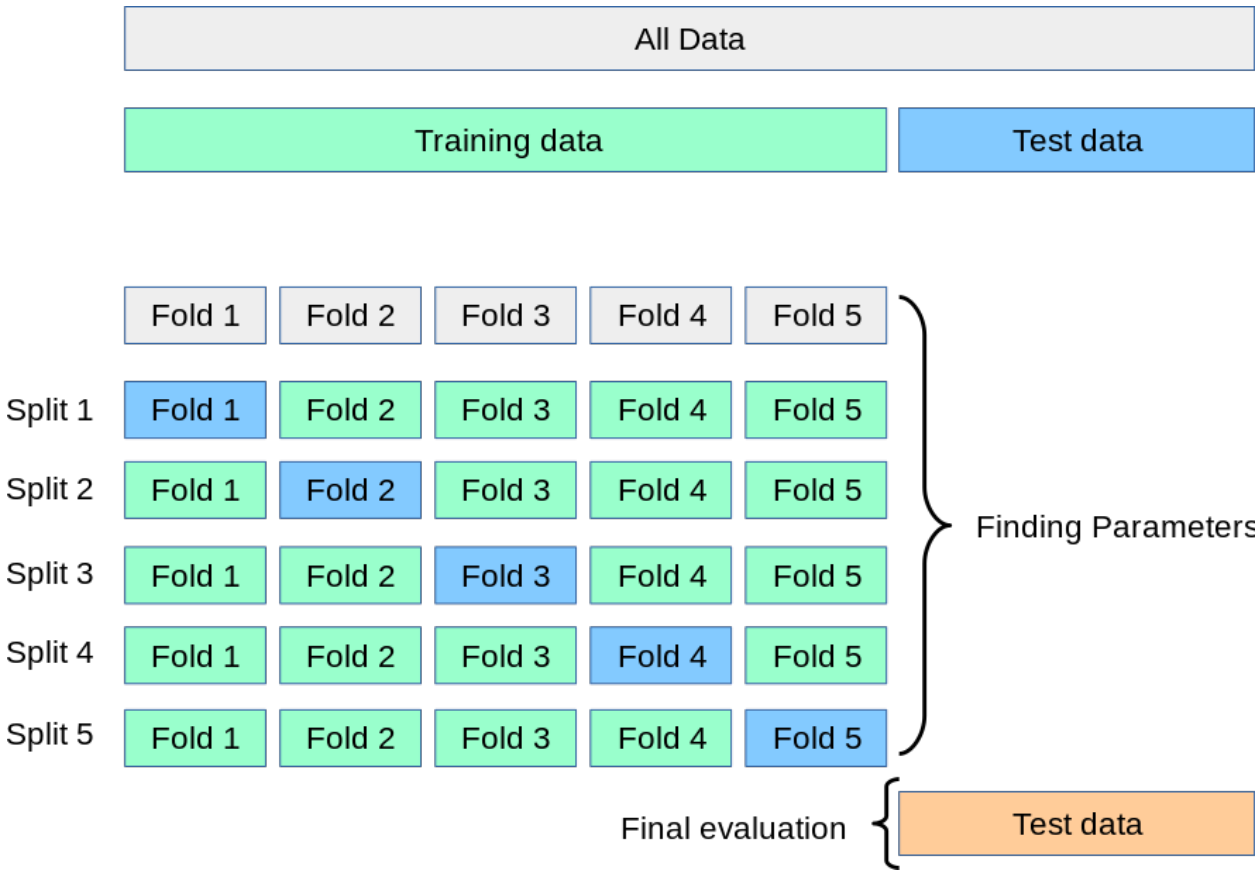
$$\sum_{i=1}^{n} (y_i - b_0 - \sum_{j=1}^{p} b_j x_{ij})^2 + \alpha \sum_{j=1}^{p} b_j^2 \to min$$

Лассо (Lasso, L1-штраф):

$$\sum_{i=1}^{n} (y_i - b_0 - \sum_{j=1}^{p} b_j x_{ij})^2 + \alpha \sum_{j=1}^{p} |b_j| \to min$$

Ridge сокращает значения коэффициентов, но не обнуляет их; Lasso способен обращать коэффициенты в ноль, выполняя тем самым отбор признаков. Гиперпараметр α управляет силой регуляризации и подбирается кросс-валидацией.

- Кросс-валидация



При k-блочной кросс-валидации (k-fold) обучающая выборка случайным образом делится на k блоков; каждый блок по очереди становится проверочным, а модель обучается на остальных k–1 блоках. Итоговая оценка – среднее по блокам:

$$CV(\alpha) = \frac{1}{k}\sum_{i=1}^{k} MSE_i$$

Из набора значений α выбирается то, при котором CV(α) минимально.

- Формулы для расчета метрик

MSE – Mean Squared Error (среднеквадратичная ошибка)

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

RMSE – Root Mean Squared Error (корень из среднеквадратичной ошибки)

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

MAE – Mean Absolute Error (средняя абсолютная ошибка)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

R2 – коэффициент детерминации

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}$$

Метрики рассчитываются на тестовой выборке.

- График предсказанные значения/остатки

Остатки — разности между фактическими и предсказанными значениями:

$$e_i = y_i - \hat{y}_i$$

Отображаем остатки на оси Y и предсказанные значения на оси X.

- Тесты нормальности остатков

Используйте готовые реализации из библиотек.

- Тест Уайта (гетероскедастичность)

Используйте готовые реализации из библиотек.