

Тема 2.
Числовые характеристики
вариационных рядов

Средняя арифметическая

Под *средней арифметической* понимается такое значение признака, которое бы имела каждая единица совокупности, если бы общий итог всех значений признака был распределён равномерно между всеми единицами совокупности.

Простая средняя

Пример 1. Требуется вычислить *средний стаж* работы 12 работников.

При этом известны *индивидуальные значения* признака (стажа) в годах:

6, 4, 5, 3, 3, 5, 5, 6, 3, 7, 4, 5.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{6 + 4 + 5 + 3 + 3 + 5 + 5 + 6 + 3 + 7 + 4 + 5}{12} = \frac{56}{12} = 4,7$$

Взвешенная средняя

Индивидуальные значения признака (стажа) в годах: 6, 4, 5, 3, 3, 5, 5, 6, 3, 7, 4, 5 (из примера 1).

Пример 2. Сгруппируем данные примера 1:

x_i	3	4	5	6	7
m_i	3	2	4	2	1

$$\bar{x} = \frac{\sum_{i=1}^k x_i m_i}{n} = \frac{3*3 + 4*2 + 5*4 + 6*2 + 7*1}{12} = 4,7$$

Средняя в интервальном ряду

$I\%$	$[80;85)$	$[85;90)$	$[90;95)$	$[95; \text{И БОЛЕЕ})$	
$\bar{a}$	82,5	87,5	92,5	97,5	
m_i	2	4	3	1	$\Sigma = 10$

$$\bar{x} = \frac{82,5 * 2 + 87,5 * 4 + 92,5 * 3 + 97,5 * 1}{10} = 89$$

Формулы

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

– простая средняя арифметическая,

$$\bar{x} = \frac{1}{\sum_{i=1}^k n_i} \sum_{i=1}^k n_i x_i$$

– взвешенная средняя арифметическая.

Задание. Имеются следующие данные о производственном стаже 100 рабочих на одном из предприятий:

Стаж работы (лет)	До 10	10 – 20
Количество человек	60	40

Определить:

- а) Средний стаж работы на предприятии: $(60 \times 5 + 40 \times 15) / 100$
- б) Среднее количество рабочих, относящихся к одной группе стажа: $(60 + 40) / 2$

Робастные показатели

- При сборе данных часто встречаются наблюдения, резко отличающиеся по величине от большинства вариантов, которые называются **аномальными вариантами**.
- *Определение.* Средние величины, которые сохраняют точность представления выборки при наличии аномальных наблюдений, называются **робастными**.

Средняя арифметическая (простая)

Пример 2.

$X = (0,12; 0,96; 0,97; 1,00; 1,01; 1,02; 1,04; 10,52),$

$$\bar{x} = \frac{0,12 + \dots + 1,04 + 10,52}{8} = 2,08$$

Средняя (усеченная порядка α)

$$\bar{x}_{\alpha} = \frac{1}{n-2m} (x_{(m+1)} + \dots + x_{(n-m)}),$$

где $\alpha = \frac{m}{n}$ — доля «ненадёжных» вариантов для малых значений симметрического вариационного ряда.

В нашем примере: $m=1$; $\alpha=1/8=0,125$;

$$\bar{x}_{0,125} = \frac{1}{8-2} (0,96 + \dots + 1,04) = 1,00$$

Среднее (по Винздору порядка α)

$$\bar{x}_{\alpha} = \frac{1}{n} \left(mx_{(m+1)} + x_{(m+1)} + \dots + x_{(n-m)} + mx_{(n-m)} \right)$$

В нашем примере

$$\bar{x}_{1/8} = \frac{1}{8} (2(0,96 + 1,04) + 0,97 + \dots + 1,02) = 1,00$$

Вариация

Термин "вариация" произошел от латинского *variatio* – изменение, колеблемость, различие.

Под ***вариацией в статистике*** понимают такие количественные изменения величины исследуемого признака в пределах однородной совокупности, которые обусловлены перекрещивающимся влиянием действия различных факторов.

Среднее линейное отклонение

Среднее линейное отклонение определяется как средняя арифметическая из отклонений индивидуальных значений от средней, без учета знака этих отклонений:

$$\bar{d} = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

$$\bar{d} = \frac{\sum_{i=1}^k |x_{(i)} - \bar{x}| m_i}{\sum_{i=1}^k m_i}$$

Дисперсия

Дисперсия –
это средняя
арифметическая
квадратов отклонений
каждого значения
признака
от общей средней

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

$$\sigma^2 = \frac{\sum_{i=1}^k m_i (x_{(i)} - \bar{x})^2}{\sum_{i=1}^k m_i}$$

$$\sigma_{\bar{x}}^2 = \frac{\sum x^2}{n} - (\bar{x})^2 = \overline{x^2} - (\bar{x})^2$$

Среднее квадратическое отклонение

Среднее квадратическое отклонение представляет собой корень квадратный из дисперсии.

$$\sigma = \sqrt{\sigma^2}$$

Среднее квадратическое отклонение является мерой надежности средней. Чем меньше среднее квадратическое отклонение, тем лучше средняя арифметическая отражает собой всю представляемую совокупность.

Относительные показатели вариации

Относительное линейное отклонение

характеризует долю усредненного значения абсолютных отклонений от средней величины.

$$K_d = \frac{\bar{d}}{\bar{x}} 100\%$$

Коэффициент вариации характеризует степень однородности выборки

$$V = \frac{\sigma}{\bar{x}} 100\%$$

Относительные показатели вариации

Замечание.

Если $V \leq 33\%$, то выборка считается однородной по исследуемому признаку.

Если $33\% < V < 100\%$, то выборка имеет допустимую степень концентрации.

Если $V > 100\%$, то выборка считается неоднородной и нет смысла считать числовые характеристики.

Асимметрия и эксцесс

Показатели, характеризующие геометрическую форму распределения:

Асимметрия характеризует меру скошенности графика влево / вправо,

$$As = \frac{\mu_3}{\sigma^3}$$

Эксцесс характеризует меру его высоты.

$$E_x = \frac{\mu_4}{\sigma^4} - 3$$

μ_s - центральные моменты s -го порядка

Центральные моменты

Моменты случайной величины

- *Начальный момент s -го порядка $\alpha_s[X]$*

$$\alpha_s[X] = \begin{cases} \sum_{i=1}^n x_i^s p_i & - \text{ для дискретной случайной величины;} \\ \int_{-\infty}^{+\infty} x^s f(x) dx & - \text{ для непрерывной случайной величины.} \end{cases}$$

- *Математическое ожидание $M[X] = \alpha_1[X]$*
- *Центральный момент s -го порядка $\beta_s[X]$*

$$\beta_s[X] = \begin{cases} \sum_{i=1}^n (x_i - M[X])^s p_i & - \text{ для дискретной случайной величины;} \\ \int_{-\infty}^{+\infty} (x - M[X])^s f(x) dx & - \text{ для непрерывной случайной величины.} \end{cases}$$

Нормальное распределение

Плотность вероятности

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


**Оценка параметров
нормального распределения
($n > 20$)**

$$\mu = \bar{x} = \frac{1}{n} \sum_i x_i$$

$$\sigma = s = \sqrt{\frac{\sum_i (x_i - \bar{x})^2}{n - 1}}$$

Стандартное норм. распр.

$$\sigma = 1; \mu = 0$$



Доверительный интервал

Определение

Точечной оценкой называется число, которое используют для оценки параметра ГС.

Для того, чтобы делать содержательные выводы, стараются находить не точечные, а интервальные оценки.

Определение

Доверительный интервал - это интервал, который с заданной вероятностью накрывает оцениваемый параметр ГС.

Важно!

Имейте ввиду, что для разных выборок одной и той же ГС могут получаться разные доверительные интервалы!

Уровни значимости и доверия

При работе с доверительными интервалами часто используют два термина.

- Уровень значимости α - это вероятность, с которой значение параметра не попадает в доверительный интервал.
- Уровень доверия $\beta = 1 - \alpha$ - это вероятность того, что доверительный интервал покрывает значение параметра.

Обычно уровень значимости равен 0.01, 0.05, 0.1, что соответствует уровню доверия 0.99, 0.95, 0.9. Очень часто уровни значимости и доверия измеряются в процентах, то есть уровень доверия 0.99 и 99% - это одно и то же.

Доверительный интервал для среднего

Если выборка больше 30, но стандартное отклонение нам неизвестно, то вместо σ мы будем использовать выборочное стандартное

отклонение $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$.

Теорема



Доверительный интервал для среднего при неизвестной дисперсии, но большой выборке ($n > 30$), имеет вид $\left(\bar{x} - \frac{s}{\sqrt{n}} z_{\alpha}; \bar{x} + \frac{s}{\sqrt{n}} z_{\alpha} \right)$.

где z_{α} - это квантиль нормального распределения уровня $1 - \frac{\alpha}{2}$.

Квантили

Квантиль (β квантиль) x_β — число, такое, что заданная случайная величина превышает его лишь с фиксированной вероятностью $(1 - \beta)$, т.е. $P(X \leq x_\beta) = \beta$.

Квантиль рассчитывается по уравнению: $F(x_\beta) = \beta$
 $\beta = 1 - \alpha$



Критерий согласия

Критерием согласия называют статистический критерий проверки гипотезы о предполагаемом законе неизвестного распределения.

H_0 : «между эмпирическим распределением и теоретической моделью нет никакого различия».

Критерий Пирсона

Критерий согласия χ^2 (хи-квадрат)
Пирсона.

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

n -объем выборки

k -число интервалов разбиения выборки

n_i -число значений выборки, попавших в i -й интервал

np_i - теоретическая частота попадания значений случайной величины X в i -й интервал.

Критерий Пирсона: выводы

Правило применения критерия χ^2 .

*По формуле вычисляют - $\chi^2_{\text{набл}}$ выборочное значение статистики критерия.

*выбрав уровень значимости α критерия, по таблице χ^2 -распределения находим критическую точку $\chi^2_{\alpha, df}$

*Если $\chi^2_{\text{набл}} \leq \chi^2_{\alpha, df}$, то гипотеза H_0 не противоречит опытным данным;


если $\chi^2_{\text{набл}} > \chi^2_{\alpha, df}$, то гипотеза H_0 отвергается.

Число степеней свободы $df = k - 1 - v$,

где v — количество оцениваемых параметров по выборке

Демонстрационный пример

Построим эмпирическую гистограмму и теоретическую кривую



Необходимым условием применения критерия Пирсона является наличие в каждом из интервалов не менее 5 наблюдений

Правило сложения дисперсий

Пусть вся совокупность разбита на k групп:

m_j — количество объектов, включённых в j -ую группу;

$\bar{x}_j$ — среднее значение признака в j -ой группе;

$\bar{x}$ — общее среднее.

Относительные показатели вариации

Внутригрупповая дисперсия

характеризует случайную вариацию в каждой отдельной группе

$$\delta_j^2 = \frac{\sum_{i=1}^{m_j} (x_{ij} - \bar{x}_j)^2}{m_j} = \frac{\sum_{i=1}^{m_j} x_{ij}^2}{m_j} - (\bar{x}_j)^2$$

Средняя из внутригрупповых дисперсий

характеризует вариацию, возникающую под влиянием случайных факторов, кроме групповых

$$\bar{\delta}^2 = \frac{\sum_{j=1}^k \delta_j^2 m_j}{\sum_{j=1}^k m_j}$$

Дисперсия совокупности

Межгрупповая дисперсия отражает вариацию изучаемого признака, которая возникает под влиянием признака-фактора, положенного в основу группировки.

$$\sigma_{м.гр.}^2 = \frac{\sum_{j=1}^k (\bar{x}_j - \bar{x})^2 m_j}{\sum_{j=1}^k m_j}$$

Дисперсия признака может быть определена как сумма межгрупповой дисперсии и среднего значения из внутригрупповых дисперсий, т.е. получим *формулу сложения дисперсий* :

$$\sigma^2 = \bar{\delta}^2 + \sigma_{м.гр.}^2$$