

Тема 4.

Регрессионный анализ

Группы методов

Две группы методов: методы корреляционного анализа и методы регрессионного анализа

Корреляционный анализ

Существует ли связь между явлениями?

Насколько сильная связь между явлениями?

Регрессионный анализ

Каков характер связи между явлениями?

Построение регрессионной модели явлений.


Построение уравнения регрессии

Задача построения уравнения регрессии для одного факторного и одного результативного признака формулируется следующим образом:

Пусть имеется набор значений двух переменных: результативного признака y_i и факторного признака x_i . Между этими переменными существует объективная связь вида: $y_i = f(x_i) + \varepsilon_i$.

Необходимо по данным наблюдения $y_i, x_i, i = \overline{1, n}$ подобрать функцию $\hat{y} = F(x)$, наилучшим образом описывающую существующую связь.

Графическая интерпретация



$$y_i = a + bx_i + e_i \quad i = 1, 2, \dots, n$$

Случайные ошибки

$$y_i = a + bx_i + e_i \quad i = 1, 2, \dots, n$$

Предполагается, что случайная ошибка имеет **нулевое математическое ожидание и постоянную дисперсию σ^2** , а ошибки $\varepsilon^{(i)}$, $\varepsilon^{(j)}$ для различных наблюдений i, j **независимы**.

Переменные модели должны иметь распределение, близкое к **нормальному**.

Зависимая и независимые переменные должны быть измерены в **метрической шкале**.

Для построения линейных регрессий, зависима и независимые переменные должны иметь **линейную** связь.

Допущения

Отсутствие автокорреляции – отсутствие независимости остатков. Выявляется с помощью теста Дурбина-Уотсона (обнаруживает автокорреляцию первого порядка).

- Если $d=0$ – полная положительная автокорреляция
- Если $d=4$ – полная отрицательная автокорреляция
- Если $d=2$ – отсутствие автокорреляции


Гомоскедастичность - дисперсия остатков одинакова для каждого значения. Определяется с помощью диаграммы рассеяния.

Автокорреляция ошибок


Автокорреляция (последовательная корреляция) остатков определяется как корреляция между соседними значениями случайных отклонений во времени (временные ряды) или в пространстве (перекрестные данные). Она обычно встречается во временных рядах и очень редко – в пространственных данных.

Возможны следующие случаи:

- Случай **положительной автокорреляции** ошибок регрессии, когда знаки соседних отклонений, как правило, совпадают между собой ($e_i \approx e_{i-1}$).



- Случай **отрицательной автокорреляции**, когда соседние отклонения имеют как правило противоположные знаки ().



Метод наименьших квадратов

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \rightarrow \min$$

Применение МНК для расчёта параметров регрессии рассмотрим на примере

$$\hat{y} = a + bx$$

$$S = \sum_{i=1}^n (y_i - a - bx_i)^2 \rightarrow \min$$

Вычисление коэффициентов

$$a = \frac{\sum_{i=1}^n y_i - b \sum_{i=1}^n x_i}{n} = \bar{y} - b\bar{x}$$

$$b = \frac{\frac{\sum x \sum y}{n} - \sum xy}{\frac{(\sum x)^2}{n} - \sum x^2} \quad \text{или} \quad b = r_{xy} \frac{\sigma_y}{\sigma_x}$$

Значимость параметров

Значимость параметров линейной модели определяется с помощью t-критерия Стьюдента.

- для параметра а:

$$t_a = |a| \frac{\sqrt{n-2}}{\sigma_{y-\hat{y}}}$$

$$t_b = |b| \frac{\sqrt{n-2}}{\sigma_{y-\hat{y}}} \sigma_x$$

- для параметра b:

$$\sigma_{y-\hat{y}} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}} \quad \sigma_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}}$$

Параметр признаётся значимым, если выполняется неравенство: $t_{расч.} > t_{v,\alpha}$

($v = n - m$ – число степеней свободы; m – число оцениваемых параметров)

Значимость уравнения

Вывод о правильности вида взаимосвязи и характеристику значимости всего уравнения регрессии получают с помощью F-критерия Фишера.

$$F_{расч} > F_{\nu_1, \nu_2}$$

$F_{расч}$ - расчётное значение критерия Фишера;

F_{ν_1, ν_2} - критическое значение критерия Фишера, выбираемое по специальной таблице распределения F-критерия.

$$\nu_1 = m - 1, \nu_2 = n - m$$

m – число параметров уравнения регрессии.

Р – расчетное Коэффициент детерминации


$$F_{\text{р.}} = \frac{S_{\text{факт}}}{S_{\text{ост}}} = \frac{R^2}{1 - R^2} \cdot \frac{n - m}{m + 1}$$

$$R^2 = \frac{\text{Var}(\hat{y})}{\text{Var}(y)} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Коэффициент множественной детерминации R-квадрат показывает, какую долю изменчивости (можно выразить в процентах) зависимой переменной (Y) объясняет независимая переменная (регрессионная модель).

- Под **качеством уравнения регрессии** понимается степень близости (соответствия) рассчитанных по данному уравнению значений признака-результата $f(x)$ фактическим (наблюдаемым) значениям y .
- Чем ближе R-квадрат к 1, тем выше качество регрессионной модели.

Формулы коэффициента детерминации

$$\sigma_y^2 = \sigma_{\hat{y}}^2 + \sigma_{y-\hat{y}}^2$$

$$\sigma_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n} \quad \sigma_{\hat{y}}^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{n} \quad \sigma_{y-\hat{y}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$$

$$R^2 = \frac{\sigma_{\hat{y}}^2}{\sigma_y^2} = 1 - \frac{\sigma_{y-\hat{y}}^2}{\sigma_y^2}$$

Матричное представление

$$y_i = a + b x_i + e_i, i = 1, 2, \dots, m$$

$$Y = X \beta + U$$

$$Y = \begin{pmatrix} y_1 \\ \dots \\ y_m \end{pmatrix}$$

$$U = \begin{pmatrix} u_1 \\ \dots \\ u_m \end{pmatrix}$$

$$\beta = \begin{pmatrix} a \\ b \end{pmatrix}$$

$$X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \dots & \dots \\ 1 & x_m \end{pmatrix}$$

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Множественная регрессия

Уравнение множественной линейной регрессии



$$\hat{y} = a_0 + a_1x_1 + a_2x_2 + \dots + a_mx_m,$$

где $\hat{y}$ – теоретические значения результативного признака, полученные путем подстановки соответствующих значений факторных признаков в уравнение регрессии;

$x_1, x_2, \dots, x_m$ – значения факторных признаков;

$a_0, a_1, \dots, a_m$ – параметры уравнения (коэффициенты регрессии).

Линейная и логистическая регрессии. Примеры результатов



Линеаризация

Подходы к линеаризации нелинейных уравнений

В параболе $y = a + vx + cx^2$, заменяя переменные $x_1 = x$, а $x_2 = x^2$, получаем двухфакторное уравнение линейной регрессии $y = a + vx_1 + cx_2$.

Для равносторонней гиперболы мы можем заменить $1/x$ на z и получим линейное уравнение регрессии, оценка параметров которого может быть дана МНК.

Для степенной функции $y = a x^b$ применяется логарифмирование левой и правой части уравнения

$\log y = \log \alpha + \log x^\beta$, а затем замена переменных

$y_1 = \log y$; $z = \log x$ и $\alpha_1 = \log \alpha$, получаем уравнение в линейном виде:

$$y_1 = \alpha_1 + \beta z$$