

МЕТОДЫ СНИЖЕНИЯ РАЗМЕРНОСТИ МОДЕЛЕЙ

1. Структурный подход к обработке многомерных данных

Совокупность описаний объектов и отношений между этими описаниями называется **структурой данных**.

Целью анализа структуры данных является построение математической модели исследуемого явления в виде функционального, статистического или иного описания. Такая модель позволяет заменить экспериментальные данные, как способ представления, на некоторый более общий закон, из которого исходные данные вытекают уже как частный случай.

Другими словами, целью структурного анализа данных являются выводы о взаимоотношениях объектов из некоторого множества, сведения о которых могут и не содержаться в явном виде в исходной информации. Да и форма представления данных (описаний объектов) может быть самой разнообразной: числовые таблицы, качественные таблицы, тексты и др.

На практике широко используется табличное представление данных.

Пусть таблица экспериментальных данных состоит из n строк (по числу объектов) и m столбцов (по числу признаков, показателей).

Структурная схема обработки данных такой таблицы осуществляется в три этапа.

Этап 1. Приведение экспериментальных данных к стандартному виду, пригодному для ввода и обработки в ЭВМ.

Основная цель этапа состоит в переходе от описательных и абстрактных значений признаков (показателей) к числовому представлению.

Такой процесс называется **шкалированием** и является предметом изучения теории измерений.

В результате этого этапа имеем матрицу шкальных (количественных) значений

$$X = \{x_{ij}\}, \quad i = \overline{1, n}, \quad j = \overline{1, m},$$

где x_{ij} – шкальное (количественное) значение j -го показателя для i -го объекта.

Наиболее часто используются 3 типа шкал.

1. Шкала наименований. Здесь показатели называются классификационными или номинальными ("профессия", "торговая марка", "тип двигателя", вариант инвестиционного проекта и т.д.).

2. Порядковая шкала. Здесь показатели называются качественными или ранговыми ("сила ветра в баллах", "оценка на экзамене", "образование", рейтинг финансовой организации и т.д.)

3. Количественные шкалы интервалов, отношений, разностей, абсолютных значений.

Примером признака, измеренного в абсолютной шкале, может служить "количество элементов некоторого множества", "количество единиц оборудования"; в шкале отношений измеряются, например, вес, длина; в шкале интервалов измеряются время, температура, размер дивидендов, прибыль и т.д.

Сами показатели можно рассматривать как оси системы координат в m -мерном пространстве.

Тогда каждый i -й объект с описанием $X_i = \{x_{ij}\}$, $j = \overline{1, m}$ можно интерпретировать как точку с координатами $x_{i1}, x_{i2}, \dots, x_{im}$ в этом пространстве.

Пространство разнотипных признаков размерности m называется **пространством описания**.

Так как величины X_j , $j = \overline{1, m}$ могут иметь различный физический смысл и различные шкалы измерений, удобнее перейти к стандартизированной матрице исходных данных

$$X_j^* = \{x_{ij}^*\}, i = \overline{1, n}, j = \overline{1, m}.$$

Переход осуществляется по формуле:

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{\sigma_j}; \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}; \quad \sigma_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2.$$

Для стандартизованных переменных легко вычисляются все основные числовые характеристики:

$$\bar{x}_j^* = \frac{1}{n} \sum_{i=1}^n x_{ij}^* = 0; \quad D[X_j^*] = \frac{1}{n} \sum_{i=1}^n (x_{ij}^*)^2 = 1;$$

$$R[X_j^* X_k^*] = r_{jk} = \frac{1}{n} \sum_{i=1}^n x_{ij}^* x_{ik}^*; \quad j = \overline{1, m}, k = \overline{1, m}.$$

Этап 2. Разбиение множества имеющихся объектов на непересекающиеся классы $S_1, S_2, \dots, S_G$, каждый из которых соответствует определённой модели (или одной части) исследуемого явления.

Эта задача решается методами классификации, распознавания образов, дискриминантного анализа.

Этап 3. Поиск законов, описывающих поведение объектов каждого из классов $S_1, S_2, \dots, S_G$.

Здесь могут использоваться методы регрессионного, факторного анализов, интерполяции, аппроксимации, методы снижения размерности и т.д.

2. Метод главных компонент

В компонентном анализе вычисляются главные компоненты, т.е. некоррелированные комбинации исходных показателей, сохраняющие их общую дисперсию без изменений.

Определение главных компонент (ГК) производится по корреляционной матрице исходных показателей. Результатом компонентного анализа на ЭВМ являются дисперсии главных компонент, их доли в общей дисперсии и сами главные компоненты.

Другими словами, метод главных компонент (МГК) позволяет по заданной (вычисленной) m -мерной корреляционной матрице R исходных показателей $X_j, j = \overline{1, m}$ найти новую ортогональную m -мерную систему координат $Y_q, q = \overline{1, m}$ и именно так, чтобы максимум полной дисперсии лежал в направлении первой главной оси, а максимум оставшейся дисперсии – в направлении второй главной оси и т.д.




Рис. 1. Графическое представление преобразования в методе главных компонент

Процедуру вычисления последовательностей осей можно прекратить в любом месте и, например, выбрать только две первые главные компоненты, которые воспроизводят, например, лишь 80% полной дисперсии.

Главные компоненты представляют собой новое множество показателей $Y_q, q = \overline{1, m}$, которые обладают следующими свойствами.

1. Каждая главная компонента (новый фактор) является линейной комбинацией исходных нормированных показателей:

$$y_{iq} = \frac{1}{\lambda_q} \sum_{j=1}^m a_{jq} x_{ij}^*; \quad i = \overline{1, n}, \quad q = \overline{1, m}.$$

Здесь

$A = \{a_{jq}\}$ – матрица нагрузок показателей на ГК;

λ_q – собственные числа матрицы R .

2. Все главные компоненты статистически независимы друг от друга, т.е. $Cov[Y_k, Y_p] = 0$, при $k \neq p$.

3. ГК упорядочиваются по их дисперсиям:

$$D[Y_1] \geq D[Y_2] \geq \dots \geq D[Y_m].$$

4. Дисперсии $D[Y_q]$ являются собственными числами корреляционной матрицы R , а матрица преобразования A^T состоит из собственных векторов матрицы R .

Число λ_j , являющееся корнем уравнения $|R - \lambda_j E| = 0$ называется **собственным числом** или **собственным значением** матрицы R .

Здесь E – единичная матрица (все элементы нулевые, кроме диагональных, равных 1).

Для матрицы R величины λ_j будут действительными положительными числами.

Любой вектор c_j единичной длины, являющийся решением системы $R \cdot c_j = \lambda_j \cdot c_j$, называется **собственным вектором** матрицы R , соответствующим собственному числу λ_j .

5. Поскольку у корреляционной матрицы имеется лишь одно множество отличных от нуля собственных чисел, то переход к ГК определяется однозначно.

6. При переходе к ГК сумма дисперсий всех показателей остаётся неизменной:

$$\sum_{q=1}^m D[Y_q] = \sum_{j=1}^m \sigma_j^2 = \sum_{j=1}^m D[X_j^*] = m.$$

7. Исходные нормированные показатели X_j^* , $j = \overline{1, m}$ выражаются через новые Y_q , $q = \overline{1, m}$ по следующей матричной зависимости:

$$X = AY,$$

или в другом виде

$$X_j^* = \sum_{q=1}^m a_{jq} Y_q, \quad j = \overline{1, m},$$

где $Y = \{y_{iq}\}$, $i = \overline{1, n}$, $q = \overline{1, m}$ – матрица значений ГК для наблюдений.

Пусть R – корреляционная матрица стандартизованных показателей. Тогда, в соответствии с определением, дисперсия вектора Y_1 равна

$$D[Y_1] = \sum_{j=1}^m \sum_{k=1}^m a_{j1} a_{k1} r_{jk}.$$

Необходимо найти вектор–столбец a_1 , который максимизирует эту дисперсию при условии $\|a_1\| = 1$, которое обеспечивает единственность решения.

Выражение для дисперсии можно переписать в эквивалентной форме в виде скалярного произведения

$$(Ra_1, a_1) \rightarrow \max; \quad \|a_1\| = 1.$$

Решением этого соотношения является максимальное собственное значение матрицы R и соответствующий ему собственный вектор c_1 .

Аналогично находятся остальные ГК.

Таким образом, первые Q главных компонент объясняют

$$d = \frac{100\%}{m} \sum_{q=1}^Q D[Y_q]$$

процентов дисперсии исходных переменных.

На практике обычно ограничиваются таким числом компонент, при котором $d = 70 - 90\%$.

При этом условии число ГК получается значительно меньшим числа исходных показателей, что облегчает процесс анализа данных.

Коэффициенты a_{jq} главных компонент определяются по формуле

$$a_{jq} = \frac{c_{jq}}{\sqrt{\lambda_j}},$$

где λ_j , c_{jq} – собственное значение матрицы и соответствующий ему собственный вектор применительно к j -й ГК.

Исходя из значений коэффициентов главных компонент можно ранжировать факторы по степени их значимости в главной компоненте.

Можно вычислить индивидуальные значения главных компонент (для каждого наблюдения) и использовать их в дальнейшем для построения уравнения регрессии для исходных показателей.

Пример : Для 27 предприятий города методом главных компонент исследовать взаимосвязь трёх показателей: выработка (тыс. руб.) на одного среднегодового работника (X_1); уровень рентабельности (%) предприятия (X_2); фондоотдача (X_3 , %).

Решение.

Технологию использования метода главных компонент продемонстрируем на условных данных.

1. Пусть стандартизованная матрица исходных данных имеет вид:

$$X_j^* = \{x_{ij}^*\} = \begin{pmatrix} -0,971 & 0,549 & 0,076 \\ -0,868 & -1,684 & -1,069 \\ 1,478 & 0,882 & -0,534 \\ \dots & \dots & \dots \\ 0,361 & 0,253 & 1,527 \end{pmatrix}, i = \overline{1, n}, j = \overline{1, m}.$$

Размерность матрицы: $n = 27$; $m = 3$.

2. Обработка матрицы наблюдений дала следующую матрицу коэффициентов корреляции ($k = 1, 2, \dots, m; j = 1, 2, \dots, m$):

$$R = (r_{kj}) = \begin{pmatrix} 1 & 0,581 & 0,154 \\ 0,581 & 1 & 0,439 \\ 0,154 & 0,439 & 1 \end{pmatrix}.$$

3. Определитель этой матрицы

$$\det(R) = 0,524.$$

4. Найдём собственные числа матрицы R .

Число λ_j , являющееся корнем уравнения $|R - \lambda_j E| = 0$ называется **собственным числом** или **собственным значением** матрицы R .

Здесь E – единичная матрица (все элементы нулевые, кроме диагональных, равных 1).

Составим характеристическое уравнение

$$\det \begin{pmatrix} 1-\lambda & 0,581 & 0,154 \\ 0,581 & 1-\lambda & 0,439 \\ 0,154 & 0,439 & 1-\lambda \end{pmatrix} = \lambda^3 - 3\lambda^2 + 2,445\lambda - 0,524 = 0.$$

Отсюда: $\lambda_1 = 1,798$; $\lambda_2 = 0,875$; $\lambda_3 = 0,327$.

Это означает, что главная компонента Y_1 объясняет $1,798/3 = 59,9\%$ всей вариации исходных показателей. Y_2 объясняет $0,875/3 = 29,2\%$, а Y_3 $0,327/3 = 10,9\%$ всей вариации исходных показателей.

5. Найдём собственные векторы c_q матрицы R , соответствующие собственным числам λ_q .

Любой вектор c_q единичной длины, являющийся решением системы $R \cdot c_q = \lambda_j \cdot c_q$, называется **собственным вектором** матрицы R , соответствующим собственному числу λ_q .

Каждый вектор c_q имеет компоненты (c_{jq}) , $j = \overline{1, m}$; $q = \overline{1, m}$.

Для вектора c_1 имеем систему уравнений

$$\begin{aligned} (1-1,798)c_{11} + 0,581c_{21} + 0,154c_{31} &= 0; \\ 0,581c_{11} + (1-1,798)c_{21} + 0,439c_{31} &= 0; \\ 0,154c_{11} + 0,439c_{21} + (1-1,798)c_{31} &= 0. \end{aligned}$$

Получаем компоненты вектора c_1 :

$$c_1 = \begin{pmatrix} c_{11} \\ c_{21} \\ c_{31} \end{pmatrix} = \begin{pmatrix} 1,262 \\ 1,469 \\ 1,0 \end{pmatrix}.$$

Для вектора c_2 имеем систему уравнений

$$\begin{aligned} (1-0,875)c_{12} + 0,581c_{22} + 0,154c_{32} &= 0; \\ 0,581c_{12} + (1-0,875)c_{22} + 0,439c_{32} &= 0; \\ 0,154c_{12} + 0,439c_{22} + (1-0,875)c_{32} &= 0. \end{aligned}$$

Получаем компоненты вектора c_2 :

$$c_2 = \begin{pmatrix} c_{12} \\ c_{22} \\ c_{32} \end{pmatrix} = \begin{pmatrix} -0,144 \\ -0,234 \\ 1,0 \end{pmatrix}.$$

Для вектора c_3 имеем систему уравнений

$$(1 - 0,327)c_{12} + 0,581c_{23} + 0,154c_{33} = 0;$$

$$0,581c_{13} + (1 - 0,327)c_{23} + 0,439c_{33} = 0;$$

$$0,1541c_{13} + 0,439c_{23} + (1 - 0,327)c_{33} = 0.$$

Получаем компоненты вектора c_3 :

$$c_3 = \begin{pmatrix} c_{13} \\ c_{23} \\ c_{33} \end{pmatrix} = \begin{pmatrix} 1,307 \\ -1,779 \\ 1,0 \end{pmatrix}.$$

Матрица собственных векторов принимает вид:

$$(c_q) = \begin{pmatrix} 1,262 & -0,144 & 1,307 \\ 1,469 & -0,234 & -1,779 \\ 1,0 & 1,0 & 1,0 \end{pmatrix}.$$

6. Пронормируем векторы c_q . Найдём векторы

$$c_{qH} = c_q / |c_q|$$

и получим матрицу нормированных собственных векторов c_H .

Получаем:

$$|c_1| = \sqrt{1,262^2 + 1,469^2 + 1,0^2} = 2,18.$$

$$|c_2| = \sqrt{(-0,144)^2 + (-0,234)^2 + 1,0^2} = 1,04.$$

$$|c_3| = \sqrt{(1,307)^2 + (-1,779)^2 + 1,0^2} = 2,421.$$

$$c_H = \begin{pmatrix} 0,579 & -0,139 & 0,539 \\ 0,674 & -0,225 & -0,734 \\ 0,459 & 0,964 & 0,413 \end{pmatrix}.$$

Должно выполняться условие

$$(c_H)^T c_H = E.$$

Проверяем:

$$0,579^2 + 0,674^2 + 0,459^2 = 1;$$

$$(-0,139)^2 + (-0,225)^2 + 0,964^2 = 1;$$

$$0,539^2 + (-0,734)^2 + 0,413^2 = 1.$$

7. Матрицу факторного отображения A получаем из уравнения:

$$A = (c_H) \sqrt{\lambda}.$$

$$A = \begin{pmatrix} 0,579 & -0,139 & 0,539 \\ 0,674 & -0,225 & -0,734 \\ 0,459 & 0,964 & 0,413 \end{pmatrix} \cdot \begin{pmatrix} \sqrt{1,798} & 0 & 0 \\ 0 & \sqrt{0,875} & 0 \\ 0 & 0 & \sqrt{0,327} \end{pmatrix} = \begin{pmatrix} 0,776 & -0,130 & 0,308 \\ 0,904 & -0,210 & -0,420 \\ 0,616 & 0,902 & 0,236 \end{pmatrix}.$$

Матрица факторного отображения A содержит частные коэффициенты корреляции, представляющие связи исходных показателей и главных компонент.

Из равенства $A^T A = \lambda$ следует условие

$$\sum_{j=1}^m a_{jq}^2 = \lambda_q.$$

Проверяем:

$$\sum_{j=1}^3 a_{j1}^2 = 0,776^2 + 0,904^2 + 0,616^2 = 1,798;$$

$$\sum_{j=1}^3 a_{j2}^2 = (-0,130)^2 + (-0,210)^2 + 0,902^2 = 0,875;$$

$$\sum_{j=1}^3 a_{j3}^2 = 0,308^2 + (-0,420)^2 + 0,236^2 = 0,327.$$

8. Система уравнений взаимосвязи нормированных показателей (опустим * у обозначения) X_j и Y_q имеет вид:

$$X_1 = 0,776Y_1 - 0,130Y_2 + 0,308Y_3;$$

$$X_2 = 0,904Y_1 - 0,210Y_2 - 0,420Y_3;$$

$$X_3 = 0,616Y_1 + 0,902Y_2 + 0,236Y_3.$$

9. Система уравнений взаимосвязи показателей Y_q и X_j выражается через матрицу A и собственные числа λ_q по соотношению

$$Y_q = \frac{1}{\lambda_q} \sum_{j=1}^m a_{jq} X_j; \quad q = \overline{1, m}.$$

Получаем:

$$Y_1 = (1/1,798)(0,776X_1 + 0,904X_2 + 0,616X_3 = 0,432X_1 + 0,503X_2 + 0,343X_3;$$

$$Y_2 = (1/0,875)(-0,130X_1 - 0,210X_2 + 0,902X_3 = -0,149X_1 - 0,240X_2 + 1,031X_3;$$

$$Y_3 = (1/0,327)(0,308X_1 - 0,420X_2 + 0,236X_3 = 0,942X_1 - 1,284X_2 + 0,804X_3.$$

10. В матричном виде имеем соотношения:

$$X = (X_1, X_2, \dots, X_m); \quad Y = (Y_1, Y_2, \dots, Y_Q);$$

$$A = (a_{jq}); \quad X^T = A \cdot Y^T; \quad Y^T = A^{-1} \cdot X^T.$$

Получаем:

$$A^{-1} = \begin{pmatrix} 0,542 & 0,507 & 0,196 \\ -0,776 & -0,010 & 0,994 \\ 1,554 & -1,283 & -0,075 \end{pmatrix}.$$

$$X^T = \{x_{\mu}^*\} = \begin{pmatrix} -0,971 & -0,868 & 1,478 & \dots & 0,361 \\ 0,549 & -1,684 & 0,882 & \dots & 0,253 \\ 0,076 & -1,069 & -0,534 & \dots & 1,527 \end{pmatrix}.$$

$$Y^T = A^{-1} \cdot X^T = (y_{qi}) = \begin{pmatrix} -0,233 & -1,533 & 1,143 & \dots & 0,623 \\ 0,823 & -0,372 & -1,687 & \dots & 1,236 \\ -2,218 & 0,892 & 1,205 & \dots & 0,121 \end{pmatrix}.$$

Пример По 52 предприятиям города собраны данные по 5 показателям: X_1 – коэффициент сменности оборудования; X_2 – среднегодовая численность персонала; X_3 – среднегодовая стоимость фондов; X_4 – среднегодовой фонд заработной платы персонала; X_5 – непроизводственные расходы. Ниже приведена сокращённая матрица исходных данных:

№ предприятия	X_1	X_2	X_3	X_4	X_5
1	1,37	26006	167,69	47750	17,72
2	1,49	23935	186,1	50391	18,39
3	1,44	22589	220,45	43149	26,46
...	...	...	...	...	...
52	1,22	11795	78,11	22225	19,41

Обработать имеющиеся данные методом факторного анализа.

Решение.

Проведём анализ с помощью пакета программ (Анализ – Обработка данных – Факторный анализ – Метод главных компонент).

Ниже приведены результаты работы программы факторного анализа.

Дескриптивные статистики

	Среднее	Стд. откл.	Анализ N
X1	1,3390	,14312	52
X2	14803,02	9979,264	52
X3	92,8387	92,99981	52
X4	27724,69	19587,29	52
X5	19,5598	4,74804	52

Корреляционная матрица

		X1	X2	X3	X4	X5
Корреляция	X1	1,00000	,22414	,38083	,19452	-,38946
	X2	,22414	1,00000	,78645	,91721	,00215
	X3	,38083	,78645	1,00000	,62873	-,05263
	X4	,19452	,91721	,62873	1,00000	,02402
	X5	-,38946	,00215	-,05263	,02402	1,00000
Знач. (односторон.)	X1		,055	,003	,084	,002
	X2	,055		,000	,000	,494
	X3	,003	,000		,000	,355
	X4	,084	,000	,000		,433
	X5	,002	,494	,355	,433	

а. Детерминант = ,036

Полная объясненная дисперсия

Компонента	Начальные собственные значения			Суммы квадратов нагрузок извлечения		
	Всего	% дисперсии	Кумулятивный %	Всего	% дисперсии	Кумулятивный %
1	2,6931	53,862	53,862	2,6931	53,862	53,862
2	1,3312	26,624	80,486	1,3312	26,624	80,486
3	,5870	11,741	92,227			
4	,3383	6,765	98,992			
5	,0504	1,008	100,000			

Метод выделения: Анализ главных компонент.

Можно выбрать две главные компоненты, вклад которых в дисперсию изучаемых признаков составляет 80,486%.

Матрица факторных нагрузок *A* имеет вид:

0,4529	– 0,70957	0,50413	– 0,1925	– 0,0126
0,9518	0,209987	– 0,13638	– 0,0448	– 0,17286
0,87961	0,0070	0,14787	0,4490	0,0635
0,89274	0,241139	– 0,19001	– 0,3054	0,1277
– 0,11816	0,85149	0,50643	– 0,0663	– 0,0045

Матрица главных компонент будет иметь вид:

№ предприятия	Y_1	Y_2	Y_3	Y_4	Y_5
1	1,061	0,004	–0,541	–0,052	–0,270
2	1,2335	–0,3635	0,3639	–0,391	0,819
3	1,0496	0,8351	1,787	0,323	0,7429
...	...	...	...	...	...
52	–0,3935	0,32689	–0,6269	0,5681	0,3388

3. Факторный анализ

Факторный анализ – это способ приведения (синтеза) множества непосредственно наблюдаемых показателей $X_j = \{x_{ij}\}, i = \overline{1, n}, j = \overline{1, m}$ к меньшему числу $Q < m$ новых линейно независимых факторов (признаков, показателей, главных компонент) $Y_q, q = \overline{1, Q}$.

Пусть исходные данные представлены в виде матрицы

$$X_j = \{x_{ij}\}, i = \overline{1, n}, j = \overline{1, m},$$

где n – количество наблюдений,
 m – количество показателей.

Так как величины X_j могут иметь различный физический смысл и различные шкалы измерений, удобнее перейти к стандартизированной матрице исходных данных

$$X_j^* = \{x_{ij}^*\}, i = \overline{1, n}, j = \overline{1, m}.$$

В факторном анализе предполагается линейная связь между измеряемыми нормированными показателями и факторами:

$$X_j^* = \sum_{q=1}^Q a_{jq} Y_q,$$

где a_{jq} – подлежащие определению коэффициенты.