

ЛИНЕЙНЫЙ ДИСКРИМИНАНТНЫЙ АНАЛИЗ

Линейный дискриминантный анализ (Linear Discriminant Analysis, LDA) – раздел многомерного статистического анализа данных, в рамках которого разрабатываются методы решения задачи различения (дискриминации) объектов наблюдений по выделенным признакам

Методы дискриминантного анализа опираются на методы однофакторного одномерного и многомерного дисперсионного анализа и основаны на расчете F -статистики [1, разд. 1.4.3.4].

Пусть задано K классов (групп), к которым относятся n объектов наблюдения. Для каждого объекта измерены значения описывающих его признаков. Многомерный вектор значений признаков имеет вид

$$X_k = \begin{pmatrix} x_{1k} \\ x_{2k} \\ \dots \\ x_{pk} \end{pmatrix}, \quad x_{jk} = (x_{1jk}, x_{2jk}, \dots, x_{n_kjk})^T, \quad (1)$$

где x_{jk} – вектор значений j -го признака в k -м классе, $j = \overline{1, p}$, $k = \overline{1, K}$;

x_{ijk} – i -е значение j -го признака в k -м классе, $i = \overline{1, n_k}$; n_k – количество объектов в k -м классе; p – количество признаков (дискриминантных переменных).

Все методы дискриминантного анализа можно разбить на две тесно связанные группы: методы интерпретации межгрупповых различий и методы классификации объектов по группам (классам).

Методы первой группы предназначены для решения задачи интерпретации, которая заключается в анализе различий между группами

(классами) и ответами на вопросы по результатам проведенного анализа: возможно ли, используя данный набор признаков, отличить одну группу объектов от другой; насколько хорошо эти характеристики позволяют провести различие, и какие из них наиболее информативны. Интерпретационные методы дискриминантного анализа подразделяются, в свою очередь, на методы пошагового расширения совокупности признаков и методы пошагового сокращения совокупности признаков.

Рассмотрим логику метода пошагового расширения совокупности признаков.

1. Определяется признак, для которого средние значения в K классах наиболее различны. Для каждого признака различие измеряется с помощью F -статистики однофакторного одномерного дисперсионного анализа. Выбирается тот признак, для которого F -статистика максимальна: $F_{\max}$.

2. Задается пороговое значение F -статистики для включения признака в модель: F_{enter} .

3. Сравнивается максимальное значение F -статистики с пороговым значением F -включения: $F_{\max} > F_{\text{enter}}$. Если неравенство выполняется, то признак включается; иначе – делается вывод о том, что ни один признак не вносит вклад в разделение классов.

4. Анализируются пары, образованные отобранным и одним из оставшихся признаков, после чего находится пара, дающая наилучшее различие (максимальное значение F -статистики), из которой и отбирается признак в случае, если $F_{\max} > F_{\text{enter}}$. На этом этапе различие измеряется с помощью F -статистики однофакторного многомерного дисперсионного анализа.

5. Образуются тройки из первых двух и каждого из оставшихся признаков. Наилучшая тройка по F -статистике определяет третий признак и т. д.

Таким образом, на каждом шаге этой процедуры отбирается признак, который в сочетании с отобранными ранее признаками дает наилучшее различие. Процесс продолжается до тех пор, пока не будут рассмотрены все возможные признаки или пока оставшиеся признаки не перестанут улучшать различие. Отметим, что вместо F -статистики в качестве показателя эффективности модели при реализации пошаговой процедуры могут использоваться и другие характеристики

Методы классификации позволяют решать задачу классификации, связанную с получением одной или нескольких дискриминантных или классификационных функций, обеспечивающих возможность отнесения заданного объекта к одному из классов на основе рассмотрения совокупности значений его признаков.

В основе дискриминантного анализа лежит предположение о том, что описание объектов каждого k -го класса представляет собой реализацию многомерной случайной величины, распределенной по нормальному закону с вектором средних $\bar{X}_k$ и ковариационной матрицей S_k :

$$S_k = \frac{1}{n_k - 1} (X_k - \bar{X}_k)^T (X_k - \bar{X}_k). \quad (2)$$

Рассмотрим несколько упрощенную геометрическую интерпретацию алгоритма LDA для случая двух классов (рис. 2). Пусть дискриминантные переменные x_j – оси p -мерного евклидова пространства. Каждый объект (наблюдение) является точкой этого пространства с координатами, представляющими собой фиксированные значения каждой переменной. Если оба класса отличаются друг от друга по наблюдаемым переменным, их можно представить как скопления точек в разных областях рассматриваемого пространства, которые могут частично перекрываться. Для определения положения каждого класса можно вычислить его центроид, являющийся точкой, координаты которой соответствуют средним значениям переменных в рассматриваемом классе.




Рис. 2. Геометрическая интерпретация дискриминантного анализа (случай двух классов)

Задача дискриминантного анализа заключается в построении дискриминантной функции: $f(x) = a_1x_1 + a_2x_2 = c$ (для случая двух переменных), которая наилучшим образом разделяет объекты на классы. Дискриминантная функция для каждого из классов проходит через центроид класса и имеет вид для первого класса:

$$\bar{f}_1(x) = a_1\bar{x}_{11} + a_2\bar{x}_{21} = c_1, \quad (3)$$

для второго класса:

$$\bar{f}_2(x) = a_1\bar{x}_{12} + a_2\bar{x}_{22} = c_2. \quad (4)$$

В случае p переменных дискриминантная функция имеет вид

$$f(x) = a_1x_1 + a_2x_2 + \dots + a_px_p = \sum_{j=1}^p a_jx_j = c, \quad (5)$$

где c – константа дискриминации.

Соответственно дискриминантная функция для первого класса:

$$\bar{f}_1(x) = a_1\bar{x}_{11} + a_2\bar{x}_{21} + \dots + a_p\bar{x}_{p1} = \sum_{j=1}^p a_j\bar{x}_{j1} = c_1, \quad (6)$$

дискриминантная функция для второго класса:

$$\bar{f}_2(x) = a_1\bar{x}_{12} + a_2\bar{x}_{22} + \dots + a_p\bar{x}_{p2} = \sum_{j=1}^p a_j\bar{x}_{j2} = c_2. \quad (7)$$

Коэффициенты дискриминантной функции определяются таким образом, чтобы как можно больше различались между собой функции $\bar{f}_1(x)$ и $\bar{f}_2(x)$, т. е. чтобы для двух множеств (классов) было максимальным выражение

$$\bar{f}_1(x) - \bar{f}_2(x) = \sum_{j=1}^p a_j\bar{x}_{j1} - \sum_{j=1}^p a_j\bar{x}_{j2} \rightarrow \max. \quad (8)$$

Для каждого i -го наблюдения в k -м классе можно вычислить значение дискриминантной функции $f_{ik}(x)$ и найти его отклонение от значения дискриминантной функции для k -го класса:

$$f_{ik}(x) - \bar{f}_k(x) = a_1(x_{i1k} - \bar{x}_{1k}) + a_2(x_{i2k} - \bar{x}_{2k}) + \dots + a_p(x_{ipk} - \bar{x}_{pk}). \quad (9)$$

Внутригрупповая вариация в k -м классе может быть измерена как сумма квадратов отклонений:

$$\sum_{i=1}^{n_k} (f_{ik}(x) - \bar{f}_k(x))^2. \quad (10)$$

Соответственно для двух классов суммарная внутригрупповая вариация:

$$\sum_{k=1}^2 \sum_{i=1}^{n_k} (f_{ik}(x) - \bar{f}_k(x))^2 = A^T (Y_1^T Y_1 + Y_2^T Y_2) A, \quad (11)$$

где A – вектор коэффициентов дискриминантной функции (в случае более двух классов A – матрица коэффициентов); $Y_1 = X_1 - \bar{X}_1$ и $Y_2 = X_2 - \bar{X}_2$ – матрицы отклонений наблюдаемых значений исходных переменных от их средних величин соответственно в первом и втором классе.

Учитывая, что объединенная ковариационная матрица задается выражением

$$S = \frac{1}{n_1 + n_2 - 2} (Y_1^T Y_1 + Y_2^T Y_2), \quad (12)$$

формулу (11) можно представить как

$$\sum_{k=1}^2 \sum_{i=1}^{n_k} (f_{ik}(x) - \bar{f}_k(x))^2 = A^T (S(n_1 + n_2 - 2)) A. \quad (13)$$

Межгрупповая вариация может быть измерена как

$$(\bar{f}_1(x) - \bar{f}_2(x))^2 = A^T (\bar{X}_1 - \bar{X}_2)(\bar{X}_1 - \bar{X}_2)^T A. \quad (14)$$

При нахождении коэффициентов дискриминантной функции следует исходить из критерия, согласно которому для рассматриваемых объектов внутригрупповая вариация минимизируется, а межгрупповая вариация максимизируется. В этом случае достигается наилучшее разделение двух классов, что соответствует условию максимизации величины F :

$$F = \frac{A^T (\bar{X}_1 - \bar{X}_2)(\bar{X}_1 - \bar{X}_2)^T A}{A^T (S(n_1 + n_2 - 2)) A} \rightarrow \max. \quad (15)$$

В точке, где функция F достигает максимума, частные производные по коэффициентам A будут равны нулю. Если вычислить частные производные $\frac{\partial F}{\partial a_1}, \frac{\partial F}{\partial a_2}, \dots, \frac{\partial F}{\partial a_p}$ и приравнять их к нулю, то после преобразований получим выражение для вычисления коэффициентов дискриминантной функции:

$$A = S^{-1}(\bar{X}_1 - \bar{X}_2), \quad (16)$$

где S^{-1} – обратная объединенная ковариационная матрица.

Обобщенное расстояние Махаланобиса, равное дистанции между классами в многомерном пространстве признаков, оценивается как

$$D^2 = A^T (\bar{X}_1 - \bar{X}_2). \quad (17)$$

Далее полученные значения коэффициентов подставляют в формулу (5) дискриминантной функции. Для каждого объекта в обоих классах вычисляют дискриминантные функции и находят среднее значение функции для каждого класса: $\bar{f}_1(x)$ и $\bar{f}_2(x)$.

Таким образом, каждое i -е наблюдение, которое первоначально описывалось p переменными (признаками), будет отображено в одномерном пространстве, т. е. ему будет соответствовать одно значение дискриминантной функции. Следовательно, размерность признакового пространства снижается. Перед тем как приступить непосредственно к процедуре классификации, нужно определить границу, разделяющую в частном случае два рассматриваемых класса. Такой величиной может

быть значение функции, равноудаленное от $\bar{f}_1(x)$ и $\bar{f}_2(x)$, которое называется константой дискриминации:

$$c = \frac{1}{2}(\bar{f}_1(x) + \bar{f}_2(x)). \quad (18)$$

Если значение дискриминантной функции $f(x)$ объекта меньше константы дискриминации ($f(x) < c$), то объект относят ко второму классу, иначе – к первому.

В случае наличия K классов достаточно построить $K - 1$ дискриминантных функций. На рис. 3 приведен пример для трех классов.




Рис. 3. Геометрическая интерпретация дискриминантного анализа (случай трех классов)

Условия использования методов дискриминантного анализа совпадают с ограничениями использования дисперсионного анализа:

- многомерный вектор значений признаков имеет многомерное нормальное распределение;
- ковариационные матрицы признаков, рассчитанные по K группам, равны;
- значения признаков стохастически независимы.

Кроме того, добавляется условие линейной независимости признаков (отсутствие мультиколлинеарности), входящих в дискриминантную функцию.

Методы дискриминантного анализа предполагают использование исходных признаков (дискриминантных переменных) количественного типа.

Возможен также учет в функции дискриминации качественного признака путем введения фиктивных переменных.

Рассмотрим качественный признак d , значения которого могут принимать q уровней: d_l , $l = \overline{0, q}$. Вводим фиктивные переменные:

d_0 – фиктивная переменная равна единице, если значение качественного признака для объекта x равно нулевому уровню;

d_1 – фиктивная переменная равна единице, если значение качественного признака для объекта x равно первому уровню;

...

d_q – фиктивная переменная равна единице, если значение качественного признака для объекта x равно q -му уровню.

Для учета качественного признака в дискриминантную функцию добавляют $(q - 1)$ фиктивных переменных, в результате чего функция имеет вид

$$f(x) = \sum_{j=1}^p a_j x_j + \sum_{l=1}^q \beta_l d_l, \quad (19)$$

где β_l – коэффициент при фиктивной переменной l -го уровня.

Достоинства LDA-алгоритма:

- модель классификации имеет четкую содержательную интерпретацию с возможностью оценивания вклада каждого признака в результаты классификации;
- относительно высокая точность прогнозов в случае линейной разделимости классов (граница между классами описывается линейной функцией);
- уменьшение размерности пространства признаков путем проецирования исходных данных на подпространство меньшей размерности с сохранением информации о классовых различиях. Уменьшение пространства признаков может привести к упрощению модели, ускорению и повышению производительности вычислений.

Недостатки LDA-алгоритма:

- необходимость предобработки исходных данных: стандартизация значений признаков; исключение выбросов (аномальных наблюдений);
- необходимость включения признаков в модель, статистически значимо влияющих на результирующую переменную (класс);

- жесткие ограничения на использование метода: нормальная распределенность исходных признаков; равенство ковариационных матриц признаков в K группах; стохастическая независимость исходных признаков;
- низкая точность в случае нелинейности границы, разделяющей классы в пространстве.

Пример В табл. 1 представлены данные о времени написания тестовых заданий программистами двух категорий (классов): x_1 – время написания первого тестового задания, x_2 – время написания второго тестового задания, x_3 – время написания третьего тестового задания. Приведены данные о показателях эффективности семи программистов (объектов), из которых четверо имели первую категорию и трое – вторую категорию. Необходимо построить правило отнесения программиста к категории с помощью методов дискриминантного анализа.

Таблица 1

Исходные данные

Номер	x_1	x_2	x_3	Класс
1	20	30	15	1
2	24	31	12	1
3	19	37	14	1
4	17	38	15	1
5	10	39	10	2
6	9	37	11	2
7	8	35	12	2

Многомерный вектор исходных значений переменных для первого и второго класса имеет вид

$$X_1 = \begin{pmatrix} 20 & 30 & 15 \\ 24 & 31 & 12 \\ 19 & 37 & 14 \\ 17 & 38 & 15 \end{pmatrix}, \quad X_2 = \begin{pmatrix} 10 & 39 & 10 \\ 9 & 37 & 11 \\ 8 & 35 & 12 \end{pmatrix}.$$

Рассчитаем среднее значение каждой переменной в первом и втором классе для определения координат центроидов классов:

$$\bar{x}_{11} = 20; \quad \bar{x}_{21} = 34; \quad \bar{x}_{31} = 14; \quad \bar{x}_{12} = 9; \quad \bar{x}_{22} = 37; \quad \bar{x}_{32} = 11.$$

Матрицы отклонений наблюдаемых значений исходных переменных от их средних величин соответственно в первом и втором классе равны:

$$Y_1 = \begin{pmatrix} 0 & -4 & 1 \\ 4 & -3 & -2 \\ -1 & 3 & 0 \\ -3 & 4 & 1 \end{pmatrix}, \quad Y_2 = \begin{pmatrix} 1 & 2 & -1 \\ 0 & 0 & 0 \\ -1 & -2 & 1 \end{pmatrix},$$

$$Y_1^T = \begin{pmatrix} 0 & 4 & -1 & -3 \\ -4 & -3 & 3 & 4 \\ 1 & -2 & 0 & 1 \end{pmatrix}, \quad Y_2^T = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ -1 & 0 & 1 \end{pmatrix}.$$

Дискриминантная функция в общем виде имеет вид

$$f(x) = a_1x_1 + a_2x_2 + a_3x_3.$$

Объединенная ковариационная матрица рассчитывается по формуле (12):

$$S = \frac{1}{5} (Y_1^T Y_1 + Y_2^T Y_2) = \begin{pmatrix} 5,6 & -4,6 & -2,6 \\ -4,6 & 9,2 & 1 \\ -2,6 & 0,4 & 1,6 \end{pmatrix}.$$

Обратная ковариационная матрица равна

$$S^{-1} = \begin{pmatrix} 16,1 & 7,1 & 21,8 \\ 5,4 & 2,5 & 7,2 \\ 24,9 & 10,9 & 34,2 \end{pmatrix}.$$

Коэффициенты дискриминантной функции определяются в соответствии с формулой (16). Вектор коэффициентов равен

$$A = S^{-1}(\bar{X}_1 - \bar{X}_2) = \begin{pmatrix} 16,1 & 7,1 & 21,8 \\ 5,4 & 2,5 & 7,2 \\ 24,9 & 10,9 & 34,2 \end{pmatrix} \begin{pmatrix} 11 \\ -3 \\ 3 \end{pmatrix} = \begin{pmatrix} 221,3 \\ 73 \\ 343,2 \end{pmatrix}.$$

Дискриминантная функция после оценки коэффициентов (процедура параметрической идентификации) имеет вид

$$f(x) = 221,3x_1 + 73x_2 + 343,2x_3.$$

Далее рассчитывается значение дискриминантной функции для каждого объекта:

$$f_{11} = 221,3 \cdot 20 + 73 \cdot 30 + 343,2 \cdot 15 = 11\,764;$$

$$f_{12} = 11\,692,6; \quad f_{13} = 11\,710,5; \quad f_{14} = 11\,684,1;$$

$$f_{21} = 8492; \quad f_{22} = 8467,9; \quad f_{23} = 8443,8.$$

Среднее значение дискриминантной функции для первого и второго класса:

$$\bar{f}_1(x) = 11\,712,8; \quad \bar{f}_2(x) = 8467,9.$$

На заключительном этапе рассчитывается константа дискриминации:

$$c = \frac{1}{2}(\bar{f}_1(x) + \bar{f}_2(x)) = 10\,090,35.$$

Пусть необходимо отнести к одной из категорий программиста, имеющего результаты тестирования: $x_1 = 15$; $x_2 = 36$; $x_3 = 12$.

Рассчитывается значение дискриминантной функции:

$$f(x) = 221,3 \cdot 15 + 73 \cdot 36 + 343,2 \cdot 12 = 10\,065,9.$$

В результате решения задачи классификации программист относится ко второй категории, так как $f(x) < c$.

Пример 2.

Дискриминантный анализ: 2 признака, 3 класса

📌 Постановка задачи

Классифицируем фрукты по двум признакам:

- x_1 — сладость (от 0 до 10)
- x_2 — кислота (от 0 до 10)

Три класса фруктов:

Класс	Фрукт
0	 Яблоко
1	 Лимон
2	 Виноград

Обучающая выборка — по 2 образца каждого класса:

Фрукт	Сладость (x_1)	Кислота (x_2)	Класс (y)
Ябл. 1	7	3	0
Ябл. 2	8	2	0
Лим. 1	2	9	1
Лим. 2	3	8	1
Вин. 1	9	5	2
Вин. 2	8	6	2

Вопрос: к какому классу отнести новый фрукт G со сладостью $x_1 = 6$ и кислотой $x_2 = 5$?



Шаг 1. Средние классов

$$\bar{x}_0 = (7.5, 2.5), \quad \bar{x}_1 = (2.5, 8.5), \quad \bar{x}_2 = (8.5, 5.5)$$

Шаг 2. Ковариационная матрица (общая)

Объединяем все отклонения от средних своих классов:

Точка	Класс	$x_1 - \bar{x}_{1k}$	$x_2 - \bar{x}_{2k}$
Ябл.1	0	$7 - 7.5 = -0.5$	$3 - 2.5 = 0.5$
Ябл.2	0	$8 - 7.5 = 0.5$	$2 - 2.5 = -0.5$
Лим.1	1	$2 - 2.5 = -0.5$	$9 - 8.5 = 0.5$
Лим.2	1	$3 - 2.5 = 0.5$	$8 - 8.5 = -0.5$
Вин.1	2	$9 - 8.5 = 0.5$	$5 - 5.5 = -0.5$
Вин.2	2	$8 - 8.5 = -0.5$	$6 - 5.5 = 0.5$

Считаем **общую ковариационную матрицу** (делим на $n - K = 6 - 3 = 3$):

$$S = \frac{1}{3} \begin{bmatrix} \sum (x_1 - \bar{x}_{1k})^2 & \sum (x_1 - \bar{x}_{1k})(x_2 - \bar{x}_{2k}) \\ \sum (x_2 - \bar{x}_{2k})(x_1 - \bar{x}_{1k}) & \sum (x_2 - \bar{x}_{2k})^2 \end{bmatrix}$$

Считаем элементы:

$$\sum (x_1 - \bar{x}_{1k})^2 = (-0.5)^2 + 0.5^2 + (-0.5)^2 + 0.5^2 + 0.5^2 + (-0.5)^2 = 6 \cdot 0.25 = 1.5$$

$$\sum (x_2 - \bar{x}_{2k})^2 = 0.5^2 + (-0.5)^2 + 0.5^2 + (-0.5)^2 + (-0.5)^2 + 0.5^2 = 1.5$$

$$\sum (x_1 - \bar{x}_{1k})(x_2 - \bar{x}_{2k}) = (-0.5)(0.5) + (0.5)(-0.5) + (-0.5)(0.5) + (0.5)(-0.5) + (0.5)(-0.5) + (-0.5)(0.5)$$

$$= -0.25 - 0.25 - 0.25 - 0.25 - 0.25 - 0.25 = -1.5$$

Итого:

$$S = \frac{1}{3} \begin{bmatrix} 1.5 & -1.5 \\ -1.5 & 1.5 \end{bmatrix} = \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix}$$

Шаг 3. Обратная ковариационная матрица

$$S^{-1} = \frac{1}{0.5 \cdot 0.5 - (-0.5)(-0.5)} \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} = \frac{1}{0} \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}$$

Матрица вырождена (определитель = 0) — в реальных данных так бывает редко. Добавим **регуляризацию** (малую величину на диагональ), чтобы можно было обратить:

$$S_{reg} = \begin{bmatrix} 0.5 + 0.01 & -0.5 \\ -0.5 & 0.5 + 0.01 \end{bmatrix} = \begin{bmatrix} 0.51 & -0.5 \\ -0.5 & 0.51 \end{bmatrix}$$

$$\det = 0.51 \cdot 0.51 - (-0.5)(-0.5) = 0.2601 - 0.25 = 0.0101$$

$$S_{reg}^{-1} = \frac{1}{0.0101} \begin{bmatrix} 0.51 & 0.5 \\ 0.5 & 0.51 \end{bmatrix} = \begin{bmatrix} 50.5 & 49.5 \\ 49.5 & 50.5 \end{bmatrix}$$

Шаг 4. Расстояние Махаланобиса до каждого класса

Формула квадрата расстояния Махаланобиса:

$$D_k^2(\mathbf{x}) = (\mathbf{x} - \bar{\mathbf{x}}_k)^T S^{-1} (\mathbf{x} - \bar{\mathbf{x}}_k)$$

Для нового фрукта $G = (6, 5)$:

До 🍏 Яблока (класс 0)

$$\mathbf{x} - \bar{\mathbf{x}}_0 = (6 - 7.5, 5 - 2.5) = (-1.5, 2.5)$$

$$D_0^2 = \begin{bmatrix} -1.5 & 2.5 \end{bmatrix} \begin{bmatrix} 50.5 & 49.5 \\ 49.5 & 50.5 \end{bmatrix} \begin{bmatrix} -1.5 \\ 2.5 \end{bmatrix}$$

Шаг 5. Правило классификации

Объект относится к классу с минимальным расстоянием Махаланобиса:

Класс	Фрукт	D_k^2	D_k
 1	Лимон	24.5	4.95
 0	Яблоко	58	7.62
 2	Виноград	452	21.26

Новый фрукт (6, 5) → 🍋 Лимон! 

Алгоритмы классификации

1. Рассмотрим случай $m = 1$.

Пусть имеются две генеральные совокупности одномерной величины X_1 и X_2 с известными законами распределениями $X_1 = N(m_1, \sigma^2)$ и $X_2 = N(m_2, \sigma^2)$ (рис. 8.2).

Пусть наблюдаемый объект имеет значение Z . К какой из генеральных совокупностей (S_1 или S_2) принадлежит этот объект?




Рис. 8.2. Принятие решения для одной переменной

Функция плотность величины X_1 при $X_1 = Z$ равна

$$f_1(Z) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(Z - m_1)^2}{2\sigma^2} \right\}.$$

Функция плотность величины X_2 при $X_2 = Z$ равна

$$f_2(Z) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(Z - m_2)^2}{2\sigma^2} \right\}.$$

Выбираем следующий простой алгоритм классификации: если $f_1(Z) \geq f_2(Z)$, то отнесём объект к первой генеральной совокупности S_1 , если $f_1(Z) < f_2(Z)$, то — ко второй совокупности S_2 .

Таким образом, имеем правило принятия решения:

$$S_1 : f_1(Z) / f_2(Z) \geq 1; \quad S_2 : f_1(Z) / f_2(Z) < 1.$$

Так как
$$\frac{f_1(Z)}{f_2(Z)} = \exp \left\{ -\frac{2(m_1 - m_2)Z - (m_1^2 - m_2^2)}{2\sigma^2} \right\},$$

то область S_1 задаётся неравенством:

$$\frac{(m_1 - m_2)Z}{\sigma^2} \geq \frac{(m_1^2 - m_2^2)}{2\sigma^2}.$$

2. Рассмотрим теперь m -мерный случай.

Пусть имеются две генеральные совокупности величин X_{1j} и X_{2j} с известными m -мерными распределениями

$$X_1 = N(M_1, R) \quad \text{и} \quad X_2 = N(M_2, R).$$

Для вектора наблюдений $Z = (z_1, z_2, \dots, z_m)$ плотности вероятностей этих величин равны соответственно

$$f_1(Z) = \frac{1}{\sqrt{(2\pi)^m |R|}} \exp \left\{ -\frac{1}{2} (Z - M_1) R^{-1} (Z - M_1)^T \right\},$$

$$f_2(Z) = \frac{1}{\sqrt{(2\pi)^m |R|}} \exp \left\{ -\frac{1}{2} (Z - M_2) R^{-1} (Z - M_2)^T \right\}.$$

Области S_1 и S_2 определяются аналогично:

$$S_1 : f_1(Z) / f_2(Z) \geq 1; \quad S_2 : f_1(Z) / f_2(Z) < 1.$$

Для области S_1 получаем обобщение неравенства

$$(M_1 - M_2) R^{-1} (Z)^T \geq \frac{1}{2} (M_1 - M_2) R^{-1} (M_1 + M_2)^T.$$

Если обозначить $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_m) = (M_1 - M_2) R^{-1}$

и
$$C = (1/2) (M_1 - M_2) R^{-1} (M_1 + M_2)^T,$$

то указанное неравенство можно записать в виде

$$\alpha(Z)^T \geq C,$$

где $\alpha(Z)^T$ – дискриминантная функция,

C – пороговое значение.

3. Предположим теперь, что известны априорные вероятности P_1 и $P_2 = 1 - P_1$ того, что случайно наблюдаемый объект принадлежит соответственно к первой генеральной совокупности или ко второй.

Пусть также известны стоимости ошибочной классификации:

$C_{2/1}$ – стоимость потерь из-за отнесения ко второй генеральной совокупности вектора наблюдений Z , принадлежащего к первой генеральной совокупности;

$C_{1/2}$ – стоимость потерь из-за отнесения к первой генеральной совокупности вектора наблюдений Z , принадлежащего ко второй генеральной совокупности.

Тогда по теореме Байеса наблюдаемый вектор Z будет принадлежать первой совокупности S_1 с вероятностью

$$P_{S_1}(Z) = \frac{P_1 f_1(Z)}{P_1 f_1(Z) + P_2 f_2(Z)},$$

а второй совокупности с вероятностью

$$P_{S_2}(Z) = \frac{P_2 f_2(Z)}{P_1 f_1(Z) + P_2 f_2(Z)}.$$

Тогда, если мы отнесём вектор наблюдений Z к первой совокупности S_1 , то математическое ожидание потерь составит величину

$$L_1(Z) = P_{S_2}(Z)C_{1/2}.$$

Если отнести вектор наблюдений Z ко второй совокупности S_2 , то математическое ожидание потерь составит величину

$$L_2(Z) = P_{S_1}(Z)C_{2/1}.$$

В качестве алгоритма классификации примем

$$S_1: \frac{L_1(Z)}{L_2(Z)} \leq 1, \quad S_2: \frac{L_1(Z)}{L_2(Z)} > 1.$$

Несложно определить, что область S_1 задаётся неравенством

$$(M_1 - M_2)R^{-1}(Z)^T \geq \frac{1}{2}(M_1 - M_2)R^{-1}(M_1 + M_2)^T + \ln\left(\frac{P_2 C_{1/2}}{P_1 C_{2/1}}\right).$$

Если какая-либо априорная информация о генеральных совокупностях отсутствует, то обычно полагают $C_{1/2} = C_{2/1}$.

Если m -мерные векторы математических ожиданий M_1 , M_2 и ковариационная матрица R генеральных совокупностей неизвестны, то по обучающим выборкам S_1 и S_2 находят оценки этих параметров. В этом случае оценка ковариационной матрицы вычисляется по формуле

$$\tilde{R} = \frac{1}{n_1 + n_2 - 2} [(n_1 - 1)\tilde{R}_1 + (n_2 - 1)\tilde{R}_2],$$

где $\tilde{R}_1, \tilde{R}_2$ — несмещённые оценки ковариационных матриц R_1, R_2 ;

n_1, n_2 — объёмы выборок из S_1 и S_2 соответственно.

4. Рассмотрим задачу дискриминации для случая G нормально распределённых генеральных совокупностей $X_{g_i} \sim N(M_g, R)$, $g = \overline{1, G}$.

Дискриминантную функцию i -й и q -й совокупностей можно записать в виде

$$W_{iq} = U_{iq} - C_{iq} = (M_i - M_q)R^{-1}(Z)^T - \frac{1}{2}(M_i - M_q)R^{-1}(M_i + M_q)^T.$$

Если параметры генеральных совокупностей неизвестны, то вычисляют их оценки по соответствующим обучающим выборкам, причём

$$\tilde{R} = \frac{1}{\sum_{g=1}^G n_g - G} \left(\sum_{g=1}^G (n_g - 1) \tilde{R}_g \right),$$

где $\tilde{R}_g$ – несмещённая оценка ковариационной матрицы $R_g = R$;

n_g – объём выборки из S_g -й совокупности, $g = \overline{1, G}$.

Если для всех $q \neq i$ выполняется неравенство $W_{iq} \geq 0$, то наблюдаемый вектор относят к совокупности S_i .

Дискриминантный анализ широко используется во многих прикладных исследованиях: психологическое тестирование взрослых и детей; тестирование при приёме на работу; анализ переписи населения; изучение эффектов какого-либо метода лечения; изучение различий между фирмами, географическими районами; социологические исследования и др.

Считается, что наилучшим правилом классификации является байесовское решающее правило, обеспечивающие минимальные средние потери от неправильной классификации и основанные на отношении апостериорных вероятностей различных классов в данной точке пространства признаков.

На практике эти отношения оцениваются по обучающей выборке (наблюдениям с известной классификацией) с помощью параметрических и непараметрических методов. Примером могут служить линейные дискриминантные функции Р.Фишера для нормальных распределений или метод "ближайшего соседа".

Другим возможным методом дискриминантного анализа является минимизация оценки среднего риска или метод "скользящего экзамена" в заранее заданном классе решающих правил.

Линейная дискриминантная функция Р.Фишера – такая линейная комбинация признаков, средние значения которых в разных классах, отнесённые к их средним квадратическим отклонениям максимально различаются.

Для нормальных распределений, отличающихся только средними, дискриминантная функция задаёт байесовское правило классификации.

В дискриминантном анализе нескольких классов для реализации байесовского решающего правила надо рассматривать несколько функций, позволяющие сравнивать апостериорные вероятности классов.