


Тема 10.

Data Mining

Мультидисциплинарная область




Эволюция технологий хранения и обработки данных

- ... — 1960-е:
 - Файлы и файловые архивы
- 1960-е:
 - Первые СУБД, иерархические, сетевые и т.д.
- 1970-е:
 - Реляционная модель данных, реляционные СУБД
- 1980-е:
 - «Продвинутые» СУБД (объектно-реляционные и объектные, «расширенные» реляционные, дедуктивные и д.р.)
 - «Специализированные» СУБД (гео-, научные, инженерные и д.р.)
- 1990-е — ...:
 - Мультимедийные БД, WWW, хранилища,
 - витрины данных, OLAP, Data Mining

Актуальность и необходимость интеллектуального анализа данных

- Проблема больших объемов («Data explosion»):
 - Средства автоматического сбора данных, повсеместное внедрение СУБД, электронный документооборот, WWW, мультимедийные архивы и т.д. Все ведет к росту объемов и усложнению структуры хранимой информации.
- Традиционные средства не справляются:
 - Информационный поиск и стат. анализ не везде помогают – много данных, сложная структура и нужно знать точно, что искать.
 - Вывод: много данных, но мало информации для аналитика.
- Необходимо:
 - Разработка программных средств автоматизированного анализа данных большого объема и сложной структуры.

Интеллектуальный анализ данных (Data Mining)



Системы *интеллектуального анализа данных* (ИАД) – класс программных систем поддержки принятия решений, задачей которых является поиск скрытых, ранее неизвестных, содержательных и потенциально полезных закономерностей в больших объемах разнородных, сложно структурированных данных.

Han J., Kamber M. Data Mining: Concepts and Techniques // Morgan Kaufmann, 2000

Процесс ИАД (1)


- Анализ предметной области:
 - выявление и формулировка необходимых априорных знаний о предметной области, целей анализа, задач приложения, сценариев использования
- Формирование и подготовка данных для анализа:
 - поиск (или выбор) «сырых» данных, возможно реализация подсистемы сбора (консолидации)
 - предобработка данных (нормализация, дискретизация, обработка пропущенных значений, удаление артефактов, проверка консистентности)
 - уменьшение размерности, выбор значимых характеристик, расчет интегральных показателей и инвариантов
- Определение типа решаемой задачи анализа:
 - классификация, прогнозирование, кластеризация, поиск исключений, ассоциативный анализ и т.д.

Процесс ИАД (2)

- Выбор (или разработка) алгоритма анализа:
 - определение ограничений и требований к алгоритму по точности, размеру, интерпретируемости, скорости построения и применения получаемых моделей, по типу исходных данных
- Собственно «Data mining»:
 - применение выбранного алгоритма анализа для поиска закономерностей выбранного типа и построение моделей
- Проверка моделей и представление результатов анализа:
 - визуализация, преобразование, удаление избыточности, оценка точности, достоверности моделей и т.д.
- Применение построенных моделей:
 - Descriptive data mining - информирование аналитика, «описательные» модели, основная цель – визуализация
 - Predictive data mining – прогнозирование неизвестных значений или характеристик в «новых» данных с помощью построенных моделей , основная цель – прогноз

Программные системы ИАД

- Типовая архитектура:



- Классификация систем ИАД:

- ☐ По типу анализируемых данных
- ☐ По типу решаемых задач
- ☐ По методам анализа и классам алгоритмов
- ☐ По области применения

Типы исходных данных (1)

- Транзакционные базы данных и репозитории «событий»
 - Объекты анализа – «события» различной структуры с числовыми и категориальными атрибутами, и с временной меткой
- Реляционные и объектные СУБД
 - Объекты анализа сложным образом взаимосвязаны (заданно ER-схемой), имеют разнотипные атрибутами, наследование (расширение)
- Многомерные OLAP-хранилища
 - Объекты анализа – срезы многомерно OLAP куба, т.е. набор числовых мер, при фиксированных значениях измерений
- Временные ряды и числовые данные большого объема
 - Обработка результатов наблюдений, научных экспериментов, характеристик технологических процессов


Типы исходных данных (2)

- Географические и пространственные данные
 - Привязка к пространственным координатам, учет географии объектов при анализе (например при определении меры сходства или расстояния) , учет перемещения в пространстве (moving objects)
- Символьные последовательности
 - ДНК цепочки, машинные коды, трассы выполнения процессов, тексты программ на ЯП
- Электронные тексты на естественном языке
 - анализ содержимого документов, проблема представления, морфология
- Гипертекстовые данные и WWW
 - структурированный текст на естественном языке, учет гиперссылок и нетекстового содержания
- Мультимедия
 - Звук, видео, изображения

Задачи ИАД = типы выявляемых закономерностей

- Классификация («Обучение с учителем»)
 - Отнесение объектов к заранее определенным категориям
- Прогнозирование («Обучение с учителем»)
 - На основании известных значений атрибутов анализируемого объекта определяются значения неизвестных атрибутов
- Ассоциации («Обучение без учителя»)
 - Выявление зависимостей между атрибутами
- Кластеризация («Обучение без учителя»)
 - Выделение компактных подгрупп «похожих» объектов
- Дискриминантный анализ («Обучение без учителя»)
 - Выявление атрибутов которые «различают» (дискриминируют) две или более возникающие совокупности (группы)
- Выявление исключений («Обучение с и без учителя»)
 - Поиск объектов, которые своими характеристиками значительно отличаются от остальных

Методы анализа



Область применения систем ИАД

- Системы ИАД «общего назначения»

- По сути включают framework, библиотеку алгоритмов анализа и набор программных средств для реализации ИАД процесса для широкого класса входных данных и прикладных задач
- Примеры DataMiner, MS Analysis Services, Oracle BI, PolyAnalyst

- Специализированные системы ИАД

- Набор решаемых задач и алгоритмов решения, а также средств подготовки данных и визуализации результата ориентирован на конкретную предметную область
- ИАД процесс максимально «автоматизирован», но конечным потребителем информации все равно является эксперт-аналитик
- Области применения: маркетинг, анализ финансовых рисков, здравоохранение, страхование, кредитование, телекоммуникации, компьютерная безопасность, мониторинг оборудования и технологических процессов, антитерроризм, интернет и т.д.

Место ИАД в процессе поддержки принятия решений в СЦ

Задачи:

- Расчет индикаторов на основе данных предметной области
- Определение тенденций и прогнозирование значений индикаторов
- Выявление аномалий в значениях индикаторов



Отличия ИАД систем (1)

- Наличие «обучения»
 - база знаний формируются на основе анализируемых данных, а не экспертных знаний (в отличии от традиционных экспертных систем и систем информационного поиска)
 - структура модели и искомые зависимости заранее не известны (в отличии от статистических пакетов, ориентированных на расчет статистик, проверку гипотез и оценку параметров распределений)

Отличия ИАД систем (2)

- Наличие большого объема данных сложной структуры
 - зачастую скорость работы алгоритмов в ИАД важнее отклонений по точности (“quick and dirty solution”)
 - большинство алгоритмов работают с исходными данными в виде числовой матрицы признаков, сложная структура реальных объектов в ИАД, приводит к необходимости решать задачу построения пространства характеристик и отображения в него свойств исходных объектов
 - перечисленные особенности отличают ИАД системы от традиционных систем машинного обучения, в которых как правило решается обратная задача – построение достоверной модели в условиях малой обучающей выборки

Отличия ИАД систем (3)

- Наличие человека - аналитика как окончательного потребителя результатов работы ИАД системы
 - в сценарии работы любой системы ИАД всегда присутствует аналитик, даже если полученная в результате модель далее используется для автоматической классификации
 - аналитик формирует тренировочные наборы, производит настройку алгоритмов, обучение и дообучение, анализирует полученные модели и принимает решения об их дальнейшем использовании
 - таким образом, системы автоматической классификации, кластеризации и распознавания образов, даже использующие возможность дообучения, не являются системами ИАД

Методы работы с данными


Методы группы:

- кластерный анализ
- метод ближайшего соседа
- метод k -ближайшего соседа
- рассуждение по аналогии

Методы группы:

- логические методы
 - нечеткие запросы и анализы
 - символьные правила
 - деревья решений
 - генетические алгоритмы.
- методы визуализации
- методы кросс-табуляции
- методы, основанные на уравнениях

Статистические и кибернетические методы



Методы группы:

- *дескриптивный анализ и описание исходных данных*
- *анализ связей (корреляционный и регрессионный анализ, факторный анализ, дисперсионный анализ)*
- *многомерный статистический анализ (компонентный анализ, дискриминантный анализ, многомерный регрессионный анализ, канонические корреляции и др.)*
- *анализ временных рядов (динамические модели и прогнозирование)*



Методы группы:

- *искусственные нейронные сети (распознавание, кластеризация, прогноз);*
- *эволюционное программирование (в т.ч. алгоритмы метода группового учета аргументов);*
- *генетические алгоритмы (оптимизация);*
- *ассоциативная память (поиск аналогов, прототипов);*
- *нечеткая логика;*
- *деревья решений;*
- *системы обработки экспертных знаний.*

Описательные и прогнозирующие методы

Методы группы:

- алгоритм k -средних
- k -медианы
- иерархические методы кластерного анализа
- самоорганизующиеся карты Кохонена
- методы кросс-табличной визуализации

Методы группы:

- нейронные сети
- деревья решений,
- линейная регрессия
- метод ближайшего соседа
- метод опорных векторов