


Тема 3.

Корреляционный и дисперсионный анализ

Диаграмма рассеяния

Пример 1. Построить диаграмму рассеяния для результатов наблюдения за возрастом и артериальным давлением группы людей, приведенных в таблице.

№	Возраст, лет (x)	Давление, мм.рт.ст. (y)
1	43	128
2	48	120
3	56	135
4	61	143
5	67	141
6	70	152







Свойства коэффициента корреляции

Основные свойства коэффициента корреляции:

Сильная
обратная
связь

Нет
линейной
связи

Сильная
прямая
связь



Шкала силы связи

Степень тесноты связей



Сильные связи



Слабые связи


шкала Чеддока

Величина коэффициента корреляции	0.1 - 0.3	0.3 - 0.5	0.5 - 0.7	0.7 - 0.9	0.9 - 1.0
Характеристи ка силы связи	слабая	умеренная	заметная	высокая	весьма высокая

средняя

сильная


Примеры корреляций



- а) строгая положительная корреляция
- б) положительная корреляция
- в) слабая положительная корреляция
- г) нулевая корреляция

- д) отрицательная корреляция
- е) строгая отрицательная корреляция
- ж) нелинейная корреляция
- з) нелинейная корреляция

Пример коэффициента

	A	B	C	D	E	F	G
1	Возраст курящего, x	Число сигарет в день, y					
2	27	6					
3	64	10					
4	36	9					
5	42	18					
6	31	7					
7	18	12					
8	53	5					
9	64	12					
10	58	3					
11	25	7					
12							
13	Коэффициент корреляции		-0,03507				

Виды корреляций

Ложная корреляция

Если между двумя исследуемыми величинами установлена тесная зависимость, то из этого еще не следует их причинная взаимообусловленность. За счет эффектов одновременного влияния неучтенных факторов смысл истинной связи может искажаться. Поэтому такую корреляцию часто называют **«ложной»**.

Частная корреляция

- Если две переменные коррелируют, всегда можно предположить, что эта корреляция обусловлена влиянием третьей переменной, как общей причины совместной изменчивости первых двух переменных.
- Для проверки этого предположения достаточно **исключить влияние этой третьей переменной** и вычислить корреляцию двух переменных без учета влияния третьей переменной (при фиксированных ее значениях).
- Корреляция, вычисленная таким образом называется **частной**.

Количественная шкала (I способ вычисления коэфф.)

Линейный коэффициент корреляции.

Определение. *Линейным коэффициентом корреляции* признаков ξ и η , вычисленным по выборке Z называется величина:

$$r_{X,Y} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma_X} \right) \left(\frac{y_i - \bar{y}}{\sigma_Y} \right) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}},$$

где $\sigma_X = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$, $\sigma_Y = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}$.

Корреляционная таблица

Двумерное распределение частот можно представить в виде таблицы:

X \ Y	y_1	y_2	...	y_l	m_{i*}
x_1	m_{11}	m_{12}	...	m_{1l}	m_{1*}
x_2	m_{21}	m_{22}	...	m_{2l}	m_{2*}
...	...	...	...	...	...
x_k	m_{k1}	m_{k2}	...	m_{kl}	m_{k*}
m_{*j}	m_{*1}	m_{*2}	...	m_{*l}	n

m_{ij} - частота наблюдаемой пары (x_i, y_j)

$$n = \sum_{i=1}^k \sum_{j=1}^l m_{ij} \qquad m_{i*} = \sum_{j=1}^l m_{ij} \qquad m_{*j} = \sum_{i=1}^k m_{ij}$$

Вычисление коэффициента

(II способ вычисления коэфф.)

Парный коэффициент корреляции
если оба признака измерены
в количественных шкалах:

$$r_{xy} = \frac{s_{xy}}{\sigma_x \sigma_y}$$

где σ_x , σ_y – среднее квадратическое отклонение признаков x , y соответственно,

$$s_{xy} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^l m_{ij} (x_i - \bar{x})(y_j - \bar{y})$$

– ковариация признаков X и Y ,
где m_{ij} – абсолютная частота наблюдаемой
пары значений (x_i, y_j) в выборке объема n .

Значимость корреляции

Корреляционный анализ

Проверка значимости коэффициента корреляции

$$t_{расч} = |r_{xy}| \sqrt{\frac{n-2}{1-r_{xy}^2}}$$

$t_p > t_{табл.}$ - существует зависимость между X и Y

$t_p \leq t_{табл.}$ - величины X и Y независимы

Ранговая (порядковая) шкала

Теорема. Пусть признаки ξ и η измерены в ранговой шкале, а результаты наблюдений за этими признаками представлены выборками

$$P = \left\{ p_i, i = \overline{1, n} \right\} \quad \text{и} \quad Q = \left\{ q_i, i = \overline{1, n} \right\}$$

Тогда коэффициент корреляции между ξ и η равен:

$$\rho = 1 - 6 \frac{\sum_{i=1}^n (p_i - q_i)^2}{n(n^2 - 1)}$$

формула
Спирмена

Номинальная (качественная) шкала

Коэффициент корреляции Пирсона

если оба признака измерены

в дихотомической шкале,

(т. е. принимают значения – 0 и 1):

где $p(x)$ – доля выборочных значений признака $x=1$;

$p(y)$ – доля выборочных значений признака $y=1$;

$p(x, y)$ – доля вариантов (x_i, y_i) с единичными значениями у обоих признаков.

$$\varphi = \frac{p(x, y) - p(x)p(y)}{\sqrt{p(x)(1 - p(x))p(y)(1 - p(y))}}$$

Дисперсионный анализ

- Цель дисперсионного анализа - исследование наличия или отсутствия существенного влияния какого-либо качественного или количественного фактора на изменения исследуемого результативного признака.
- Для этого фактор, предположительно имеющий или не имеющий существенного влияния, разделяют на *классы градации* (говоря иначе, группы) и выясняют, *одинаково ли влияние фактора* путём исследования значимости между средними в наборах данных, соответствующих градациям фактора.

Основы дисперсионного анализа

- При дисперсионном анализе исследуется отношение **двух дисперсий**. Дисперсия – это характеристика рассеивания данных вокруг среднего значения.
- **Первая** - дисперсия, объяснённая влиянием фактора, которая характеризует рассеивание значений между градациями фактора (группами) вокруг средней всех данных.
- **Вторая** - необъяснённая дисперсия, которая характеризует рассеивание данных внутри градаций (групп) вокруг средних значений самих групп.
- Первую дисперсию можно назвать межгрупповой, а вторую - внутригрупповой.
- Отношение этих дисперсий называется фактическим отношением Фишера и сравнивается с критическим значением отношения Фишера. Если фактическое отношение Фишера больше критического, то средние классов градации отличаются друг от друга и исследуемый фактор существенно влияет на изменение данных. Если меньше, то средние классов градации не отличаются друг от друга и фактор не имеет существенного влияния.

Виды дисперсионного анализа

- Суть дисперсионного анализа сводится к изучению влияния одной или нескольких независимых переменных, обычно именуемых факторами, на зависимую переменную. Зависимые переменные представлены значениями абсолютных шкал (шкала отношений). Независимые переменные являются номинативными (шкала наименований), то есть отражают групповую принадлежность, и могут иметь два или более значения (типа, градации или уровня). Градации, соответствующие независимым выборкам объектов, называются межгрупповыми, а градации, соответствующие зависимым выборкам, — внутригрупповыми.

В зависимости от типа и количества переменных различают:

- однофакторный и многофакторный дисперсионный анализ (одна или несколько независимых переменных);
- одномерный и многомерный дисперсионный анализ (одна или несколько зависимых переменных);
- дисперсионный анализ с повторными измерениями (для зависимых выборок);
- дисперсионный анализ с постоянными факторами, случайными факторами, и смешанные модели с факторами обоих типов

Допущения дисперсионного анализа

Исходными положениями дисперсионного анализа являются

- нормальное распределение значений изучаемого признака в генеральной совокупности;
- равенство дисперсий в сравниваемых генеральных совокупностях;
- случайный и независимый характер выборки.

Нулевой гипотезой в дисперсионном анализе является утверждение о равенстве средних значений:

При отклонении нулевой гипотезы принимается альтернативная гипотеза о том, что не все средние равны, то есть имеются, по крайней мере, две группы, отличающиеся средними значениями

Однофакторный дисперсионный анализ

- Простейшим случаем дисперсионного анализа является одномерный однофакторный анализ для двух или нескольких независимых групп, когда все группы объединены по одному признаку. В ходе анализа проверяется нулевая гипотеза о равенстве средних.
- **При анализе двух групп** дисперсионный анализ тождественен двухвыборочному t -критерию Стьюдента для независимых выборок, и величина F -статистики равна квадрату соответствующей t -статистики.
- Для подтверждения положения о равенстве дисперсий обычно применяется критерий Ливена (*Levene's test*). В случае отвержения гипотезы о равенстве дисперсий основной анализ неприменим. Если дисперсии равны, то для оценки соотношения межгрупповой и внутригрупповой изменчивости применяется F -критерий Фишера
- Если F -статистика превышает критическое значение, то нулевая гипотеза не может быть принята (отвергается) и делается вывод о неравенстве средних. При анализе средних двух групп результаты могут быть интерпретированы непосредственно после применения критерия Фишера.
- **При наличии трёх и более групп** требуется попарное сравнение средних для выявления статистически значимых отличий между ними.

Исходные данные

Исходные данные для однофакторного анализа

Уровень фактора A	Результативный признак Y
A_1	$y_{11}, y_{12}, \dots, y_{1n_1}$
A_2	$y_{21}, y_{22}, \dots, y_{2n_2}$
...	...
A_m	$y_{m1}, y_{m2}, \dots, y_{mn_m}$

Число степеней свободы:

$f_{\text{общ}} = N - 1$, где $N = \sum_{i=1}^m n_i$ – общее число наблюдений

$f_{\text{факт}} = m - 1$, где m – число уровней(градаций) фактора

$f_{\text{ост}} = N - m$

Дисперсии

Общая

$$S_{\text{общ}}^2 = \frac{\sum_{i=1}^m \sum_{j=1}^n (y_{ij} - \bar{y})^2}{N - 1}$$

Факторная

$$S_{\text{факт}}^2 = \frac{\sum_{i=1}^m (\bar{y}_i - \bar{y})^2 n_i}{m - 1}$$

Остаточная

$$S_{\text{ост}}^2 = \frac{\sum_{i=1}^m \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2}{N - m}$$

Критерий Фишера

$$F_{\text{набл}} = \frac{S_{\text{факт}}^2}{S_{\text{ост}}^2}$$

Если $F_{\text{набл}} > F_{\text{крит}}$, то H_0 отвергается.

Критерий Левина

Проверка равенства дисперсий в группах

1. Для каждой группы i и каждого наблюдения Y_{ij} :

$$Z_{ij} = |Y_{ij} - \bar{Y}_i|$$

где:

- $\bar{Y}_i$ — среднее по группе i .

1. Анализируем полученные абсолютные отклонения Z_{ij} — это словно «новые» данные, которые показывают вариабельность внутри групп.
2. Выполняем стандартный односторонний анализ вариаций (ANOVA) по этим Z_{ij} , чтобы проверить гипотезу о равенстве средних значений Z по группам.

$$F_{табл.}(\gamma, \nu_1 = m - 1, \nu_2 = N - m);$$