

Министерство образования Республики Беларусь
Белорусский государственный университет
Факультет радиофизики и компьютерных технологий
Кафедра системного анализа и компьютерного моделирования

СОГЛАСОВАНО

Заведующий кафедрой

Яцков Н.Н.

«26» сентября 2023 г.

СОГЛАСОВАНО

Декан факультета

Ушаков Д.В.

«26» сентября 2023 г.

Интеллектуальный анализ данных

Электронный учебно-методический комплекс для специальностей:
1-98 01 01 «Компьютерная безопасность» (по направлениям);
1-31 04 02 «Радиофизика»;
1-31 04 03 «Физическая электроника»

Регистрационный № 2.4.2-24/371

Автор:

Яцков Н. Н., кандидат физико-математических наук, заведующий кафедрой системного анализа и компьютерного моделирования.

Рассмотрено и утверждено на заседании Научно-методического совета БГУ
19.10.2023 г., протокол № 2.

Минск 2023

УДК 004.6(075.8)+004.81.032.26(075.8)
Я 936

Утверждено на заседании Научно-методического совета БГУ
Протокол № 2 от 19.10.2023 г.

Решение о депонировании вынес:
Совет факультета радиофизики и компьютерных технологий
Протокол № 2 от 26.09.2023 г.

А в т о р :

Яцков Николай Николаевич, кандидат физико-математических наук, заведующий кафедрой системного анализа и компьютерного моделирования факультета радиофизики и компьютерных технологий БГУ.

Рецензенты:

кафедра цифровых систем и технологий ГУО «Институт бизнеса БГУ» (заведующий кафедрой Ткалич Т.А., доктор экономических наук, профессор);

Хейдоров Игорь Эдуардович, доцент кафедры радиофизики и цифровых медиатехнологий БГУ, кандидат физико-математических наук, доцент.

Яцков, Н. Н. Интеллектуальный анализ данных : электронный учебно-методический комплекс для специальностей: 1-98 01 01-02 «Компьютерная безопасность» (по направлениям), 1-31 04 02 «Радиофизика», 1-31 04 03 «Физическая электроника» / Н. Н. Яцков ; БГУ, Фак. радиофизики и компьютерных технологий , Каф. системного анализа и компьютерного моделирования. – Минск : БГУ, 2023. – 124 с. : ил. – Библиогр.: с. 124.

Электронный учебно-методический комплекс (ЭУМК) по учебной дисциплине «Интеллектуальный анализ данных» предназначен для студентов специальностей 1-98 01 01-02 «Компьютерная безопасность» (по направлениям), 1-31 04 02 «Радиофизика», 1-31 04 03 «Физическая электроника». В ЭУМК содержатся основные определения и задачи интеллектуального анализа данных, методы статистического и кластерного анализа, нейронных сетей, стохастического поиска, классификации, поиска ассоциативных правил, визуализации многомерных данных.

СОДЕРЖАНИЕ

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА	5
1. ТЕОРЕТИЧЕСКИЙ РАЗДЕЛ	6
1.1. Основные понятия дисциплины «Интеллектуальный анализ данных»	6
1.1.1. Интеллектуальный анализ данных	6
1.1.2. Методы, модели и задачи дисциплины.....	7
1.1.3. Данные	9
1.1.4. Примеры практического применения дисциплины «Интеллектуальный анализ данных».....	12
1.2. Методы предварительного анализа	13
1.2.1. Описательная статистика	13
1.2.2. Очистка данных.....	15
1.2.3. Нормировка и стандартизация данных	16
1.2.4. Анализ выбросов и аномальных значений	18
1.3. Корреляционный анализ.....	20
1.3.1. Коэффициент корреляции Пирсона.....	20
1.3.2. Ранговая корреляция.....	25
1.3.3. Множественная и частная корреляции	28
1.4. Регрессионный анализ.....	29
1.4.1. Регрессия	29
1.4.2. Регрессионный анализ	30
1.5. Методы снижения размерности данных.....	35
1.6. Иерархические методы кластерного анализа.....	40
1.6.1. Кластерный анализ	40
1.6.2. Иерархические методы кластерного анализа	44
1.7. Неиерархические и графовые методы кластерного анализа.....	48
1.7.1. Неиерархические методы кластерного анализа	48
1.7.2. Графовые методы кластерного анализа	53
1.8. Нейронные сети	55
1.8.1. Нейронная сеть.....	55
1.8.2. Алгоритмы обучения нейронных сетей	59
1.8.3. Нейронные сети Кохонена.....	60
1.9. Стохастические методы поиска.....	63

1.9.1.	Методы случайного поиска	64
1.9.2.	Эволюционные стратегии случайного поиска	67
1.9.3.	Генетические алгоритмы	70
1.10.	Методы классификации. деревья решений	71
1.10.1.	Деревья решений	71
1.10.2.	Анализ данных с использованием деревьев решений	72
1.10.3.	Алгоритмы построения деревьев решений.....	77
1.11.	Методы классификации на основе байесовских сетей и расстояний	80
1.11.1.	Байесовская классификация	80
1.11.2.	Метод k -ближайших соседей	83
1.11.3.	Метод наименьшего расстояния (до центров классов)	85
1.11.4.	Методы перекрёстной проверки	86
1.12.	Методы поиска ассоциативных правил.....	88
1.12.1.	Ассоциативные правила	88
1.12.2.	Алгоритмы поиска ассоциативных правил	90
1.13.	Методы визуализации данных	95
1.13.1.	Визуальное представление данных	95
1.13.2.	Методы визуализации многомерных данных	96
1.13.3.	Принципы качественной визуализации	102
1.14.	Процесс интеллектуального анализа данных.....	103
1.15.	Стандарты и рынок инструментов интеллектуального анализа данных.....	111
1.15.1.	Организационные и человеческие факторы	111
1.15.2.	Стандарты интеллектуального анализа данных.....	112
1.15.3.	Рынок инструментов интеллектуального анализа данных.....	116
2.	ПРАКТИЧЕСКИЙ РАЗДЕЛ	119
3.	РАЗДЕЛ КОНТРОЛЯ ЗНАНИЙ	120
3.1.	Перечень рекомендуемых средств диагностики	120
3.2.	Темы реферативных работ	120
3.3.	Вопросы для подготовки к зачету.....	122
4.	ВСПОМОГАТЕЛЬНЫЙ РАЗДЕЛ	124
4.1.	Список рекомендуемой литературы	124
4.2.	Электронные ресурсы	124

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

Электронный учебно-методический комплекс (ЭУМК) по учебной дисциплине «Интеллектуальный анализ данных» разработан в соответствии с требованиями Положения об учебно-методическом комплексе на уровне высшего образования и предназначен для студентов I ступени высшего образования специальностей 1-98 01 01-02 «Компьютерная безопасность» (по направлениям), 1-31 04 02 «Радиофизика», 1-31 04 03 «Физическая электроника». Содержание разделов ЭУМК соответствует образовательному стандарту высшего образования специальности. Главная цель ЭУМК – оказание методической помощи студентам в систематизации учебного материала в процессе подготовки к аттестации по учебной дисциплине «1-98 01 01-02 «Компьютерная безопасность» (по направлениям), 1-31 04 02 «Радиофизика», 1-31 04 03 «Физическая электроника».

Цель ЭУМК – оказание методической помощи студентам в получении современных знаний по учебной дисциплине «Интеллектуальный анализ данных», систематизации учебного материала в процессе подготовки к итоговой аттестации.

В структуру ЭУМК входит: 1. Теоретический раздел (включает краткий конспект лекций по учебной дисциплине в соответствии с типовым учебным планом по специальности). 2. Практический раздел (материалы для проведения практических занятий по дисциплине в соответствии с учебным планом). 3. Раздел контроля знаний (содержит перечень рекомендуемых средств диагностики, контрольных мероприятий управляемой самостоятельной работы студентов; темы реферативных работ и вопросы для подготовки к экзамену). 4. Вспомогательный раздел (включает список рекомендуемой литературы и электронные ресурсы).

Работа с ЭУМК должна включать на первом этапе ознакомление с тематическим планом дисциплины, представленным в учебной программе, а также тематикой лекций и лабораторных занятий. Для подготовки к лабораторным занятиям и промежуточным зачетам необходимо использовать материалы, представленные в разделе учебно-методического обеспечения дисциплины, а также материалы для текущего контроля самостоятельной работы. В ходе подготовки к итоговой аттестации рекомендуется ознакомиться с требованиями к компетенциям по дисциплине, изложенными в учебной программе, структурой рейтинговой системы, а также перечнем вопросов к зачету. Для написания рефератов могут быть использованы информационно-аналитические материалы, указанные в соответствующем разделе ЭУМК.

1. ТЕОРЕТИЧЕСКИЙ РАЗДЕЛ

В теоретическом разделе изложен краткий конспект лекций в соответствии с учебной программой дисциплины.

1.1. Основные понятия дисциплины «Интеллектуальный анализ данных»

1.1.1. Интеллектуальный анализ данных

Термин «интеллектуальный анализ данных» (ИАД) происходит от англоязычного термина «data mining», который часто переводится как поиск или «добыча» данных, извлечение информации, «раскопка» данных, средства поиска закономерностей, извлечение знаний, анализ шаблонов, извлечение «зерен знаний из гор данных», «раскопка» знаний в базах данных, информационная «проходка» данных, «промывание» данных. Наиболее удачный перевод – интеллектуальный анализ данных.

Понятие «data mining» введено в 1989 г. основателем дисциплины русским ученым Г. Пятецким-Шапиро. ИАД приобрел высокую популярность в применении примерно с первой половины 1990-х гг. До этого времени обработка и анализ данных осуществлялись в рамках прикладной статистики, при этом в основном решались задачи обработки небольших баз данных.

Дисциплина ИАД представляет собой мультидисциплинарную область на базе таких наук, как прикладная статистика, распознавание образов, искусственный интеллект, теория баз данных и др. (рисунок 1).




Рисунок 1 – Интеллектуальный анализ данных как мультидисциплинарная область.

Интеллектуальный анализ данных – это процесс обнаружения в сырых данных (в базе данных) ранее неизвестных, неочевидных, практически полезных, объективных и доступных интерпретации знаний, необходимых для принятия решений в различных сферах человеческой деятельности.

Суть и цель технологии ИАД можно охарактеризовать как поиск в больших объемах данных неочевидных, объективных и полезных на практике знаний или закономерностей.

Неочевидные найденные закономерности не обнаруживаются стандартными методами обработки информации или экспертным путем.

Объективные обнаруженные закономерности будут полностью соответствовать действительности, в отличие от экспертного мнения, которое всегда является субъективным.

Практически полезные выводы имеют конкретное значение, которому можно найти практическое применение.

Знания – совокупность фактов, закономерностей и правил, с помощью которых решается поставленная задача.

Отличия ИАД от других методов анализа данных. Традиционные методы анализа данных (статистические методы) и OLAP (On-Line Analytical Processing) в основном ориентированы на проверку заранее сформулированных гипотез и на «грубый», разведочный анализ, составляющий основу оперативной аналитической обработки данных, в то время как одно из основных положений ИАД – поиск неочевидных закономерностей. Методы ИАД могут самостоятельно находить такие закономерности и самостоятельно строить гипотезы о взаимосвязях. Поскольку именно формулировка гипотезы относительно зависимостей является самой сложной задачей, преимущество ИАД по сравнению с другими методами анализа очевидно. Большинство статистических методов для выявления взаимосвязей в данных используют концепцию усреднения по выборке, приводящую к операциям над несуществующими величинами, тогда как ИАД оперирует реальными значениями.

Достаточно долго дисциплина ИАД не признавалась полноценной самостоятельной областью анализа данных. На сегодня определилось несколько точек зрения на ИАД. Сторонники одной из них считают его составной частью классического анализа данных. Сторонники другого направления – это те, кто принимает ИАД как альтернативу традиционному подходу к анализу. Есть и середина, приверженцы которой рассматривают возможность совместного использования современных достижений в области ИАД и в классическом статистическом анализе данных (см. наиболее известный интернет-источник – сайт www.kdnuggets.com).

1.1.2. Методы, модели и задачи дисциплины

К основным методам ИАД относят следующие:

- 1) *статистического анализа* (описательная статистика, корреляционный, регрессионный и дисперсионный анализ, метод главных компонент и факторный анализ);
- 2) *классификации и прогнозирования* (искусственные нейронные сети, деревья решений, метод k-ближайших соседей, байесовские сети);
- 3) *кластеризации* (иерархические и неиерархические методы кластерного анализа);
- 4) *поиска ассоциативных правил*;
- 5) *стохастические методы оптимизации и генетические алгоритмы*;
- 6) *визуализации данных*.

Моделями ИАД называют знания, полученные с помощью методов ИАД. Моделями ИАД могут быть деревья решений, кластеры, ассоциативные правила, математические функции (аналитические модели).

Методы ИАД позволяют решить многие задачи, с которыми сталкивается аналитик, из них основными являются: классификация, кластеризация, регрессия, ассоциация, визуализация.

Постановка задач ИАД. Пусть выполняется анализ некоторого набора объектов – многомерных данных $n_1, n_2, \dots, n_N$, полученных из базы данных или эксперимента (таблица 1). Каждый из рассматриваемых объектов $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$, $i = 1, 2, \dots, N$, характеризуется набором из K признаков $X_1, X_2, \dots, X_K$ измеряемых показателей объектов, Y – значения выходного параметра, или регистрируемые значения выходной характеристики (значения Y могут быть неизвестны).

Таблица 1 – Набор многомерных данных.

	X_1	X_2	...	X_K	Y
n_1	x_{11}	x_{12}	...	x_{1K}	y_1
n_2	x_{21}	x_{22}	...	x_{2K}	y_2
...	...	...	...	...	...
n_N	x_{N1}	x_{N2}	...	x_{NK}	y_N

Рассмотрим подробнее задачи ИАД, решаемые в ходе анализа набора многомерных данных.

Классификация. Задача классификации сводится к определению класса объекта по его характеристикам. Следует отметить, что в данной задаче множество классов, к которым может принадлежать объект, заранее известно. Экспертные значения Y известны и дискретны для ограниченного набора объектов $n_1, n_2, \dots, n_L$, где $L \ll N$, которые принадлежат m классам. Необходимо $(N - L)$ объектов разнести в m классов. Используются: байесовская классификация, методы деревьев решений, метод k -ближайших соседей, нейронные сети.

Кластеризация. Кластеризация является логическим продолжением идеи классификации. Это задача более сложная, особенность кластеризации заключается в том, что классы объектов изначально не предопределены. В результате кластеризации происходит разбиение объектов на независимые группы – кластеры. Экспертные значения Y не известны. Необходимо N объектов разнести в M кластеров. Используются: иерархические и неиерархические методы кластерного анализа, нейронные сети Кохонена.

Регрессия. Задача регрессии состоит в определении по известным характеристикам объекта n_i значения его выходного параметра y_i . Значение выходного параметра Y – это множество действительных чисел. Таким образом, экспертные значения Y известны и непрерывны для N объектов. Необходимо найти уравнения (не)линейной регрессии, аппроксимирующие Y . Применяются:

регрессионный анализ, нейронные сети, стохастические методы поиска и генетические алгоритмы.

Ассоциация. Задача поиска ассоциативных правил заключается в нахождении частых зависимостей, или ассоциаций, между объектами. Найденные зависимости представляются в виде правил и могут быть использованы как для лучшего понимания природы анализируемых данных, так и для предсказания появления событий. Наиболее популярные алгоритмы поиска ассоциативных правил – Apriori и FPG.

Визуализация. Задача визуализации состоит в создании графического образа анализируемых данных. Для решения задачи визуализации используются графические методы, демонстрирующие наличие закономерностей в данных.

Другие задачи ИАД. Прогнозирование. Задача прогнозирования – оценка пропущенных или будущих значений численных показателей объектов исследования. Определение отклонений/выбросов. Задача анализа выбросов – определение нехарактерных шаблонов или объектов в данных.

Следует отметить, что большинство аналитических методов, используемых в ИАД, – это известные математические алгоритмы и методы. Новым в их применении является возможность их использования при решении тех или иных конкретных проблем, обусловленных новыми возможностями технических и программных средств.

1.1.3. Данные

Понятие данных. В широком понимании данные представляют собой факты, текст, графики, картинки, звуки, аналоговые или цифровые видеосегменты. Данные могут быть получены в результате измерений, экспериментов, арифметических и логических операций. Данные должны быть представлены в форме, пригодной для хранения, передачи и обработки. Иными словами, данные есть необработанный материал, предоставляемый поставщиками данных и используемый потребителями для формирования информации на их основе.

Данные – это представление фактов, объектов, идей в формализованном виде (коде), пригодном для передачи, обработки, интерпретации и получения новой информации.

Пример набора данных представлен в таблице 2.

По горизонтали таблице 2 располагаются атрибуты объекта, или его признаки (пол, температура, давление, состояние), по вертикали – объекты (фамилии пациентов клиники). Объект описывается как набор атрибутов. Объект также известен как запись, случай, пример, строка таблицы и т. д.

Объектом называется единичный набор принимаемых элементами значений.

Атрибут – свойство, характеризующее объект. Атрибут также называют переменной, полем таблицы, измерением, характеристикой.

Переменная – свойство или характеристика, общая для всех изучаемых объектов, проявление которой может изменяться от объекта к объекту. Значение переменной является проявлением признака.

Таблица 2 – Результаты врачебного обхода пациентов в клинике.

Пациент	Пол	Температура, °С	Систолическое кровяное давление, mmHg	Состояние
А.А. Иванов	м	36,6	120	Отличное
П.П. Петров	м	36,7	125	Хорошее
С.С. Сидорова	ж	39,0	160	Неудовлетворительное
В.В. Васильев	м	37,5	140	Удовлетворительное
Г.Г. Григорьев	м	37,5	145	Удовлетворительное
Т.А. Томин	ж	36,6	125	Хорошее
С.П. Пушкина	ж	36,6	110	Хорошее
В.М. Ляпишев	м	39,5	170	Неудовлетворительное
С.П. Самойлов	м	37,0	130	Удовлетворительное

В ходе анализа данных, как правило, нет возможности рассмотреть всю интересующую нас совокупность объектов. Изучение очень больших объемов данных – дорогостоящий процесс, требующий больших временных затрат, который неизбежно приводит к ошибкам, связанным с человеческим фактором. Вполне достаточно рассмотреть некоторую часть всей совокупности, т. е. выборку, и получить интересующую нас информацию на ее основании. Однако размер выборки должен зависеть от разнообразия объектов, представленных в генеральной совокупности. В выборке должны быть представлены различные комбинации и элементы генеральной совокупности.

Генеральная совокупность – вся совокупность изучаемых объектов, интересующая исследователя.

Выборка – часть генеральной совокупности, определенным способом отобранная в целях исследования и получения выводов о свойствах и характеристиках генеральной совокупности.

Измерение – процесс присвоения чисел характеристикам изучаемых объектов согласно определенному правилу. В процессе подготовки данных измеряется не сам объект, а его характеристики.

Шкала – правило, в соответствии с которым объектам присваиваются числа. Переменные могут являться числовыми данными либо символьными/категориальными.

Числовые данные, в свою очередь, могут быть дискретными и непрерывными. Дискретные данные служат значениями признака, общее число которых конечно либо бесконечно, но может быть подсчитано при помощи натуральных чисел от одного до бесконечности. Непрерывные данные – данные, значения которых могут принимать какое угодно значение в некотором интервале.

Типы шкал наборов данных. Существует пять типов шкал измерений: номинальная, порядковая, интервальная, относительная и дихотомическая.

Номинальная шкала – шкала, содержащая только категории; данные в ней не могут упорядочиваться, с ними не могут быть произведены никакие арифметические действия. *Пример.* Профессия, город проживания, семейное положение. Для этой шкалы применимы только такие операции, как «равно» или «не равно».

Порядковая шкала – шкала, в которой числа присваивают объектам для обозначения относительной позиции объектов, но не величины различий между ними. Шкала измерений дает возможность ранжировать значения переменных. Измерения же в порядковой шкале только содержат информацию о порядке следования величин, но не позволяют сказать насколько одна величина больше другой, или насколько она меньше другой. *Пример.* Место (1-е, 2-е, 3-е), которое команда получила на соревнованиях, номер студента в рейтинге успеваемости (1-й, 23-й и т. д.), при этом неизвестно, насколько один студент успешнее другого, известен лишь его номер в рейтинге. Для этой шкалы применимы только такие операции, как «равно», «не равно», «больше», «меньше».

Интервальная шкала – шкала, разности между значениями которой могут быть вычислены, однако их отношения не имеют смысла. Эта шкала позволяет находить разницу между двумя величинами, обладает свойствами номинальной и порядковой шкал, а также позволяет определить количественное изменение признака. *Пример.* Температура тела двух пациентов клиники составляет 36,7 °С и 38,1 °С, однако нельзя сказать, что температура одного из пациентов в 1,04 раза выше.

Относительная шкала – шкала, в которой есть определенная точка отсчета и возможны отношения между значениями шкалы. *Пример.* Два новорожденных младенца весят – 4 кг и 3 кг. Первый в 1,33 раза тяжелее.

Дихотомическая шкала – шкала, содержащая только две категории. *Пример.* Пол (мужской и женский).

Типы наборов данных. Данные, состоящие из записей – наиболее часто встречающиеся. Примеры таких наборов данных: табличные, матричные, документальные, транзакционные или операционные.

Транзакционные данные представляют собой особый тип данных, где каждая запись, являющаяся транзакцией, включает набор значений (таблица 3).

Таблица 3 – Пример транзакционных данных.

№	Идентификатор товара
1	Хлеб, вода, молоко, шоколад
2	Масло, вода, орехи
3	Орехи, масло, хлеб, вода
4	Масло, орехи

Графические данные. Примеры графических данных: интернет-данные, молекулярные структуры, графы, карты, изображения (рисунок 2). Преимуществом графического представления данных является большая простота их восприятия, чем, например, табличных данных.




Рисунок 2 – Примеры графических данных: *а* – люминесцентные изображения микроматрицы ДНК; *б* – раковых клеток; *в* – карты Кохонена.

1.1.4. Примеры практического применения дисциплины «Интеллектуальный анализ данных»

Медицина. Объекты исследований – пациенты медицинских учреждений. Атрибуты объектов: симптомы заболеваний, методы лечения, результаты анализов и т. д. Задачи: классификация вида заболевания, определение наиболее целесообразного способа лечения, предсказание длительности и исхода заболевания, оценивание риска осложнений, определение синдромов – наиболее характерных для данного заболевания совокупности симптомов.

Биоинформатика. Объекты – гены. Атрибуты: биологические процессы и функции, заболевания. Задача: определение генов-маркеров и генетических сетей на их основе, контролирующих те или иные признаки живого организма.

Геология. Объекты – географические места разведки. Атрибуты объектов: параметры физико-химического состава пробы почв. Обучающая выборка: районы известных месторождений. Тестируемая выборка: потенциально интересные районы, где могут быть найдены месторождения пород. Основная задача – предсказание месторождений полезных ископаемых.

Банковское дело. Объекты – клиенты банка. Атрибуты объектов: информация о клиентах (возраст, образование, доход, наличие недвижимости). Задачи: оценка кредитоспособности клиентов; принятие инвестиционных решений на финансовом рынке; выявление мошенничества с кредитными карточками; сегментация клиентов (для предоставления различного рода услуг разным категориям клиентов).

Торговля. Объекты – покупатели. Атрибуты объектов: информация о покупателях. Задачи: анализ покупательской корзины (выявление товаров, которые покупатели стремятся приобретать вместе), выявление шаблонов (если покупатель приобрел фотоаппарат, то скоро он купит батарейки), оптимизация закупок, стимулирование спроса.

1.2. Методы предварительного анализа

Как правило, под статистическими методами интеллектуального анализа данных подразумевают несколько групп методов:

1. Методы предварительного анализа статистических данных, включают в себя описательную статистику, очистку данных, нормировку данных, анализ выбросов и аномальных значений.

2. Методы выявления связей и закономерностей: корреляционный анализ, линейный и нелинейный регрессионный анализ, дисперсионный и факторный анализ.

3. Многомерный статистический анализ: метод главных компонент, факторный анализ, метод независимых компонент.

В данной главе рассматривается первая группа статистических методов интеллектуального анализа данных – методы предварительного анализа данных.

1.2.1. Описательная статистика

Методы описательной статистики исследуемого набора данных применяются на предварительной стадии анализа и, как правило, нацелены на получение информации о центральной тенденции, изменчивости или вариации в исходных данных. Основные элементы описательной статистики представлены в таблице 4.

Таблица 4 – Основные элементы описательной статистики.

Оценки центральной тенденции или положения	Оценки вариации в данных	Другие оценки
Арифметическое среднее Медиана Мода	Диапазон Дисперсия Среднеквадратическое отклонение Среднее абсолютное отклонение	Квантиль Квартиль Перцентиль 5-чисельное описание Коробчатая диаграмма

Пусть выполняется анализ некоторого набора данных $(n_1, n_2, \dots, n_N)$, полученных из базы данных или эксперимента (таблица 1). Каждый из рассматриваемых объектов $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$, $i = 1, 2, \dots, K$, характеризуется набором из K признаков $X_1, X_2, \dots, X_K$, измеряемых показателей объектов.

Требуется определить характеристики центральной тенденции и вариации наборов данных $X_j = (x_{1j}, x_{2j}, \dots, x_{Nj})^T$, $j = 1, 2, \dots, K$, представляющих колонки таблицы. Рассмотрим подробнее основные элементы описательной статистики, представленные в таблице 4.

Характеристики центральной тенденции. Выборочное среднее значение – это приближение теоретического среднего распределения выборки $x_{1j}, x_{2j}, \dots$,

x_{Nj} объема N , основанное на вычислении арифметического среднего значения по выборке из него:

$$\bar{X}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}.$$

На практике для положительных вещественных чисел в случае наличия выбросов в данных также используется геометрическое среднее значение.

Геометрическое среднее значение – это корень степени N из произведения N чисел выборки $x_{1j}, x_{2j}, \dots, x_{Nj}$:

$$\bar{X}_j = \sqrt[N]{\prod_{i=1}^N x_{ij}}.$$

Медиана – точная середина выборки, которая делит ее на две равные части. Медиана является более устойчивой оценкой в случае наличия выбросов. Однако ее доверительный интервал значительно шире, чем для среднего значения.

Мода – значение случайной величины, демонстрирующее максимум эмпирической функции плотности распределения.

Характеристики вариации. Диапазон – интервал значений случайной величины:

$$d_j = \max_i x_{ij} - \min_i x_{ij}, i = 1, 2, \dots, N.$$

Выборочная дисперсия – среднее арифметическое квадратов отклонения значений выборки от их среднего значения

$$D_j = \frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{X}_j)^2.$$

Выборочная исправленная дисперсия (эмпирическая или несмещенная оценка):

$$S_j^2 = \frac{N}{(N-1)} D_j = \frac{1}{(N-1)} \sum_{i=1}^N (x_{ij} - \bar{X}_j)^2.$$

Выборочное среднее абсолютное отклонение:

$$A_j = \frac{1}{N} \sum_{i=1}^N |x_{ij} - \bar{X}_j|.$$

Квантиль – такое число, что заданная случайная величина не превышает его лишь с фиксированной вероятностью p .

Квантиль уровня 0,25 называется *первым* или *нижним квартилем* (Q_1).

Квантиль уровня 0,5 называется *медианой* или *вторым квартилем* (Q_2).

Квантиль уровня 0,75 называется *третьим* или *верхним квартилем* (Q_3).

Межквартильный диапазон – диапазон между первым и третьим квартилями ($IQR = Q_3 - Q_1$).

Квантиль уровня $\alpha = p / 100$ называют p -й *перцентилью*.

Медиану, два квартиля (первый и третий) и экстремумы объединяет 5-чисельное описание.

Коробчатая диаграмма – графическое изображение 5-чисельного описания выборки. В случае наличия выбросов экстремумы пересчитываются:

$$f_{\min} = Q_1 - 1,5 \cdot (IQR),$$

$$f_{\max} = Q_3 + 1,5 \cdot (IQR).$$

Пример коробчатой диаграммы для выборки по признаку X_j представлен на рисунке 3.




Рисунок 3 – Коробчатая диаграмма для выборки по признаку X_j .

1.2.2. Очистка данных

После того как получен набор данных, необходимо оценить качество данных и, если потребуется, выполнить процедуру очистки данных. Под данными низкого качества, или грязными данными, подразумеваются отсутствующие, неточные или бесполезные с точки зрения практического применения данные. Наиболее распространенные виды грязных данных: пропущенные значения, дубликаты, шумы, выбросы. Очистка данных направлена на устранение пропущенных значений дубликатов данных, исправление данных, представленных в неверном формате.

Пропущенные значения в экспериментальных данных могут быть обусловлены различными причинами, как правило, экспериментального характера. *Пример.* $n_1 = (1, NA, 10, NA, 3, 5)$, где NA (от англ. Not Available) – пропущенное значение. Как поступить с пропущенными данными? Есть несколько способов работы с ними:

1. Исключить объекты с пропущенными значениями из дальнейшей обработки. Это наиболее простой способ, однако и наименее эффективный как с точки зрения затрат на проведение исследований (потеря результатов дорогостоящих экспериментов), так и с позиции ИАД. Основная задача ИАД заключается в использовании наиболее полного набора данных для нахождения скрытых знаний.

2. Рассчитать новые значения для пропущенных данных, например, с помощью метода k -ближайших соседей. Суть метода заключается в поиске наиболее похожих объектов из набора данных и последующей замене пропущенного значения на усредненное значение соответствующего атрибута ближайших к нему соседей.

3. Игнорировать пропущенные значения в процессе анализа и в дальнейшем использовать те методы ИАД, которые успешно работают с пропущенными значениями.

4. Заменить пропущенные значения на их возможные значения (так называемые значения по умолчанию, среднее или медианное значения, вычисленные по данному атрибуту).

Если для некоторых объектов обнаружено слишком большое количество пропущенных значений (например, более 66 %), то такие данные считаются неинформативными и исключаются из последующего анализа.

Дубликатами называются записи с одинаковыми значениями всех атрибутов. Пример. $n_1 = (1, 5, 10, 3, 3, 5)$, $n_2 = (3, 1, 3, 1, 2, 2)$, $n_3 = (2, 2, 1, 2, 4, 2)$, $n_4 = (3, 1, 3, 1, 2, 2)$, $n_5 = (3, 1, 3, 1, 2, 2)$, $n_6 = (4, 2, 1, 3, 1, 1)$. Объекты n_2, n_4, n_5 – дубликаты. В большинстве случаев дублирование данных является результатом ошибки при подготовке данных. Однако это может быть и способом повышения значимости некоторых данных. Необходимо удалить дубликаты либо заменить группы дубликатов на одну уникальную запись с вводом весового фактора для данной записи. Последняя процедура называется взвешиванием. Пример. $n_1 = (1, 5, 10, 3, 3, 5, w = 1)$, $n_2 = (3, 1, 3, 1, 2, 2, w = 3)$, $n_5 = (4, 2, 1, 3, 1, 1, w = 1)$, где w – весовой фактор. Последующий анализ выполняется с учетом весовых факторов.

1.2.3. Нормировка и стандартизация данных

Нормировка данных. Экспериментальные шумы – достаточно общая проблема ИАД. Высокий уровень шума приводит к значительным искажениям и информационной неопределенности в данных (рисунок 4).




Рисунок 4 – Экспериментальная характеристика $I(t)$, измеренная в условиях высокого (а) и низкого (б) экспериментальных шумов.

Задача аналитика состоит в том, чтобы обнаружить шумы и оценить степень их влияния на результаты дальнейшего анализа. В случае необходимости – применить методы нормировки и сглаживания данных. Нормировка данных позволяет минимизировать влияние экспериментальных шумов и учесть эффект технических искажений. В общем случае, нормировка –

это корректировка атрибутов $X_j = (x_{1j}, x_{2j}, \dots, x_{Nj})^T, j = 1, 2, \dots, K$, в соответствии с некоторыми функциями преобразования

$$X'_j = f(X_j),$$

где X'_j – нормированное значение атрибута X_j ; f – некоторая функция нормировки, вид которой определяется отдельно для устранения тех или иных экспериментальных эффектов. Пример нелинейной нормировки представлен на рисунке 5.




Рисунок 5 – Диаграмма рассеяния данных, построенная по выборкам признаков X_i и X_j , до (а) и после (б) нелинейной нормировки колонки данных атрибута X_j .

Простейшим видом нормировки является линейное преобразование значений атрибута к интервалу $[a; b]$:

$$X'_j = a + (b - a) \cdot \frac{X_j - \min\{X_j\}}{\max\{X_j\} - \min\{X_j\}}.$$

Стандартизация данных. Для устранения неоднородностей в данных результаты из различных экспериментов должны быть приведены к единому стандарту. Как правило, процедура стандартизации данных включает операции шкалирования и центрирования признаков объектов:

$$X'_j = \frac{X_j - \bar{X}_j}{S_{X_j}},$$

где

$$\bar{X}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}, S_{X_j} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{X}_j)^2}.$$

Операции центрирования и шкалирования могут применяться к профилям объектов (рисунок 6).




Рисунок 6 – Пример центрирования (а) и шкалирования (б) профилей объектов n_i и n_j .

Математическое ожидание и дисперсия стандартизованной переменной или атрибута равны 0 и 1 соответственно. Пример стандартизации экспериментальных данных представлен на рисунке 7.




Рисунок 7 – Гистограммы и коробчатые диаграммы нескольких наборов экспериментальных данных до (а) и после стандартизации (б).

1.2.4. Анализ выбросов и аномальных значений

Выбросы – резко отличающиеся объекты или значения атрибутов объектов в наборе данных, не несущие полезной информации. Выбросы появляются из-за экспериментальных эффектов, из-за ошибки измерений или необычной

природы входных данных. Выбросы могут быть и частью исследуемых распределений.

В общем случае объекты-выбросы должны быть выделены и удалены из таблицы данных, а атрибуты-выбросы заменены на пропущенные значения NA. Для обнаружения выбросов используются графические методы (коробчатые диаграммы, диаграммы рассеяния), статистические методы, методы на основе вычисления расстояний между объектами.

Графические методы позволяют визуально определить наличие или отсутствие выбросов в данных. Наибольшее распространение получили подходы на основе построения коробчатых диаграмм, диаграмм рассеяния (рисунок 8, *а*), дендрограмм (рисунок 8, *б*). Достоинством графических методов является простота и наглядность, недостатком – субъективность в оценке принадлежности данных к выбросам.

В основе статистических методов определения выбросов лежат гипотезы о наличии нормального распределения данных. Наибольшее применение получили методы на основе критерия Граббса и максимального правдоподобия. Однако во многих случаях данные характеризуются негауссовыми законами распределений, что значительно усложняет применение статистических методов.




Рисунок 8 – Диаграмма рассеяния (*а*) и дендрограмма кластеризации (*б*) некоторого набора данных с наличием выбросов.

В методах на основе вычисления расстояний производится расчет парных или средних расстояний между точками данных. К данной группе алгоритмов относятся методы: k -ближайших соседей, пороговые и кластерного анализа.

В методе k -ближайших соседей выбросами являются те объекты, среднее расстояние от которых до k -ближайших соседей больше, чем некоторая заданная величина d .

Пороговые методы основываются на вычислении среднего расстояния от одного объекта до остальных объектов выборки. Выбросами являются объекты, для которых выполняется условие – среднее расстояние больше, чем некоторое заданное значение d' . Часто в качестве выбросов принимают первые k' объектов с наибольшими средними расстояниями.

Методы кластерного анализа разбивают данные на группы, или кластеры, по степени подобия объектов. Кластеры, содержащие малое число объектов выделяются, а объекты, попавшие в эти кластеры – это выбросы.

Аномальные значения представляют собой информативные выбросы.

Для анализа данных с наличием аномальных значений, или информационных выбросов, используют различные методы анализа данных (ранговые коэффициенты корреляции, кластерного анализа и снижения размерности данных). Рекомендуется проводить сравнение полученных результатов анализа данных с аномальными значениями (или выбросами) и с их отсутствием.

Для устранения эффектов вносимых наличием информационных выбросов в данных используются различного вида трансформации данных. Наибольшее распространение получила логарифмическая трансформация данных

$$X'_j = \log_a(X_j),$$

где X'_j – трансформированные значения атрибута X_j ; a – некоторое вещественное число.

1.3. Корреляционный анализ

1.3.1. Коэффициент корреляции Пирсона

Наиболее важным случаем статистической зависимости является корреляционная зависимость.

Корреляция (корреляционная зависимость) — статистическая взаимосвязь двух или нескольких случайных величин.

Пусть выполняется анализ некоторого набора данных $(n_1, n_2, \dots, n_N)$, полученных из базы данных или эксперимента. Строки матрицы входных данных содержат результаты для регистрируемых параметров исследуемых объектов данных. Признаки $X_1, X_2, \dots, X_k$, характеризующие различные свойства объектов, могут быть независимыми или взаимосвязанными, т. е. *коррелированными*.

Корреляционный анализ в дисциплине ИАД – это совокупность методов обнаружения статистической зависимости или корреляции между двумя и более признаками объектов, т. е. столбцами таблицы входных данных (таблица 1).

Задачей линейного корреляционного анализа является выявление линейной зависимости, или корреляции, между двумя и более признаками объектов. Стоит отметить, что корреляционный анализ не позволяет определить вид функциональной связи, а только наличие или отсутствие предполагаемой линейной связи. Вид функциональной связи определяется в ходе регрессионного анализа. Здесь мы ограничимся рассмотрением гипотезы о наличии линейной связи.

Выборочный коэффициент корреляции Пирсона для двух признаков, X_i и X_j , представляет собой отношение их ковариации к произведению среднеквадратических отклонений этих величин:

$$r_{X_i X_j} = \frac{\text{cov}_{X_i X_j}}{\sigma_{X_i} \sigma_{X_j}},$$

где

$$\text{cov}_{X_i X_j} = M[(X_i - M[X_i])(X_j - M[X_j])],$$

$$\text{cov}_{X_i X_j} = \frac{1}{N} \sum_{l=1}^N (x_{li} - \bar{X}_i)(x_{lj} - \bar{X}_j),$$

$$\bar{X}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}, \quad \sigma_{X_i} = \sqrt{\frac{1}{N} \sum_{l=1}^N (x_{li} - \bar{X}_i)^2},$$

$$\sigma_{X_j} = \sqrt{\frac{1}{N} \sum_{l=1}^N (x_{lj} - \bar{X}_j)^2}.$$

Тогда

$$r_{X_i X_j} = \frac{\sum_{l=1}^N (x_{li} - \bar{X}_i)(x_{lj} - \bar{X}_j)}{\sqrt{\sum_{l=1}^N (x_{li} - \bar{X}_i)^2 \sum_{l=1}^N (x_{lj} - \bar{X}_j)^2}}.$$

Если признаки X_i и X_j независимы и одинаково распределены, то выборочный коэффициент корреляции сходится к теоретическому при безграничном возрастании объема выборки.

Основные свойства коэффициента корреляции:

1. $-1 \leq r_{X_i X_j} \leq 1$.

2. $r_{X_i X_j} = \pm 1$ для линейно связанных признаков. *Пример.* $X_i = -\alpha X_j$, где α – константа.

3. $r_{X_i X_j} = 0$ для не связанных линейной связью признаков.

4. Коэффициент корреляции – безразмерная величина.

r^2 называется *коэффициентом детерминации* и отражает порцию общей вариации между двумя признаками X_i и X_j . Коэффициент детерминации часто используется в качестве критерия для оценки качества регрессионного анализа.

$(1 - r^2)$ называется *коэффициентом амимации* и отражает вариацию, не являющуюся общей между двумя признаками X_i и X_j .

Определение значимости коэффициента Пирсона. Выборочный коэффициент корреляции сам по себе является случайной величиной и практически всегда отличается от 0. Таким образом, требуется оценить значимость выборочной величины коэффициента корреляции Пирсона, т.е. проверить гипотезу о равенстве нулю выборочного коэффициента корреляции:

$H_0: r_{X_i X_j} = 0$ – различия между двумя признаками X_i и X_j значимы;

$H_1: r_{X_i X_j} \neq 0$ – различия между признаками X_i и X_j не значимы (наличие линейной связи).

Если гипотеза H_0 будет принята, то оценка коэффициента корреляции не значительно отличается от 0, и величины линейно не связаны друг с другом. Если гипотеза H_0 будет отвергнута, то выборочный коэффициент корреляции значим, а признаки X_i и X_j связаны линейным соотношением.

Если распределения признаков X_i и X_j подчиняются нормальному распределению, то можно воспользоваться статистикой Фишера

$$F_{\text{расч}} = \frac{r_{X_i X_j}^2}{1 - r_{X_i X_j}^2} (N - 2).$$

Если гипотеза H_0 верна, то статистика $F_{\text{расч}}$ подчиняется распределению Фишера с $v_1 = 1$ и $v_2 = N - 2$ степенями свободы, выполняется условие для критических значений

$$F_{v_1, v_2, 1-\alpha/2}^{\text{табл}} < F_{\text{расч}} < F_{v_1, v_2, \alpha/2}^{\text{табл}}.$$

Пример. Требуется определить значимость коэффициента корреляции $r = -0,5$ и $N = 6$.

$$F_{\text{расч}} = \frac{(-0,5)^2}{1 - (-0,5)^2} \cdot (6 - 2) = \frac{0,25}{0,75} \cdot 4 \approx 1,33.$$

Из таблицы распределения Фишера находим критические точки для $v_1 = 1$ и $v_2 = N - 2$, $\alpha = 0,1$:

$$F_{v_1=1, v_2=4, 1-\alpha/2}^{\text{табл}} = 0,0045 < F_{\text{расч}} = 1,33 < F_{v_1=1, v_2=4, \alpha/2}^{\text{табл}} = 7,71.$$

Гипотеза H_0 принимается – различия значимы между признаками X_i и X_j . Линейной корреляции нет.

Для определения значимости также можно использовать статистику Стьюдента. Вводится статистика

$$t_{\text{расч}} = \sqrt{F}.$$

Если гипотеза верна, то статистика подчиняется распределению Стьюдента с $v = N - 2$ степенями свободы. Ввиду симметрии распределения Стьюдента можно ограничиться рассмотрением односторонней критической области для критерия ($P(|t_{\text{расч}}| \geq t_{v=N-2, \alpha/2}) = \alpha/2$). Таким образом, критерий для проверки нулевой гипотезы

$$H_0, \text{ если } |t_{\text{расч}}| < t_{v, \alpha/2}^{\text{табл}},$$

$$H_1, \text{ если } |t_{\text{расч}}| \geq t_{v, \alpha/2}^{\text{табл}}.$$

Пример. Требуется определить значимость коэффициента корреляции $r = -0,5$ и $N = 6$.

$$|t_{\text{расч}}| = |\sqrt{F_{\text{расч}}}| = |\sqrt{1,33}| = 1,15.$$

Из таблицы распределения Стьюдента находим критические точку для $\nu = 4$ и $\alpha = 0,1$:

$$|t_{\text{расч}}| = 1.15 < t_{\nu=4, \alpha/2=0.05}^{\text{табл}} = 2,13.$$

Гипотеза H_0 принимается – различия значимы, линейная связь между признаками X_i и X_j отсутствует.

На практике задача корреляционного анализа решается в 2 этапа:

1. Вычисляются парные коэффициенты корреляции между всеми признаками.

2. Проверяется значимость оценок коэффициентов корреляции. Незначимые оценки приравниваются 0.

По результатам проверки делается вывод о наличии линейных связей между признаками исследуемых объектов.

Пример. Результаты наблюдений за характеристиками канала передачи представлены в таблице 5. Предполагается, что выборки по всем вариантам X_1 - X_5 подчиняются нормальному закону распределения. Необходимо определить наличие линейных корреляционных связей между пропускной способностью канала и остальными факторами.

Таблица 5 – Результаты наблюдений за характеристиками канала передачи.

№	Пропускная способность канала (кбит/с)	Соотношение сигнал/шум (дБ)	Остаточное затухание (дБ) на частоте (Гц)		
			1020	1800	2400
	X_1	X_2	X_3	X_4	X_5
1	26,37	41,98	17,66	16,05	22,85
2	28,00	43,83	17,15	15,47	23,25
3	27,83	42,83	15,38	17,59	24,55
4	31,67	47,28	18,39	16,92	26,59
5	23,50	38,75	18,32	15,66	26,22
6	21,04	35,12	17,81	17,00	27,52
7	16,94	32,07	21,42	16,77	25,76
8	37,56	54,25	26,42	15,68	23,10
9	18,84	32,70	17,23	15,92	23,41
10	25,77	40,51	30,43	15,29	25,17
11	33,52	49,78	21,71	15,61	25,39
12	28,21	43,84	28,33	15,70	24,56
13	28,76	44,03	30,42	16,87	24,45
14	24,60	39,46	21,66	15,25	23,81
15	24,51	38,78	25,77	16,05	24,48

Проверку гипотезы о значимости оценок коэффициентов корреляции произведем с уровнем значимости $\alpha = 0,1$.

На первом этапе выполняется стандартизация по колонкам исходной матрицы данных (таблице 6).

Таблица 6 – Результаты выполнения стандартизации исходных данных.

№	Пропускная способность канала (кбит/с)	Соотношение сигнал/шум (дБ)	Остаточное затухание (дБ) на частоте (Гц)		
			1020	1800	2400
	X_1	X_2	X_3	X_4	X_5
1	-0,02	0,05	-0,82	-0,10	-1,38
2	0,28	0,36	-0,92	-0,90	-1,09
3	0,25	0,19	-1,26	2,03	-0,14
4	0,96	0,93	-0,68	1,10	1,35
5	-0,55	-0,49	-0,69	-0,64	1,08
6	-1,01	-1,09	-0,79	1,21	2,03
7	-1,77	-1,59	-0,09	0,90	0,74
8	2,06	2,08	0,89	-0,61	-1,20
9	-1,42	-1,49	-0,90	-0,28	-0,97
10	-0,13	-0,19	1,67	-1,15	0,31
11	1,31	1,34	-0,03	-0,71	0,47
12	0,32	0,36	1,26	-0,58	-0,13
13	0,42	0,39	1,66	1,03	-0,21
14	-0,35	-0,37	-0,04	-1,21	-0,68
15	-0,36	-0,48	0,76	-0,10	-0,19

Далее производится вычисление парных коэффициентов корреляции и проверка их значимости (таблица 7).

Таблица 7 – Результаты корреляционного анализа.

	X_2	X_3	X_4	X_5
r_{1j}	0,93	0,25	-0,13	-0,22
t	9,12	0,93	0,47	0,81

Критическое значение $t_{кр} (N - 2; \alpha/2) = t_{кр}(13, 0,05) = 1,77$. Статистика критерия больше критического значения только для r_{12} . Остальные коэффициенты корреляции следует признать равными нулю.

Пусть r_{ij} – коэффициент корреляции между признаками X_i и X_j . Тогда определим корреляционную матрицу R исходных данных как

$$R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1K} \\ r_{21} & 1 & \dots & r_{2K} \\ \dots & \dots & \dots & \dots \\ r_{K1} & r_{K2} & \dots & 1 \end{bmatrix}.$$

Используя матрицу R , можно оценить коэффициент корреляции между признаком X_j и остальными признаками $X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_K$

$$R_{j0} = \left(1 - \frac{|R|}{|R_{jj}|} \right)^{\frac{1}{2}},$$

где $|R|$ – определитель матрицы R ; $|R_{jj}|$ – определитель минора R_{jj} матрицы R . Значимость коэффициента корреляции между признаком X_j и остальными признаками $X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_K$ определяется по критерию Фишера:

$$F_{\text{расч}} = \frac{R_{j0}^2}{1 - R_{j0}^2} \frac{(N - K)}{(K - 1)}.$$

Если гипотеза H_0 верна, то статистика $F_{\text{расч}}$ подчиняется распределению Фишера с $v_1 = K - 1$ и $v_2 = N - K$ степенями свободы.

Следует отметить, что: 1) корреляционная зависимость не обязательно устанавливается между двумя признаками X_i и X_j ; 2) наличие корреляции между двумя признаками X_i и X_j не всегда свидетельствует об их взаимосвязи (например, признаки X_i и X_j линейно не зависят друг от друга, а зависят от некоторого случайного фактора ξ , но эта зависимость не обнаружена); 3) коэффициент корреляции Пирсона не применим для негауссовых данных и при наличии выбросов в данных.

1.3.2. Ранговая корреляция

Ранговые коэффициенты корреляции используются в случае, когда корреляционный коэффициент Пирсона не применим. Например, когда признаки не подчиняются нормальному закону распределения, а также в случае наличия выбросов в данных. На практике чаще всего используются критерии Спирмена и Кендэла.

Критерий Спирмена. Коэффициент корреляции рангов, или Спирмена, относится к непараметрическим показателям связи между переменными, измеренными в ранговой шкале (ранг – порядковый номер элемента выборки в ряду, построенном в результате выполнения сортировки элементов выборки по возрастанию). При расчете коэффициента не требуется каких-либо предположений о характере распределений признаков в генеральной совокупности. Коэффициент Спирмена определяет степень тесноты связи порядковых признаков, которые в данном случае представляют собой ранги сравниваемых величин.

Пусть заданы две выборки негауссовых случайных величин X и Y :

$$\begin{Bmatrix} X \\ Y \end{Bmatrix} = \begin{Bmatrix} x_1 & x_2 & \dots & x_N \\ y_1 & y_2 & \dots & y_N \end{Bmatrix}.$$

Рассмотрим основные этапы построения статистики критерия Спирмена.

На первом этапе требуется заменить значения элементов выборок X и Y их рангами:

$$\begin{Bmatrix} X \\ Y \end{Bmatrix} = \begin{Bmatrix} Rng(x_1) & Rng(x_2) & \dots & Rng(x_N) \\ Rng(y_1) & Rng(y_2) & \dots & Rng(y_N) \end{Bmatrix}.$$

Затем необходимо вычислить модуль разности между рангами D и квадрат разности рангов D^2 для каждой колонки:

$$\begin{Bmatrix} D \\ D^2 \end{Bmatrix} = \begin{Bmatrix} |Rng(x_1) - Rng(y_1)| & \dots & |Rng(x_N) - Rng(y_N)| \\ |Rng(x_1) - Rng(y_1)|^2 & \dots & |Rng(x_N) - Rng(y_N)|^2 \end{Bmatrix}.$$

Статистикой критерия Спирмена служит выборочный коэффициент корреляции ранговых наборов $Rng(x_1), Rng(x_2), \dots, Rng(x_N)$ и $Rng(y_1), Rng(y_2), \dots, Rng(y_N)$

$$\rho = 1 - \frac{6 \sum_{i=1}^N D_i^2}{N(N^2 - 1)}.$$

Величина коэффициента корреляции Спирмена также лежит в интервале $[-1; +1]$. Коэффициент корреляции Спирмена, как и коэффициент Пирсона, может быть положительным и отрицательным, характеризуя направленность связи между двумя признаками, измеренными в ранговой шкале. $\rho = 1$ – полное соответствие наборов рангов, $\rho = -1$ – полностью противоположные наборы рангов.

Для проверки гипотезы о значимости коэффициента корреляции Спирмена ($H_0: \rho_{X_i X_j} = 0, H_1: \rho_{X_i X_j} \neq 0$) используется таблица распределения коэффициента Спирмена с числом степеней свободы $\nu = N$. Ввиду симметрии распределения коэффициента корреляции Спирмена можно ограничиться рассмотрением односторонней критической области для критерия ($P(|\rho_{расч}| \geq \rho_{\nu=N, \alpha/2}) = \alpha/2$). Тогда

$$H_0, \text{ если } |\rho_{расч}| < \rho_{\nu, \alpha/2}^{табл},$$

$$H_1, \text{ если } |\rho_{расч}| \geq \rho_{\nu, \alpha/2}^{табл}.$$

Пример. Вычислить корреляцию по критерию Спирмена между наборами данных

$$\begin{Bmatrix} X \\ Y \end{Bmatrix} = \begin{Bmatrix} 5 & 9 & 17 & 1 & 2 & 21 & 3 & 29 & 7 & 100 \\ 6 & 16 & 18 & 1 & 3 & 21 & 7 & 20 & 15 & 22 \end{Bmatrix}.$$

Заменим значения элементов X и Y их рангами:

$$\begin{Bmatrix} X \\ Y \end{Bmatrix} = \begin{Bmatrix} 4 & 6 & 7 & 1 & 2 & 8 & 3 & 9 & 5 & 10 \\ 3 & 6 & 7 & 1 & 2 & 9 & 4 & 8 & 5 & 10 \end{Bmatrix}.$$

Вычислим модуль разности рангов D и квадрат разности рангов D^2 для каждой колонки:

$$\begin{Bmatrix} D \\ D^2 \end{Bmatrix} = \begin{Bmatrix} 1 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 & 0 \end{Bmatrix}.$$

Рассчитаем статистику Спирмена

$$\rho_{расч} = 1 - \frac{6 \sum D^2}{N(N^2 - 1)} = 1 - \frac{6 \cdot 4}{10 \cdot (10^2 - 1)} = 0,976.$$

Критическое значение $\rho_{кр}(N = 10, \alpha/2 = 0,05) = 0,56$. Статистика критерия больше критического значения. Гипотеза H_0 не принимается. Наличие линейной корреляции между наборами данных X и Y подтверждается.

Критерий Кендэла. Корреляционный ранговый коэффициент Кендэла является более универсальным и чувствительным к данным, чем коэффициент Спирмена.

Как и в критерии Спирмена, строятся ранги наборов данных $x_1, x_2, \dots, x_N$ и $y_1, y_2, \dots, y_N$. Однако вместо модуля разности рангов считаются количества согласованных и несогласованных пар колонок данных $\begin{pmatrix} Rng(x_i) \\ Rng(y_i) \end{pmatrix}$ и

$\begin{pmatrix} Rng(x_j) \\ Rng(y_j) \end{pmatrix}$. Пара $\begin{pmatrix} Rng(x_i) \\ Rng(y_i) \end{pmatrix}$ и $\begin{pmatrix} Rng(x_j) \\ Rng(y_j) \end{pmatrix}$ является *согласованной*, если

$$\begin{pmatrix} Rng(x_i) > Rng(x_j) \\ Rng(y_i) > Rng(y_j) \end{pmatrix} \text{ или } \begin{pmatrix} Rng(x_i) < Rng(x_j) \\ Rng(y_i) < Rng(y_j) \end{pmatrix}.$$

Пара $\begin{pmatrix} Rng(x_i) \\ Rng(y_i) \end{pmatrix}$ и $\begin{pmatrix} Rng(x_j) \\ Rng(y_j) \end{pmatrix}$ является *несогласованной*, если

$$\begin{pmatrix} Rng(x_i) > Rng(x_j) \\ Rng(y_i) < Rng(y_j) \end{pmatrix} \text{ или } \begin{pmatrix} Rng(x_i) < Rng(x_j) \\ Rng(y_i) > Rng(y_j) \end{pmatrix}.$$

Вычисляется количество совпадающих C и несовпадающих пар B по всем возможным комбинациям $x_i - x_j$ и $y_i - y_j$. Статистика Кендэла

$$\tau = \frac{2(C - B)}{N(N - 1)}.$$

Статистика Кендэла представляет собой отношение превышения согласованности над несогласованностью к максимальному количеству возможных пар колонок $N(N - 1)/2$. Коэффициент Кендэла τ характеризует число совпадающих и несовпадающих пар. $\tau = 1$ – если все пары согласованны, т. е. $B = 0$ и

$$C = C_N^2 = \frac{N!}{(N-2)!2!} = \frac{N(N-1)}{2}.$$

$\tau = -1$ – если все пары не согласованны, т.е. $C = 0$ и

$$B = C_N^2 = \frac{N!}{(N-2)!2!} = \frac{N(N-1)}{2}.$$

Для проверки значимости при $N \rightarrow \infty$ можно использовать статистику Стьюдента. Вводится статистика

$$t_{\text{расч}} = \frac{\tau}{\sqrt{\frac{2(2N+5)}{9N(N-1)}}}. \quad (1)$$

В знаменателе формулы (1) располагается среднеквадратическое отклонение коэффициента Кендэла τ . Из таблицы распределения Стьюдента находим критические точки для $v = \infty$ и заданного уровня значимости α . Тогда критерий проверки гипотезы о наличии корреляционной связи

$$H_0, \text{ если } |t_{\text{расч}}| < t_{v=\infty, \alpha/2}^{\text{табл}}$$

$$H_1, \text{ если } |t_{\text{расч}}| \geq t_{v=\infty, \alpha/2}^{\text{табл}}.$$

1.3.3. Множественная и частная корреляции

Множественная корреляция. Решим задачу нахождения линейной корреляции между более чем двумя выборками ($K > 2$). Кендэл предложил использовать ранговый коэффициент совпадения (или конкордации)

$$w = \frac{12}{K^2(N^3 - N)} \sum_{i=1}^N \left(\sum_{j=1}^K R_{ij} - \frac{K(N+1)}{2} \right)^2,$$

где R_{ij} – ранг i -го элемента в j -й выборке.

Рассмотрим основные свойства множественного коэффициента корреляции Кендэла:

1. $0 \leq w \leq 1$, $w = 1$, когда все ранжировки совпадают.

2. Коэффициент w и среднее арифметическое коэффициента Спирмена $\langle \rho \rangle$, вычисленное по всем парам выборки, линейно связаны: $w = [(K-1) \langle \rho \rangle + 1]/K$.

3. При больших N статистика $K(N-1)w$ распределена по закону χ^2 с $(N-1)$ степенями свободы. (Нулевая гипотеза H_0 : $w = 0$, т. е. случайная величина $K(N-1)w$ распределена по χ^2 с $(N-1)$, $\chi^2_{\text{расч}} \leq \chi^2_{v, \alpha}$, H_1 : $w > 0$, тогда $K(N-1)w > \chi^2_{v, \alpha}$).

Частная корреляция. Частным коэффициентом корреляции между случайными величинами X и Y , при исключении влияния случайной величины Z является

$$r_{XY|Z} = \frac{r_{XY} - r_{XZ}r_{YZ}}{\sqrt{(1-r_{XZ}^2)(1-r_{YZ}^2)}}.$$

Если случайные величины X, Y, Z распределены по независимым нормальным законам, то для больших N статистика $N^{1/2} \arctg r_{XYZ}$ распределена по стандартному нормальному закону $N(0,1)$.

В заключение следует отметить, что ранговый коэффициент Кендэла переносится на случай частной корреляции с помощью аналогичной формулы

$$\tau_{XY|Z} = \frac{\tau_{XY} - \tau_{XZ}\tau_{YZ}}{\sqrt{(1-\tau_{XZ}^2)(1-\tau_{YZ}^2)}}.$$

1.4. Регрессионный анализ

1.4.1. Регрессия

Термин «регрессия» ввел Ф. Гамильтон в 1885 г. в работе «Регрессия к середине в наследовании роста», где он сравнивал средний рост детей со средним ростом их родителей. Гамильтон заметил, что рост детей у высоких (низких) родителей обычно также выше (ниже) среднего по популяции, но при этом отклонение от среднего у детей меньше, чем у родителей.

В настоящее время под регрессией понимают зависимость среднего значения какой-либо величины от другой или других величин.

Рассмотрим основную идею регрессии на примере подгонки прямой под облако экспериментальных точек $(x_i, y_i), i = 1, 2, \dots, N$ (рисунок 9).

Регрессионная модель задается выражением

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad (2)$$

где ε_i – остаток или ошибка аппроксимации в точке $x_i, i = 1, 2, \dots, N$. Единственным условием точности подгонки прямой (2) является близость к нулю всех остатков $\varepsilon_i, i = 1, 2, \dots, N$.




Рисунок 9 – Подгонка прямой под облако экспериментальных точек.

Наиболее простые формулы для оценок параметров прямой регрессии $\hat{\alpha}$ и $\hat{\beta}$ получаются, если в качестве меры оценки точности взять сумму квадратов остатков:

$$q = \sum_{i=1}^N \varepsilon_i^2 = \sum_{i=1}^N (y_i - \alpha - \beta x_i)^2.$$

Тогда оценки $\hat{\alpha}$ и $\hat{\beta}$ определяются по методу наименьших квадратов:

$$\begin{cases} \hat{\beta} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} \\ \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \end{cases}.$$

Пусть выполняется анализ некоторого набора данных $n_1, n_2, \dots, n_N$, полученных из базы данных или эксперимента. Значения выходного параметра Y

известны и представляют собой множество действительных чисел. Предположим, что матрица результатов наблюдений $X = \{X_1, X_2, \dots, X_K\}$ является единственной информацией об изучаемых объектах, имеющейся в распоряжении исследователя. Данная матрица содержит некоторые ошибки (помехи или шум), обусловленные погрешностями измерений, влиянием неучтенных случайных факторов и т. д. Задача регрессии состоит в определении по известным характеристикам объекта n_i значения его выходного параметра y_i .

1.4.2. Регрессионный анализ

В регрессионном анализе требуется установить функциональную взаимосвязь между выходной характеристикой Y и признаками $X_1, X_2, \dots, X_K$, которая наилучшим способом описывала бы экспериментальные данные

$$Y = f(B, X_1, X_2, \dots, X_K) + E,$$

где E – ошибка аппроксимации экспериментальных данных; $B = \{\beta_1, \beta_2, \dots, \beta_k\}^T$ – набор некоторых параметров (не)линейной функциональной зависимости ($k \leq K$); f – функция или уравнение регрессии. Стоит отметить, что в качестве выходной характеристики системы Y можно взять один из признаков X_j и искать функциональный вид его связи с остальными признаками.

Регрессионный анализ – это совокупность методов построения и исследования регрессионной зависимости между величинами Y и $X_1, X_2, \dots, X_K$ по статистическим данным.

Задача регрессионного анализа решается в 4 этапа:

Этап 1. Стандартизация матрицы входных данных.

Этап 2. Выбор вида уравнения регрессии.

Этап 3. Вычисление коэффициентов уравнения регрессии.

Этап 4. Оценка значимости коэффициентов регрессии и проверка адекватности построенной регрессионной модели.

Линейная регрессия. Рассмотрим более подробно задачу линейного регрессионного анализа. Предположим, что с точностью до случайных ошибок зависимая переменная Y есть линейная комбинация $\beta_1 X_1 + \beta_2 X_2 + \dots + \beta_K X_K$ независимых признаков $X_1, X_2, \dots, X_K$ с неизвестными коэффициентами $\beta_1, \beta_2, \dots, \beta_K$. Тогда измерения $y_i, i = 1, 2, \dots, N$, по переменной Y , имеют вид

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i. \quad (3)$$

Запишем систему уравнений (3) или общую модель линейной регрессии в матричном виде

$$Y = XB + E,$$

где

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_N \end{bmatrix}, \quad B = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_K \end{bmatrix}, \quad X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ \dots & \dots & \dots & \dots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix}, \quad E = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_N \end{bmatrix}.$$

X – называется матрицей плана эксперимента. Будем полагать, что столбцы матрицы X – линейно-независимы, а ошибки ε_i независимы и имеют нормальное распределение $N(0, \sigma^2)$, т. е. $M[\varepsilon_i] = 0$; $D[\varepsilon_i] = \sigma^2 = \text{const}$; $M[\varepsilon_i \cdot \varepsilon_j] = 0$; при $i \neq j$.

Задача линейного регрессионного анализа состоит в нахождении вектора неизвестных коэффициентов B . Вектор необходимо выбрать таким образом, чтобы обеспечить минимум ошибки аппроксимации экспериментальных данных. Используются различные меры для оценки ошибки аппроксимации (максимальная ошибка ε_i , сумма модулей ε_i и т. д.). Наибольшее распространение в качестве такой меры получила среднеквадратическая ошибка или сумма квадратов отклонений

$$q = \sum_{i=1}^N \varepsilon_i^2.$$

В матричном виде

$$Q = E^T E,$$

где T – оператор транспонирования. На основе остаточной суммы квадратов отклонений разработан специальный метод оценки коэффициентов уравнений регрессии – метод наименьших квадратов (МНК). МНК позволяет получить оценки правдоподобия неизвестных коэффициентов уравнений регрессии при нормальном распределении признаков $X_1, X_2, \dots, X_K$.

Оценим параметры регрессионной модели B по МНК. Выразим матрицу ошибок аппроксимации как

$$E = Y - XB.$$

Тогда остаточная сумма квадратов отклонений есть

$$Q = E^T E = (Y - XB)^T (Y - XB) = Y^T Y - Y^T X B - (XB)^T Y + (XB)^T X B.$$

Воспользуемся выражениями из матричной алгебры $(AB)^T = B^T A^T$, тогда

$$Q = Y^T Y - Y^T X B - B^T X^T Y + B^T X^T X B.$$

Вычислим и приравняем к нулю частные производные от Q по неизвестным коэффициентам B :

$$\begin{aligned} \frac{\partial(Y^T Y)}{\partial B} &= 0, \\ \frac{\partial(Y^T X B)}{\partial B} &= \frac{\partial((X^T Y)^T B)}{\partial B} = \left[\frac{\partial(A^T B)}{\partial B} = A \right] = X^T Y, \\ \frac{\partial(B^T X^T Y)}{\partial B} &= \frac{\partial(B^T (X^T Y))}{\partial B} = \left[\frac{\partial(B^T A)}{\partial B} = A \right] = X^T Y, \\ \frac{\partial(B^T X^T X B)}{\partial B} &= \frac{\partial(B^T (X^T X) B)}{\partial B} = \left[\frac{\partial(B^T A B)}{\partial B} = 2AB \right] = 2(X^T X)B, \\ \frac{\partial Q}{\partial B} &= -2X^T Y + 2X^T X B = 0. \end{aligned}$$

Откуда оценка неизвестных коэффициентов в матричном виде есть

$$\hat{B} = (X^T X)^{-1} X^T Y.$$

Точка минимума $\hat{B}$ называется МНК-оценкой. Матрица $X^T X$ является определяющей и несет в себе основную информацию.

Определим ошибку в оцененных коэффициентах регрессии $\hat{B}$. Для этого воспользуемся одним из основных свойств МНК-оценок

$$\text{cov}\{\hat{B}\} = \sigma^2 (X^T X)^{-1},$$

где

$$\sigma^2 = D[\varepsilon_i] = S_{\text{ост}}^2 = \frac{(Y - X\hat{B})^T (Y - X\hat{B})}{N - K},$$

$S_{\text{ост}}^2$ – остаточная суммы квадратов отклонений (ошибок), нормированная на число степеней свободы $N - K$ (здесь K – число параметров линейной модели), характеризует уровень отклонения реальных значений от линейной модели.

Матрицу ковариации оценок коэффициентов можно записать в следующем виде:

$$\text{cov}\{\hat{B}\} = \begin{bmatrix} S^2(\beta_1) & \text{cov}\{\beta_1, \beta_2\} & \dots & \text{cov}\{\beta_1, \beta_K\} \\ \text{cov}\{\beta_2, \beta_1\} & S^2(\beta_2) & \dots & \text{cov}\{\beta_2, \beta_K\} \\ \dots & \dots & \dots & \dots \\ \text{cov}\{\beta_K, \beta_1\} & \text{cov}\{\beta_K, \beta_2\} & \dots & S^2(\beta_K) \end{bmatrix},$$

где $S^2(\beta_j)$ – оценка выборочной дисперсии по параметру β_j , $j = 1, 2, \dots, K$. Необходимо определить диагональные элементы ковариационной матрицы, которые являются оценками выборочной дисперсии ошибки коэффициентов линейной регрессии.

Рассмотрим подробнее матрицу $X^T X$.

$$\begin{aligned} X^T X &= \begin{bmatrix} x_{11} & x_{21} & \dots & x_{N1} \\ x_{12} & x_{22} & \dots & x_{N2} \\ \dots & \dots & \dots & \dots \\ x_{1K} & x_{2K} & \dots & x_{NK} \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ \dots & \dots & \dots & \dots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix} = \\ &= \begin{bmatrix} \sum_{i=1}^N x_{i1}^2 & \sum_{i=1}^N x_{i1}x_{i2} & \dots & \sum_{i=1}^N x_{i1}x_{iK} \\ \sum_{i=1}^N x_{i2}x_{i1} & \sum_{i=1}^N x_{i2}^2 & \dots & \dots \\ \dots & \dots & \dots & \dots \\ \sum_{i=1}^N x_{iK}x_{i1} & \dots & \dots & \sum_{i=1}^N x_{iK}^2 \end{bmatrix}. \end{aligned}$$

Перейдем от абсолютных значений к нормированным величинам матрицы X , т. е. выполним стандартизацию исходных данных. Воспользуемся преобразованием

$$x'_{ij} = \frac{x_{ij} - \bar{X}_j}{S_{X_j}}, i = 1, 2, \dots, N, j = 1, 2, \dots, K,$$

где

$$\bar{X}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}, S_{X_j} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_{ij} - \bar{X}_j)^2}.$$

В этом случае, диагональные элементы матрицы $X^T X$ есть

$$\begin{aligned} \sum_{i=1}^N x'^2_{ij} &= \sum_{i=1}^N \frac{(x_{ij} - \bar{X}_j)^2}{S_{X_j}^2} = \frac{N}{N} \sum_{i=1}^N \frac{(x_{ij} - \bar{X}_j)^2}{S_{X_j}^2} = \\ &= \left[\frac{1}{N} \sum_{i=1}^N \frac{(x_{ij} - \bar{X}_j)(x_{ij} - \bar{X}_j)}{S_{X_j} S_{X_j}} = r = 1 \right] = N. \end{aligned}$$

Недиагональные элементы матрицы $X^T X$ –

$$\begin{aligned} \sum_{i=1}^N x'_{ij} x'_{iu} &= \sum_{i=1}^N \frac{(x_{ij} - \bar{X}_j)(x_{iu} - \bar{X}_u)}{S_{X_j} S_{X_u}} = \\ &= \frac{N}{N} \sum_{i=1}^N \frac{(x_{ij} - \bar{X}_j)(x_{iu} - \bar{X}_u)}{S_{X_j} S_{X_u}} = N r_{ju}. \end{aligned}$$

Тогда стандартизированная матрица

$$X'^T X' = \begin{bmatrix} N & Nr_{12} & \dots & Nr_{1K} \\ Nr_{21} & N & \dots & Nr_{2K} \\ \dots & \dots & \dots & \dots \\ Nr_{K1} & Nr_{K2} & \dots & N \end{bmatrix}.$$

Нормируем матрицу $X'^T X'$ на N

$$M = \frac{X'^T X'}{N} = \begin{bmatrix} 1 & r_{12} & \dots & r_{1K} \\ r_{21} & 1 & \dots & r_{2K} \\ \dots & \dots & \dots & \dots \\ r_{K1} & r_{K2} & \dots & 1 \end{bmatrix}.$$

Матрица $X'^T X'$ называется *информационной*. Она является положительно-определенной и невырожденной.

Выразим матрицу ковариаций B следующим образом

$$\text{cov}\{\hat{B}\} = \sigma^2 (X'^T X')^{-1} = \frac{S_{\text{ост}}^2}{N} M^{-1}.$$

Откуда получим оценки диагональных элементов для ковариационной матрицы МНК-оценок $\hat{B}$

$$S^2(\hat{\beta}_j) = \frac{S_{\text{ост}}^2}{N} \frac{|M_{jj}|}{|M|} = \frac{S_{\text{ост}}^2}{N(1-R_{j0}^2)}, j = 1, 2, \dots, K,$$

где $|M|$ – определитель матрицы M ; $|M_{jj}|$ – определитель минора M_{jj} матрицы M ; R_{j0} – коэффициент корреляции между признаком X_j и остальными признаками $X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_K$. При $R_{j0} \rightarrow 1$ дисперсия оценки j -го коэффициента $S^2(\hat{\beta}_j) \rightarrow \infty$, т. е. коррелированные признаки информации не несут, а только «зашумляют» данные.

Определение значимости коэффициентов регрессии. Если оценки коэффициентов регрессии $\hat{\beta}_j, j = 1, 2, \dots, K$, подчиняются нормальному закону распределения, то мы можем воспользоваться критерием Стьюдента (фактически о равенстве коэффициента нулю).

Для каждого коэффициента $\beta_j, j = 1, 2, \dots, K$, выдвигаем гипотезы: $H_0: \beta_j = 0$; $H_1: \beta_j \neq 0$. Если гипотеза верна, то отношение оценки $\hat{\beta}_j$ к его среднеквадратическому отклонению должно подчиняться распределению Стьюдента с $v = (N - K)$ степенями свободы.

Вводится статистика

$$t_{\text{расч},j} = \frac{\hat{\beta}_j}{S_{\text{ост}}} \sqrt{N(1-R_{j0}^2)}.$$

Таким образом, критерий

$$H_0, \text{ если } |t_{\text{расч},j}| < t_{v,\alpha/2}^{\text{табл}},$$

$$H_1, \text{ если } |t_{\text{расч},j}| \geq t_{v,\alpha/2}^{\text{табл}}.$$

Замечание. На практике в программах типа Excel также приводится p -величина, представляющее собой вероятность того, что случайная величина, имеющая распределение Стьюдента, примет значение не меньше по абсолютной величине, чем наблюдаемое. Если $p > \alpha$, то H_0 гипотеза принимается.

Проверка точности регрессионной модели. Для оценки точности модели можно использовать критерий Фишера о проверке дисперсий. Вводится сумма квадратов разностей регрессионных значений с их средним

$$SS_{\text{пер}}^2 = \sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2,$$

где $\hat{y}_i = \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_K x_{iK}$ (рисунок 10).

Проверяется гипотеза: $H_0: \sigma_{\text{пер}}^2 = \sigma^2$ – модель не значима (не адекватная); $H_1: \sigma_{\text{пер}}^2 > \sigma^2$ – модель точная (адекватная). Вводится статистика




Рисунок 10.

$$F_{\text{расч}} = \frac{SS_{\text{рег}}^2 / K}{S_{\text{ост}}^2}.$$

Если гипотеза H_0 верна, то статистика $F_{\text{расч}}$ подчиняется распределению Фишера с $\nu_1 = K$ и $\nu_2 = N - K$: H_0 , если $F_{\text{расч}} < F_{\nu_1, \nu_2, \alpha}^{\text{табл}}$. В этом случае модель не принимается. Чем больше отношение $F_{\text{расч}}$, тем больше есть оснований полагать, что совокупность переменных $X_1, X_2, \dots, X_K$ действительно объясняет изменчивость Y .

Общие рекомендации, которые необходимо учитывать в ходе линейного регрессионного анализа. Существенно исказить результаты могут: 1) данные (наличие выбросов, аномальные значения, изменение разброса в данных, в последнем случае задача решается с помощью взвешенного МНК); 2) коррелированность признаков (необходимо выполнить на предварительном этапе корреляционный анализ и исключить коррелируемые признаки); 3) неадекватность линейной модели (используется нелинейная модель регрессии и нелинейный МНК).

Нелинейная регрессия. В общем случае уравнение нелинейной регрессии решается нелинейным МНК с использованием методов оптимизации. Выражение для матрицы ошибок аппроксимации

$$Q = E^T E = (Y - \Phi(A, X_1, X_2, \dots, X_K))^T (Y - \Phi(A, X_1, X_2, \dots, X_K)).$$

Необходимо определить нелинейную функцию Φ и набор ее параметров A , при которых бы достигался минимум Q . Оценки ошибок в полученных параметрах определяются с помощью методов оценки доверительных интервалов, таких как методы Монте-Карло, стандартных асимптотических ошибок, исчерпывающего поиска (exhaustive search).

1.5. Методы снижения размерности данных

Методы снижения размерности используются для сжатия многомерных данных без потери сущности данных или информации, хранящихся в данных.

Основные задачи, решаемые с помощью методов снижения размерности:

1. Визуализация данных (наглядность представления).
2. Сжатие информации (сжатие объемов хранения данных, исключение дублирующейся информации, шума).
3. Исключение неинформативных данных (подразумевает лаконизм исследуемых данных, выделение основных факторов).
4. Определение связи между наблюдаемыми и скрытыми переменными (или факторами).

К методам снижения размерностей данных относятся методы главных и независимых компонент, факторный анализ, нелинейные методы понижения размерности данных. Рассмотрим подробно метод главных компонент.

Пусть выполняется анализ некоторого набора многомерных данных $(n_1, n_2, \dots, n_N)$, полученных из базы данных или эксперимента. Каждый из рассматриваемых объектов $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$, $i = 1, 2, \dots, N$, характеризуется набором из K признаков $X_1, X_2, \dots, X_K$. Каждый из признаков, т. е. набор

данных, расположенный в колонке таблицы, подчиняется нормальному закону распределения.

Рассмотрим матрицу входных данных в виде

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ \dots & \dots & \dots & \dots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix}.$$

Идея метода главных компонент состоит в учете корреляционной связи между признаками $X_1, X_2, \dots, X_K$, на основе которой можно совершить переход в пространство новых переменных $Z_1, Z_2, \dots, Z_K$. Компонента Z_1 представляет собой линейную комбинацию признаков $X_1, X_2, \dots, X_K$ таких, что дисперсия по данной компоненте максимальна из всех возможных комбинаций. Компонента Z_2 выбирается из условия, что дисперсия по данной компоненте максимальна из всех оставшихся линейных и некоррелированных комбинаций $X_1, X_2, \dots, X_K$. И так далее для компонент $Z_3, Z_4, \dots, Z_K$. Необходимо осуществить переход в новое пространство признаков таким образом, чтобы суммы дисперсий были равны в исходном $X_1, X_2, \dots, X_K$ и новом $Z_1, Z_2, \dots, Z_K$ пространстве признаков (рисунок 11).

Z_1	Z_2	...	Z_K		X_1	X_2	...	X_K
z_{11}	z_{12}	...	z_{1K}	n_1	x_{11}	x_{12}	...	x_{1K}
z_{21}	z_{22}	...	z_{2K}	n_2	x_{21}	x_{22}	...	x_{2K}
.....								
z_{N1}	z_{N2}	...	z_{NK}	n_N	x_{N1}	x_{N2}	...	x_{NK}

$\downarrow \quad \downarrow \quad \quad \downarrow \quad \quad \downarrow \quad \downarrow \quad \downarrow$
 $\sigma^2(Z_1) \geq \sigma^2(Z_2) \geq \dots \geq \sigma^2(Z_K) \quad \sigma^2(X_1) \quad \sigma^2(X_2) \quad \sigma^2(X_K)$

Рисунок 11 – Набор данных в исходном $X_1, X_2, \dots, X_K$ и преобразованном $Z_1, Z_2, \dots, Z_K$ пространстве признаков.

Процедура выделения главных компонент подобна вращению системы координат $X_1, X_2, \dots, X_K$, максимизирующему дисперсию нового признака и минимизирующему разброс вокруг нее.

Пример. Пусть есть N объектов в пространстве двух признаков X_1, X_2 . Необходимо подобрать такое вращение системы координат (X_1, O, X_2) на угол γ , чтобы перейти к новой системе координат (Z_1, O, Z_2) , в которой ось Z_1 направлена вдоль главной оси эллипса рассеяния, а ось Z_2 – вдоль малой оси эллипса (Рисунок :

$$\begin{cases} Z_1 = \alpha_{11}X_1 + \alpha_{21}X_2 \\ Z_2 = \alpha_{12}X_1 + \alpha_{22}X_2 \end{cases}.$$

Или в матричном виде $Z = X \cdot A$, где $X = (X_1, X_2)$, $Z = (Z_1, Z_2)$ и $A = \begin{pmatrix} \cos \gamma & -\sin \gamma \\ \sin \gamma & \cos \gamma \end{pmatrix}$.




Рисунок 12 – Пример перехода от признаков X_1, X_2 к преобразованным признакам Z_1, Z_2 .

Преобразование не затрагивает геометрической структуры взаимного расположения точек объектов. Поэтому суммарная дисперсия расположения объектов остается прежней.

Метод главных компонент требует предварительной стандартизации данных. Стандартизация исходных данных подразумевает выполнение операций центрирования и шкалирования

$$X' = \begin{bmatrix} x'_{11} & x'_{12} & \dots & x'_{1K} \\ x'_{21} & x'_{22} & \dots & x'_{2K} \\ \dots & \dots & \dots & \dots \\ x'_{N1} & x'_{N2} & \dots & x'_{NK} \end{bmatrix}, \quad x'_{ij} = \frac{x_{ij} - \bar{X}_j}{\sigma(X_j)},$$

где $i = 1, 2, \dots, N, j = 1, 2, \dots, K$.

Ковариационная матрица нормированных данных $\text{cov}\{X'\}$ представляет собой корреляционную матрицу R :

$$\text{cov}\{X'\} = \frac{X'^T X'}{N} = R = \begin{bmatrix} 1 & r_{12} & \dots & r_{1K} \\ r_{21} & 1 & \dots & r_{2K} \\ \dots & \dots & \dots & \dots \\ r_{K1} & r_{K2} & \dots & 1 \end{bmatrix}.$$

Важное условие для применимости метода главных компонент – коррелированность признаков $X_1, X_2, \dots, X_K$. Если признаки $X_1, X_2, \dots, X_K$ не коррелируют между собой, то метод главных компонент не работает.

Предположим, что вся структура данных X' может быть преобразована в другие переменные, называемые главными компонентами Z

$$Z_j = a_{1j} X'_1 + a_{2j} X'_2 + \dots + a_{Kj} X'_K, \quad (4)$$

где a_{ij} , $i = 1, 2, \dots, K$ и $j = 1, 2, \dots, K$, называются параметрами загрузки главных компонент. Причем в методе главных компонент переход задается таким образом, чтобы выполнялись следующие условия:

1. Дисперсии разброса проекций объектов на главные компоненты расположены по убыванию:

$$\sigma^2(Z_1) \geq \sigma^2(Z_2) \geq \dots \geq \sigma^2(Z_K).$$

2. Главные компоненты линейно-независимы:

$$\text{cov}(Z) = \frac{Z^T Z}{N} = \begin{pmatrix} \sigma^2(Z_1) & 0 & \dots & 0 \\ 0 & \sigma^2(Z_2) & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma^2(Z_K) \end{pmatrix}.$$

3. Суммы выборочных дисперсий по исходным признакам и главным компонентам равны:

$$\sum_{j=1}^K \sigma^2(Z_j) = \sum_{j=1}^K \sigma^2(X'_j).$$

Таким образом, целью метода главных компонент является определение неизвестных параметров загрузки a_{ij} , $i = 1, 2, \dots, K$ и $j = 1, 2, \dots, K$, преобразования (4).

Задача нахождения главных компонент $Z_1, Z_2, \dots, Z_K$ совпадает с задачей нахождения собственных чисел и собственных векторов корреляционной матрицы R наблюдаемых показателей. Если ее собственные числа $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K$, а единичные собственные векторы $a_j = (a_{1j}, a_{2j}, \dots, a_{Kj})^T$, $j = 1, 2, \dots, K$, отвечают этим числам, то проекции объектов на главные компоненты вычисляются по формуле

$$Z = X'A,$$

где A – матрица собственных векторов a_j ,

$$A = (a_1, a_2, \dots, a_K) = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1K} \\ a_{21} & a_{22} & \dots & a_{2K} \\ \dots & \dots & \dots & \dots \\ a_{K1} & a_{K2} & \dots & a_{KK} \end{pmatrix},$$

$Z = (Z_1, Z_2, \dots, Z_K)$ – матрица всех K главных компонент:

$$Z = (Z_1, Z_2, \dots, Z_K) = \begin{pmatrix} z_{11} & z_{12} & \dots & z_{1K} \\ z_{21} & z_{22} & \dots & z_{2K} \\ \dots & \dots & \dots & \dots \\ z_{N1} & z_{N2} & \dots & z_{NK} \end{pmatrix}.$$

Причем $\sigma^2(Z_j) = \lambda_j$, $j = 1, 2, \dots, K$. Следует отметить, что преобразование A является ортогональным, т. е. $A^T = A^{-1}$, $A^T A = I$, где I – единичная матрица (

$a_j^T a_j = 1, a_i^T a_j = 0, i \neq j$). Собственные значения λ_j матрицы R определяются решением уравнения

$$|R - \lambda I| = 0.$$

Собственные векторы $a_j, j=1, 2, \dots, K$, находятся с помощью решения системы уравнений

$$R a_j = \lambda_j a_j, j = 1, 2, \dots, K,$$

или в общем матричном виде:

$$R A = A \Lambda,$$

где Λ – матрица собственных значений

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \lambda_K \end{pmatrix}.$$

Рассмотрим матрицу ковариации координат объектов в пространстве главных компонент $Z_1, Z_2, \dots, Z_K$:

$$\begin{aligned} \text{cov}\{Z\} &= \frac{Z^T Z}{N} = \frac{(X' A)^T X' A}{N} = \frac{A^T X'^T X' A}{N} = \frac{A^T (X'^T X') A}{N} = \\ &= A^T R A = \left[A^T = A^{-1} \right] = A^{-1} R A = \left[R A = A \Lambda \Rightarrow \Lambda = A^{-1} R A \right] = \Lambda. \end{aligned}$$

Таким образом, матрица ковариаций содержит на главной диагонали собственные значения корреляционной матрицы R такие, что $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K$.

Отметим, что след матрицы при ортогональных преобразованиях не меняется, т. е. $Tr[\Lambda] = Tr[R] = \sum_{j=1}^K \sigma^2(Z_j) = \sum_{j=1}^K \sigma^2(X'_j)$, откуда следует выполнение условия равенства сумм выборочных дисперсий исходных признаков и выборочных дисперсий проекций объектов на главные компоненты.

Несмотря на то, что вместо K признаков получается такое же количество главных компонент, вклад большей части главных компонент в объясняемую дисперсию оказывается небольшим. Исключают из рассмотрения те главные компоненты, вклад которых мал. При помощи M первых (наиболее весомых) главных компонент можно объяснить основную часть суммарной дисперсии в данных.

Отметим другие важные характеристики, используемые в методе главных компонент:

Относительная доля разброса, приходящаяся на j -ую главную компоненту

$$\alpha_j = \frac{\sigma^2(Z_j)}{\sigma^2(Z_1) + \sigma^2(Z_2) + \dots + \sigma^2(Z_K)} = \frac{\lambda_j}{\lambda_1 + \lambda_2 + \dots + \lambda_K}.$$

Относительная доля разброса, приходящаяся на j первых компонент

$$\gamma_j = \frac{\sigma^2(Z_1) + \sigma^2(Z_2) + \dots + \sigma^2(Z_j)}{\sigma^2(Z_1) + \sigma^2(Z_2) + \dots + \sigma^2(Z_K)} = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_j}{\lambda_1 + \lambda_2 + \dots + \lambda_K}.$$

На практике в ходе решения задач снижения размерностей данных выбираются первые компонент, так чтобы $\gamma_j \geq 0.90 - 0.95$.

Метод главных компонент позволяет описать большой набор признаков K небольшим числом главных компонент M , $M \ll K$, при этом различия между объектами зависят от доли изменчивости, связанной с данной главной компонентой. Связи между признаками и главными компонентами – линейные.

1.6. Иерархические методы кластерного анализа

1.6.1. Кластерный анализ

Решение задачи разбиения множества элементов без обучения называется *кластерным анализом*. Кластерный анализ не требует априорной информации о данных и позволяет разделить множество исследуемых объектов на группы похожих объектов – *кластеры*. В дальнейшем мы можем анализировать не весь кластер объектов, а только его представителя – объект, имеющий медианные или усредненные значения по независимым переменным. Это дает возможность резко сокращать большие объемы данных, делать их компактными и наглядными. Основные цели кластеризации:

1. Упрощение дальнейшей обработки данных, т. е. разбиение исходного множества объектов на кластеры для работы с каждой группой в отдельности (задачи классификации, регрессии, прогнозирования).
2. Сжатие данных – сокращение объема хранимых данных (оставив по одному представителю от каждого кластера).
3. Выделение нетипичных объектов. Нетипичные объекты – элементы множества, которые не подходят ни к одному из кластеров (задачи одноклассовой классификации, поиск выбросов).
4. Построение иерархии множества объектов.

Задачу кластеризации можно сформулировать следующим образом.

Имеется некоторое конечное множество объектов произвольной природы $C = \{n_1, n_2, \dots, n_N\}$, каждый из которых $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$, $i = 1, 2, \dots, N$, характеризуется набором из K -признаков. Необходимо кластеризовать эти объекты, т. е. разбить их множество на заданное или произвольное количество групп (кластеров или классов) так, чтобы в каждую группу оказались включенными объекты, близкие между собой в том или ином смысле. Априорная информация о классификации объектов при этом отсутствует. Метки классов $y_1, y_2, \dots, y_N$ объектов $n_1, n_2, \dots, n_N$ не известны и должны быть определены в ходе кластерного анализа. Таким образом, необходимо разбить множество векторов C на k попарно непересекающихся классов $C_1, C_2, \dots, C_k$ так, чтобы $\bigcup_{i=1}^k C_i = C$, где $1 < k < N$.

К основным типам кластеров, встречаемым на практике, принадлежат ленточные кластеры, кластеры с центром, кластеры, соединенные

перемычками, кластеры с шумом (кластеры могут накладываться на разреженный фон из редко расположенных объектов), перекрывающиеся кластеры (рисунок 13).




Рисунок 13 – Типы кластеров на примере двумерных наборов данных:

1 – ленточные кластеры; 2 – кластеры с центром; 3 – кластеры, соединенные перемычками; 4 – кластеры на разреженном фоне из редко расположенных объектов; 5 – перекрывающиеся кластеры; 6 – регулярные кластеры; 7 – кластеры различной плотности; 8 – отсутствие кластеров.

Каждый метод кластеризации имеет свои ограничения и выделяет кластеры лишь некоторых типов.

В общем случае кластерный анализ включает два вспомогательных этапа – это предварительная обработка (pre-processing) и пост-обработка данных (post-processing). На этапе предварительной обработки данных производятся нормализация данных и удаление объектов-выбросов. В ходе пост-обработки результатов кластерного анализа осуществляется удаление малых кластеров и кластеров-выбросов, дробление больших кластеров (по заранее определенному критерию), объединение близких кластеров.

Для нахождения определенного решения задачи кластерного анализа необходимо задать: способ сравнения объектов между собой (меру сходства), способ кластеризации, разбиение данных по кластерам (установление числа кластеров).

Выбор способов сравнения, кластеризации и разбиения на кластеры, как правило, не однозначен, часто субъективен и должен быть согласован с задачами кластеризации.

Критерием для определения схожести объектов может являться расстояние между точками объектов на диаграмме рассеяния.

Для сравнения двух объектов n_i и n_j могут быть использованы следующие меры:

Евклидово расстояние:

$$d_2(n_i, n_j) = \left[\sum_{l=1}^K (x_{il} - x_{jl})^2 \right]^{\frac{1}{2}}.$$

Евклидово расстояние используется в случае, если далеко расположенным друг от друга объектам необходимо придать большие веса.

2. Стандартизированное Евклидово расстояние:

$$d(n_i, n_j) = \left[\sum_{l=1}^K \frac{(x_{il} - x_{jl})^2}{\sigma_l^2} \right]^{\frac{1}{2}},$$

где σ_l^2 – дисперсия по l -му признаку. Это расстояние используется в том случае, если необходимо исключить неоднородности по признакам в данных.

3. Метрика города:

$$d_H(n_i, n_j) = \sum_{l=1}^K |x_{il} - x_{jl}|.$$

При использовании данной метрики влияние больших выбросов практически не учитывается.

4. Расстояние Минковского (или степенное):

$$d_{\text{Минк}}(n_i, n_j) = \left[\sum_{l=1}^K (x_{il} - x_{jl})^p \right]^{\frac{1}{p}},$$

где $p = 1, 2, \dots, \infty$. Позволяет гибче учесть веса для далеко расположенных друг от друга объектов, чем Евклидово расстояние.

5. Расстояние Махаланобиса:

$$d_{\text{Мех}}(n_i, n_j) = (n_i - n_j) \text{cov}^{-1}(n_i - n_j)^T,$$

где cov – ковариационная матрица входных данных. Расстояние Махаланобиса отличается от расстояния Евклида тем, что учитывает корреляции между переменными и инвариантно к масштабу (неоднородности признаков).

6. Метрика Чебышева:

$$d_{\text{Ч}}(n_i, n_j) = \max_{1 \leq l \leq k} |x_{il} - x_{jl}|.$$

Расстояние Чебышева используется для определения различия между объектами по одному признаку.

Существуют и другие меры сравнения объектов, такие как корреляционное расстояние, расстояние χ^2 , бинарные метрики.

Если расстояние d_{ij} меньше некоторого порогового значения, то объекты помещают в один кластер. Большинство алгоритмов кластеризации используют в качестве входных данных матрицу расстояний, или отличия, которая представляет собой расстояния между объектами по выбранной метрике,

$$D = \begin{pmatrix} 0 & d_{12} & \dots & d_{1N} \\ d_{21} & 0 & \dots & d_{2N} \\ \dots & \dots & \dots & \dots \\ d_{N1} & d_{N2} & \dots & 0 \end{pmatrix}.$$

Рассмотрим математические характеристики кластера – центр, радиус и среднеквадратическое отклонение.

Центр кластера – это среднее геометрическое место точек в пространстве переменных, которое вычисляется по формуле

$$c = \frac{1}{N^*} \sum_{i=1}^{N^*} n_i,$$

где N^* – число объектов в кластере.

Радиус кластера – максимальное расстояние объекта от центра кластера в пространстве переменных

$$r = \max(d(n_i, c)).$$

Среднеквадратическое отклонение – является оценкой меры разброса точек в кластере и имеет следующий вид:

$$\sigma = \sqrt{\frac{1}{N^*} \sum_{i=1}^{N^*} d^2(n_i, c)}.$$

Критерии качества кластеризации. Каким образом определить возможное число кластеров в данных? Очевидно, что в кластерах внутрикластерные расстояния, как правило, меньше межкластерных расстояний. На этом принципе построены основные критерии качества кластеризации. Рассмотрим несколько критериев оценки оптимальности кластеризации.

1. Сумма расстояний до центров кластеров, к которым отнесены объекты, равна

$$Q_1 = \sum_{l=1}^k \sum_{n_i \in C_l} d(n_i, c_l) \rightarrow \min,$$

где l – номер кластера; n_i – вектор признаков i -го объекта в l -м кластере, C_l – множество объектов в l -м кластере; c_l – вектор признаков центра l -го кластера. Сумма расстояний до центров кластеров при успешной кластеризации должна стремиться к минимальному значению.

2. Сумма квадратов расстояний до центров кластеров, к которым отнесены объекты, равна

$$Q_2 = \sum_{l=1}^k \sum_{n_i \in C_l} d^2(n_i, c_l) \rightarrow \min.$$

В данном критерии учитывается вклад далеко расположенных объектов от центра кластера. Сумма квадратов расстояний до центров кластеров при успешной кластеризации должна стремиться к минимальному значению.

3. Сумма внутрикластерных расстояний между объектами в кластерах имеет вид

$$Q_3 = \sum_{l=1}^k \sum_{n_i, n_j \in C_l} d(n_i, n_j) \rightarrow \min.$$

Сумма внутрикластерных расстояний между объектами в кластерах при успешной кластеризации должна стремиться к минимальному значению.

1.6.2. Иерархические методы кластерного анализа

По способам кластеризации методы кластерного анализа можно разделить на две большие группы – иерархические и неиерархические методы. Каждая из групп методов включает множество подходов и алгоритмов.

Иерархические методы используют последовательное объединение объектов в кластеры, малых кластеров, в большие, которое может быть визуально отображено в виде дерева вложенных кластеров – дендрограммы (рисунок 14).



Рисунок 14 – Дендрограмма.

Дендрограмма – графическое представление распределения объектов внутри дерева кластеров. Как правило, на графе дендрограммы вдоль оси x располагают номера объектов, а вдоль оси y – значения меры сходства. В иерархических методах кластерного анализа число кластеров скрыто или условно. В неиерархических методах число кластеров заранее известно.

Для построения дендрограммы необходимо выбрать оценку расстояний между объектами и метод объединения или связывания объектов в кластеры. Методы иерархического кластерного анализа различаются по способу, или методу, связывания объектов в кластеры.

Если кластеры i и j объединяются в кластер r и требуется рассчитать расстояние до кластера s (рисунок 15), то используется формула Ланса-Уильямса

$$d_{rs} = \alpha_i d_{is} + \alpha_j d_{js} + \beta d_{ij} + \gamma |d_{is} - d_{js}|,$$

где α_i , α_j , β , γ – числовые параметры. Эта универсальная формула обобщает практически все способы определения расстояния между кластерами. Для каждого метода связывания по формуле Ланса-Уильямса рассчитываются расстояния связывания d_{rs} при определённых сочетаниях параметров α_i , α_j , β , γ и уже известных расстояниях d_{is} , d_{js} , d_{ij} .

Наиболее часто используются следующие методы связывания объектов/кластеров r и s :

1. Метод ближнего соседа (расстояние между ближайшими соседями, ближайшими объектами кластеров – $d_{rs} = \min(d_{is}, d_{js})$; $\alpha_i = \alpha_j = 0.5$, $\beta = 0$, $\gamma = -0.5$):

$$d_{rs} = \frac{d_{is} + d_{js}}{2} - \frac{1}{2} |d_{is} - d_{js}|.$$

В методе хорошо группируются кластеры некруглой формы и неравных размеров. Однако метод ближайшего соседа чувствителен к выбросам и шумам.




Рисунок 15 – Расстояние между объектами i и j (a) и расстояние между кластерами r и s (б).

2. Метод дальнего соседа (расстояние между самыми дальними соседями – $d_{rs} = \max(d_{is}, d_{js})$; $\alpha_i = \alpha_j = 0.5$, $\beta = 0$, $\gamma = 0.5$):

$$d_{rs} = \frac{d_{is} + d_{js}}{2} + \frac{1}{2} |d_{is} - d_{js}|.$$

Метод дальнего соседа менее чувствителен к выбросам и шумам, чем метод ближайшего соседа, однако имеет тенденции к чрезмерному дроблению кластеров и к образованию шаровидных кластеров, также плохо применим для ленточных кластеров и неравных по размерам кластеров.

3. Метод средней связи (среднее расстояние между всеми объектами пары кластеров с учетом расстояний внутри кластеров; $\alpha_i = m_i / (m_i + m_j)$, $\alpha_j = m_j / (m_i + m_j)$, $\beta = 0$, $\gamma = 0$):

$$d_{rs} = \frac{m_i d_{is} + m_j d_{js}}{m_i + m_j},$$

где m_i и m_j – число объектов в i -м и j -м кластерах соответственно. Данный метод является промежуточным вариантом между методами ближнего и дальнего соседей. Метод хорошо применим для неравных по размерам кластеров.

4. Центроидный метод (расстояние между центрами кластеров; $\alpha_i = m_i / (m_i + m_j)$, $\alpha_j = m_j / (m_i + m_j)$, $\beta = -\alpha_i \alpha_j$, $\gamma = 0$):

$$d_{rs} = \frac{m_i d_{is} + m_j d_{js}}{m_i + m_j} - \frac{m_i m_j d_{ij}}{(m_i + m_j)^2}.$$

Метод является наиболее оптимальным для случая неравных по размерам кластеров и кластеров различной плотности.

5. Метод медианной связи ($\alpha_i = \alpha_j = 0.5$, $\beta = -0.25$, $\gamma = 0$):

$$d_{rs} = \frac{d_{is} + d_{js}}{2} - \frac{1}{4} d_{ij}.$$

Метод используется при наличии выбросов в кластерах и в условиях высокого фонового шума.

Таким образом, в иерархических методах в большой кластер объединяются те малые кластеры, расстояние между которыми минимально.

Иерархические методы делятся на:

- *агломеративные*, характеризующиеся последовательным объединением исходных объектов и соответствующим уменьшением числа кластеров (построение кластеров снизу вверх);
- *дивизимные* (делимые), в которых число кластеров возрастает начиная с одного, в результате чего образуется последовательность расщепляющихся групп (построение кластеров сверху вниз).

Базовый алгоритм иерархического *агломеративного* метода кластерного анализа:

1. Множество объектов $n_1, n_2, \dots, n_N$ необходимо представить как множество N кластеров $C_1 = \{n_1\}, C_2 = \{n_2\}, \dots, C_N = \{n_N\}, k = N$.
2. Вычислить матрицу отличия D и расстояния связей между кластерами.
3. Выбрать два наиболее близких друг к другу кластера и объединить. (например, кластеры C_q и C_p объединить в новый кластер $\{C_q, C_p\}$. $k = k - 1$).
4. Если $k = 1$ (все кластеры объединены в один), то остановка. Иначе перейти к п. 2.

Базовый алгоритм иерархического *дивизимного* метода кластерного анализа:

1. Множество объектов $n_1, n_2, \dots, n_N$ рассматривается как один кластер $C_i = \{n_1, n_2, \dots, n_N\}, i = 1$.
2. Выбрать объект n_q у которого среднее расстояние до других объектов в кластере C_i наибольшее, т. е.

$$\bar{d}_{C_i}(n_q) = \frac{1}{N_{C_i}} \sum_{n_j \in C_i} d(n_j, n_q) \rightarrow \max,$$

где N_{C_i} – число объектов в кластере C_i . Выбранный объект n_q удаляется из класса C_i и формирует новый кластер $C_{i+1} = \{n_q\}$.

3. Объекты n_j из класса C_i , для которых разницы между средними расстояниями до элементов кластеров C_i и C_{i+1} являются положительными, т.е. $(\bar{d}_{C_{i+1}}(n_j) - \bar{d}_{C_i}(n_j)) > 0$, переносятся в новый кластер C_{i+1} до тех пор, пока соответствующие разницы не станут отрицательными. $i = i + 1$.

4. Если $i = N$ (все кластеры стали синглетонами, т.е. состоящими из одного объекта), то остановка. Иначе, выбрать следующий кластер для расщепления (например, кластер с наибольшим радиусом) и перейти к п. 2.

В ходе практического применения иерархических методов часто встает вопрос о выборе наиболее оптимального метрического расстояния и метода связывания объектов. Два наугад выбранных объекта на иерархическом дереве связаны между собой так называемым кофенетическим расстоянием, величина которого определяется расстоянием между двумя кластерами, в которых находятся данные объекты (рисунок 16).




Рисунок 16 – Кофенетический корреляционный коэффициент.

Мерой линейной связи между кофенетическими и метрическими расстояниями является кофенетический корреляционный коэффициент k . Построение иерархического дерева считается успешным, если кофенетический корреляционный коэффициент близок к 1. Для наиболее успешной кластеризации строится дендрограмма иерархического дерева.

Выделение значимых кластеров. Для выделения значимых кластеров можно задать некоторое пороговое значение T меры расстояний сходства (горизонтальная ось T на дендрограмме, рисунок 16). Число значимых кластеров определяется количеством пересечений линии порога T и связей иерархического дерева. Причем каждая из отсекаемых линией порога ветвей дерева будет формировать отдельный кластер. На практике часто выбирают пороговое значение T на основе визуального анализа плотности распределения ветвей построенной дендрограммы. Альтернативный способ выделения значимых кластеров – метод задания фиксированного числа кластеров. Пороговое значение меры сходства T устанавливается в корне иерархического дерева. Затем значение порога T постепенно снижается до тех пор, пока не будет установлено число пересечений линии порога T и связей иерархического дерева, равное заданному количеству кластеров.

Достоинства иерархических методов кластерного анализа: 1) методы не требуют задания точного числа кластеров; 2) дендрограммы соответствуют реальным и понятным текстурам на практике (например, генетические сети в биоинформатике).

Недостатки: 1) если принято неверное объединение двух кластеров, то оно не может быть изменено в ходе анализа; 2) напрямую не происходит минимизация критерия качества кластеризации Q ; 3. Чувствительность к шумам и выбросам.

Сложность работы с большими наборами данных. Чрезмерное дробление больших кластеров.

1.7. Неиерархические и графовые методы кластерного анализа

1.7.1. Неиерархические методы кластерного анализа

При большом количестве объектов ($N > 200$) иерархические методы кластерного анализа не эффективны, ввиду больших вычислительных затрат и сложности интерпретации дерева кластеров. В таких случаях могут использоваться неиерархические методы кластерного анализа.

В неиерархических методах кластерного анализа необходимо задать гипотезу о числе кластеров k , способ сравнения объектов между собой (меру сходства или расстояние d_{ij}) и функцию качества кластеризации Q . В основе неиерархических методов лежит разбиение набора данных на заданное число кластеров k таким образом, чтобы целевая функция алгоритма Q достигала экстремума.

Рассмотрим подробнее неиерархические методы на примере наиболее распространенного алгоритма k -средних.

Алгоритм k -средних. Выдвигается гипотеза о том, что выборка $n_1, n_2, \dots, n_N$ – случайна, независима и состоит из смеси K -мерных гауссовых распределений (представляющих собой кластеры данных). Необходимо оценить центры распределений $c_1, c_2, \dots, c_k$ и определить объекты, попадающие в k кластеров.

В простейшем случае расстояние между двумя объектами n_i и n_j может быть рассчитано по Евклидовой метрике. Число кластеров может быть оценено по гистограмме расстояний между объектами, которая строится на основе матрицы отличия D (рисунок 17).




Рисунок 17 – Пример оценки числа кластеров на основе гистограммы расстояний между объектами

В качестве критерия оптимальности можно выбрать сумму квадратов расстояний до центров кластеров, к которым отнесены объекты.

Суть метода k -средних заключается в следующем. Среди множества объектов выбираются k элементов в качестве начальных центров кластеров. Для каждого объекта рассчитываются расстояния до центров кластеров, и данный объект относится к тому кластеру, расстояние до которого оказалось

минимальным. После чего для этого кластера (в котором изменилось количество объектов) рассчитывается новое положение центра кластера (как среднее по каждому признаку X_j) по всем включенным в кластер объектам. Затем для новых центров кластеров процедура пересчета расстояний повторяется, формируются новые кластеры и центры. Итерации повторяются до тех пор, пока центры кластеров перестанут смещаться или функция Q не достигнет минимума. В общем случае в результате применения метода k -средних исходное множество объектов разделяется ровно на k кластеров.

Для удобства вычислений в методе k -средних вводится матрица разбиений $U = \{u_{ij}\}$, $i = 1, 2, \dots, N$ и $j = 1, 2, \dots, k$, вычисляемая на m -ой итерации метода

$$u_{ij}^{(m)} = \begin{cases} 1, & \text{если } d(n_i, c_j^{(m)}) = \min_{1 \leq l \leq k} d(n_i, c_l^{(m)}) \\ 0, & \text{в остальных случаях} \end{cases},$$

где c_j , $j = 1, 2, \dots, k$ – центры кластеров. Набор ограничений для матрицы разбиений $u_{ij} \in [0,1]$, $\sum_{j=1}^k u_{ij} = 1$, $0 < \sum_{i=1}^N u_{ij} < N$, $i = 1, 2, \dots, N$ и $j = 1, 2, \dots, k$ (таблица 8).

Таблица 8 – Пример матрицы разбиения U (7 объектов разнесены в три кластера – $C_1 = \{n_1, n_4, n_5, n_7\}$, $C_2 = \{n_2, n_6\}$, $C_3 = \{n_3\}$).

Объект	C_1	C_2	C_3
n_1	1	0	0
n_2	0	1	0
n_3	0	0	1
n_4	1	0	0
n_5	1	0	0
n_6	0	1	0
n_7	1	0	0

Используя матрицу разбиений U на $(m-1)$ -й итерации можно вычислить центры кластеров на m -й итерации

$$c_j^{(m)} = \frac{\sum_{i=1}^N u_{ij}^{(m-1)} n_i}{\sum_{i=1}^N u_{ij}^{(m-1)}}, \quad j = 1, 2, \dots, k.$$

Алгоритм:

1. Инициализация параметров метода: $Q^{(0)}$, $U^{(0)}$, $c_1^{(0)}$, $c_2^{(0)}$, ..., $c_k^{(0)}$, ε (точность вычисления), $m = 1$. Выбрать количество кластеров k .

2. Определить центры кластеров на m -й итерации $c_1^{(m)}$, $c_2^{(m)}$, ..., $c_k^{(m)}$. (Если $m=1$, то $c_1^{(m)} = c_1^{(0)}$, $c_2^{(m)} = c_2^{(0)}$, ..., $c_k^{(m)} = c_k^{(0)}$)

3. Пересчитать расстояния от объектов $n_1, n_2, \dots, n_N$ до центров кластеров $c_1^{(m)}, c_2^{(m)}, \dots, c_k^{(m)}$. Обновить матрицу разбиения $U^{(m)}$. Рассчитать $Q^{(m)}$.

4. Проверить условие остановки алгоритма. Если $|Q^{(m)} - Q^{(m-1)}| \leq \varepsilon$, то завершить процесс кластеризации. Иначе $m = m + 1$ и перейти к п. 2.

Основным недостатком алгоритма k -средних является то, что осуществляется локальная, а не глобальная минимизация функции Q . Как правило, результативность метода сильно зависит от выбора начальных центров кластеров. На практике начальные центры кластеров выбирают случайным образом либо по какому-то правилу. Рассмотрим основные правила, или стратегии, для выбора начальных центров кластеров.

Алгоритм простейшей расстановки (рисунок 18, а):

1. Вводится некоторый порог $h > 0$. Центр первого кластера – $c_1 = n_1$.

2. Следующий центр кластера c_2 такой ближайший n_i , что минимальное расстояние от n_i до c_1 будет больше h .

...

k . В качестве центра c_k выбирают такой ближайший n_i , что минимальное расстояние от n_i до $c_1, c_2, \dots, c_{(k-1)}$ будет больше h .

Алгоритм максимального расстояния (рисунок 18, б):

1. Центр первого кластера – $c_1 = n_1$.

2. Следующий центр кластера c_2 – элемент n_i , находящийся на максимальном расстоянии от c_1 .

...

k . В качестве центра c_k выбирают такой элемент n_i , который располагается на максимальном расстоянии от n_i до $c_1, c_2, \dots, c_{(k-1)}$.




Рисунок 18 – Примеры выбора начальных центров трех кластеров по методу простейшей расстановки (а) и максимального расстояния (б).

Следует отметить неудовлетворительную работу метода k -средних в случае наличия кластеров различных размеров, различной плотности, нешаровидной или ленточной форм. В этом случае неиерархический анализ проводят в несколько этапов. На первом этапе для достаточно большого k выполняется неиерархический анализ по методу k -средних. На втором этапе необходимо выполнить иерархическую кластеризацию для найденных центров k кластеров. На завершающем этапе требуется сгруппировать ближайшие кластеры на основе визуального анализа дендрограммы.

В общем случае для оценки числа кластеров в методе k -средних используется адаптивный подход. Для $k = 2, 3, \dots, k'$ кластеров выполняется кластеризация $(k'-1)$ раз. Оптимальным количеством кластеров является такое минимальное количество кластеров, для которого функция качества разбиения достигает требуемого экстремума. Выбор оптимального количества кластеров обусловлен степенью приближения результатов кластеризации к идеальному решению.

Алгоритм Fuzzy k -средних. Дальнейшее развитие алгоритма представляет собой алгоритм Fuzzy k -средних, который основан на предположении о том, что кластеры являются нечеткими множествами. *Нечеткое* (или размытое) множество – понятие множества, для которого функция принадлежности элемента к тому или иному классу может принимать любые значения в интервале $[0, 1]$, а не только значения 0 или 1, т. е., некоторый объект n_i может принадлежать тому или иному кластеру с некоторой вероятностью, которая записывается в матрице разбиений U . На m -й итерации матрица разбиений $U^{(m)}$ формируется на основе квадратов расстояний от объекта n_i до центра j -го кластера

$$u_{ij}^{(m)} = \frac{1}{\sum_{q=1}^k \left(\frac{d^2(n_i, c_j)}{d^2(n_i, c_q)} \right)^{\frac{1}{w-1}}},$$

где $c_j, j = 1, 2, \dots, k$ – центры кластеров. В алгоритме используется показатель нечеткости $w \in (1, \infty)$, регулирующий нечеткость разбиения. При $w \rightarrow \infty$ нечеткость увеличивается. Обычно используется $w = 2$. Набор ограничений для матрицы разбиений $u_{ij} \in [0, 1]$, $\sum_{j=1}^k u_{ij} = 1$, $0 < \sum_{i=1}^N u_{ij} < N$, $i = 1, 2, \dots, N$ и $j = 1, 2, \dots, k$ (таблица 9). Объект n_i относится к тому или иному кластеру по критерию максимума принадлежности данному кластеру.

Таблица 9 – Пример матрицы разбиения U для 7 объектов и трех кластеров, являющихся нечеткими множествами.

Объект	C_1	C_2	C_3
n_1	0,6	0,3	0,1
n_2	0,1	0,8	0,1
n_3	0,05	0,05	0,9
n_4	0,8	0,05	0,15
n_5	0,7	0,1	0,2
n_6	0,3	0,5	0,2
n_7	0,5	0,3	0,2

По матрице разбиений U на $(m-1)$ -й итерации вычисляются центры кластеров на m -ой итерации

$$c_j^{(m)} = \frac{\sum_{i=1}^N (u_{ij}^{(m-1)})^w n_i}{\sum_{i=1}^N (u_{ij}^{(m-1)})^w}, \quad j = 1, 2, \dots, k.$$

Алгоритм:

1. Инициализация параметров метода: $Q^{(0)}$, $U^{(0)}$, $c_1^{(0)}$, $c_2^{(0)}$, ..., $c_k^{(0)}$, ε (точность вычисления), $w = 2$, $m = 1$. Выбрать количество кластеров k .
2. Определить центры кластеров $c_1^{(m)}$, $c_2^{(m)}$, ..., $c_k^{(m)}$. (Если $m = 1$, то $c_1^{(m)} = c_1^{(0)}$, $c_2^{(m)} = c_2^{(0)}$, ..., $c_k^{(m)} = c_k^{(0)}$).
3. Пересчитать квадраты расстояний от объектов $n_1, n_2, \dots, n_N$ до центров кластеров $c_1^{(m)}$, $c_2^{(m)}$, ..., $c_k^{(m)}$. Обновить матрицу разбиения $U^{(m)}$. Рассчитать $Q^{(m)}$.
4. Проверить условие остановки алгоритма. Если $|Q^{(m)} - Q^{(m-1)}| \leq \varepsilon$, то завершить процесс кластеризации. Иначе $m = m + 1$ и перейти к п. 2.

В алгоритмах нечеткой кластеризации (Fuzzy k -средних) для оценки качества разбиения на k -кластеров применяются несколько подходов на основе вычисления матрицы разбиений U .

В качестве функции качества разбиения Q используются оценки внутрикластерных и межкластерных различий

$$Q_{\text{Вн}} = \sum_{j=1}^k \sum_{i=1}^N u_{ij}^w d^2(n_i, c_j) \rightarrow \min,$$

$$Q_{\text{Меж}} = \sum_{j=1}^k \sum_{i=1}^N u_{ij}^w d^2(c_j, \langle n \rangle) \rightarrow \max,$$

которые должны стремиться к минимальному и максимальному значениям соответственно при успешной кластеризации, $\langle n \rangle$ – среднее арифметическое всех входных векторов.

Индекс эффективности описывает межкластерные и внутрикластерные различия и стремится к максимальному значению при успешной кластеризации

$$PI = \sum_{j=1}^k \sum_{i=1}^N u_{ij}^w (d^2(c_j, \langle n \rangle) - d^2(n_i, c_j)) \rightarrow \max.$$

Для оценки четкости разбиения используются показатели четкости – коэффициент разбиения PC и индекс четкости CI .

$$PC = \frac{\sum_{j=1}^k \sum_{i=1}^N u_{ij}^2}{N}.$$

Коэффициент разбиения PC принимает максимальное значение 1 в случае наиболее четкого разбиения (вероятность принадлежности объекта к какому-либо из кластеров равна 1, а к остальным – 0 и минимальное значение $1/k$), в случае наиболее нечеткого разбиения (вероятность принадлежности объекта к любому из кластеров равна $1/k$).

Индекс четкости $CI \in [0,1]$ представляет собой линейную функцию от коэффициента четкости, построенную в целях приведения шкалы измерения характеристики к нулевому значению.

$$CI = \frac{k \cdot PC - 1}{k - 1}.$$

Также часто используются критерии на основе энтропии E .

$$E = - \frac{\sum_{j=1}^k \sum_{i=1}^N u_{ij} \ln(u_{ij})}{N}.$$

Значение критерия достигает 0 при наиболее четком разбиении, а максимума $\ln(k)$ – при нечетком разбиении. Недостаток критерия – оценка стремится к минимальному количеству кластеров. Для устранения недостатка используется нормализация данного критерия

$$E^* = - \frac{\sum_{j=1}^k \sum_{i=1}^N u_{ij} \ln(u_{ij})}{N} \times \frac{N}{N - k}.$$

Значение нормированного критерия достигает 0 при наиболее четком разбиении, а максимума $N \ln(k) / (N - k)$ – при нечетком разбиении.

Для приведения верхнего значения шкалы измерения энтропии к 1 вводится дополнительный критерий – модифицированная энтропия

$$E_{\text{Мод}} = - \frac{\sum_{j=1}^k \sum_{i=1}^N u_{ij} \ln(u_{ij})}{N} \times \frac{1}{\ln(k)}.$$

1.7.2. Графовые методы кластерного анализа

Графовые методы кластерного анализа представляют собой промежуточную группу методов между иерархическими и неиерархическими алгоритмами. Рассмотрим основные алгоритмы графовых методов кластерного анализа.

Алгоритм кратчайшего незамкнутого пути (КНП). Алгоритм требует предположения о количестве кластеров k . Алгоритм (рисунок 19):

1. Установить количество кластеров k . Вычислить матрицу отличия D . Найти две близлежащие точки и соединить их ребром.
2. Найти изолированную точку, ближайшую к некоторой неизолированной, и соединить эти две точки ребром.
3. Если в выборке остаются изолированные точки, то перейти к п. 2, иначе, к п. 4.
4. Удалить $(k - 1)$ самых длинных ребер.
5. Скрепленные ребрами группы точек объединить в кластеры.




Рисунок 19 – Граф результатов кластеризации 16 объектов в четыре кластера с использованием метода кратчайшего незамкнутого пути.

Достоинством метода КНП является простота реализации. К недостаткам следует отнести высокую чувствительность алгоритма к шуму и выбросам, а также медленную сходимость в случае больших наборов данных.

Алгоритм выделения связанных компонент. В алгоритме необходимо задать минимальное и максимальное количество кластеров k_1 и k_2 . Используется параметр – расстояние R , характеризующее размер кластера. Алгоритм:

1. Установить k_1 и k_2 , R .
2. Представить выборку в виде КНП-графа, где вершины графа – объекты n_i (связанные по методу КНП), ребра – пары объектов n_i и n_j , разделенные расстоянием d_{ij} .
3. Удалить все ребра (связи между объектами n_i и n_j), для которых $d_{ij} > R$.
4. Присвоить $k :=$ число связанных компонент (связанных групп объектов).
5. Проверить условие остановки алгоритма: если $k \in [k_1, k_2]$, то завершить поиск; скрепленные ребрами группы точек объединить в кластеры. Иначе, если $k < k_1$, то уменьшить R ; если $k > k_2$, то увеличить R и перейти к п. 2.

Начальное приближение для R оценивается на основе гистограммы расстояний между объектами. Достоинством метода является отсутствие жесткого требования относительно числа кластеров k .

Алгоритм ФОРЭЛ (формальный элемент). Алгоритм автоматически определяет количество кластеров k , а также использует фиксированный параметр R , характеризующий размер кластера.

1. Задать R . $k = 1$.
2. Выбрать случайным образом объект n_i и на его основе сформировать центр нового кластера $c_k = n_i$.
3. Объекты, расположенные от центра кластера c_k на расстоянии, не большем R , вносятся в кластер C_k .
4. Вычислить центр масс c_k^m в кластере C_k .
5. Если $c_k \neq c_k^m$, то установить новый центр кластера $c_k = c_k^m$; перейти к п. 3. Иначе изъять объекты, попавшие в кластер C_k из дальнейшего анализа и перейти к п. 6.

6. Проверить условие остановки алгоритма: если все объекты кластеризованы, то завершить кластерный анализ. Иначе $k = k + 1$ и перейти к 2.

Преимущество алгоритма ФОРЭЛ заключается в том, что, варьируя параметр R , можно управлять детальностью кластеризации. Однако это же является недостатком метода в случае автоматического запуска кластеризации, т. е. метод чувствителен к выбору параметра R и центра первого кластера.

Можно объединить алгоритмы КНП и ФОРЭЛ. На первом этапе по методу кратчайшего незамкнутого пути находят k групп кластеров. На втором этапе по методу ФОРЭЛ находят точные кластеры.

1.8. Нейронные сети

1.8.1. Нейронная сеть

Идея нейронных сетей родилась в рамках теории искусственного интеллекта в результате попыток имитировать способность биологических нервных систем обучаться и исправлять ошибки.

Нейрон. Нейронные сети (от англ. neural networks) – это модели биологических нейронных сетей мозга, в которых процессы возбуждения и передачи импульса контролируются относительно простыми однотипными элементами – нейронами.

Естественный нейрон имеет множество входных отростков – дендритов, по которым нервные импульсы поступают в нейрон, и одно длинное выходное волокно – аксон (рисунок 20). По аксону нервный импульс с нейрона передается другим нейронам. Передача импульса между аксоном одного нейрона и дендритом другого нейрона осуществляется через *синапс*.




Рисунок 20 – Естественный нейрон.

Искусственный нейрон (или формальный нейрон) – элемент искусственных нейронных сетей, моделирующий некоторые функции биологического, или естественного, нейрона (рисунок 21). Главная функция искусственного нейрона – формировать выходной сигнал в зависимости от сигналов, поступающих на его вход.




Рисунок 21 – Искусственный нейрон.

Пусть выполняется анализ некоторого набора данных $n_1, n_2, \dots, n_N$, полученных из базы данных или эксперимента. Каждый из рассматриваемых объектов $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$, $i = 1, 2, \dots, N$, характеризуется набором из K признаков $X_1, X_2, \dots, X_K$. Для L объектов (эталонной выборки) значения зависимой переменной $y_1, y_2, \dots, y_L$ известны и дискретны (являются метками m -классов), а для $N - L$ объектов (тестируемой выборки) значения $y_{L+1}, y_{L+2}, \dots, y_N$ не известны и должны быть определены. Независимые переменные $X_1, X_2, \dots, X_K$ могут иметь любое распределение.

Предположим, что на входы нейрона поступает объект данных $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$. Модель формального нейрона для обработки объекта n_i представлена на рисунке 22.




Рисунок 22 – Формализованная модель нейрона.

Простейший, или формальный, нейрон состоит из $K + 1$ входов-синапсов, ядра нейрона, включающего сумматор входных сигналов s и функциональный преобразователь ϕ , точки ветвления.

На K входов, или синапсов, нейрона передаются значения $x_{i1}, x_{i2}, \dots, x_{iK}$ независимых переменных $X_1, X_2, \dots, X_K$ объекта n_i . Вес каждого синапса регулируется настраиваемым параметром синаптической связи w_j , $j = 0, 1, 2, \dots, K$. На нулевой вход нейрона подается 1, что характеризует некоторое смещение (например, экспериментальное смещение вследствие влияния фонового шума и

т. д.). Таким образом, каждый синапс умножает значение независимой переменной объекта на вес синапса.

Сумматор вычисляет скалярное произведение входного объекта $n_i = (x_{i1}, x_{i2}, \dots, x_{iK})$ на вектор настраиваемых параметров $W = (w_0, w_1, \dots, w_K)$

$$t = \sum_{j=1}^K w_j x_{ij} + b,$$

где $b = w_0 \cdot 1$ – смещение (скалярный параметр).

Далее сигнал t поступает на функциональный преобразователь $y = \varphi(t)$, характеризуемый функцией активации $\varphi(t)$. В качестве функций активации часто используется функция Хэвисайда или функция знака

$$\varphi(t) = \begin{cases} 1, & t > 0, \\ 0, & t \leq 0. \end{cases} \text{ или } \varphi(t) = \text{sgn}(t) = \begin{cases} 1, & t > 0, \\ -1, & t \leq 0. \end{cases}$$

Точка ветвления служит для рассылки выходного сигнала y по нескольким адресам.

Нейронная сеть может состоять из одного или более нейронов. Нейронные сети бывают слоистыми и полносвязными. В *слоистых* сетях выходной сигнал j -го слоя подается на входы нейронов $(j + 1)$ -го слоя. Число нейронов в каждом слое может быть любым. В *полносвязных* сетях каждый нейрон передает свой выходной сигнал остальным нейронам, включая себя.

В многослойных сетях в рамках одного слоя данные обрабатываются параллельно, а в масштабах всей сети обработка ведется последовательно от слоя к слою.

Аппарат нейронных сетей используется для решения таких задач ИАД, как классификация (обучение с учителем), кластеризация (обучение без учителя), визуализация и снижение размерности данных, прогнозирование. Рассмотрим задачи классификации и кластеризации данных.

Общий принцип разработки нейронной сети состоит в создании модели нейронов сети и поиска неизвестных весов синапсов нейронов.

Алгоритм:

1. Разработка нейронов сети. Для задач кластеризации данных число нейронов сети m соответствует числу кластеров.

2. Обучение нейронной сети. Нахождение вектора неизвестных весов синапсов $w_j, j = 1, 2, \dots, K$, для каждого нейрона сети по обучающей выборке $n_1, n_2, \dots, n_L$.

3. Применение нейронной сети к тестируемой выборке $n_{L+1}, n_{L+2}, \dots, n_N$.

Обучение нейронной сети – процесс подстройки ее внутренних параметров, т.е. весов синапсов $w_j, j = 0, 1, 2, \dots, K$, для каждого нейрона под решение конкретной задачи.

Эпоха – одна итерация в процессе обучения, включающая предъявление всех примеров (объектов) из обучающего множества.

Неизвестные веса определяются таким образом, чтобы минимизировать ошибку обучения – некоторую функцию разности между выходными и желаемыми значениями зависимой переменной.

Персептрон. Персептрон является некоторым классом моделей мозга или его систем. Рассмотрим модель зрительной системы (рисунок 23). Модель состоит из сенсорных S -элементов, ассоциирующих A -элементов и реагирующего R -элемента. Сенсорные элементы возбуждаются, если величина входного сигнала окажется выше некоторого порогового значения. Если число возбуждающих сигналов превосходит число тормозящих, то A -нейрон возбуждается и передает сигнал на R -нейрон.




Рисунок 23 – Модель зрительной системы.

Реагирующий элемент выбирает некоторое действие, если

$$R = \sum_{j=1}^K w_j x_{ij} > 0,$$

где $w_j, j = 0, 1, 2, \dots, K$, – веса синапсов R -нейрона, x_{ij} – выходы A -нейронов.

С помощью персептрона можно осуществить классификацию объектов по двум классам C_1 и C_2 .

Рассмотрим задачу обучения однопейронного персептрона. Требуется по обучающей выборке $n_1, n_2, \dots, n_L$ построить линейную функцию

$$f(n_i) = W \cdot n_i,$$

которая удовлетворяла бы

$$\begin{aligned} f(n_i) &> 0 \text{ для } n_i \in C_1, \\ f(n_i) &< 0 \text{ для } n_i \in C_2. \end{aligned}$$

Алгоритм:

1. Инициализировать $W^{(0)}$, $k = 1$, задать параметр остановки алгоритма l . Запишем обучающую выборку $n_1, n_2, \dots, n_L$ в виде бесконечной последовательности $n_1, n_2, \dots, n_L, n_1, n_2, \dots, n_L, n_1, n_2, \dots, n_L, \dots$ или $n_1, n_2, \dots, n_\infty$.

2. Персептрону последовательно предъявляется очередной объект n_k из обучающей выборки, затем осуществляется коррекция весов синапсов персептрона $W^{(k)}$ по правилу

$$W^{(k)} = \begin{cases} W^{(k-1)}, & \text{если } W^{(k-1)} \cdot n_k > 0 \text{ и } n_k \in C_1, \\ W^{(k-1)}, & \text{если } W^{(k-1)} \cdot n_k < 0 \text{ и } n_k \in C_2, \\ W^{(k-1)} + n_k, & \text{если } W^{(k-1)} \cdot n_k \leq 0 \text{ и } n_k \in C_1, \\ W^{(k-1)} - n_k, & \text{если } W^{(k-1)} \cdot n_k \geq 0 \text{ и } n_k \in C_2. \end{cases}$$

3. Проверка условия остановки: если l раз подряд правильно классифицируются элементы обучающей выборки, то выполнить остановку алгоритма.

Иначе $k = k + 1$ и перейти к п. 2.

1.8.2. Алгоритмы обучения нейронных сетей

В основе большинства алгоритмов обучения нейронных сетей лежит следующий принцип. Нейронной сети последовательно (или в случайном порядке, как в методе стохастического градиента) предоставляются объекты n_i , $i = 1, 2, \dots, L$, из эталонной выборки. Вычисляется некоторая функция ошибок F . Веса синаптических настраиваемых параметров w_j , $j = 0, 1, 2, \dots, K$, корректируются. Предъявляется следующий объект n_{i+1} и т. д. Процедуры обучения реализуют нахождение минимума функции ошибок F , например, методом градиентного спуска. Существующие алгоритмы различаются выбором функционала ошибки F и реализацией метода градиентного спуска.

Рассмотрим основные алгоритмы обучения нейронных сетей.

Алгоритм Хебба. Предположим, что необходимо настроить один нейрон на классификацию объектов по двум классам C_1 и C_2 по обучающей выборке $n_1, n_2, \dots, n_L$. Множество эталонных откликов нейрона –

$$y_i = \begin{cases} 1, & n_i \in C_1 \\ -1, & n_i \in C_2 \end{cases}, i = 1, 2, \dots, L.$$

Функцией активации является функция знака – $\varphi(t) = \text{sgn}(t)$.

Правило Хебба: Если нейрон правильно классифицирует входной вектор n_i , то порог синаптических связей снижается пропорционально этому вектору.

Алгоритм:

1. Инициализировать $W^{(0)}$, $k = 1$.

2. Для всех пар (n_i, y_i) , $i = 1, 2, \dots, L$, эталонной выборки выполнить коррекцию весового фактора по формуле

$$W^{(k)} = W^{(k-1)} + n_i y_i.$$

3. Проверить условие остановки для найденного весового фактора $W^{(k)}$. Вычислить

$$s_i = \text{sgn}(W^{(k)} \cdot n_i).$$

Если $s_i = y_i$ для всех $i = 1, 2, \dots, L$, то остановить процедуру обучения.

Иначе $k = k + 1$ и перейти к 2.

Адаптивное обучение. Предположим, что необходимо настроить один нейрон на классификацию объектов в два класса C_1 и C_2 по обучающей выборке $n_1, n_2, \dots, n_L$.

Цель обучения нейронной сети – нахождение такого вектора весов W , чтобы ошибка неправильной классификации была минимальной:

$$F(W) = \sum_{i=1}^L (\varphi(W \cdot n_i) - y_i)^2 \rightarrow \min.$$

Данная задача решается итерационными методами наискорейшего или градиентного спуска. В ходе обучения на k -й итерации производится корректировка коэффициентов синаптической связи в направлении антиградиента функции $F(W)$:

$$W^{(k)} = W^{(k-1)} - h \cdot \text{grad}(F(W^{(k-1)})),$$

где

$$\text{grad}(F(W)) = 2 \sum_{i=1}^L (\varphi(W \cdot n_i) - y_i) \varphi'(W \cdot n_i) \cdot n_i, \quad (5)$$

h – параметр обучения.

На практике реализуют метод стохастического градиента, в котором вместо вычисления суммы в формуле (5) итерационный шаг делают сразу после предъявления очередного обучающего вектора n_k по правилу

$$W^{(k)} = W^{(k-1)} - h(\varphi(W^{(k-1)} \cdot n_k) - y_k) \varphi'(W^{(k-1)} \cdot n_k) \cdot n_k. \quad (6)$$

Алгоритм:

1. Инициализировать $W^{(0)}$, $k = 1$.
2. Нейрону случайным образом предъявляется объект n_k из обучающей выборки, затем осуществляется коррекция весов синапсов нейрона $W^{(k)}$ по правилу (6).
3. Проверить условие остановки. Если весовые факторы или ошибка обучения $F(W)$ не изменяются, то остановить процедуру обучения. Иначе $k = k + 1$ и перейти к п. 2.

1.8.3. Нейронные сети Кохонена

Нейронные сети Кохонена представляют собой класс нейронных сетей, основным элементом которых является слой Кохонена.

Нейронная сеть слой Кохонена. Алгоритм функционирования самообучающегося слоя Кохонена или слоя соревнующихся нейронов является одним из вариантов кластеризации многомерных данных.

Пусть выполняется анализ некоторого набора данных $n_1, n_2, \dots, n_N$. Метки классов $y_1, y_2, \dots, y_N$ объектов не известны. Требуется разбить набор данных на m классов, выделив m эталонных образцов (центров кластеров или классов).

Нейроны слоя Кохонена представляют собой узлы или центры кластеров, синаптические веса которых $W_1, W_2, \dots, W_m$ должны быть определены. Нейронная сеть с конкурирующей активационной функцией анализирует выходные значения нейронов слоя и в качестве результата выдает номер наиболее близко расположенного нейрона сети (нейрона-«победителя») к классифицируемому объекту (рисунок 24, а). Конкурирующая активационная функция для слоя возвращает выходы, равные 0 для всех нейронов, за исключением нейрона-«победителя», для которого выход равен 1. Номер

активного нейрона-«победителя» определяет ту группу (кластер), к которой наиболее близок входной вектор-объект.




Рисунок 24 – Слой Кохонена (а) и карта Кохонена с прямоугольной конфигурацией (б).

В общем случае задача сводится к поиску минимума функции

$$F(W_1, W_2, \dots, W_m) = \frac{1}{2} \sum_{j=1}^m \sum_{n_i \in C_j} \|n_i - W_j\|^2 \rightarrow \min,$$

где C_j - множество объектов j -го класса, т.е. множество объектов выборки, которые ближе к ядру класса W_j , $\|\dots\|$ – Евклидова норма вектора

$$\|a\| = \sqrt{a_1^2 + a_2^2 + \dots + a_K^2}.$$

Минимизацию функции F относительно ядра W_j можно осуществить методом стохастического градиентного спуска по итерационной формуле

$$W_j^{(k)} = W_j^{(k-1)} + h \cdot (n_k - W_j^{(k-1)}),$$

где h – параметр обучения, который может уменьшаться в ходе обучения.

Если вектор n_k относится к кластеру C_j , то центр этого кластера W_j смещается в сторону объекта n_k на расстояние $h \cdot (n_k - W_j^{(k-1)})$. Когда на вход сети поступает все большее и большее число объектов, нейрон, являющийся ближайшим, снова корректирует свой весовой вектор. В конечном счете, если в слое имеется достаточное количество нейронов, то каждая группа близких объектов окажется связанной с одним из нейронов слоя. В этом и заключается свойство самоорганизации слоя Кохонена.

Алгоритм:

1. Задать размер слоя m . Инициализировать начальные значения ядер $W_1^{(0)}, W_2^{(0)}, \dots, W_m^{(0)}$. Установить $k = 1$.

2. Слою сети случайным образом предъявляется объект n_k . Вычислить расстояния d_{kj} между вектором n_k и всеми ядрами $W_j, j = 1, 2, \dots, m$, например, Евклидово расстояние

$$d_{kj} = \left[\sum_{t=1}^K (x_{kt} - w_{jt})^2 \right]^{\frac{1}{2}}.$$

3. Определить нейрон, для которого расстояние d_{kj} минимально. Выполнить коррекцию его весового вектора на величину $h \cdot (n_k - W_j^{(k-1)})$.

4. Проверить условие остановки (стабилизации ядер). Если весовые факторы ядер или ошибка обучения F не изменяются, то алгоритм завершает работу.

Иначе $k = k + 1$ и перейти к п. 2.

Самоорганизующиеся карты Кохонена. Дальнейшим развитием слоя Кохонена стали самоорганизующиеся карты Кохонена (англ. Self-Organizing Maps). Самоорганизующаяся карта Кохонена – это однослойная нейронная сеть с конкурирующей активационной функцией, имеющая определенную топологию размещения нейронов в K -мерном пространстве признаков. В отличие от слоя Кохонена карта Кохонена после обучения поддерживает такое топологическое свойство, когда близким входным векторам соответствуют близко расположенные активные нейроны. Как правило, карта Кохонена представляет собой двумерную сетку с прямоугольными или шестиугольными ячейками, в узлах которой располагаются нейроны (рисунок 24, б). Нейроны сети соединены с соседними нейронами. При обучении подстраиваются веса не только нейрона-«победителя», но и его соседей.

В процессе создания карты Кохонена в начале задается ее конфигурация (прямоугольная или шестиугольная), количество нейронов и размер карты. Затем проводится инициализация весов нейронов, для чего применяются специальные алгоритмы (в простейшем случае веса инициализируются малыми случайными значениями). Один из способов обучения карты Кохонена заключается в том, что на каждом шаге обучения из исходного набора данных случайно выбирается один из векторов n_k , а затем производится поиск наиболее похожего на него вектора коэффициентов нейронов W_j . При этом выбирается нейрон-«победитель», вектор которого наиболее близок к вектору входов. В отличие от слоя Кохонена осуществляется коррекция весового вектора не только нейрона-«победителя», но и весовых векторов остальных активных нейронов W_q , хотя и в меньшей степени – в зависимости от удаления от нейрона-«победителя»

$$W_q^{(k)} = W_q^{(k-1)} + A \cdot h_q(n_k - W_q^{(k-1)}),$$

где h_q – параметр скорости обучения (уменьшается в ходе обучения); $A = 1$ для $q = j$, $A = 0,5$ для $q \neq j$ и $d_{qj} < R_j$, где d_{qj} – расстояние между нейронами W_q и W_j , R_j – радиус окрестности нейрона-«победителя», $A = 0$ для $q \neq j$ и $d_{qj} > R_j$.

В результате векторы весов нейрона-«победителя» W_j и его ближайших соседей W_q перемещаются ближе к входному вектору n_k . Форма и величина окрестности R_j вокруг нейрона-«победителя» в процессе обучения изменяются. Начинают с очень большой области R_j (может включать все нейроны слоя Кохонена). Нейроны карты Кохонена будут упорядочиваться так, чтобы при равномерной плотности векторов входа нейроны также были распределены равномерно. Если векторы входа распределены неравномерно, то и нейроны будут иметь тенденцию распределяться в соответствии с плотностью размещения векторов входа.

Алгоритм:

1. Задать конфигурацию и размер карты (например – $l \times v = m$, где l и v – целые числа). Инициализировать начальные значения ядер $W_1^{(0)}, W_2^{(0)}, \dots, W_m^{(0)}$. Установить $k = 1$.

2. Нейронной сети случайным образом предъявляется объект n_k . Вычислить расстояния d_{kj} между вектором n_k и всеми ядрами $W_j, j = 1, 2, \dots, m$.

3. Определить нейрон-«победителя» (для которого расстояние d_{kj} минимально). Выполнить коррекцию весового вектора нейрона-«победителя» и его соседей на величину $A \cdot h_q(n_k - W_q^{(k-1)})$.

4. Проверить условие остановки (стабилизации ядер). Если весовые факторы ядер или ошибка обучения F не изменяются, то алгоритм завершает работу.

Иначе $k = k + 1$ и перейти к п. 2.

На практике, кроме решения задач кластеризации, карты Кохонена также используется для визуализации данных на топологической карте в пространстве латентных переменных и последующей оценки количества кластеров.

1.9. Стохастические методы поиска

В лекции рассматривается класс методов оптимизации, достаточно интенсивно используемый в ходе интеллектуального анализа данных – стохастические методы поиска.

Стохастические методы поиска позволяют находить глобальные экстремумы многомодальных функций. Как правило, данная задача характерна для анализа «грязных» экспериментальных данных (уровень экспериментального шума достаточно высок). Среди множества локальных экстремумов (например, минимумов) целевой функции необходимо определить истинный, т. е. глобальный экстремум (минимум), действительно соответствующий физическим параметрам исследуемых процессов.

Пусть задана некоторая многомодальная целевая функция Φ (рисунок 25, а), определяемая набором параметров A и представляющая собой меру совпадения экспериментальных и теоретических данных

$$\Phi(A) = f(E(t), F(A, t)),$$

где f – математический оператор для функции Φ ; $E(t)$ – набор экспериментальных данных; $F(A, t)$ – теоретическая функция; $A = \{a_1, a_2, \dots, a_K\}$ – вектор параметров, $\gamma_j < a_j < \beta_j$, $\gamma_j = \text{const}$ и $\beta_j = \text{const}$, $j = 1, 2, \dots, K$ – набор граничных условий для параметров. Необходимо определить глобальный минимум функции $\Phi(A)$. Традиционные алгоритмы нахождения экстремумов функций, такие как градиентные и поисковые методы оптимизации, неудовлетворительно справляются с решением данной задачи.




Рисунок 25 – Многомодальная функция (а) и этапы изменения температуры T в методе имитации отжига (б).

Наиболее эффективными методами решения задачи поиска экстремумов многомодальных функций являются стохастические методы поиска. К данной группе методов относятся методы случайного поиска, эволюционные и генетические алгоритмы.

1.9.1. Методы случайного поиска

Рассмотрим базовые алгоритмы случайного поиска, такие как простой стохастический поиск, случайный поиск, алгоритмы Метрополиса и имитации отжига.

Простой стохастический поиск. Процедура простого стохастического поиска заключается в вычислении целевой функции в N точках случайно подобранных комбинаций значений переменных. Среди N вычисленных величин функции находят минимальное значение, что соответствует глобальному минимуму функции. Выбор случайных точек может производиться различными способами. В простейшем случае N точек выбираются случайным образом в соответствии с равномерным законом распределения.

Алгоритм:

1. Сгенерировать N случайных точек $A_i = \{a_{i1}, a_{i2}, \dots, a_{iK}\}$, $i = 1, 2, \dots, N$.
2. Вычислить $\Phi(A_i)$, $i = 1, 2, \dots, N$.
3. Определить минимальное значение $\Phi(A_i)$.

Обычно на начальных этапах распределение для N точек является равномерным, а затем плотность вероятности изменяется в районе предполагаемого оптимума. Точность нахождения глобального минимума повышается и гарантируется при $N \rightarrow \infty$.

Случайный поиск. В данном методе поиск производится из какой-то одной начальной точки. Обычно задается начальная точка, объявляем ее текущей и вычисляем в ней значений целевой функции. Текущей точке придаем приращение в виде случайного вектора δ , и вычисляется значение целевой функции. Если значение целевой функции улучшилось, то данную точку делаем текущей. Иначе изменяем величину вектора приращения δ . Повторяем процедуру случайного поиска до выполнения условий сходимости алгоритма.

Алгоритм:

1. Выбрать случайным образом начальные приближения $A = A_0 = \{a_1^{(0)}, a_2^{(0)}, \dots, a_K^{(0)}\}$.
2. Вычислить $\Phi(A)$.
3. Сгенерировать шаг $\delta = \{\delta_1, \delta_2, \dots, \delta_K\}$ (δ_j – реализация нормальной случайной величины $N(0, \sigma^2)$).
4. Вычислить $\Phi(A + \delta)$.
5. Если $\Phi(A + \delta) < \Phi(A)$, то новая точка $A = A + \delta$.
Если $\Phi(A + \delta) > \Phi(A)$, то уменьшить шаг δ (изменив σ).
6. Проверка сходимости алгоритма. Если сходимость не достигнута, то перейти к п. 2.

Стоит отметить, что приращение в виде случайного вектора δ генерируется как нормальная случайная величина со средним 0 и среднеквадратическим отклонением σ . Параметр σ уменьшается по мере приближения к глобальному минимуму. Достижение глобального минимума достигается за счет стохастичности выбора нового приближения δ .

Метод Метрополиса. Приведенные выше методы простого стохастического поиска и случайного поиска имеют невысокую эффективность с точки зрения временных затрат и точности вычислений. Н.К. Метрополисом была предложена модификация алгоритма случайного поиска, которая включает вероятность движения в запрещенную область

$$P = \frac{1}{1 + \exp\left(\frac{\Phi(A + \delta) - \Phi(A)}{T}\right)},$$

где T – некоторый параметр. Вероятность движения в запрещенную область варьируется изменением значения параметра T .

Алгоритм:

1. Выбрать случайным образом начальные приближения $A = A_0$. Инициализировать параметр T .
2. Вычислить $\Phi(A)$.
3. Сгенерировать шаг $\delta = \{\delta_1, \delta_2, \dots, \delta_K\}$ (δ_j – реализация нормальной случайной величины $N(0, \sigma^2)$).
4. Вычислить $\Phi(A + \delta)$.
5. Если $\Phi(A + \delta) < \Phi(A)$, то новая точка $A = A + \delta$.
Если $\Phi(A + \delta) > \Phi(A)$, то новая точка $A = A + \delta$ с вероятностью P .
Иначе уменьшить шаг δ (изменив σ).
6. Проверка сходимости алгоритма. Если сходимость не достигнута, то перейти к п. 2.

Метод имитации отжига. Идеи Н.К. Метрополиса легли в основу метода имитации отжига, разработанного С. Киркпатриком в 1983 г. Метод имитации отжига основан на физических аналогиях.

Отжигом называется процесс нагрева вещества с последующим охлаждением. Вещество «отжигают» – нагревают до высокой температуры, а

затем медленно охлаждают, пошагово уменьшая температуру. Атомы вещества совершают незначительные перемещения, вероятность которых уменьшается с понижением температуры. На каждом шаге системе атомов дается некоторое время для того, чтобы большинство из них оказалось в состоянии с минимальной при данной температуре энергией. В конце концов атомы занимают состояния с некоторой потенциальной энергией, приближающейся к минимальной (рисунок 25, б).

В методе имитации отжига задается начальное состояние. Затем по принципу случайного блуждания генерируется новое состояние. Если значение целевой функции в новом состоянии лучше прежнего, то поиск продолжается из нового состояния. Иначе, случайным образом разыгрывается по вероятности $P = \exp(-(\Phi(A^*) - \Phi(A))/T)$ принятие решения из запрещенной области ($(\Phi(A^*) - \Phi(A)) > 0$). Как и в методе Метрополиса, для контроля движения в запрещенную область используется параметр T – температура. При уменьшении температуры движение в запрещенную область происходит менее интенсивно. Точность нахождения глобального минимума зависит от скорости понижения температуры (увеличивается при более медленном понижении температуры).

Алгоритм:

1. Выбрать случайным образом начальные приближения $A = A_0$. Задать $T_{\min}$, $T_{\max}$, скорость понижения температуры ν ($0 < \nu < 1$). Инициализировать параметр $T = T_{\max}$.

2. Генерация новых приближений $A^* = A + \delta$, $\delta = \{\delta_1, \delta_2, \dots, \delta_K\}$ (δ_j – реализация нормальной случайной величины $N(0, \sigma^2)$).

3. Вычислить $\Phi(A)$ и $\Phi(A^*)$.

4. Если $\Phi(A^*) < \Phi(A)$, то новая точка $A^* = A$.

Иначе вычислить $P = \exp(-(\Phi(A^*) - \Phi(A))/T)$.

Если $z < P$, z – реализация равномерной случайной величины в интервале $[0, 1]$, то новая точка $A^* = A$.

Иначе $T = \nu \cdot T$.

5. Проверка сходимости алгоритма. Если сходимость не достигнута, то перейти к п. 2.

На практике реализации метода имитации отжига определяются выбором закона понижения температуры, способом генерации положения новой точки, выражением для вероятности принятия пробной точки. Так, например, случайный вектор приращений δ может являться функцией температуры

$$\delta = z T,$$

или

$$\delta = z \cdot T \left[\left(1 + \frac{l}{T} \right)^{2\xi-1} - 1 \right],$$

где $z = \{z_1, z_2, \dots, z_K\}$ – вектор реализаций нормальной стандартизированной случайной величины $N(0, 1)$, $\xi = \{\xi_1, \xi_2, \dots, \xi_K\}$ – вектор реализаций равномерно

распределенной случайной величины в интервале $[0, 1]$; l – номер текущей итерации метода.

1.9.2. Эволюционные стратегии случайного поиска

Эволюционные стратегии случайного поиска основаны на подражании идеям эволюции с помощью естественного отбора (Ч. Дарвин). Экспериментальные данные рассматриваются в терминах теории эволюций живого мира.

Основные выводы из теории Дарвина «Происхождение видов»:

Все популяции имеют потенциал для экспоненциального роста численности (т. е. для выживания).

Потомки стремятся иметь полное сходство с родителями.

Небольшие вариации в потомках значительно повышают вероятность выживания.

Индивидуумы, чьи вариации (мутации) наиболее приспособлены к условиям внешней среды, имеют наибольшую вероятность к выживанию (естественный отбор).

Рассмотрим основные термины и определения, используемые в алгоритмах эволюционного поиска (рисунок 26).




Рисунок 26 – Представление экспериментальных данных в терминах теории эволюций.

Живые организмы состоят из клеток, которые имеют одинаковый набор хромосом. Хромосомы являются ключевыми элементами организма.

Хромосома (аналог параметра a_j в методах случайного поиска) состоит из генов, блоков ДНК. Каждый ген кодирует соответствующий ему белок. Если мы переведем параметр в двоичную систему счисления, то получим последовательность 0 и 1, где каждый бит информации будет кодировать один ген (1 – ген выражен, т. е. клетка синтезирует заданный белок, 0 – ген подавлен, синтеза белка не происходит).

Особь (индивидуум) – набор из заданного количества хромосом (одно из возможных решений задачи или набор параметров) $n_i = \{a_{i1}, a_{i2}, \dots, a_{iK}\}$.

Популяция – набор особей $n_1, n_2, \dots, n_N$.

Приспособленность к выживанию – функция полезности или пригодности каждой особи в популяции ($y_i = \Phi(n_i)$).

Селекция – процедура нахождения наиболее приспособленных особей ($y_i \rightarrow \min$).

Скрещивание – выбор двух наиболее приспособленных особей и обмен их генами.

Мутация – небольшое случайное изменение гена.

Поклоение – эволюционный процесс, в результате которого родители меняются на своих потомков.

Эволюция – чередование поколений, в которых хромосомы изменяют свои значения так, чтобы каждое новое поколение наилучшим способом приспособлялось к внешней среде.

Естественный отбор – процесс формирования новой популяции из старой, после чего старая популяция погибает.

Таким образом, эволюционные алгоритмы работают с совокупностью особей, или популяцией. Каждая особь представляет собой возможное решение задачи и оценивается мерой ее приспособленности к внешним условиям. Наиболее приспособленные особи получают возможность воспроизводить потомков с помощью перекрестного скрещивания. Это приводит к появлению новых особей, сочетающих в себе некоторые полезные характеристики, наследуемые от родителей. Наименее приспособленные особи с наименьшей вероятностью воспроизводят потомков, поэтому свойства, присущие им, будут постепенно исчезать из популяции в процессе эволюции. Базовый принцип эволюционного развития по Дарвину представлен на рисунке 27.

В результате процессов эволюции необходимо вывести особь с наилучшей приспособленностью, т. е. найти набор параметров $n_i = \{a_{i1}, a_{i2}, \dots, a_{iK}\}$, обеспечивающий глобальный минимум целевой функции Φ .



Рисунок 27 – Базовый принцип эволюционного развития по Дарвину.

Рассмотрим подробнее основные этапы эволюции.

Селекция. Селекция родителей для формирования потомков, как и процедура отбора решений очередного поколения, может иметь

стохастическую, детерминистическую либо смешанную природу. Для нахождения наиболее приспособленных особей широко используются методы рулетки, турнирного отбора и стратегии элитизма.

Метод рулетки. В методе рулетки вероятность отбора каждого индивидуума популяции пропорциональна приспособленности конкретного индивида. Необходимое число решения отбирается запусками рулетки. Колесо рулетки содержит по одному сектору для каждого индивидуума популяции. Размер i -го сектора пропорционален приспособленности соответствующего индивидуума.

Алгоритм:

Вычислить пропорциональную приспособленность каждой особи n_i , $i = 1, 2, \dots, N$.

$$p(n_i) = \frac{\Phi(n_i)}{\sum_{j=1}^N \Phi(n_j)}.$$

По методу рулетки (используя датчик случайных чисел) выбрать для скрещивания $N/2$ наиболее приспособленных особей.

Турнирный отбор. Пример смешанной стратегии – турнирный отбор, при котором выбирается случайный набор индивидуумов (чаще всего это пара) имеющий лучшую приспособленность и проходит турнир. Турнирный отбор может реализовать $N/2$ турниров, чтобы выбрать $N/2$ особей. Каждый турнир построен на выборке k элементов из популяции, и отбора лучшей особи среди них. Наиболее распространен турнирный отбор с $k = 2$.

Стратегия элитизма. Стратегия элитизма предполагает передачу наиболее перспективных решений из поколения в поколение с целью обеспечить их сохранение в процедуре отбора. Особи с наибольшей приспособленностью гарантировано переходят в новую популяцию. Использование элитизма обычно позволяет ускорить сходимость генетического алгоритма. Однако повышается вероятность попадания алгоритма в локальный минимум.

Скрещивание. Скрещивание осуществляет обмен частями хромосом между двумя (может быть и больше) особями в популяции. Скрещивание может быть одноточечным или многоточечным (рисунок 28).

Необходимо среди $N/2$ пар выполнить попарно скрещивание так, чтобы от каждой пары родителей образовалось по паре потомков. Потомок определяется как конкатенация части первого и второго родителя.

Мутация. При применении оператора мутации для каждой особи производится небольшое случайное изменение j -го параметра с определенной вероятностью p_j .

Основное отличие эволюционных алгоритмов от генетических состоит в том, что эволюционные стратегии поиска используют только операции селекции и мутации. Поэтому эволюционные алгоритмы нашли применение

при исследовании малых популяций. Генетические алгоритмы используют еще и скрещивание, что характерно для больших популяций.

	Родители		Потомки
Одноточечное скрещивание:	<u>11101001000</u> 00001010101	$\Rightarrow$	11101010101 00001001000
Двухточечное скрещивание:	<u>11101001000</u> 00 <u>001010101</u>	$\Rightarrow$	<u>11001011000</u> 00101000101
Многоточечное скрещивание:	<u>11101001000</u> 00 <u>001010101</u>	$\Rightarrow$	<u>10001000100</u> 01101011001

Рисунок 28 – Генетические операции скрещивания.

Базовый алгоритм эволюционной стратегии поиска:

1. Задать N , Φ , k , число поколений M , $l = 0$. Сгенерировать начальную популяцию $A_0 = \{n_1^{(0)}, n_2^{(0)}, \dots, n_N^{(0)}\}$.
2. Вычислить приспособленность y_i каждой особи n_i , $i = 1, 2, \dots, N$, и популяции в целом (например, $\sum y_i$).
3. *Селекция*. Отбор k наиболее приспособленных особей.
4. *Мутация*. Для каждой приспособленной особи генерируется потомок путем изменения j -го параметра с вероятностью p_j .
Поместить k наиболее приспособленных потомков в новую популяцию.
5. Выполнить операции п. 3–4 ($N/k - 1$) раз.
6. Проверка сходимости алгоритма.
Если сходимость достигнута ($l > M$), то завершить поиск.
Иначе $l = l + 1$ и перейти к п. 2.

1.9.3. Генетические алгоритмы

Генетические алгоритмы представляют собой развитие эволюционных стратегий случайного поиска, включают этапы скрещивания в больших объемах популяций и ориентированы на работу с параметрами, закодированными в двоичном коде.

Классическое кодирование набора параметров в хромосомах генетических алгоритмов осуществляется с помощью бинарных строк. При бинарном кодировании отдельный параметр решения кодируется в строку некоторым числом двоичных битов m . Причем m может быть различным для каждого параметра. Бинарная строка по-другому называется генотипом, а биты – генами.

В генетических алгоритмах случайным образом выбирают начальный набор особей и переводят их хромосомы в двоичный код. Принцип работы классического генетического алгоритма представлен на рисунке 29.




Рисунок 29 – Структура и принцип работы классического генетического алгоритма.

Базовый генетический алгоритм:

1. Задать N , Φ , число поколений M , $l = 0$. Сгенерировать начальную популяцию $A_0 = \{n_1^{(0)}, n_2^{(0)}, \dots, n_N^{(0)}\}$.
2. Вычислить приспособленность y_i каждой особи n_i , $i = 1, 2, \dots, N$, и популяции в целом (например, $\sum y_i$).
3. *Селекция*. Выбрать особи n_i и n_j из популяции.
4. *Скрещивание*. Выполнить скрещивание особей n_i и n_j .
5. *Мутация*. Для потомков особей n_i и n_j выполнить операцию мутации.
6. Поместить наиболее приспособленного потомка в новую популяцию.
7. Выполнить операции п. 3–6 ($N-1$) раз.
8. Если сходимость достигнута ($l > M$), то завершить поиск. Иначе $l = l + 1$ и перейти к п. 2.

Существующие генетические алгоритмы различаются по механизму кодирования (двоичный код, код Грея), функции качества приспособленности (например, критерии χ^2 или Колмогорова), процедуре селекции (метод рулетки, турнир, элитизм), генерации разнообразия эволюционной изменчивости (скрещивание, мутация), настройке системных параметров, условия остановки алгоритма, способам инициализации начальной популяции.

Достоинства генетических алгоритмов: глобальная оптимизация; простота в реализации; не требуют вычисления производных; параллелизм; высокая степень интеграции с другими методами оптимизации.

К основному недостатку следует отнести медленную сходимость, особенно в области глобального экстремума.

1.10. Методы классификации. деревья решений

1.10.1. Деревья решений

Деревья решений – один из методов автоматического анализа данных, в основном используется для решения задач классификации. Рассмотрим задачу классификации более подробно.

Пусть выполняется анализ некоторого набора данных $(n_1, n_2, \dots, n_N)$, полученных из базы данных или эксперимента. Допускается, что для L объектов

(эталонной выборки) значения зависимой переменной $y_1, y_2, \dots, y_L$ известны и дискретны (являются метками m -классов), а для $N - L$ объектов (тестируемой выборки) значения $y_{L+1}, y_{L+2}, \dots, y_N$ не известны и должны быть определены. Независимые переменные $X_1, X_2, \dots, X_K$ могут иметь любое распределение. Группа объектов $n_1, n_2, \dots, n_L$ называется *обучающей* или *эталонной выборкой*. Группа объектов $n_{L+1}, n_{L+2}, \dots, n_N$ называется *тестируемой выборкой*.

Задача классификации состоит в определении неизвестных значений зависимой переменной $y_{L+1}, y_{L+2}, \dots, y_N$ и классификации $N - L$ объектов в m классов.

Деревья решений – это один из методов нахождения правил или решений $y_{L+1}, y_{L+2}, \dots, y_N$, где каждому объекту n_i соответствует единственный узел, дающий решение y_i .

Правило – логическая конструкция, представленная в виде «если ... то» («if ... then»). Пример графа дерева решений представлен на рисунке 30.




Рисунок 30 – Пример графа дерева решений.

Основной принцип использования дерева решений состоит в следующем. Берем объект n_i и двигаемся от вершины иерархического графа (корень дерева) вниз по дереву, правильно отвечая на вопросы, расположенные в узлах дерева. В конечном счете, добираемся до правильного ответа – решения.

Узел дерева представляет собой расщепление, осуществляемое по признаку X_j .

Максимальное количество расщеплений в одном узле X_j равно количеству дискретных значений, принимаемых признаком X_j . Если признак X_j принимает непрерывные значения, то для него выполняется процедура дискретизации.

Листом дерева называется конечный узел дерева, узел решения. Листья дерева представляют собой метки классов.

Таким образом, движение осуществляется от корня к листьям по принципу построения вопросов или правил к признаку текущего узла. Для составления правил используются логические операторы «And», «Or», «Nor».

1.10.2. Анализ данных с использованием деревьев решений

Основные этапы построения деревьев решений.

1. Отбор обучающей и тестируемой выборок.

2. Построение дерева по обучающей выборке.
 - I) Анализ признаков объектов.
 - II) Определение критерия или функции качества разбиения узлов дерева (индекс Джини, энтропия, ошибка классификации).
 - III) Определение атрибутов узлов дерева.
 - IV) Остановка построения и сокращение дерева.
 - V) Обработка пропущенных значений.
3. Сокращение дерева.
4. Извлечение правил из деревьев решений.
5. Анализ тестируемой выборки.

Рассмотрим подробнее ключевые элементы этапов построения деревьев решений.

Анализ признаков объектов. В основе построения большинства методов деревьев решений лежит методика «разделяй и властвуй». Общий принцип методики заключается в рекурсивном разбиении множества объектов из обучающей выборки на подмножества, содержащие объекты, относящиеся к одинаковым классам. Сформулируем действия, выполняемые в рамках данной методики:

1. Для текущего узла дерева определить наиболее значимый признак из K признаков в соответствии с выбранным критерием качества разбиения узла.
2. Разделить множество объектов эталонной выборки в данном узле на несколько подмножеств на основе отобранного наиболее значимого признака и произвести последующее расщепление.
3. Если в узлах-потомках объекты принадлежат к одному классу – завершить построение соответствующих ветвей (или дерева, если построены все ветви). Иначе для каждого из узлов-потомков и соответствующих им подмножеств, определенных на предыдущем шаге рекурсивно выполнить анализ (перейти к п. 1).

Критерии и функции качества разбиения. Функции качества разбиения (критерии разбиения) должны удовлетворять следующим свойствам:

1. В узлах должно производиться такое разбиение, чтобы полученные подмножества ассоциировались с данным узлом проверки.
2. Объекты подмножеств, получаемых в результате разбиения, должны являться представителями одного класса или максимально приближенными к такому разбиению.
3. Количество объектов из других классов («примесей») в каждом классе должно стремиться к минимуму.

Рассмотрим основные критерии разбиения.

Индекс Джини. Индекс Джини характеризует меру неопределенности в узле t :

$$G(t) = 1 - \sum_{j=1}^m [p(j|t)]^2,$$

где $p(j|t)$ – относительная частота класса C_j в узле t ; m – число классов. С помощью индекса Джини осуществляется выбор атрибута на основе

расстояний между классами. Индекс Джини достигает максимального значения $1 - m^{-1}$, когда объекты распределены равномерно по всем классам и минимального значения 0, когда все объекты размещены в одном классе. В последнем случае выбор атрибута или признака наиболее эффективен.

После того как осуществлен выбор признака для узла t , необходимо определить на какое количество узлов-потомков расщепить исходный узел t (рисунок 31).




Рисунок 31 – Пример разбиения узла на два (а) и более чем два (б) узла-потомка.

Качество расщепления узла t на k потомков определяется на основе индекса Джини:

$$G_s(t) = \sum_{i=1}^k \frac{M_{t_i}}{M_t} G(t_i),$$

где M_t – число объектов в узле t ; M_{t_i} – число объектов в t_i -м узле-потомке. Наилучшим считается то разбиение, для которого $G_s(t)$ минимально.

Энтропия (или информационная энтропия). Энтропия является оценкой меры неопределенности в узле t :

$$E(t) = - \sum_{j=1}^m p(j|t) \log_2 p(j|t),$$

где $p(j|t)$ – относительная частота класса C_j в узле t ; m – число классов. Энтропия достигает максимума ($\log_2 m$) когда все объекты распределены по всем классам. Выбор признака не эффективен. Энтропия достигает минимума (0), когда все объекты размещены в одном классе классов. В этом случае выбор признака эффективен.

Качество расщепления узла t на k потомков оценивается на основе коэффициента прироста информации:

$$GI_s(t) = E(t) - \sum_{i=1}^k \frac{M_{t_i}}{M_t} E(t_i),$$

где M_t – число объектов в узле t ; M_{t_i} – число объектов в t_i -м узле-потомке. Наилучшим считается то разбиение, для которого $GI_s(t)$ максимально.

Данный критерий имеет тенденции к установлению большого количества расщеплений и к выбору признаков, имеющих наибольшее количество значений. Для устранения недостатков критерия информационного расщепления используется критерий отношения информации

$$GI'_s(t) = - \frac{GI_s(t)}{\sum_{i=1}^k \frac{M_{t_i}}{M_t} \log_2 \left(\frac{M_{t_i}}{M_t} \right)}.$$

В критерии отношения информации экстра-информационное расщепление на основе энтропии штрафуются.

Ошибка классификации. Ошибка классификации в узле t вычисляется как

$$Er(t) = 1 - \max_j p(j|t),$$

где $p(j|t)$ – относительная частота класса C_j в узле t ; $j = 1, 2, \dots, m$ – число классов.

Ошибка классификации достигает максимального значения $(1 - m^{-1})$, когда все объекты распределены по всем классам. Ошибка классификации минимальна (0), когда все объекты размещены в одном классе. Выбор признака эффективен.

Остановка построения дерева. *Остановка* – такой момент в процессе построения дерева, когда следует прекратить дальнейшее ветвление. Правило остановки должно определять, является ли рассматриваемый узел внутренним узлом (т. е. разбивается дальше) или же он конечный узел, или решение.

Выделяют три варианта остановки построения дерева.

1. «*Ранняя остановка*» (prepruning) определяет целесообразность дальнейшего разбиения узла на основе одного из выбранных критериев. Например, если индекс Джини перестает изменяться от узла к узлу, то прекратить ветвление.

2. Ограничение глубины дерева. Построение заканчивается, если достигнута заданная глубина дерева (например, определено некоторое суммарное количество узлов в дереве или задана максимальная длина цепи узлов).

3. Задание минимального количества объектов, которые будут содержаться в конечных узлах дерева.

Сокращение дерева. Процедура *сокращения* дерева используется для отсечения наименее информативных ветвей дерева с целью устранения избыточной информации и приведения дерева решений к более компактному виду, удобному для последующей интерпретации (рисунок 32). Деревья, получаемые после отсечения некоторых ветвей, называют *усеченными*.

Основное правило сокращения деревьев – ветвь отсекается в том узле, где эта процедура не приводит к значительному возрастанию ошибки классификации. На практике для оценки размера дерева используются методы перекрестной проверки. Простая перекрестная проверка состоит в том, что обучающая выборка случайным образом делится на две выборки – условно обучающую и тестируемую. Применим разработанное дерево к тестируемой выборке. Необходимо последовательно отсекал ветку в каждом узле дерева. Если усеченное дерево справляется с тестами классификации не хуже или лучше, чем неусеченное дерево, то оставить дерево сокращенным. Иначе – вернуть ветку. Отсеченную ветвь заменяют на значение, которое принимает большинство объектов на данной ветви.




Рисунок 32 – Пример отсечения ветвей дерева.

Обработка пропущенных значений. Если у каких-либо объектов в обучающей выборке есть пропущенные значения (NA), то основной принцип построения дерева решений не изменяется. В узле с пропущенными значениями признака возможны несколько стратегий. Например, можно заменить пропущенное значение значением по умолчанию или медианным значением по признаку или добавить специальную ветвь.

Если есть пропущенные значения у объектов из тестируемой выборки, то используются аналогичные подходы: замена пропущенного значения на значение по умолчанию или на медианное значение по заданному признаку, перемещение в сторону накопления большего числа событий или движение по специальной ветви, предназначенной для обработки пропущенных значений.

Извлечение правил из деревьев. После завершения этапа построения дерева из дерева необходимо извлечь правила. Наибольшую популярность получил алгоритм 1R построения правил. Правило строится по принципу «если ... то ...». Результатом правила является метка класса, характерная для наибольшего числа объектов из данного класса.

Пример расщепления узла дерева X_j приведен на рисунке 33. Для узла X_j строятся три правила:

- 1) если $X_j = 1$, то $y = 0$, $Er = 1 - 3/5 = 2/5$;
- 2) если $X_j = 2$, то $y = 1$, $Er = 1 - 4/4 = 0$;
- 3) если $X_j = 3$, то $y = 1$, $Er = 1 - 3/5 = 2/5$.

Ошибка классификации Er характеризует точность выполнения правила.




Рисунок 33 – Пример расщепления узла дерева X_j .

1.10.3. Алгоритмы построения деревьев решений

В литературе описано множество алгоритмов построения деревьев решений, среди которых можно выделить алгоритмы ID3, покрытия, CART и C4.5. Рассмотрим подробнее базовые и наиболее простые алгоритмы, такие как ID3 и алгоритм покрытия.

Алгоритм ID3 (Induction of dimension). Алгоритм использует рекурсивное разбиение подмножеств в узлах дерева по одному из выбранных атрибутов. Идея метода фактически не отличается от основных принципов построения деревьев, изложенных выше. В качестве критерия разбиения узлов дерева используются критерии информационной энтропии и прироста информации.

Рассмотрим пример построения дерева решений. Набор экспериментальных данных (наблюдений $N = 14$ объектов) представлен в таблице 10.

Таблица 10 – Исходный набор данных.

Объекты	X_1	X_2	X_3	X_4	Y	Объекты	X_1	X_2	X_3	X_4	Y
n_1	1	1	1	2	0	n_8	1	2	1	2	0
n_2	1	1	1	1	0	n_9	1	3	2	2	1
n_3	2	1	1	2	1	n_{10}	3	2	2	2	1
n_4	3	2	1	2	1	n_{11}	1	2	2	1	1
n_5	3	3	2	2	1	n_{12}	2	2	1	1	1
n_6	3	3	2	1	0	n_{13}	2	1	2	2	1
n_7	2	3	2	1	1	n_{14}	3	2	1	1	0

Рассмотрим четыре варианта разбиения исходных данных по четырем признакам (рисунок 34).




Рисунок 34 – Четыре варианта разбиения первоначального разбиения дерева для разных переменных.

Рассмотрим значение энтропии исходного множества по признакам X_1 , X_2 , X_3 , X_4 до разбиения. Значение исходной энтропии:

$$E = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0,94.$$

Значение энтропии по трем узлам-потомкам признака X_1

$$E(X_1 = 1) = -\frac{2}{5} \log_2 \left(\frac{2}{5} \right) - \frac{3}{5} \log_2 \left(\frac{3}{5} \right) = 0,97,$$

$$E(X_2 = 2) = -\frac{4}{4} \log_2 \left(\frac{4}{4} \right) - \frac{0}{4} \log_2 \left(\frac{0}{4} \right) = 0,$$

$$E(X_3 = 3) = -\frac{3}{5} \log_2 \left(\frac{3}{5} \right) - \frac{2}{5} \log_2 \left(\frac{2}{5} \right) = 0,97.$$

Вычислим коэффициент прироста информации для признака X_1 ($k = 3$):

$$GI_S(X_1) = 0,94 - \left(\frac{5}{14} \cdot 0,97 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0,97 \right) = 0,94 - 0,69 = 0,25.$$

По аналогии вычислим значения коэффициента прироста информации по остальным признакам: $GI_S(X_2) = 0,03$, $GI_S(X_3) = 0,15$ и $GI_S(X_4) = 0,05$. Максимальный коэффициент прироста информации 0,25 для признака X_1 , поэтому в качестве корня дерева необходимо выбрать признак X_1 и выполнить по нему разбиение.

Рассмотрим построение дерева по признаку X_1 .

$X_1 = 1$ (таблица 11). Выберем в данном узле дерева следующую переменную для разбиения, исключив переменную X_1 . Три варианта разбиения данных представлены на рисунке 35.

Таблица 11 – Множество объектов в узлах-потомках $X_1 = 1$ и $X_1 = 3$ для разбиения узла X_1 .

$X_1 = 1$						$X_1 = 3$					
Объекты	X_1	X_2	X_3	X_4	Y	Объекты	X_1	X_2	X_3	X_4	Y
n_1	1	1	1	2	0	n_4	3	2	1	2	1
n_2	1	1	1	1	0	n_5	3	3	2	2	1
n_8	1	2	1	2	0	n_6	3	3	2	1	0
n_9	1	3	2	2	1	n_{10}	3	2	2	2	1
n_{11}	1	2	2	1	1	n_{14}	3	2	1	1	0




Рисунок 35 – Возможные разбиения дерева для объектов подмножества $X_1 = 1$.

Рассчитаем коэффициенты прироста информации для расщепления узла-потомка $X_1 = 1$ для признаков X_2 , X_3 , X_4 : $GI_S(X_2) = 0,57$, $GI_S(X_3) = 0,97$ и

$GI_S(X_4)=0,02$. Таким образом, следующим признаком, по которому произойдет разбиение ветви узла $X_1 = 1$, будет признак X_3 . Дальнейшее разбиение этой ветви уже не потребуется, так как в получившихся подмножествах все объекты относятся только к одному классу.

$X_1 = 2$. Дальнейшее разбиение этой ветви не потребуется, так как в получившемся подмножестве все объекты относятся только к одному классу.

$X_1 = 3$ (таблица 11). Три варианта разбиения данных представлены на рисунке 36. Рассчитаем коэффициенты прироста энтропии для расщепления узла-потомка $X_1 = 3$ для признаков X_2, X_3, X_4 : $GI_S(X_2)=0,02$, $GI_S(X_3)=0,02$ и $GI_S(X_4)=0,97$. Следующим признаком, по которому произойдет разбиение ветви узла $X_1 = 3$, будет признак X_4 .




Рисунок 36 – Возможные разбиения дерева для объектов подмножества $X_1 = 3$.

Дальнейшее разбиение этой ветви не требуется. Построенное дерево будет выглядеть так, как изображено на рисунке 37. Извлекаем правила из дерева решений:

- 1) если $X_1 = 1$ и $X_3 = 1$, то $y = 0$;
- 2) если $X_1 = 1$ и $X_3 = 2$, то $y = 1$;
- 3) если $X_1 = 2$, то $y = 1$;
- 4) если $X_1 = 3$ и $X_4 = 1$, то $y = 0$;
- 5) если $X_1 = 1$ и $X_3 = 2$, то $y = 1$.

Теперь классифицируем некоторый объект из тестируемой выборки, например $n_{15} = (1, 1, 1, 1)$.

Данный объект подчиняется правилу 1, т. е. метка его класса – $y_{15} = 0$.




Рисунок 37 – Дерево решений.

Следует отметить, что в данном примере признак X_2 используется только для построения дерева, но не используется для классификации объектов из тестируемой выборки (в силу своей невысокой информационной значимости).

Алгоритм покрытия. Алгоритм покрытия заключается в построении деревьев решений для каждого класса в отдельности. На каждом этапе генерируется проверка узла дерева, который покрывает или разделяет множество объектов обучающей выборки на два подмножества, одно из которых содержит объекты только одного класса. Разбиение производится до тех пор, пока не будет построено подмножество, содержащие объекты только одного класса (рисунок 38).




Рисунок 38 – Геометрическая интерпретация идеи алгоритма покрытия.

1.11. Методы классификации на основе байесовских сетей и расстояний

1.11.1. Байесовская классификация

Байесовская классификация является одним из наиболее распространенных методов интеллектуального анализа данных. Другие названия метода: байесовское моделирование, байесовская статистика, метод байесовских сетей. Часто метод байесовской классификации называют наивным подходом, потому что он исходит из положения о взаимной независимости признаков.

В основе байесовской классификации лежат следующие предположения:

- 1) все переменные или признаки $X_1, X_2, \dots, X_K$ являются одинаково важными и статистически независимыми;
- 2) предполагается, что перед началом классификации определенный процент данных принадлежит конкретному классу.

Введем обозначения:

$P(y = C_r)$ – априорная вероятность того, что рассматриваемый объект (например – n_i) относится к классу C_r , $r = 1, 2, \dots, m$.

E – событие, соответствующие равенству элементов произвольного объекта n_i конкретным значениям b_j , $j = 1, 2, \dots, K$, т.е. $n_i = (x_{i1} = b_1, x_{i2} = b_2, \dots, x_{iK} = b_K)$.

$P(E)$ – вероятность наступления события E .

$P(x_{ij} = b_j | y = C_r)$ – условная вероятность равенства j -й переменной объекта n_i некоторому значению b_j при условии принадлежности объекта n_i к классу C_r .

$P(E | y = C_r)$ – условная вероятность наступления события E или равенства элементов объекта n_i конкретным значениям b_j , $j = 1, 2, \dots, K$ при условии, что объект n_i относится к классу C_r .

Идея алгоритма байесовской классификации заключается в расчете условной вероятности принадлежности объекта n_i к классу C_r при равенстве его независимых переменных x_{ij} определенным значениям b_j , $j = 1, 2, \dots, K$. Из теории вероятностей известно, что данную условную вероятность можно вычислить по формуле

$$P(y = C_r | E) = \frac{P(E | y = C_r)P(y = C_r)}{P(E)},$$

где

$$P(E) = \sum_{r=1}^m P(E | y = C_r)P(y = C_r).$$

Другими словами, формируются правила, в условных частях которых сравниваются все независимые переменные с возможными значениями. В заключительной части присутствуют все возможные значения зависимой переменной. Например, если $x_{i1} = b_1$ и $x_{i2} = b_2$ и ... и $x_{iK} = b_K$, то $y = C_r$.

Для каждого из этих правил по формуле Байеса определяется его вероятность. Предполагая, что переменные принимают значения независимо друг от друга, выразим условную вероятность $P(E | y = C_r)$, или апостериорную вероятность того, что рассматриваемый объект относится к классу C_r , $r = 1, 2, \dots, m$, через произведение вероятностей для каждой независимой переменной

$$\begin{aligned} P(E | y = C_r) &= P(x_{i1} = b_1 | y = C_r) \times P(x_{i2} = b_2 | y = C_r) \times \dots \\ &\dots \times P(x_{iK} = b_K | y = C_r) = \prod_{j=1}^K P(x_{ij} = b_j | y = C_r). \end{aligned}$$

Тогда вероятность всего правила

$$P(y = C_r | E) = \frac{\left[\prod_{j=1}^K P(x_{ij} = b_j | y = C_r) \right] P(y = C_r)}{P(E)}, \quad (7)$$

где

$$P(x_{ij} = b_j | y = C_r) = \frac{P(x_{ij} = b_j \text{ и } y = C_r)}{P(y = C_r)}. \quad (8)$$

Таким образом, для объекта из тестируемой выборки $n_i = (x_{i1} = b_1, x_{i2} = b_2, \dots, x_{iK} = b_K)$ необходимо предсказать метку класса y_i . Причем, метка класса y_i должна быть такой чтобы максимизировать вероятность $P(E | y = C_r)$.

Алгоритм байесовской классификации:

1. По обучающей выборке рассчитать априорные вероятности $P(y = C_r)$, $r = 1, 2, \dots, m$.
2. Для элементов объекта n_i из тестируемой выборки рассчитать условные вероятности по формуле (8).
3. Рассчитать апостериорные вероятности принадлежности события E (т. е. событие объекта n_i) к каждому из классов по формуле (7).
4. Объект n_i классифицируется к тому классу, условная вероятность которого максимальна.

Пример. Рассмотрим использование метода байесовской классификации на примере анализа экспериментальных данных таблицы 11.

Рассчитаем неизвестные вероятности по формулам (7) и (8). Вероятности того, что рассматриваемый объект n_i относится к классу $C_1 = 1$ и $C_2 = 0$:

$$P(y=1) = \frac{9}{14} \text{ и } P(y=0) = \frac{5}{14}.$$

Возможные условные вероятности для определенных значений признака X_1 :

$$P(X_1=1 | y=1) = \frac{P(X_1=1 \text{ и } y=1)}{P(y=1)} = \frac{2/14}{9/14} = 2/9,$$

$$P(X_1=2 | y=1) = \frac{P(X_1=2 \text{ и } y=1)}{P(y=1)} = \frac{4/14}{9/14} = 4/9,$$

$$P(X_1=3 | y=1) = \frac{P(X_1=3 \text{ и } y=1)}{P(y=1)} = \frac{3/14}{9/14} = 1/3,$$

$$P(X_1=1 | y=0) = \frac{P(X_1=1 \text{ и } y=0)}{P(y=0)} = \frac{3/14}{5/14} = 3/5,$$

$$P(X_1=2 | y=0) = \frac{P(X_1=2 \text{ и } y=0)}{P(y=0)} = \frac{0/14}{5/14} = 0,$$

$$P(X_1=3 | y=0) = \frac{P(X_1=3 \text{ и } y=0)}{P(y=0)} = \frac{2/14}{5/14} = 2/5;$$

признака X_2 (без промежуточных вычислений):

$$P(X_2=1 | y=1) = 2/9, \quad P(X_2=2 | y=1) = 4/9, \quad P(X_2=3 | y=1) = 1/3, \\ P(X_2=1 | y=0) = 2/5, \quad P(X_2=2 | y=0) = 2/5, \quad P(X_2=3 | y=0) = 1/5;$$

признака X_3 :

$$P(X_3=1 | y=1) = 1/3, \quad P(X_3=2 | y=1) = 2/3, \quad P(X_3=3 | y=1) = 0, \\ P(X_3=1 | y=0) = 4/5, \quad P(X_3=2 | y=0) = 1/5, \quad P(X_3=3 | y=0) = 0;$$

признака X_4 :

$$P(X_4=1|y=1)=1/3, \quad P(X_4=2|y=1)=2/3, \quad P(X_4=3|y=1)=0, \\ P(X_4=1|y=0)=3/5, \quad P(X_4=2|y=0)=2/5, \quad P(X_4=3|y=0)=0.$$

Теперь классифицируем некоторый объект из тестируемой выборки, например, $n_{15} = (1, 1, 1, 1)$. Его условные вероятности

$$P(y=1|E) = P(X_1=1|y=1) \times P(X_2=1|y=1) \times P(X_3=1|y=1) \times \\ \times P(X_4=1|y=1) \times P(y=1) / P(E)$$

и

$$P(y=0|E) = P(X_1=1|y=0) \times P(X_2=1|y=0) \times P(X_3=1|y=0) \times \\ \times P(X_4=1|y=0) \times P(y=0) / P(E).$$

Подставляя числовые значения, получим

$$P(y=1|E) = \frac{\frac{2}{9} \times \frac{2}{9} \times \frac{1}{3} \times \frac{1}{3} \times \frac{9}{14}}{P(E)} \approx \frac{0,0035}{P(E)},$$

$$P(y=0|E) = \frac{\frac{3}{5} \times \frac{2}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{5}{14}}{P(E)} \approx \frac{0,0411}{P(E)}.$$

Подставим значение для вероятности $P(E)$ ($= 0,0035 + 0,0411$):

$$P(y=1|E) = \frac{0,0035}{0,0035 + 0,0411} = 0,08$$

$$P(y=0|E) = \frac{0,0411}{0,0035 + 0,0411} = 0,92.$$

Таким образом, при указанных условиях наиболее вероятно объект $n_{15} = (1, 1, 1, 1)$ относится к классу $C_2 = 0$.

Байесовская классификация хорошо работает в случае пропущенных значений. При подсчете вероятностей пропущенные значения просто пропускаются из правил. Это не влияет на соотношение вероятностей.

Если в тестируемой выборке нет ни одного значения $x_{ij} = b_j$, то вероятность такого правила равна нулю. Чтобы избежать этого, к каждой вероятности добавляется некоторое малое значение отличное от нуля.

Достоинства байесовских сетей: сети достаточно просто интерпретируются и позволяют проводить анализ по сценарию «что ... если ...», а также позволяют избежать проблемы переучивания (избыточного усложнения модели).

Недостатки: на практике признаки часто зависимы, тогда перемножение условных вероятностей некорректно; для непрерывных переменных требуется предварительная дискретизация, это может привести к потере значимых закономерностей.

1.11.2. Метод k -ближайших соседей

Метод k -ближайших соседей (от англ. k -nearest neighbour algorithm, kNN) – метод автоматической классификации объектов. Основным принципом метода

ближайших соседей является то, что объект присваивается тому классу, который является наиболее распространенным среди соседей данного элемента (рисунок 39). Соседи берутся из множества объектов, классы которых уже известны, и исходя из ключевого для данного метода значения k , высчитывается, какой класс наиболее многочислен среди них.




Рисунок 39 – К-ближайших соседей к объекту n_i .

В методе k -ближайших соседей требуются: объекты эталонной выборки $n_1, n_2, \dots, n_L$, метрика для расчета расстояния между объектами выборки, число k ближайших соседей. Классификация неизвестного объекта n_i из тестируемой выборки производится следующим образом:

1) для объекта n_i задается радиус R области, содержащий k_R ближайших соседей-объектов из обучающей выборки, или определяются k ближайших соседей, наиболее близко расположенных к данному объекту;

2) для объекта n_i вычисляется количество ближайших соседей из области радиусом R принадлежащих к каждому из m классов: $I_1, I_2, \dots, I_m$;

3) объект n_i классифицируется в тот класс C_r , в который попало наибольшее число объектов из k_R ближайших соседей.

Каким образом выбрать k ближайших соседей? Если k слишком мал, то метод чувствителен к шуму. Если k слишком велик, то окрестность может включать объекты из других классов, что приводит к ошибке классификации объектов. Один из методов, широко используемых для оценки числа ближайших соседей – метод перекрестного контроля.

Алгоритм:

1. Установить минимальные и максимальные числа ближайших соседей $k_{\min}$ и $k_{\max}$, $k = k_{\min}$. Разбить обучающее множество объектов $A = \{n_1, n_2, \dots, n_L\}$ на S_i , $i = 1, 2, \dots, V$, подмножеств, или сегментов. Предположим, что сегмент S_i является тестируемым множеством, а $A \setminus S_i$ – обучающим множеством.

2. Выполнить классификацию по методу k -ближайших соседей для всех подмножеств $A \setminus S_i$, $i = 1, 2, \dots, V$. Вычислить ошибки классификации Q_i для всех сегментов S_i , $i = 1, 2, \dots, V$.

Для V классификаций вычислить среднюю ошибку классификации Q_k

$$Q_k = \frac{1}{V} \sum_{i=1}^V Q_i.$$

3. Если $k < k_{\max}$, то $k = k + 1$ и перейти к п. 2. Иначе определить минимум Q_k и соответствующие ему k .

Метрика для расчета расстояния между объектами выборки выбирается исходя из условий решаемой задачи. В качестве расстояний между двумя объектами могут использоваться, например – евклидово расстояние или коэффициент корреляции Пирсона.

Достоинства метода k -ближайших соседей: простота реализации алгоритма и интерпретируемость решений, полученных на основе прямой обработки прецедентов.

Недостатки: приходится хранить в оперативной памяти компьютера всю обучающую выборку, а также неустойчивость работы алгоритма в случае наличия шумов и выбросов.

1.11.3. Метод наименьшего расстояния (до центров классов)

Метод наименьшего расстояния (simple distance-based algorithm) является наиболее простым и очевидным способом классификации среди методов, использующих вычисления расстояний между объектами в пространстве признаков. Метод предполагает, что объекты внутри одного класса более похожи, т. е. имеют наименьшие расстояния между собой, чем объекты из других классов.

Идея метода заключается в следующем. По элементам обучающей выборки вычисляются центры классов c_r , $r = 1, 2, \dots, m$. Например, как среднее арифметическое, вычисленное по координатам объектов данного класса. Неизвестный объекта n_i из тестируемой выборки относится к тому классу C_r , расстояние до центра d_{ir} которого будет минимальным (рисунок 40).




Рисунок 40 – Базовый принцип метода наименьшего расстояния

Алгоритм:

1. Для объектов обучающей выборки вычислить центры классов $c_r = \frac{1}{N_r} \sum_{i \in C_r} n_i$, $r = 1, 2, \dots, m$, где N_r – число объектов класса C_r .

2. Для объекта n_i из тестируемой выборки вычислить расстояния d_{ir} до центров m классов.

3. Объект n_i классифицируется в тот класс C_r , расстояние до центра которого является минимальным.

Успех метода наименьшего расстояния определяется заданием наиболее оптимальных способов вычисления расстояний между объектами и центрами классов. На практике метод успешно работает для достаточно больших эталонных выборок.

1.11.4. Методы перекрёстной проверки

В связи с тем, что алгоритмы перекрёстного контроля (cross-validation) активно используются в ИАД, для проверки точностей моделей классификации и регрессии, рассмотрим подробно алгоритмы перекрёстного контроля на примере решения задачи регрессии.

При помощи алгоритмов перекрёстного контроля можно определить какая из рассматриваемых регрессионных или квалификационных моделей наиболее точно описывает набор L объектов из обучающей выборки. Похожая задача решается в ходе выполнения лабораторной работы №2 «Нелинейный метод наименьших квадратов», где используется критерии минимума целевой функции хи-квадрат, взвешенных остатков и автокорреляционной функции. Метод перекрёстного контроля является более точным способом проверки регрессионных моделей, т.к. учитывает эффект переобучения моделей. Однако и время-затратным, т.к. требует большое количество вычислений.

Простой перекрестный контроль. Обучающий набор данных разбивается на две выборки – условно эталонную/обучающую и тестируемую. Регрессионная или классификационная модель строится по объектам обучающей выборки, а ошибка модели вычисляется по объектам из тестируемой выборки.

Алгоритм:

1. Случайный отбор и исключение набора l объектов из обучающей выборки (например, 30% от данных).

2. Регрессионный анализ ($L-l$) объектов обучающей выборки – подбор параметров функции $f(x)$, при котором функция описывает экспериментальные данные наилучшим образом.

3. Вычисление оценки ошибки модели по исключенным объектам из выборки:

$$Q = \frac{1}{l} \sum_{i=1}^l \varepsilon_i^2.$$

Метод не чувствителен к переобучению, что является его недостатком. Это вызвано тем, что часть данных, размещенная в тестируемой выборке, не учитывается в процессе обучения, что снижает точность метода. Достоинства –

простота и небольшое количество вычислений (решается одна задача оптимизации).

Скольльзящий контроль (Leave-one-out). Устраняется недостаток простого перекрестного контроля. В процессе обучения учитываются все объекты данных, что увеличивает точность метода, но существенно замедляет вычисления.

Обучающий набор данных разбивается на L групп условно обучающих и тестируемых выборок. Обучающие выборки формируются по принципу поочерёдного исключения одного объекта и внесение его в тестируемую выборку. Регрессионная или классификационная модель строится по объектам обучающей выборки, а ошибка вычисляется по объекту из тестируемой выборки.

Алгоритм первой итерации метода.

1. Выбор и исключение объекта n_i из обучающей выборки.
2. Регрессионный анализ объектов обучающей выборки.
3. Вычисление ошибки в исключенной точке ($Q_i = \varepsilon_i^2$).

Выполнить алгоритм для остальных объектов (требуется $L-1$ итераций).
Рассчитать среднюю ошибку:

$$\bar{Q} = \frac{1}{L} \sum_{i=1}^L Q_i .$$

Метод чувствителен к переобучению, что является несомненным достоинством. Недостаток – большое количество вычислений (решается L задач оптимизации).

V-кратный перекрёстный контроль. Является промежуточным вариантом между алгоритмами простого и скользкого контроля, цель которого – уменьшить количество вычислений, при этом сохранить приемлемую точность регрессионной или классификационной модели. Обучающий набор данных разбивается на V групп условно обучающих и тестируемых выборок.

Алгоритм для первой итерации метода.

1. Исключение объектов первой группы (тестируемая выборка) из обучающей выборки.
2. Регрессионный анализ объектов обучающей выборки.
3. Вычисление ошибки по объектам исключенной группы ($Q_i = \varepsilon_i^2$).

Выполнить алгоритм для остальных $V-1$ итераций. Рассчитать среднюю ошибку:

$$\bar{Q} = \frac{1}{V} \sum_{i=1}^V Q_i .$$

Достоинства метода – чувствительность к переобучению и оптимальное количество вычислений (решается $V \ll L$ задач оптимизаций). Недостаток – требуется определение оптимального числа V , что не всегда очевидно и требует дополнительных расчетов или допущений.

1.12. Методы поиска ассоциативных правил

1.12.1. Ассоциативные правила

Одной из наиболее распространенных задач интеллектуального анализа данных является определение часто встречающихся наборов объектов в большом множестве наборов данных. Например, поиск закономерностей между связанными событиями в базах данных. На основе полученных закономерностей могут быть построены ассоциативные правила.

Впервые задача поиска ассоциативных правил была использована для нахождения типичных шаблонов покупок, совершаемых в супермаркетах. В сфере торговли объектами анализа служат товары, приобретенные покупателями. Решаемые задачи: анализ потребительской корзины и товаров, которые следует продвигать совместно; прогнозирование спроса.

Ассоциативные правила позволяют находить закономерности между связанными событиями. Примером такого правила служит утверждение, что покупатель, приобретающий «хлеб», приобретет и «молоко» с вероятностью 0.75.

Рассмотрим постановку задачи поиска ассоциативных правил на примере некоторой базы данных. База данных содержит информацию о покупательских транзакциях.

Транзакция – это набор товаров, купленных покупателем за один визит. Пусть $I = \{n_1, n_2, \dots, n_N\}$ – множество товаров (объектов) общим числом N . Тогда $D = \{T_1, T_2, \dots, T_m\}$ – множество транзакций, где каждая транзакция T_r – это набор элементов из множества товаров I .

Пример. Пусть в наличии имеется множество товаров $I = \{\text{шоколад, хлеб, масло, вода, молоко, орехи}\}$, или, вводя символьное обозначение, $I = \{a, b, c, d, e, f\}$ ($N = 6$). Возможен следующий набор транзакций $D = \{T_1, T_2, T_3, T_4\}$ ($m = 4$), где $T_1 = \{\text{хлеб, вода, молоко, шоколад}\}$, $T_2 = \{\text{масло, вода, орехи}\}$, $T_3 = \{\text{орехи, масло, хлеб, вода}\}$, $T_4 = \{\text{масло, орехи}\}$.

Пусть $D(n_i)$ – множество транзакций, в которые входит объект n_i , а $|D(n_i)|$ – число транзакций, в которые входит объект n_i . В рассмотренном выше примере $D(\text{вода}) = \{T_1, T_2, T_3\} = \{\{\text{хлеб, вода, молоко, шоколад}\}, \{\text{масло, вода, орехи}\}, \{\text{орехи, масло, хлеб, вода}\}\}$. $|D(\text{вода})| = 3$.

Допустим, что F – произвольный набор объектов. Тогда $D(F)$ – множество транзакций, в которые входит набор F . *Пример (продолжение).* Пусть $F = \{\text{масло, вода}\}$, тогда $D(F) = D(\{\text{масло, вода}\}) = \{T_2, T_3\} = \{\{\text{масло, вода, орехи}\}, \{\text{орехи, масло, хлеб, вода}\}\}$.

Рассмотрим основные термины и характеристики, используемые в методах поиска ассоциативных правил.

Поддержка набора F (support) – отношение количества транзакций $|D(F)|$, в которое входит набор F , к общему количеству транзакций m :

$$\text{Supp} = \frac{|D(F)|}{m}.$$

Пример (продолжение). $\text{Supp}(F) = \text{Supp}(\{\text{масло, вода}\}) = 2 / 4 = 0,5$.

Набор F называется *часто встречающимся*, если значение его поддержки $\text{Supp}(F)$ больше или равно минимальному значению поддержки $\text{Supp}_{\min}(F)$, заданного пользователем:

$$\text{Supp}(F) \geq \text{Supp}_{\min}(F).$$

В ходе поиска ассоциативных правил требуется найти множество всех часто встречающихся наборов L

$$L = \{F \mid \text{Supp}(F) \geq \text{Supp}_{\min}(F)\}.$$

Пример (продолжение). Множество всех часто встречающихся наборов для поддержки $\text{Supp}_{\min}(F) = 0,5$ включает: {хлеб} ($\text{Supp} = 0,5$), {хлеб, вода} ($\text{Supp} = 0,5$), {масло} ($\text{Supp} = 0,75$), {масло, вода} ($\text{Supp} = 0,5$), {масло, вода, орехи} ($\text{Supp} = 0,5$), {масло, орехи} ($\text{Supp} = 0,75$), {вода} ($\text{Supp} = 0,75$), {вода, орехи} ($\text{Supp} = 0,5$), {орехи} ($\text{Supp} = 0,75$).

В общем случае результаты анализа принято представлять в виде ассоциативных правил. В ходе поиска правил выделяют два этапа: 1) нахождение всех частых наборов объектов; 2) генерация ассоциативных правил из найденных частых наборов объектов.

Ассоциативные правила имеют вид – если (условие), то (результат), где условие – набор объектов из множества I , с которым ассоциированы объекты, включенные в результат данного правила. Например, если ({масло, вода}), то ({орехи}).

Ассоциативные правила строятся на основе частых наборов F и являются возможными комбинациями объектов, входящих в него.

Пример (продолжение). Для набора {масло, вода, орехи} правила: если ({масло}), то ({вода}); если ({масло}), то ({орехи}); если ({масло}), то ({вода, орехи}); если ({вода}), то ({масло}); если ({вода}), то ({орехи}); если ({вода}), то ({масло, орехи}); если ({орехи}), то ({масло}); если ({орехи}), то ({вода}); если ({орехи}), то ({масло, вода}); если ({масло, вода}), то ({орехи}); если ({масло, орехи}), то ({вода}); если ({вода, орехи}), то ({масло}).

Выделяют три вида правил.

Полезные правила – содержат действительную информацию, которая ранее была не известна и имеет логическое объяснение.

Тривиальные правила – содержат действительную и легко объяснимую информацию, которая уже известна.

Непонятные правила – содержат информацию, которая не может быть объяснена. Такие правила могут быть получены на основе аномальных значений или глубоко скрытых знаний. Напрямую такие правила нельзя использовать для принятия решений. Требуется дополнительный анализ.

Основным достоинством ассоциативных правил является их легкое восприятие человеком и простая реализация на языке программирования.

Для оценки полезности правил используются несколько критериев, такие как поддержка правила, достоверность правила и улучшение правила.

Поддержка правила (support) – показывает, какой процент (или доля) транзакций поддерживает данное правило. Правило $X \Rightarrow Y$ (из наличия условия

X следует результат Y , т. е. если X , то Y) имеет поддержку, равную поддержке набора F , который составляют X и Y :

$$\text{Supp}(X \Rightarrow Y) = \text{Supp}(F = X \cup Y) = \frac{|D(F = X \cup Y)|}{m}.$$

Пример (продолжение). $\text{Supp}(\text{если } (\{\text{вода, масло}\}), \text{то } (\{\text{орехи}\})) = \text{Supp}(\{\text{вода, масло, орехи}\}) = 2 / 4 = 0,5$.

Достоверность правила (confidence) – показывает вероятность того, что из наличия в транзакции набора X следует наличие в ней набора Y . Достоверностью правила $X \Rightarrow Y$ является отношение числа транзакций, содержащих X и Y , к числу транзакций, содержащих набор X :

$$\text{Conf}(X \Rightarrow Y) = \frac{|D(F = X \cup Y)|}{|D(X)|} = \frac{\text{Supp}(F = X \cup Y)}{\text{Supp}(X)}.$$

Чем выше достоверность, тем лучше правило. *Пример (продолжение).* $\text{Conf}(\text{если } (\{\text{вода}\}), \text{то } (\{\text{орехи}\})) = 2/3$; $\text{Conf}(\text{если } (\{\text{орехи}\}), \text{то } (\{\text{вода}\})) = 2/3$; $\text{Conf}(\text{если } (\{\text{вода, масло}\}), \text{то } (\{\text{орехи}\})) = 2 / 2 = 1$; $\text{Conf}(\text{если } (\{\text{вода}\}), \text{то } (\{\text{орехи, масло}\})) = 2 / 3$.

Замечание. Достоверность не позволяет корректно определить полезность правила, если

$$\text{Conf}(X \Rightarrow Y) = \frac{\text{Supp}(F = X \cup Y)}{\text{Supp}(X)} < \text{Supp}(Y).$$

Это значит, что вероятность случайно угадать наличие в транзакции набора Y больше, чем предсказать это с помощью правила $X \Rightarrow Y$. *Пример.* $\text{Conf}(\text{если } (\{\text{вода}\}), \text{то } (\{\text{орехи}\})) = 2 / 3 = 0,66 < \text{Supp}(\text{орехи}) = 3 / 4 = 0,75$.

Улучшение правила (improvement) – показывает, полезнее ли правило случайного угадывания

$$\text{Impr}(X \Rightarrow Y) = \frac{\text{Supp}(F = X \cup Y)}{\text{Supp}(X) \cdot \text{Supp}(Y)}.$$

Если $\text{Impr} > 1$, то с помощью правила предсказать наличие набора Y вероятнее, чем случайное угадывание. Иначе, если $\text{Impr} < 1$, то наоборот или отрицательное правило. *Пример.* $\text{Impr}(\text{если } (\{\text{вода}\}), \text{то } (\{\text{орехи}\})) = 0,5 / (0,75 \cdot 0,75) \approx 0,89 < 1$. Правило – если $(\{\text{вода}\})$, то не $(\{\text{орехи}\})$.

1.12.2. Алгоритмы поиска ассоциативных правил

Существует множество различных стратегий поиска ассоциативных правил (например, AprioriTid, AprioriHybrid, DHP, PARTITION). Здесь мы рассмотрим два базовых алгоритма Apriori и FPG.

Алгоритм Apriori. Алгоритм Apriori является наиболее распространенным алгоритмом поиска ассоциативных правил и использует простейший перебор всех возможных элементов данных.

Алгоритм Apriori использует свойство поддержки – антимонотонность: поддержка любого набора элементов не может превышать минимальной поддержки любого из его подмножеств.

$$\text{Supp}(F) \leq \text{Supp}(E), \text{ при } E \subseteq F.$$

Пример. $\text{Supp}(\{\text{хлеб, масло, молоко}\}) \leq \text{Supp}(\{\text{хлеб, масло}\})$, $\text{Supp}(\{\text{хлеб, масло, молоко}\}) \leq \text{Supp}(\{\text{хлеб, молоко}\})$, $\text{Supp}(\{\text{хлеб, масло, молоко}\}) \leq \text{Supp}(\{\text{масло, молоко}\})$.

Из свойства антимонотонности поддержки набора F следует:

1) с ростом размера набора элементов поддержка уменьшается либо остается такой же;

2) любой k -элементный набор F будет часто встречающимся, когда все его $(k - 1)$ -элементные подмножества будут часто встречающимися.

Наборы элементов из I можно представить в виде решетки (рисунок 41). На k -м уровне решетки представлены k -элементные наборы. Рассмотрим набор элементов $I = \{A, B, C, D\}$. Пусть $\text{Supp}(\{A, B\}) < \text{Supp}_{\min}$, т. е. не является часто встречающимся. Тогда, согласно свойству антимонотонности, все его супермножества $\{A, B, C\}$, $\{A, B, D\}$, и $\{A, B, C, D\}$ также не являются часто встречающимися и отбрасываются. На рисунке 41 ветвь, начиная с $\{A, B\}$, выделена фоном.




Рисунок 41 – Иллюстрация свойства антимонотонности для набора элементов $I = \{A, B, C, D\}$.

Алгоритм Apriori:

1. $k = 1$. Отбор всех 1-элементных наборов данных. Установить $\text{Supp}_{\min}$.
2. Вычислить поддержку для каждого k -элементного кандидата.
3. Отобрать множество часто встречаемых кандидатов L_k , для которых $\text{Supp}(L_k) \geq \text{Supp}_{\min}$.

Отсесть k -элементные кандидаты, для которых $\text{Supp}(L_k) < \text{Supp}_{\min}$.

4. $k = k + 1$.

5. Если не удастся создавать k -элементные наборы, то завершить алгоритм. Иначе перейти к п. 2.

Результат работы алгоритма – множество наборов элементов $L = \{L_1 \cup L_2 \cup \dots \cup L_k\}$.

Пример. Допустим, в наличии имеется множество элементов $I = \{a, b, c, d, e, f\}$ ($N = 6$) и набор транзакций $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$, где $T_1 = \{a, b, c\}$, $T_2 = \{b, d\}$, $T_3 = \{b, a, d, c\}$, $T_4 = \{e, d\}$, $T_5 = \{a, b, c, d\}$, $T_6 = \{f\}$. Требуется определить ассоциативные правила для часто встречающихся товаров, $\text{Supp}_{\min} = 0,5$, с использованием алгоритма Apriori.

Формирование 1-элементных кандидатов. Вычислим поддержку для всех 1-элементных кандидатов: $\text{Supp}(\{a\}) = 0,5$, $\text{Supp}(\{b\}) = 0,67$, $\text{Supp}(\{c\}) = 0,5$, $\text{Supp}(\{d\}) = 0,67$, $\text{Supp}(\{e\}) = 0,17$, $\text{Supp}(\{f\}) = 0,17$. Отсечем элементы $\{e\}$ и $\{f\}$, для которых $\text{Supp} < \text{Supp}_{\min}$. Тогда множество часто встречающихся 1-элементных кандидатов $L_1 = \{\{a\}, \{b\}, \{c\}, \{d\}\}$.

Формирование 2-элементных кандидатов. 2-элементные кандидаты формируются на основе часто встречаемых 1-элементных кандидатов и их поддержки равны: $\text{Supp}(\{a, b\}) = 0,5$, $\text{Supp}(\{a, c\}) = 0,5$, $\text{Supp}(\{a, d\}) = 0,33$, $\text{Supp}(\{b, c\}) = 0,5$, $\text{Supp}(\{b, d\}) = 0,5$, $\text{Supp}(\{c, d\}) = 0,33$. Отсечем элементы $\{a, d\}$ и $\{c, d\}$, для которых $\text{Supp} < \text{Supp}_{\min}$. Сформируем множество часто встречающихся 2-элементных кандидатов $L_2 = \{\{a, b\}, \{a, c\}, \{b, c\}, \{b, d\}\}$.

Формирование 3-элементных кандидатов. 3-элементные кандидаты строятся на основе часто встречаемых 2-элементных кандидатов и их поддержки равны: $\text{Supp}(\{a, b, c\}) = 0,5$, $\text{Supp}(\{a, b, d\}) = 0,33$, $\text{Supp}(\{a, c, d\}) = 0,33$, $\text{Supp}(\{b, c, d\}) = 0,33$. Часто встречающимся 3-элементным кандидатом будет только один набор $L_3 = \{a, b, c\}$.

Таким образом, результатом работы алгоритма является множество $L = \{L_1 \cup L_2 \cup L_3\} = \{\{a\}, \{b\}, \{c\}, \{d\}, \{a, b\}, \{a, c\}, \{b, c\}, \{b, d\}, \{a, b, c\}\}$. Возможные правила: если $(\{a\})$, то $(\{b\})$; если $(\{b\})$, то $(\{a\})$; если $(\{a, b\})$, то $(\{c\})$; если $(\{a, c\})$, то $(\{b\})$; если $(\{b, c\})$, то $(\{a\})$ и т. д.

Алгоритм FPG (frequent pattern-growth strategy). В основе метода FPG лежит предобработка базы транзакций. В результате предобработки база данных преобразуется в компактную древовидную структуру – дерево популярных предметных наборов FP (Frequent-Pattern Tree).

Метод выполняет декомпозицию одной сложной задачи на множество более простых, что позволяет избежать затратной процедуры генерации кандидатов, характерной для алгоритма Apriori.

Алгоритм FPG включает два этапа.

Этап 1. Первое сканирование базы данных транзакций. Строится FP-дерево, представляющее информацию о часто встречаемых наборах данных. FP-дерево позволяет производить эффективное извлечение данных на втором этапе сканирования базы данных.

Этап 2. Второе сканирование базы данных транзакций.

Для каждого объекта n_i , $i = 1, 2, \dots, N$, необходимо построить цепочки путей по FP дереву (двигаясь от корня дерева).

Упорядоченные в порядке убывания нормированной поддержки значения узлов дерева формируют новый набор транзакций S .

По наборам транзакций S построить новые условные FP-деревья для каждого из элементов n_i , $i = 1, 2, \dots, N$.

Для каждого условного FP-дерева найти все узлы, для которых поддержка $\text{Supp} \geq \text{Supp}_{\min}$.

Начиная с корня дерева, записывать наикратчайшие пути, ведущие к узлам с поддержкой $\text{Supp}(L_k) \geq \text{Supp}_{\min}$. Данные пути будут представлять собой часто встречаемые наборы, на основе которых формируются правила.

Рассмотрим использование алгоритма FPG на примере анализа набора транзакций $D = \{T_1, T_2, T_3, T_4, T_5, T_6, T_7\}$, где $T_1 = \{a, b, c, d, e\}$, $T_2 = \{a, b, c\}$, $T_3 = \{a, c, d, e\}$, $T_4 = \{b, c, d, e\}$, $T_5 = \{b, c\}$, $T_6 = \{b, d, e\}$, $T_7 = \{c, d, e\}$, состоящего из множества элементов $I = \{a, b, c, d, e\}$ ($N = 5$). Для БД требуется обнаружить все популярные предметные наборы с минимальной нормированной поддержкой правила ($\text{Supp}^* = m \cdot \text{Supp}$), равной 3,

Этап 1. Первое сканирование базы данных транзакций.

Отбирается множество часто встречающихся предметов ($\text{Supp}^* \geq 3$): $(c, 6)$, $(b, 5)$, $(d, 5)$, $(e, 5)$, $(a, 3)$.

Обнаруженные часто встречающиеся предметы упорядочиваются в порядке возрастания их поддержки в транзакциях: $T_1 = \{c, b, d, e, a\}$, $T_2 = \{c, b, a\}$, $T_3 = \{c, d, e, a\}$, $T_4 = \{c, b, d, e\}$, $T_5 = \{c, b\}$, $T_6 = \{b, d, e\}$, $T_7 = \{c, d, e\}$.

Создается корневой или нулевой узел FP-дерева. Построение дерева начинается с транзакции $T_1 = \{c, b, d, e, a\}$. Построения узлов дерева осуществляется сверху вниз. Узлами дерева являются элементы упорядоченного набора транзакции.

Правило формирования узлов FP-дерева. Если для очередного предмета транзакции в ходе движения вниз по дереву встречается узел, имя которого совпадает с именем предмета, то предмет не создает нового узла, а индекс соответствующего узла в дереве увеличивается на 1. В противном случае для этого предмета создается новый узел и ему присваивается индекс 1. Пример построения FP-дерева для семи транзакций представлен на рисунке 42, а.

Этап 2. Второе сканирование базы данных транзакций.

Для каждого популярного объекта из множества $\{a, b, c, d, e\}$ построим цепочку путей по FP-дереву (двигаясь от корня дерева) и определим часто встречаемые наборы элементов.

Для элемента a ($\text{Supp}^* = 3$) на диаграмме FP-дерева наблюдается 3 пути: $\{cbdea, cba, cdea\}$. Множество элементов и их нормированная поддержка в последовательностях путей для элемента a : $(c, 3)$, $(b, 2)$, $(d, 2)$, $(e, 2)$. На основе последовательностей путей к узлам a , упорядоченных по возрастанию нормированной поддержки, сформируем новый набор транзакций без учета конечного узла $S = \{T_1^*, T_2^*, T_3^*\}$, где $T_1^* = \{c, b, d, e\}$, $T_2^* = \{c, b\}$, $T_3^* = \{c, d, e\}$. Построим условное FP-дерево для элемента a (рисунок 12.2, б). В условном FP-дереве только узел c удовлетворяет уровню минимальной поддержки 3. Для предмета a может быть сгенерирован только один часто встречающийся набор $\{c, a\}$, нормированная поддержка которого равна 3.

Для элемента b ($\text{Supp}^* = 5$) на диаграмме FP-дерева наблюдается 2 пути: $\{cb, b\}$ (путь через узел c встречается 4 раза и 1 раз нулевой путь). Условное FP-дерево для b содержит только один узел c (рисунок 42, б). Для предмета b может быть сгенерирован только один часто встречающийся набор $\{c, b\}$, нормированная поддержка которого равна 4.

Для предмета c нельзя указать путь (нулевой путь). Популярные предметные наборы отсутствуют.




Рисунок 42 – Построение FP-дерева (а) и условные FP-деревья для элементов a, b, d, e (б).

Для элемента d ($\text{Supp}^* = 5$) на диаграмме FP-дерева наблюдается 3 пути: $\{cbd$ (2 раза), cd (2 раза), $bd\}$. Множество элементов и их нормированная поддержка в последовательностях путей для элемента d : $(c, 4), (b, 3)$. Новый набор транзакций без конечного узла $S = \{T_1^*, T_2^*, T_3^*, T_4^*, T_5^*\}$, где $T_1^* = \{c, b\}$, $T_2^* = \{c, b\}$, $T_3^* = \{c\}$, $T_4^* = \{c\}$, $T_5^* = \{b\}$. Условное FP-дерево для d представлено на рисунке 42, б. Путь к узлу c : (c, d) . Путь к ближайшему узлу b : (b, d) . Для элемента d определены два часто встречающихся набора $\{c, d\}$ и $\{b, d\}$, нормированная поддержка которых равна 4 и 3 соответственно.

Для элемента e ($\text{Supp}^* = 5$) на диаграмме FP-дерева наблюдается 3 пути: $\{cbde$ (2 раза), cd (2 раза), $bd\}$. Множество элементов и их нормированная поддержка в последовательностях путей для элемента e : $(d, 5)$, $(c, 4)$, $(b, 3)$. Новый набор транзакций без конечного узла $S = \{T_1^*, T_2^*, T_3^*, T_4^*, T_5^*\}$, где $T_1^* = \{d, c, b\}$, $T_2^* = \{d, c, b\}$, $T_3^* = \{d, c\}$, $T_4^* = \{d, c\}$, $T_5^* = \{d, b\}$. Условное FP-дерево для e представлено на рисунке 42, б. Путь к узлу d : (d, e) . Путь к узлу c : (d, c, e) . Путь к ближайшему узлу b : (d, b, e) . Популярными предметными наборами для элемента e будут $(\{d, e\}, 5)$, $(\{d, c, e\}, 4)$, $(\{d, b, e\}, 3)$.

Популярные предметные наборы: $\{c, a\}$, $\{c, b\}$, $\{c, d\}$, $\{b, d\}$, $\{d, e\}$, $\{d, c, e\}$, $\{d, b, e\}$.

1.13. Методы визуализации данных

1.13.1. Визуальное представление данных

Экспериментальные данные и результаты интеллектуального анализа этих данных, представленные в виде таблиц или текстовой информации, не всегда удобны для восприятия человеком и быстрого предварительного анализа, который помог бы значительно упростить решение задачи в дальнейшем. Например, в множестве классифицирующих или ассоциативных правил аналитику часто бывает весьма сложно найти новые и полезные знания. Из-за большого объема информации это не всегда возможно и в случае построения простейших графических диаграмм (дерева решений, дендрограммы, различные двумерные графики). В связи с этим возникает необходимость в использовании более сложных и эффективных средств отображения, или визуализации, экспериментальных данных и результатов их анализа.

Визуализация данных – это метод или конечный результат трансформации численной или текстовой информации в графический вид.

Визуальный анализ данных (Visual mining) можно представить как процесс генерации гипотез. Гипотезы затем последовательно проверяются количественными методами интеллектуального анализа данных.

Визуальный анализ имеет два преимущества перед непосредственным применением количественных методов ИАД:

- позволяет быстро обнаружить неоднородности, шумы и выбросы в данных;
- визуальный анализ интуитивно понятен, не требует сложных математических или статистических алгоритмов.
- В настоящее время существует достаточно большое количество различных графических образов, позволяющих представить результаты анализа в удобном для восприятия и понимания человеком виде. Традиционные методы визуализации позволяют:
 - представлять пользователю информацию в наглядном виде;
 - компактно описывать закономерности, присущие исходному набору данных;
 - снижать размерность или сжимать информацию;
 - восстанавливать пропущенные значения в наборе данных;

находить шумы и выбросы в данных.

Процесс визуализации данных представлен на рисунке 43. Набор экспериментальных данных поступает в ядро визуализации. Ядро визуализации интегрирует методы визуализации данных и осуществляет взаимодействие с блоком количественных методов интеллектуального анализа данных. На выходе блока ядра формируются визуальные образы исследуемых данных и результатов их анализа.



Рисунок 43 – Процесс визуализации данных.

Существует несколько подходов к классификации методов визуализации данных:

- по типу данных (численные, категориальные, текстовые, иерархические, программы или алгоритмы);
- по размерности данных (одномерные, двумерные, трехмерные, многомерные);
- по типу построения визуальных образов (стандартные двумерные или трехмерные диаграммы, диаграммы на основе геометрических преобразований, отображения иконок, пиксели изображений, иерархические образы);
- по классу решаемых задач (классификация, кластеризация, ассоциация и т. д.);
- по признаку классические (традиционные) и новые методы.

Рассмотрим подробнее методы визуализации многомерных данных по такому признаку, как классические (традиционные) и новые методы. Будем предполагать, что выполняется анализ некоторого набора данных $(n_1, n_2, \dots, n_N)$, полученных из базы данных или эксперимента (см. таблицу 1).

1.13.2. Методы визуализации многомерных данных

Классические методы визуализации многомерных данных включают различные способы представления информации в виде одно-, двух- и трех-размерных диаграмм различного вида: линейчатые диаграммы, линейные и нелинейные тренды, круговые диаграммы, гистограммы, поверхности и изолинии, венские (пузырьковые) диаграммы, коробчатые диаграммы, схемы сетей, дендрограммы, деревья, диаграммы рассеяния, диаграммы-таблицы (сопряженности, сводные таблицы и диаграммы, таблицы дисперсионного анализа) (рисунки 44 и 45).




Рисунок 44 – Визуализация данных с помощью классических методов представления информации: *a* – линейчатая диаграмма; *б* – тренды; *в* – круговая диаграмма; *г* – гистограммы; *д* – поверхности и изолинии; *е* – диаграммы рассеяния.




Рисунок 45 – Визуализация данных с помощью классических методов представления информации: *a* – венские (пузырьковые) диаграммы; *б* – коробчатые диаграммы; *в* – схема сетей; *г* – дендрограмма; *д* – деревья.

К новым методам визуализации многомерных данных относят геометрические проекционные методы, методы на основе построения иконок, пиксельные методы. Рассмотрим подробнее некоторые новые методы визуализации многомерных данных.

Геометрические проекционные методы. Основная идея методов – построение проекций данных на низкие размерности (рисунок 46, а).




Рисунок 46 – Примеры построения гистограмм на основе проекции двумерных данных на некоторые оси (а) и пример отображения объекта $n_i = (0,5; 1; 0,5; 1; 0,5; 1; 0,5; 1)$ с помощью радиального метода (б).

Радиальный метод. В радиальном методе данные нормируются от 0 до 1. Строится окружность. Окружность разбивается на K радиусов, каждый из которых является координатной осью для соответствующего ему признака $X_1, X_2, \dots, X_K$. Точки пересечения линий радиусов соответствуют значениям атрибутов отображаемых данных. Пример отображения объекта $n_i = (0,5; 1; 0,5; 1; 0,5; 1; 0,5; 1)$ с помощью радиального метода представлен на рисунке 46, б.

Метод параллельных координат. Данный метод предполагает представление признаков $X_1, X_2, \dots, X_K$ параллельными линиями на недекларовой плоскости. Точки пересечения параллельных линий соответствуют значениям атрибутов отображаемых данных. Пример визуализации объектов $n_1 = (1, 5, 10, 3, 3, 5)$, $n_2 = (3, 1, 3, 1, 2, 2)$, $n_3 = (2, 2, 1, 2, 4, 2)$, $n_4 = (4, 2, 1, 3, 1, 1)$ с помощью метода параллельных координат дан на рисунке 47.

Матрица диаграмм рассеяния. Метод является комбинацией отдельных диаграмм рассеяния между исходными признаками (рисунок 48). Значения атрибутов $X_1, X_2, \dots, X_K$ отображаются в диагональных ячейках матрицы. Недиagonальные элементы матрицы содержат диаграммы рассеяния, линейные тренды и коэффициенты корреляции между признаками X_i и X_j .

Матрица диаграмм позволяет визуально оценить корреляции между различными признаками и закон распределения данных.




Рисунок 47 – Примеры визуализации объектов $n_1 = (1, 5, 10, 3, 3, 5)$, $n_2 = (3, 1, 3, 1, 2, 2)$, $n_3 = (2, 2, 1, 2, 4, 2)$, $n_4 = (4, 2, 1, 3, 1, 1)$ с помощью метода параллельных координат (а) и некоторого набора экспериментальных данных (б).




Рисунок 48 – Матрица диаграмм рассеяния.

Диаграммы обзора (survey plots). Позволяют отображать многомерные данные в виде линейных графов (рисунок 49, а). Оси признаков $X_1, X_2, \dots, X_K$ располагаются параллельно. Объекты сортируются по абсолютным значениям признаков и отображаются в виде линейчатых диаграмм на каждой из осей признаков таким образом, что отрицательные значения расположены слева от осей $X_1, X_2, \dots, X_K$, а положительные значения – справа. Внизу координатных осей расположены объекты с нулевыми значениями.

Кривые Эндрю (Andrew's curves). Отображают набор данных в виде кривых на плоскости (рисунок 49, б)

$$F(t) = X_1/\sqrt{2} + X_2 \sin(t) + X_3 \cos(t) + X_4 \sin(2t) + X_5 \cos(2t) + \dots,$$

где $\pi < t < \pi$.




Рисунок 49 – Примеры диаграмма обзора (а) и кривых Эндрю (б).

Диаграммы рассеяния на основе главных компонент. Результаты анализа главных компонент или факторного анализа, можно графически отобразить в виде двумерных или трехмерных диаграмм рассеяния (рисунок 50). Данный подход наиболее эффективен в случае, когда максимальный разброс приходится на первые несколько главных компонент.




Рисунок 50 – Примеры двумерной (а) и трехмерной (б) диаграмм рассеяния на основе главных компонент.

Самоорганизующиеся карты Кохонена. По аналогии с предыдущим методом результаты работы алгоритмов нейронных сетей на основе карт Кохонена могут использоваться для визуализации наборов данных в виде топологических карт местности. Топологическая карта представляет собой набор цветных блоков-кластеров, построенных методом параллельных координат и расположенных по мере сходности (рисунок 51).




Рисунок 51 – Пример топологической карты Кохонена размера 5×5 для представления некоторого набора многомерных данных.

Кластеры данных и их взаимное расположение определяется с помощью нейронных сетей самоорганизующихся карт Кохонена. Графическое отображение кластеров объектов строится с помощью метода параллельных координат, где значения атрибутов объектов отображаются в цветовой шкале (красный/темный цвет: $+\infty$, зеленый/светлый цвет: $-\infty$). Часто вместо цветовых значений используются средние или медианные значения по кластерам данных. Карта Кохонена представляет собой рельефное отображение данных, где горные рельефы соответствуют объектам с высокими положительными значениями атрибутов, а низменности – объектам с низкими отрицательными значениями атрибутов. Группы объектов, с промежуточными профилями значений атрибутов расположены последовательно между экстремальными областями карты. Стоит отметить, что данный метод получил широкое распространение на практике.

Методы на основе построения иконок. Основная идея методов – присвоение каждому объекту данных некоторой иконки. При этом атрибуты объекта должны отображать некоторые свойства иконок. Иконки могут объединяться в матрицы и графы, предоставляя пользователю возможность анализировать объекты данных в целом.

Линейчатые фигуры. Представляют собой иконку с некоторым количеством ветвей. Атрибуты объекта отображаются разными положениями, наклоном и длиной линий (рисунок 52, а).




Рисунок 52 – Примеры линейчатой фигуры некоторого объекта данных (а) и диаграмма лиц Чернова (б).

Лица Чернова. Метод использует кодирование значений различных переменных в характеристиках или чертах человеческого лица (рисунок 52, б). Например, X_1 – форма лица, X_2 – форма рта, X_3 – наклоны глаз, X_4 – толщина носа, X_5 – наклоны бровей, X_6 – форма глаз.

Цветные иконки. Характеризуют атрибуты объектов цветом, формой, размером, изрезанностью границ, ориентацией.

Пиксельные методы визуализации. В пиксельных методах для предоставления каждого элемента данных используются цветные пиксели. Наиболее широкое распространение получили методы заполнения пространства и пиксельная диаграмма корреляций.

В *методе заполнения пространства* каждый атрибут представляется пикселем. Цвет пикселя определяет диапазоном значения атрибута.

Пиксельная диаграмма корреляций фактически отображает матрицу диаграмм рассеяния, представленную значениями коэффициентов корреляции в цвете.

1.13.3. Принципы качественной визуализации

В связи с ростом требований к качественной визуализации данных, а также для сравнения методов визуализации между собой, в настоящее время сформулирован ряд принципов для качественного визуального представления данных.

Основные принципы качественной визуализации данных:

1. *Принцип лаконичности.* Визуальный образ должен содержать только элементы, необходимые пользователю.
2. *Принцип обобщения и унификации.* Визуальные образы должны быть обобщены и едины в форме представления.
3. *Принцип акцента на основных смысловых элементах.* Образы должны фокусировать внимание на основных информационных элементах в данных.
4. *Принцип структурности.* Образы отображают наиболее полную структуру данных.
5. *Принцип стадийности.*
6. *Принцип использования привычных ассоциаций и стереотипов.*
7. *Принцип надежности (достоверности).* Образы не должны искажать данные.

Визуальный анализ обычно выполняется в 3 этапа (рисунок 53):

1. *Беглый анализ*. Позволяет идентифицировать наиболее информативные шаблоны (профили и наборы объектов, характеризующиеся одинаковой тенденцией) и сфокусироваться на одном или нескольких из них.

2. *Увеличение и фильтрация*. Идентифицированные на предыдущем этапе шаблоны отфильтровываются и рассматриваются в большем масштабе.

3. *Детализация*. При необходимости пользователь может получить дополнительную информацию увеличив, степень детализации изображения.




Рисунок 53 – Основные этапы визуального анализа данных на примере интерпретации топологических карт Кохонена

Основные тенденции в области визуализации:

1. Разработка сложных видов диаграмм (спидометры, термометры, светофоры).

2. Повышение уровня взаимодействия пользователя с визуализацией (вращение диаграмм, замена цвета и подсветка, выделение объекта или группы объектов изображения).

3. Разработка интеллектуального программного обеспечения для визуализации данных.

1.14. Процесс интеллектуального анализа данных

Сам по себе процесс ИАД в полной мере не формализован. Однако, как и любое исследование, данный процесс можно представить в виде последовательности этапов. Традиционное представление этапов ИАД:

1. Анализ предметной области.

2. Постановка задачи.

3. Сбор и подготовка данных.

4. Построение моделей.

5. Проверка и оценка моделей.

6. Анализ данных.

7. Интерпретация и прогнозирование.

Рассмотрим подробнее основные этапы процесса ИАД.

Этап 1. Анализ предметной области. Решение любой задачи в ходе ИАД должно начинаться с изучения предметной области.

Предметная область – это область или направление реальной действительности, подлежащие описанию, моделированию или исследованию. Предметная область состоит из сущностей или объектов, различаемых по свойствам и взаимодействующих между собой каким-либо образом. Данная информация документирована в виде различных источников литературы: научные статьи, учебные пособия, научно-исследовательские отчеты, книги, энциклопедии.

Исследователю необходимо уметь прорабатывать предметную область и выделять существенную часть. Существенность данных зависит от выбора и качества проработки предметной области.

В процессе изучения предметной области должна быть создана ее модель или знания. Знания из различных источников должны быть формализованы. От того, насколько хорошо изучена, исследована и верно смоделирована предметная область, зависит успех дальнейшего процесса ИАД. Например, не проработав ключевые публикации по теме исследований, можно приступить к выполнению задачи, которая уже была решена. Или приступить к разработке программного приложения, аналог которого уже существует, но не был выявлен в ходе изучения предметной области.

Этап 2. Постановка задачи. Постановка задачи ИАД включает в себя формулировку задачи, формализацию задачи, описание статического и динамического поведения исследуемых объектов. Например, при продвижении нового программного обеспечения на рынке информационных технологий необходимо определить, какая группа клиентов или фирм будет наиболее заинтересована в данном интеллектуальном продукте.

Постановка задачи выделяет большую задачу и проблему, которую необходимо решить. Далее производится формализация данной задачи, т. е. в дальнейшем рассматриваются только наиболее важные и существенные элементы. Описание статики подразумевает формализованное описание объектов и их свойств. Описание динамики объектов подразумевает поведение объектов во времени и те причины, которые на них влияют.

Таким образом, перед выполнением ИАД необходимо корректно и правильно сформулировать те задачи, которые необходимо решить с помощью методов и моделей ИАД. Иначе технология ИАД не сможет заменить аналитика и ответить на вопросы, которые не были заданы. На данном этапе определяем, какую именно задачу необходимо решить в результате ИАД.

Этап 3. Сбор и подготовка данных. Целью этапа является разработка базы данных для ИАД. Сбор и подготовка данных важнейший этап от качества выполнения которого зависит возможность получения достоверных результатов всего процесса ИАД. Этап состоит из следующих фаз:

- 1) определение данных и требования к ним;
- 2) сбор данных;
- 3) определение необходимого количества данных;

4) очистка и нормировка данных;

5) стандартизация данных.

Рассмотрим более подробно фазы сбора и подготовки данных.

1. *Определение данных и требования к ним.* На основе имеющейся информации необходимо определить, что считать данными. Если это графики, то их нужно оцифровать. Если это функции, то их необходимо систематизировать. Если это анкеты, то их необходимо обработать. Основные требования к данным: формат представления данных; диапазоны изменения; вид хранения.

2. *Сбор данных.* На этапе сбора данных выполняются запросы в хранилища и базы данных, проводятся эксперименты, обработка бумажных носителей, документирование знаний экспертов или результаты опросов.

3. *Определение необходимого количества данных.* Требуется определить количество данных, необходимое для достоверных выводов ИАД. Можно положиться на опыт предыдущих исследований и взять такое же количество данных. Другой подход состоит в использовании небольшого набора данных, на основе которого выполняется предварительный, так называемый пилотный, или пробный, анализ. В результате пробного анализа требуется определить статистическими методами объем выборки, необходимый для достижения заданной погрешности расчетов.

4. *Очистка и нормировка данных.* На этом этапе осуществляется очистка данных. После того как получен набор данных, необходимо оценить качество данных. Под данными низкого качества, или грязными, данными подразумеваются отсутствующие, неточные или бесполезные данные с точки зрения практического применения (например, представленные в неверном формате). Наиболее распространенные виды грязных данных: пропущенные значения, дубликаты, шумы, выбросы. Нормировка данных позволяет минимизировать влияние экспериментальных шумов, искажений и прочих эффектов.

5. *Стандартизация данных.* Данные из различных экспериментов приводятся к единому стандарту. Как правило, процедура стандартизации данных включает шкалирование и центрирование.

Этап 4. Построение моделей. После того как данные подготовлены, необходимо приступить к разработке моделей. Рассмотрим подробнее основные понятия моделей и моделирования.

Моделирование – это способ исследования различных явлений путем замещения одного объекта другим (модель) с целью получения информации о важнейших свойствах объекта-оригинала.

Модель – упрощенное представление о реальном объекте (процессе, явлении и т. д.). Таким образом, моделирование – это процесс поиска и создания в природе объекта, который в некотором смысле может заменить исследуемый объект. Модель может быть материальным объектом, воспроизводящим оригинал логическими построениями или математическими выражениями и компьютерными программами.

Основные цели моделирования – интерпретация данных (объяснение объектов) и прогноз.

Классификация моделей и моделирования. Каждая модель создается для конкретной цели, и, следовательно, она уникальна. Однако наличие общих черт позволяет сгруппировать все многообразие моделей в отдельные классы, что облегчает их разработку и изучение. Наиболее популярна следующая классификация моделирования:

- 1) по характеру моделируемой стороны объекта;
- 2) по характеру процессов, протекающих в объекте;
- 3) по способу реализации модели.

Классификация по характеру моделируемой стороны объекта. В соответствии с данным признаком модели могут быть функциональными и структурными.

Функциональная модель – отображает только поведение, функцию моделируемого объекта. Моделируемый объект рассматривается как «черный ящик», имеющий входы и выходы. Физическая сущность объекта, природа протекающих в нем процессов, структура объектов остаются вне поля исследователя. При функциональном моделировании эксперимент состоит в наблюдении за выходом моделируемого объекта в зависимости от искусственного или естественного изменения входов. По этим данным и строится математическая модель (нейронная сеть, модель дисперсионного анализа).

Структурная модель – это модель, структура которой (элементы и связи) подобна структуре моделируемого объекта (деревья решений, топологическое описание дерева).

Классификация моделей по характеру процессов, протекающих в объекте:

- детерминированные модели (отображают процессы, в которых отсутствуют случайные воздействия);
- стохастические модели (отображают вероятностные процессы и события);
- статические модели (служат для описания состояния объекта в какой-либо момент времени);
- динамические модели (отображают поведение объекта во времени);
- дискретные модели (отображают поведение систем с дискретными состояниями);
- непрерывные модели (представляют системы с непрерывными процессами);
- дискретно-непрерывные модели (комбинируют системы с дискретными состояниями и непрерывными процессами).

Классификация моделей по способу реализации. По данному признаку модели подразделяются на материальные и абстрактные.

Материальные модели представляют собой реальные технические конструкции.

Абстрактные модели представляют собой определенные конструкции из общепринятых знаков на бумаге или в виде компьютерной программы. Абстрактные модели включают символьные (символические) и математические модели.

Символьная модель – это логический объект, замещающий реальный процесс и выражающий основные свойства его отношений с помощью определенной системы знаков или символов (знаки, тезаурусы, графики, диаграммы и т. п.).

Математическая модель – процесс установления соответствия моделируемому объекту некоторой математической конструкции и исследование этой модели, позволяющее получить характеристики моделируемого объекта. Математические модели подразделяются на аналитические и имитационные.

Аналитические модели – это функциональные соотношения: системы алгебраических, дифференциальных, интегро-дифференциальных уравнений, логических выражений.

Имитационные модели – учитывают влияние случайных факторов, реализуемых датчиками псевдослучайных чисел на ЭВМ. При наличии случайных факторов необходимые характеристики моделируемых процессов получаются многократными прогонами (реализациями) имитационной модели на компьютере и дальнейшей статистической обработкой накопленной информации.

Пример. Требуется сгенерировать колонку массива данных, представляющую набор значений некоторого атрибута X_j входных данных, с использованием имитационной модели. Предположим, что признак X_j подчиняется нормальному распределению с математическим ожиданием μ и дисперсией σ^2 . Сгенерируем заданное количество случайных величин N , имеющих нормальное распределение с математическим ожиданием μ и дисперсией σ^2 . Реализации x_{ij} , $i = 1, 2, \dots, N$ требуемой случайной величины могут быть получены по правилу

$$x_{ij} = \mu + z \cdot \sigma,$$

где z – реализация нормальной стандартизированной случайной величины $N(0, 1)$.

Смешанные модели представляют собой комбинации аналитических и имитационных моделей.

Построение модели ИАД включает несколько фаз, которые реализуются на **этапах 4–6 процесса ИАД**. Блок-схема этапов разработки и использования моделей ИАД расположена на рисунке 54.

Рассмотрим подробнее основные этапы построения моделей ИАД. В блоке 1 формируется содержательное описание исследуемой системы. Определяются цели моделирования (например, построение и прогноз на основе регрессии, классификация или ассоциация объектов, снижение размерности данных и т.д.). Вводятся характеристики системы исследуемых объектов (зависимые и независимые признаки объектов $X_1, X_2, \dots, X_K$), параметры системы, случайные

факторы. Выделяются наиболее значимые процессы, атрибуты и параметры, устанавливаются необходимые упрощения и аппроксимации. Выявляются существенные аспекты, исключаются второстепенные.

Построение модели




Рисунок 54 – Блок-схема этапов 4–6 процесса ИАД, включающих использование моделей.

В блоке 2 осуществляется алгоритмическое построение модели или нескольких моделей ИАД (например, уравнений линейной или нелинейной регрессии, деревьев решений, байесовских сетей, нейронной сети, кластерной модели и т. д.). Здесь же производится выбор наиболее удобного и эффективного метода ИАД для реализации задачи моделирования. Строятся схема модели и алгоритм использования методов ИАД. В блоке 3 осуществляется выбор языка программирования или программного обеспечения, реализующего ту или иную технологию ИАД. Осуществляется программная реализация алгоритмов выбранных методов и моделей ИАД. В блоке 4 реализуется отладка алгоритмов разработанных моделей и методов ИАД с учетом выбранного языка программирования. Валидация компьютерных программ производится на имитационно смоделированных данных или на обучающих экспериментальных данных (эталонной выборке). Выполняется проверка: все ли существующие параметры включены в модель, нет ли в модели несуществующих параметров, правильно ли отражены возможные функциональные связи и выполняются ли возможные балансные условия в модели, не дает ли модель абсурдные результаты и решения, если ее параметры принимают предельные значения? В блоке 5 выполняется анализ

экспериментальных данных методами ИАД с использованием разработанных моделей. В блоке 6 осуществляется проверка адекватности моделей и достоверности результатов моделирования. Стоит отметить, что проверка адекватности производится на всех этапах ИАД. Можно говорить об адекватности модели в любой ее форме, если:

- описание поведения, созданное на каком-либо этапе, достаточно точно совпадает с поведением моделируемой системы в аналогичных условиях;
- описание убедительно представлено относительно свойств системы, которые должны прогнозироваться с помощью модели.

Если в результате моделирования было построено несколько различных моделей, то на основе их оценки (точность моделирования и эффективность работы алгоритма) осуществляется отбор наилучшей модели, или коррекция, и последующие обновления разработанных моделей.

Требования к моделям ИАД: актуальность, результативность (результаты получают широкое применение), достоверность (соответствие результатов исследуемому процессу), экономичность, существенность (вскрытие неочевидных закономерностей), простота и лаконичность, открытость (возможность расширения и модификации).

В общем случае этапы 4–6 могут быть итеративными. Существует множество причин, по которым необходимо выполнить новую итерацию в построении модели. Возможные причины, по которым необходимо выполнить дополнительные итерации:

- изменились входные данные;
- появились дополнительные данные для обучения;
- изменились требования к входным данным;
- изменились параметры среды или окружения;
- изменилась цель анализа данных;
- коррекция и обновление моделей.

Этап 7. Интерпретация и прогнозирование. *Интерпретация* – объяснение и улучшение понимания объектов системы и их поведения. В ходе данного этапа исследуется поведение элементов системы на каких-либо критических точках, для которых получение данных недоступно по техническим или экономическим причинам. Решаются задачи оптимизации и оценки чувствительности системы.

Задача *оптимизации* – точное определение такого сочетания факторов и их величин, при котором обеспечивается наилучший показатель качества системы.

Анализ чувствительности – выявление факторов, которые в наибольшей степени влияющих на функционирование системы. Исходными данными являются результаты вычислительного эксперимента.

Прогнозирование – представляет собой предсказание поведения системы объектов на основе разработанной модели ИАД. Прогнозирование есть главная цель моделирования и оценка поведения системы при некотором сочетании ее управляемых и неуправляемых параметров.

В заключение следует отметить, что процесс ИАД сам по себе итерационный. В процессе ИАД следует использовать различные методы и алгоритмы, двигаясь от простых к сложным моделям, выполняя постепенное усложнение моделей.

Новый класс решаемых задач ИАД лег в основу дисциплины биоинформатика и связан с разработкой усовершенствованных подходов системного анализа и компьютерных моделей для исследования сложных биосистем в биологии, биомедицине, пищевой промышленности. *Биоинформатика* – научное направление, цель которого – разработка алгоритмов для анализа и систематизации генетической информации. Полученные алгоритмы используются для определения структур белков и макромолекул, генетических сетей и их функций для объяснения различных биологических процессов.

Пример использования процесса ИАД в биоинформатике представлен на рисунке 55.




Рисунок 55 – Визуализация этапов ИАД в биоинформатике.

По часовой стрелке на рисунке отображены фазы ИАД: разработка биочипов или микроматриц ДНК для регистрации генной информации (биочип ДНК позволяет получить информацию об экспрессии десятков тысяч генов); проведение экспериментальных измерений (эксперименты с биочипами ДНК позволяют выявить стратегии, используемые клеткой в ответ на изменение внешних условий; группы генов, функционально связанные друг с другом; реконструировать механизмы регуляции транскрипции и определить связанные с ними метаболические пути; аннотировать гены, функции которых в клетке оставались неизвестными); анализ многомерных данных, снятых с микрочипов ДНК для выделения выраженных и подавленных генов; анализ генной аннотации для определения активных биологических процессов, участвующих

в формировании заболевания; обновление баз данных и метаанализ открытых баз данных для выявления возможной структуры генетических сетей исследуемых биологических процессов; построение генетических сетей и моделирование биологических процессов на компьютере; подтверждение результатов моделирования в ходе биофизических экспериментов с использованием белков-маркеров генетических процессов; создание многоуровневых математических моделей, способных описывать поведение системы на различных уровнях детализации.

1.15. Стандарты и рынок инструментов интеллектуального анализа данных

1.15.1. Организационные и человеческие факторы

Если в компании или в научно-исследовательском центре принято решение использовать технологии ИАД, то это потребует от руководителя предприятия консолидации работы специалистов из различных областей профессиональной деятельности. Решение задачи или проблемы методами ИАД – это фактически межотраслевая задача, которая потребует интеграции и усилий специалистов различной квалификации и уровня.

Как правило, для решения задач ИАД необходимы как минимум три сотрудника: специалисты в предметной области (*domain expert*), по базам данных (*database administrator*) и в области анализа данных (*data mining specialist*). Их роли в ИАД распределяются следующим образом.

Специалист в предметной области должен иметь опыт работы в области исследований (экономист, биолог, медик, геолог, и т. д.) и быть способным объяснить факты, закономерности и характеристики, относящиеся к предметной области исследований, выдвинуть гипотезы о возможных связях между явлениями, предложить процедуры решения типовых задач.

Специалист по базам данных – эксперт, имеющий знания о том, где хранятся и в каком виде размещены данные, каким образом получить к ним доступ и как связать их между собой данные. Также он занимается модификацией данных, обеспечением целостности данных, загрузкой и ведением базы данных, их защитой, восстановлением баз данных, сбором и статистической обработкой обращений к базам данных, анализом эффективности функционирования баз данных.

Специалист по добыче и анализу данных – эксперт, способный использовать методы и модели ИАД в ходе практических исследований и проводить интерпретацию данных. Все три специалиста должны работать в одной связке и уметь разговаривать на общем языке.

Под организационными и человеческими факторами ИАД понимают наличие, умение и эффективность работы трех специалистов для решения той или иной задачи с применением технологий ИАД. Для профессиональной компании по разработке специализированного программного обеспечения в области ИАД, как правило, требуются дополнительные специалисты, такие как менеджеры, исследователи, аналитики, программисты, тестировщики.

Процесс ИАД практически никогда не является линейным, в большинстве случаев это итеративный циклический процесс. Именно итеративность гарантируют процессу ИАД такой результат, который будет адаптирован под решение конкретной задачи.

Процесс ИАД с точки зрения человеческого фактора является постоянным взаимодействием трех основных специалистов. Взаимодействие специалиста по добыче данных и специалиста по предметной области осуществляется в двух точках соприкосновения.

Первая точка – анализ предметной области, где определяются задачи и требования к будущей системе. Специалист по анализу данных должен вникнуть в предметную область, изучить ее базовые термины, другими словами, он должен провести анализ предметной области. На основании знаний методов и инструментов ИАД специалист по добыче данных предлагает вариант решения проблемы.

Второй точкой соприкосновения указанных выше экспертов является интерпретация результатов, полученных в результате ИАД. Взаимодействие специалистов по анализу и базам данных осуществляется на этапах анализа требований к данным и сбора данных. Непосредственно подготовка данных для ИАД может осуществляться специалистом по анализу данных самостоятельно либо во взаимодействии со специалистом по баз данных.

Взаимодействие трех специалистов осуществляется на завершающих этапах ИАД при проверке работоспособности системы, например при сравнении прогнозных результатов с реальными данными. При необходимости процесс ИАД возвращается на один из предыдущих этапов. От того, насколько консолидированы будут действия специалистов из разных областей, зависит длительность проекта и качество полученных результатов.

1.15.2. Стандарты интеллектуального анализа данных

Как правило, разработка приложений, направленных на интеллектуальный анализ данных в различных сферах профессиональной деятельности, не проводится изолированно и хаотично, а осуществляется в рамках свода неких правил или принципов, а точнее стандартов, принятых международным сообществом разработчиков программного обеспечения в области ИАД.

Принятые стандарты в основном затрагивают три аспекта ИАД (рисунок 56): 1) унификация интерфейсов; 2) выработка единого соглашения по хранению и передаче моделей ИАД; 3) организация процесса ИАД в целом.




Рисунок 56 – Основные стандарты интеллектуального анализа данных (ООЯП – объектно-ориентированные языки программирования).

Разработаны стандарты для унификации программных интерфейсов, посредством которых любое приложение может получить доступ к функциональности ИАД. Здесь выделяют два направления: 1) стандартизация интерфейсов для объектно-ориентированных языков программирования (CWM Data Mining, JDM); 2) регламентация разработок настроек для языка SQL, которая позволяет обращаться к инструментам ИАД, интегрированным непосредственно в реляционные базы данных (SQL/MM, OLE DB for Data Mining).

Стандарт *CWM* (Common Warehouse Metamodel) – стандарт разработан консорциумом OMG (Object Management Group – организация, занимающаяся разработкой стандартов на основе объектно-ориентированных подходов) для обмена метаданными между различными программными продуктами и репозиториями, участвующими в создании корпоративных систем принятия и поддержки решений. CWM включает в себя описание базовых элементов объектной модели, реляционных отношений, языка XML структуры семантики предметной области, архитектуры анализа данных.

Стандарт *JDM* (The Java Data Mining standard) – первая попытка создания программного интерфейса приложения Java API (Application Interface) для подключения доступа к методам ИАД из Java-приложений.

Стандарт *SQL/MM* (Standard Query Language/ Multimedia) разработан для описания библиотеки классов для объектных типов SQL. Обеспечивает интерфейс к алгоритмам ИАД.

Стандарт *OLE DB* для Data Mining разработан компанией Microsoft и применяет методы ИАД к реляционным базам данных. Стандарт расширяет возможности OLE DB и включен в SQL Server 2000 Analysis Services.

Стандарт *PMML*. Второй аспект определения стандартов связан с разработкой единого соглашения по передаче, хранению моделей ИАД и обменом различными системами программного обеспечения. Основой для подобного стандарта является язык XML (Extended Markup Language). Сам язык называется «Язык разметки для прогнозного моделирования» (*PMML* – Predicted Model Markup Language) и разработан IT-консорциумом DMG (Data Mining Group), объединяющим лидирующие компании в области анализа данных. Стандарт обеспечивает приложениям способ определения моделей ИАД, а также обмен такими моделями между *PMML*-совместимыми приложениями. *PMML* позволяет пользователям разрабатывать модели в приложении одного производителя и использовать приложения других производителей для визуализации, анализа, оценки и иного использования моделей. *PMML* включает: описание анализируемых данных (структуры и типа данных), описание схемы анализа (используемые поля данных), описание трансформации данных (преобразование типов данных), описание статистик, прогнозируемых полей и самих прогнозных моделей.

Для рекомендации по организации процесса ИАД в целом созданы стандарты *CRISP* и *SEMMA*.

Стандарт *CRISP(-DM)* (Cross Industry Standard Process for Data Mining) – это хорошо документированная и свободная модель, описывающая основные этапы ИАД, выполнение которых позволяет получить оптимальную выгоду от использования методов ИАД. Стандарт описывает подробно процесс ИАД и включает следующие этапы (рисунок 57):

1. *Осмысление проблемы (Business understanding)*. На данном этапе уделяется внимание целям проекта с точки зрения перспективности бизнеса, определяются знания в формулировке задач ИАД, разрабатывается первичный план достижения поставленных целей.

2. *Осмысление данных (Data understanding)*. Осуществляется первичный сбор данных для определения качества данных, предварительного исследования их сути, формирования гипотез о скрытых знаниях.

3. *Подготовка данных (Data preparation)*. Этап включает в себя все действия, связанные с окончательным формированием набора данных для анализа: выбор данных, очистка данных, конструирование данных, интеграция и форматирование данных.




Рисунок 57 – Жизненный цикл процесса ИАД согласно стандарту CRISP.

4. *Моделирование (Modelling)*. Фаза моделирования предназначена для выбора наиболее оптимального метода построения моделей ИАД (например, метод деревьев решений или нейронных сетей) и настройки его параметров для получения наилучших решений.

5. *Оценка результатов (Evaluation)*. Этап предназначен для более основательной проверки результатов ИАД в соответствии с поставленными бизнес-целями. Решаются задачи: оценка результатов, пересмотр процесса ИАД, определение дальнейших действий. В результате требуется принять решение, заканчивать ли проект и переходить к этапу внедрения или инициировать новую итерацию процесса ИАД.

6. *Внедрение (Deployment)*. Служит для организации знаний и их представлений в удобном для пользователя виде. Решаются задачи: планирование внедрения, планирование сопровождения и сохранения, производство конечных отчетов.

Подход *SEMMA* (Sample, Explore, Modify, Model, Asses) подразумевает, что все процессы выполняются в рамках гибкой оболочки, поддерживающей выполнение необходимых алгоритмов по обработке и анализу данных. Методология *SEMMA* не навязывает жестких правил. Стандарт *SEMMA* включает следующие фазы (рисунок 58):

1. *Выборка*. Подключение к источнику данных, разбиение данных и формирование набора данных.

2. *Исследование.* Визуальное исследование и интерактивный анализ, выявление ассоциаций.




Рисунок 58 – Жизненный цикл процесса ИАД согласно стандарту SEMMA.

3. *Модификация данных.* Предварительный анализ данных (фаза содержит методы для выбора, создания и преобразования переменных в рамках подготовки к моделированию данных, преобразования, фильтрации замещения данных).

4. *Моделирование.* Применение различных методов и моделей ИАД: кластерного анализа, нейронных сетей, деревьев решений и т. д.

5. *Оценка моделей.* Сравнение моделей и оценка их эффективности.

1.15.3. Рынок инструментов интеллектуального анализа данных

В настоящее время технологии ИАД представлены целым рядом коммерческих и свободнораспространяемых пакетов. Достаточно полный и регулярно обновляемый список программных продуктов размещен на сайте www.kdnuggets.com. Существует несколько различных способов классификации программных средств ИАД. Классификация программных средств ИАД по способу распространения программных продуктов представлена на рисунке 59.

Рассмотрим более подробно некоторые из представленных инструментов ИАД.

В состав программного продукта Matlab входят специализированные пакеты, реализующие методы ИАД. Основные пакеты – Statistics (содержит методы описательной статистики, визуализации данных, дисперсионного анализа, регрессионного анализа, кластерного анализа, классификации и прогнозирования), Neural Networks (содержит широкий набор методов нейронных сетей), Genetic Algorithms and Direct Search (включает генетические алгоритмы и метод имитации отжига). Тематические пакеты – Bioinformatics, SimBiology и другие пакеты, находящиеся в открытом доступе (SVM (support vector machines), cluster).




Рисунок 59 – Классификация программных средств ИАД по способу распространения.

Пакет R представляет собой среду статистического программирования для решения прикладных задач статистики, в том числе и задач ИАД. В данный момент язык R является общепринятым языком для обмена информации в статистическом сообществе и фактически стал стандартом для статистическим программ. В R используется интерфейс командной строки, хотя доступны и несколько графических интерфейсов пользователя, такие как RCommander, RStudio, Rapid Miner, KNIME, а также средства интеграции в офисные пакеты. Пакет R поддерживает широкий спектр статистических и численных методов, обладает хорошей расширяемостью с помощью пакетов. Пакеты представляют собой библиотеки специализированных функций для конкретных областей применения. В базовую поставку R включен основной набор пакетов, а всего по состоянию на 2006 г. доступно более 800 пакетов. Еще одной особенностью R являются графические возможности, заключающиеся в создании качественной графики, которая может включать в себя математические символы. В 2010 г. R вошел в список победителей конкурса журнала InfoWorld в номинации «Лучшее открытое программное обеспечение для разработки приложений».

Пакет SAS Enterprise-Miner позволяет оптимизировать процесс ИАД в целом, начиная от организации доступа к данным и заканчивая оценкой готовой модели. Это интегрируемый компонент системы SAS, созданный специально для выявления в огромных массивах данных информации, необходимой для принятия решений. Пакет использует стандарт SEMMA и полностью интегрирован с программным обеспечением SAS Warehouse Administrator, предназначенной для разработки и эксплуатации информационных хранилищ. В пакете реализован подход, основанный на создании диаграмм процессов обработки данных (наподобие диаграмм Simulink в Matlab). Диаграммы выступают в качестве шаблонов, которые можно

изменять для решения новых задач. Созданные диаграммы можно сохранять в формате XML.

Пакет Statistica Data Miner спроектирован и разработан как универсальное средство анализа данных, реализующие так называемый графический подход. Используются диаграммы процессов обработки данных. Интегрированы этапы сбора данных (data acquisition), предварительной обработки (preprocessing), моделирование, анализ данных, создание отчетов.

Пакет WEKA (Waikato Environment for Knowledge Analysis) является программным продуктом университета Уайкато (Новая Зеландия). Программное обеспечение разработано на языке Java и обеспечивает графический пользовательский интерфейс для работы с файлами данных и визуализации результатов (в виде таблиц и графиков). WEKA позволяет выполнять такие задачи анализа данных, как подготовка и предварительная обработка данных, кластеризация, классификация, регрессионный анализ и визуализация данных.

Пакет Python – универсальный язык программирования, широко используется в прикладных задачах, в том числе и для анализа данных. В языке делается акцент на производительность и удобочитаемость кода. Включает набор библиотек для интеллектуального анализа данных: NumPy (модули для математических вычислений), SciPy (модули для оптимизации, интегрирования, специальных функций, обработки сигналов и изображений, генетических алгоритмов, решения обыкновенных дифференциальных уравнений), Pandas (обработка табличных данных), Matplotlib (построение графических изображений), Scikit-learn (методы машинного обучения), TensorFlow, Keras (нейронные сети) и др.

2. ПРАКТИЧЕСКИЙ РАЗДЕЛ

Лабораторные занятия по курсу «Интеллектуальный анализ данных» проводятся в объеме 34 учебных часов. В задачи лабораторных занятий входит практическое применение методов интеллектуального анализа данных для решения ряда прикладных задач обработки и анализа многомерных наборов данных на примере использования среды математического программирования MATLAB.

Лабораторное занятие № 1. Основы работы в Matlab. Изучение элементов языка, основных функций и среды MATLAB. Решение систем линейных уравнений. Создание пользовательских функций и построение их графиков в среде MATLAB. Изучение генератора базовой случайной величины (6 часов).

Лабораторное занятие № 2. Нелинейный метод наименьших квадратов. Практическое освоение анализа экспериментальных данных с помощью нелинейного метода наименьших квадратов (4 часа).

Лабораторное занятие № 3. Метод главных компонент. Практическое освоение метода главных компонент для решения задач снижения размерности и визуализации многомерных данных (4 часа).

Лабораторное занятие № 4. Иерархические методы кластерного анализа. Практическое освоение методов иерархического кластерного анализа данных. (4 часа).

Лабораторное занятие № 5. Неиерархические методы кластерного анализа. Практическое освоение неиерархического кластерного анализа многомерных данных на примере метода k-средних (4 часа).

Лабораторное занятие № 6. Нейронные сети. Слой Кохонена. Изучение алгоритма нейронной сети слой Кохонена для решения задачи кластерного анализа (4 часа).

Лабораторное занятие № 7. Нейронные сети. Карты Кохонена. Изучение самоорганизующихся нейронных сетей на основе карт Кохонена для решения задач кластеризации и визуализации многомерных данных (4 часа).

Лабораторное занятие № 8. Стохастические методы поиска. Практическое освоение алгоритмов программирования стохастических методов поиска глобального экстремума (минимума) многомодальной целевой функции нескольких переменных. (4 часа).

3. РАЗДЕЛ КОНТРОЛЯ ЗНАНИЙ

3.1. Перечень рекомендуемых средств диагностики

Для диагностики компетенций, учащихся рекомендуется использовать следующие формы: устная и техническая.

Отметка за ответы на лекциях (опрос) может включать в себя полноту ответа, наличие аргументов, примеров из практики и т.д.

При оценивании практических работ принимается во внимание правильность полученных результатов, владение соответствующим теоретическим материалом, ответы на контрольные вопросы, способность учащегося теоретически обосновать и детально пояснить полученные результаты и практическую реализацию задания.

Техническая форма диагностики реализуется в виде электронных тестов, проводимых с использованием специализированных информационных систем, применяемых в БГУ.

Выполняются три контрольные работы в виде письменных тестов.

Выполняется самостоятельная работа по темам реферативных работ. При оценивании реферата (доклада) обращается внимание на содержание и полноту раскрытия темы, структуру и последовательность изложения, источники и их интерпретацию, корректность оформления.

Формой текущей аттестации по дисциплине «Интеллектуальный анализ данных» учебным планом предусмотрен зачет.

Примерные весовые коэффициенты, определяющие вклад текущего контроля знаний и текущей аттестации в итоговую отметку:

Формирование оценки за текущую успеваемость:

- Тест – 10 %.
- Контрольная работа – 10 %.
- Отчет по лабораторной работе – 60 %.
- Реферат – 20 %.

Итоговая отметка по дисциплине рассчитывается на основе отметки текущей успеваемости – 50 % и отметки на зачёте – 50 %.

3.2. Темы реферативных работ

1. Метод главных координат (Multidimensional scaling).
2. Метод сингулярного разложения (Singular-value decomposition).
3. Латентное размещение Дирихле (Latent Dirichlet allocation).
4. Метод независимых компонент (Independent component analysis).
5. Метод неотрицательного матричного разложения (Non-negative matrix factorization).
6. Метод стохастического вложения соседей с t-распределением (tSNE).
7. Метод равномерного многообразного приближения и проекции (UMAP).
8. Алгоритм BIRCH (Balanced Iterative Reducing and Clustering using Hierarchies).

9. Алгоритм байесовского иерархического кластерного анализа (Bayesian hierarchical clustering algorithm).
10. Алгоритм вероятностного иерархического кластерного анализа (probabilistic hierarchical clustering algorithm).
11. Алгоритм гибридного иерархического кластерного анализа (probabilistic hierarchical clustering algorithm).
12. Алгоритм Chameleon.
13. Алгоритм PAM (Partitioning Around Medoids).
14. Алгоритм CLARA (Clustering LARge Application).
15. Алгоритм CLARANS (Clustering Large Applications based on RANdomized Search).
16. Спектральный алгоритм кластерного анализа.
17. Алгоритм DBSCAN (Density Based Spatial Clustering of Applications with Noise).
18. Алгоритм DENCLUE (DENsity-based CLUstEring).
19. Алгоритм STING (STatistical Information Grid).
20. Алгоритм CLIQUE (CLustering In QUEst).
21. Алгоритм кластерного анализа WAVE.
22. Алгоритм EM (Expectation Maximization).
23. Алгоритм MAFLA (maximal frequent itemset algorithm).
24. Алгоритм SCAN (Structural Clustering Algorithm for Network).
25. Алгоритм C4.5.
26. Алгоритм CART.
27. Алгоритм SLIQ.
28. Алгоритм SPRINT.
29. Алгоритм Conditional Inference Tree.
30. Алгоритм RIPPER (Repeated Incremental Pruning to Produce Error Reduction)
31. Алгоритм Random forests.
32. Алгоритм Gradient Boosting.
33. Алгоритм CatBoost.
34. Алгоритм LightGBM.
35. Алгоритм XGBoost.
36. Метод опорных векторов (Support Vector Machine).
37. Сверточные нейронные сети (Convolutional neural networks).
38. Рекуррентные нейронные сети (Recurrent neural network).
39. Нейронные сети Автоэнкодеры (autoencoders).
40. Алгоритм Eclat (Equivalence CLASS Transformation).
41. Алгоритм AprioriTid.
42. Алгоритм DHP.
43. Алгоритм Charm.
44. Алгоритм GSP (generalized sequential patterns).
45. Алгоритм SPADE (Sequential Pattern Discovery using Equivalent classes).

3.3. Вопросы для подготовки к зачету

1. Основные понятия интеллектуального анализа данных. Методы и задачи интеллектуального анализа данных.
2. Данные. Понятие данных. Типы шкал наборов данных. Типы наборов данных.
3. Примеры практического применения дисциплины ИАД. Медицина. Биоинформатика. Геология. Банковское дело. Торговля.
4. Методы предварительного анализа данных. Описательная статистика. Очистка данных.
5. Методы предварительного анализа данных. Нормировка и стандартизация данных. Анализ выбросов и аномальных значений.
6. Корреляционный анализ. Коэффициент корреляции Пирсона. Ранговая корреляция.
7. Корреляционный анализ. Коэффициенты корреляции Спирмена и Кендэла. Множественная и частная корреляции.
8. Регрессионный анализ. Регрессия. Линейный и нелинейный многомерный регрессионный анализ.
9. Методы снижения размерности данных. Метод главных компонент. Примеры практического применения метода главных компонент.
10. Кластерный анализ. Основы кластерного анализа. Математические характеристики кластера. Критерии качества кластеризации. Выделение значимых кластеров.
11. Кластерный анализ. Иерархические агломеративные и дивизимные методы иерархического кластерного анализа.
12. Кластерный анализ. Неиерархические итерационные методы кластерного анализа. Алгоритм k-средних. Алгоритм Fuzzi k-средних.
13. Кластерный анализ. Графовые методы кластерного анализа. Алгоритмы кратчайшего незамкнутого пути и ФОРЭЛ.
14. Нейронные сети. Нейрон. Нейронная сеть. Архитектура нейронных сетей. Модель нейронной сети Персептрон.
15. Нейронные сети. Алгоритмы обучения нейронных сетей. Алгоритм Хебба. Адаптивное обучение.
16. Нейронные сети Кохонена. Нейронная сеть слой Кохонена.
17. Нейронные сети Кохонена. Самоорганизующиеся карты Кохонена.
18. Методы случайного поиска. Простой стохастический поиск. Случайный поиск. Метод Метрополиса.
19. Стохастический поиск по методу имитационного отжига.
20. Эволюционные стратегии поиска. Селекция. Скрещивание. Мутация.
21. Генетические алгоритмы.
22. Методы классификации. Анализ данных с использованием деревьев решений. Алгоритмы построения деревьев решений ID3 и покрытия.
23. Методы классификации. Байесовская классификация.
24. Методы классификации. Метод k-ближайших соседей. Метод наименьшего расстояния (до центров классов). Методы перекрёстной проверки.

25. Методы поиска ассоциативных правил. Суть задачи поиска ассоциативных правил. Алгоритм Apriori.
26. Методы поиска ассоциативных правил. Алгоритм FPG.
27. Методы визуального представления данных. Способы представления информации в одно-, двух-, трехмерном измерениях.
28. Алгоритмы отображения информации в более чем трех измерениях. Принципы качественной визуализации.
29. Процесс интеллектуального анализа данных. Основные этапы процесса интеллектуального анализа данных.
30. Процесс интеллектуального анализа данных. Этапы, связанные с подготовкой данных.
31. Процесс интеллектуального анализа данных. Этапы процесса, связанные с построением, проверкой, оценкой, выбором и коррекцией моделей. Анализ данных. Интерпретация и прогнозирование.
32. Стандарты и рынок инструментов интеллектуального анализа данных. Организационные и человеческие факторы.
33. Стандарты к интеллектуальному анализу данных. Рынок инструментов интеллектуального анализа данных.
34. Основные элементы m-языка программирования.
35. Анализ многомерных данных в среде Matlab.

4. ВСПОМОГАТЕЛЬНЫЙ РАЗДЕЛ

4.1. Список рекомендуемой литературы

Основная

1. Шакла, Н. Машинное обучение и TensorFlow / Н. Шакла. – СПб. : Питер, 2019. – 336 с.
2. Наглядная математическая статистика: учеб. пособие / Б. М. Лагутин. – М.: БИНОМ. Лаборатория знаний, 2021. – 472 с.
3. Николенко, С. Глубокое обучение. / С. Николенко, А. Кадурын, Е. Архангельская – СПб.: Питер, 2018. – 480 с.
4. Мэрфи, К. П. Вероятностное машинное обучение: введение / пер. с англ. А. А. Слинкина. – М.: ДМК Пресс, 2022. – 940 с.
5. Интеллектуальный анализ данных: методические указания к лабораторным работам / Н. Н. Яцков, Е. В. Лисица. – Минск: БГУ, 2019. – 51 с.

Дополнительная

1. Афифи, А. Статистический анализ: Подход с использованием ЭВМ : пер. с англ. / А. Афифи, С.Эйзен. – М., 1982. – 488 с.
2. Прикладная статистика: Классификация и снижение размерности : справ. изд. / С. А. Айвазян [и др.] ; под ред. С. А. Айвазяна. – М., 1989. – 607 с.
3. Дронов, С. В. Многомерный статистический анализ : учеб. пособие / С. В. Дронов. – Барнаул, 2003. – 213 с.
4. Дюк, В. Data Mining: учебный курс / В. Дюк, А. Самойленко. –СПб., 2001. 368 с.
5. Анализ данных и процессов: учеб. пособие / А. А. Барсегян [и др.]. – 3-е изд., перераб. и доп. – СПб., 2009. – 512 с.

4.2. Электронные ресурсы

1. Образовательный портал БГУ – учебная дисциплина «Интеллектуальный анализ данных» [Электронный ресурс]. – Режим доступа: <https://edufpmi.bsu.by/>. – Дата доступа 27.10.2023.
2. Каталог учебной дисциплины «Интеллектуальный анализ данных» в электронной библиотеке БГУ [Электронный ресурс]. – Режим доступа: <https://elib.bsu.by/handle/123456789/48681>. – Дата доступа 27.10.2023.