

Лаб_8, компонентный анализ,
сформировано с использованием <https://mashagpt.ru/>

**ЗАДАНИЕ: Уменьшение размерности датасета с помощью
РСА и визуализация)**

1. Загрузка и предварительный анализ данных

- Загрузите датасет.
- Выведите первые 5 строк, размерность матрицы признаков, названия признаков.
- Вычислите среднее и стандартное отклонение каждого признака.

2. Стандартизация данных

- Выполните стандартизацию (Z-score normalization) признаков с помощью StandardScaler.
- Объясните, зачем нужна стандартизация перед РСА.

3. Вычисление ковариационной матрицы и собственных векторов (вручную)

- Рассчитайте ковариационную матрицу стандартизированных данных.
- Найдите собственные значения и собственные векторы этой матрицы с помощью `np.linalg.eig`.
- Отсортируйте собственные пары по убыванию собственных значений.

4. Реализация РСА с помощью `sklearn.decomposition.PCA`

- Создайте объект `PCA(n_components=2)` и примените его к стандартизированному данным.
- Получите проекцию данных на первые две главные компоненты.

5. Визуализация результатов

- Постройте scatter plot проекции данных, окрасив точки по целевому классу.

- Подпишите оси: Главная компонента 1, Главная компонента 2.
- Добавьте легенду.

6. Анализ доли объясненной дисперсии

- Вычислите `explained_variance_ratio_` для двух главных компонент.
- Постройте столбчатую диаграмму (bar plot) доли объясненной дисперсии для первых 4 компонент.
- Интерпретируйте результат: сколько процентов дисперсии сохраняет проекция на 2 компоненты?

7. Загрузка весов главных компонент (loadings)

- Выведите матрицу `components_` (коэффициенты перехода от исходных признаков к главным компонентам).
- Определите, какой исходный признак вносит наибольший вклад в первую главную компоненту.

ИСПОЛЬЗОВАТЬ ДАТАСЕТ:

1. "Iris dataset" (Ирисы)

Описание: содержит 150 образцов ирисов, каждый описывается 4 признаками (длина чашелистика, ширина чашелистика, длина лепестка, ширина лепестка). Целевая переменная — сорт ириса (3 класса).

Использование: классификация видов ирисов.

Где взять: встроен в `scikit-learn`. `sklearn.datasets`

2. "Breast Cancer Wisconsin" (рак молочной железы)

Описание: Breast Cancer Wisconsin Dataset (Рак груди)

Источник: `sklearn.datasets.load_breast_cancer`

Размерность: 569 образцов × 30 признаков

Классы: 2 (злокачественный/доброкачественный)

Особенности: Характеристики ядер клеток

Интерес для PCA: Высокая размерность → явная польза снижения

Задача: бинарная классификация (злокачественный / доброкачественный рак).

Источник: встроен в scikit-learn (`load_breast_cancer()`).

Формат: числовые признаки + метки (0 или 1).

3. "Wine" (Вина)

Описание: Wine Dataset (Классификация вин)

Источник: `sklearn.datasets.load_wine`

Размерность: 178 образцов × 13 признаков

Классы: 3 сорта вин

Особенности: Химический состав вин (алкоголь, кислотность, фенолы и др.)

Задача: классификация сорта вина.

Источник: UCI Wine dataset

Формат: числовые признаки + метки классов (3 класса).

4. "Digits" (Цифры)

Описание: digits Dataset (Рукописные цифры)

Источник: `sklearn.datasets.load_digits`

Размерность: 1797 образцов × 64 признака (8×8 пикселей)

Классы: 10 цифр (0–9)

Особенности: Изображения в оттенках серого

Интерес для PCA: Визуализация кластеров цифр, потеря деталей при сжатии

Задача: классификация цифр от 0 до 9.

Источник: встроен в scikit-learn (`load_digits()`).

Формат: числовые признаки + метки (0–9).

5. "Social Network Ads"

Описание: Данные о пользователях соцсетей и их реакции на рекламу.

Задача: предсказать, кликнул пользователь на рекламу или нет (да/нет).

Особенности: sociales data — 3 числовых признака (возраст, доход, время просмотра), а также метка (0 или 1).

Источник: Можно найти в открытых репозиториях или Kaggle

6. "Bank Marketing"

Описание: Данные о маркетинговых кампаниях банка для определения, откликнется ли клиент.

Задача: задача бинарной классификации (откликнул / не откликнулся).

Источник: UCI Bank Marketing

Формат: категориальные и числовые признаки.