## Раздел 3. Проектирование баз данных

Тема 3.4.

Нормализация схемы реляционной БД.

- 1. Основные понятия нормализации.
- 2. Последовательность действий, выполняемая в процессе нормализации.

Классическая технология проектирования реляционных баз данных с использованием декомпозиции связана с теорией нормализации, основанной на анализе функциональных зависимостей между атрибутами отношений.

Функциональные зависимости определяют устойчивые отношения (связи) между объектами и их свойствами в рассматриваемой предметной области.

Для чего нужна нормализация схемы БД?

Рассмотрим для примера конкретную схему отношений и проанализируем её недостатки.

Предположим, что данные о студентах, факультетах, специальностях, включены в таблицу со следующей схемой отношения:

**СТУДЕНТ** (Код студента, Фамилия, Название факультета, Название специальности).

Код студента	Фамилия	Название факультета	Название специальности
025001	Иванов	Экономики	Менеджер-экономист
025002	Петров	ФПМИ	Математик-программист
025101	Сидоров	Журналистики	репортер

 ОТНОШЕНИЕ «СТУДЕНТ»

 Код студента
 Фамилия
 Название факультета
 Название специальности

 025001
 Иванов
 Экономики
 Менеджер-экономист

 025002
 Петров
 ФПМИ
 Математик-программист

Эта схема отношений обусловливает следующие недостатки соответствующей реальной базы данных:

- **Дублирование информации (избыточность)**. У студентов, обучающихся на одном факультете, <u>будет повторяться название факультета</u>. Для разных факультетов могут повторяться специальности.
- ▶ Потенциальная противоречивость (аномалии обновления). Если, например, изменится название специальности, то изменяя её в одном кортеже (у одного студента), необходимо изменять и во всех других кортежах, где она присутствует.
- > Потенциальная возможность потери сведений (аномалии удаления). При удалении информации о всех студентах, поступающих на определенную специальность, мы теряем все сведения об этой специальности.
- Потенциальная возможность невключения информации в базу данных (аномалии включения). В базе данных будут отсутствовать сведения о специальности, если на ней нет обучающихся студентов.

Построение рационального варианта схем отношений (обладающего лучшими свойствами при операциях включения, модификации и удаления данных, чем все остальные наборы схем) и осуществляется путем так называемой нормализации схем отношений.

Нормализация производится в несколько этапов, при этом каждая последующая итерация соответствует нормальной форме более высокого уровня и обладает лучшими свойствами по сравнению с предыдущей.

Каждой нормальной форме соответствует некоторый определенный набор ограничений, и <u>отношение находится в некоторой нормальной форме, если удовлетворяет свойственному ей набору ограничений.</u>

Таким образом - Один и тот же набор данных в реляционной модели можно представить различными способами.

Процесс нормализации данных позволяет решить вопрос о наиболее эффективной их структуре, обладающей минимальной избыточностью.

Это позволяет решить следующие задачи:

- а) исключить ненужное повторение данных,
- b) обеспечить быстрый доступ к данным,
- с) обеспечить целостность данных.

Обычно говорят только об уменьшении избыточности данных и поэтому часто нормализацией называют процесс уменьшения избыточности данных в реляционной БД. Это не совсем верно.

# В теории реляционных БД обычно выделяется следующая последовательность нормальных форм:

- первая нормальная форма (1NF);
- вторая нормальная форма (2NF);
- третья нормальная форма (3NF);
- нормальная форма Бойса— Кодда (BCNF);
- четвертая нормальная форма (4NF);
- > пятая нормальная форма, или форма проекции-соединения (5NF или PJNF).

На начальном этапе схема отношений должна находиться в первой нормальной форме (1НФ).

#### Без этого эта схема не будет считаться схемой РБД.

При некоторых предположениях о данных **третья** нормальная форма является наилучшим искомым вариантом.

Если эти предположения не выполняются, то процесс нормализации продолжается и отношение преобразуется к следующей нормальной форме.

### Основные свойства нормальных форм:

- ✓ каждая следующая нормальная форма уменьшает избыточность данных и улучшает свойства предыдущей;
- ✓ при переходе к следующей нормальной форме свойства предыдущих нормальных форм сохраняются.

Перевод отношения в следующую нормальную форму осуществляется методом «декомпозиции без потерь», т. е. разбиением исходной таблицы на несколько связанных.

Такая декомпозиция должна обеспечить равенство результатов выборок (поисковых запросов)

- из исходного отношения и
- » выборок, основанных на **совокупности** полученных в результате нормализации отношений (таблиц).

Итак, в основе классического процесса проектирования лежит <u>последовательность переходов от предыдущей</u> нормальной формы к последующей (декомпозиции).

Однако в процессе декомпозиции мы сталкиваемся с проблемой обратимости, то есть возможности восстановления исходной схемы.

Таким образом, **декомпозиция должна сохранять эквивалентность схем** БД при замене одной схемы на другую.

Схемы БД называются эквивалентными, если содержание исходной БД может быть получено путем естественного соединения отношений, входящих в результирующую схему, и при этом не появляется новых кортежей в исходной БД.

При выполнении эквивалентных преобразований **сохраняется множество исходных фундаментальных функциональных зависимостей** между атрибутами отношений.

Функциональной зависимостью набора атрибутов В отношения R от набора атрибутов А того же отношения, обозначаемой как R.A -> R.B или A -> B

называется такое соотношение проекций R[A] и R[B], при котором в каждый момент времени <u>любому элементу проекции R[A]</u> соответствует только один элемент проекции R[B], входящий вместе с ним в какой-либо кортеж отношения R.

Студ_ном	Студ_Фам	Студ_предм	Студ_оценка
27711	Иванов	БД	5
27601	Петров	БД	8

R.Студ\_ном -> R.Студ\_Фам или Студ\_ном -> Студ\_Предм

Если в отношении существует несколько функциональных зависимостей, то каждый атрибут или набор атрибутов, от которого зависит другой атрибут, называется детерминантом отношения.

Студ_ном	Студ_Фам	Студ_билет	Студ_оценка
27711	Иванов	5778	5
27601	Петров	3562	8

Студ\_ном -> Студ\_Фам, Студ\_ном -> Студ\_билет

Атрибут Студ\_ном – детерминант данного отношения

Функциональные зависимости определяют не текущее состояние БД, а все возможные ее состояния, то есть они отражают те связи между атрибутами, которые присущи реальному объекту, моделируемому с помощью схемы БД.

Набор функциональных зависимостей задает разработчик, системный аналитик, исходя из глубокого системного анализа предметной области.

# Рекомендации, которых следует придерживаться при нормализации таблиц.

- 1. Разрабатывайте схему данных таким образом, чтобы можно было бы легко объяснить ее, т. е. не комбинируйте атрибуты независимых объектов и не создавайте сложные связи.
- 2. Разрабатывайте схему данных таким образом, чтобы <u>исключить</u> возможность появления аномалий обновления.
- 3. Разрабатывайте схему данных таким образом, чтобы в связях участвовали только <u>первичные</u> (можно допустить потенциальные) <u>и внешние ключи</u>. Это позволит избежать появления подложных записей.
- 4. Не обязательно нормализовывать все таблицы БД, и притом не обязательно до форм высших порядков.

## Раздел 3. Проектирование баз данных

Тема 3.4.

Нормализация схемы реляционной БД.

- 1. Основные понятия нормализации.
- 2. Последовательность действий, выполняемая в процессе нормализации.

**Первая** нормальная форма требует соответствия исходной таблицы общим требованиям, предъявляемым к реляционным отношениям, т. е.:

- 1) таблица не должна иметь повторяющихся записей;
- 2) все атрибуты должны быть простыми (скалярными).

Первое требование легко решается введением ключевого поля, однозначно определяющего остальные поля таблицы.

Второе требование постулирует, чтобы в каждой ячейке было представлено только одно значение, а не массив или перечисление.

Составные поля должны быть разложены на простые, а многозначные — вынесены в отдельные таблицы или разложены по отдельным строкам (с дублированием значений всех остальных полей).

Т.о. - отношение находится в первой нормальной форме тогда и только тогда, когда на пересечении каждого столбца и каждой строки находятся только элементарные значения атрибутов.

Отношения, находящиеся в первой нормальной форме, часто называют **просто нормализованными** отношениями.

Соответственно, ненормализованные отношения могут интерпретироваться как таблицы с неравномерным заполнением, например таблица «Расписание», которая представлена на следующем слайде:

Преподаватель	День	Пара	Дисц	Группа
Иванов	пнд	1	БД	111101
	ВТР	1	БД	111102
	ВТР	3	АСУ	91101
Петров	ПНД	1	BM	111101
	ВТР	1	BM	111101
Киров	ПНД	2	ИТ	111101
Преподаватель	День	Пара	Дисц	Группа
<b>Преподаватель</b> Иванов	<b>День</b> ПНД	<b>Пара</b> 1	<b>Дисц</b> БД	<b>Группа</b> 111101
		-		
Иванов	ПНД	1	БД	111101
Иванов Иванов	ПНД ВТР	1 1	БД БД	111101 111102
Иванов Иванов Иванов	ПНД BTP BTP	1 1 3	БД БД АСУ	111101 111102 91101

Таблица находится во второй нормальной форме, если:

- 1) она удовлетворяет условиям первой нормальной формы;
- 2) любое поле, не входящее в ключ, должно однозначно и полно идентифицироваться значением первичного ключа.

Если первичный ключ является составным, то остальные поля должны зависеть от его полного выражения, а не от части (неключевые атрибуты должны характеризоваться полной функциональной зависимостью от первичного ключа).

Функциональная зависимость R.A -> R.B называется *полной*, если набор атрибутов В функционально зависит от A и не зависит функционально от любого подмножества A,

то есть R.A -> R.B называется полной, если: любое A1 из A => R.A1 -/-> R.B, что читается следующим образом:

для любого **A1**, являющегося <u>подмножеством A отношения R</u>, **R.B** функционально не зависит от R.A1, **в противном случае** зависимость R.A -> R.B называется **неполной**.

Т.о. - отношение находится во второй нормальной форме тогда и только тогда, когда оно находится в первой нормальной форме и не содержит неполных функциональных зависимостей непервичных (неключевых) атрибутов от отдельных атрибутов составного первичного ключа.

ФИО	Номер_Зач_ КН	Группа	Дисципл	Оценка
Иванов	45900	111101	БД	9

Первичным ключом отношения может быть (**Номер, зач.кн.. Дисциплина**), однозначно определяющие строки данного отношения.

Но атрибуты ФИО и Группа зависят только от части первичного ключа — от значения атрибута Номер зач, кн., поэтому мы должны констатировать наличие неполных функциональных зависимостей в данном отношении.

Для приведения данного отношения ко второй нормальной форме следует разбить его на проекции, при этом должно быть соблюдено условие восстановления исходного отношения без потерь.

Такими проекциями могут быть два отношения:

(ФИО, Номер.зач.кн., Группа) и (Номер зач.кн., Дисциплина. Оценка)

Этот набор отношений не содержит неполных функциональных зависимостей, и поэтому эти два отношения находятся во второй нормальной форме.

Таблица находится в третьей нормальной форме, если:

- 1) она удовлетворяет условиям второй нормальной формы;
- 2) ни одно <u>из полей таблицы, не входящих в ключ, не должно идентифицироваться</u> с помощью другого поля, не входящего в ключ

(иначе, такое отношение не должно иметь неключевых атрибутов, которые бы находились в транзитивной зависимости от первичного ключа).

Функциональная зависимость R.A -> R.B называется *транзитивной*, если существует набор атрибутов С такой, что:

- 1. С не является подмножеством А.
- 2. С не включает в себя В (В не является подмножеством С).
- 3. Существует функциональная зависимость R.A -> R.C.
- 4. Не существует функциональной зависимости R.C -> R.A.
- 5. Существует функциональная зависимость R.C -> R.B.

Другими словами, существует зависимость R.A -> R.C -> R.B Итак, отношение находится в третьей нормальной форме тогда и только тогда, когда оно находится во второй нормальной форме и не содержит транзитивных зависимостей.

На примере следующего отношения видим, что оно не находится в третьей НФ:

ФИО	Ном_Зач_Кн	Группа	Факультет	Спец-ть	Вып_Каф
Иванов	2345	111101	ФИИ	ИСиТ	АИС

В этом случае у нас есть следующие функциональные зависимости:

Номер зач .кн. -> ФИО

Номер зач.кн. -> Группа

Номер зач.кн. -> Факультет

Номер зач.кн. -> Специальность

Номер зач.кн. -> Выпускающая кафедра

#### Но при этом еще есть зависимости:

Группа -> Факультет

Группа -> Специальность

Группа -> Выпускающая кафедра

и еще: Выпускающая кафедра -> Факультет

Получается эти зависимости образуют транзитивные группы.

Для того чтобы избежать этого, мы можем предложить следующий набор отношений:

(Номер. зач. кн., ФИО. Специальность. Группа)

(Группа., Выпускающая кафедра)

(Выпускающая кафедра, Факультет)

Первичные ключи отношений выделены.

Полученный набор отношений находится в третьей нормальной форме. При этом в случае естественного соединения таблиц мы:

- ✓ не потеряем ни одной строки и
- ✓ не получим <u>лишних кортежей</u> данных.

### На этом процесс нормализации обычно заканчивается.

Если же необходима более детальная проработка данных, то дополнительно рассматривают требования нормальных форм более высокого порядка.

Третья нормальная форма постулирует отсутствие зависимости одних неключевых атрибутов от других неключевых атрибутов, забывая о том, что в ряде случаев может наблюдаться зависимость части ключевого составного атрибута от некоторого неключевого атрибута.

Если в таблице имеется такая зависимость, то необходимо перейти **к усиленной третьей нормальной форме**, или форме Бойса – Кодда (BCNF).

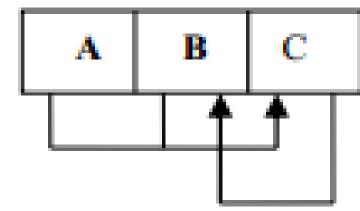
### Таблица находится в нормальной форме Бойса – Кодда, если:

- 1) удовлетворяет требованиям третьей нормальной формы;
- 2) в ней отсутствуют зависимости атрибутов составного ключа от остальных неключевых атрибутов.

#### Например:

Неключевой **атрибут** C функционально зависит от составного ключа (A + B).

**Атрибут В** в свою очередь функционально зависит от атрибута **С**, т.е. неключевой **атрибут С** выступает в роли детерминанта для атрибута В.



Не путать с неполной функциональной зависимостью – там наоборот неключевой атрибут C зависел бы от атрибута B – части составного ключа A,B)

Такая взаимозависимость требует дальнейшей декомпозиции таблицы.

Т.о., если в отношении существует несколько функциональных зависимостей, то каждый атрибут или набор атрибутов, от которого зависит другой атрибут, называется детерминантом отношения.

Студ_ном	Студ_Фам	Студ_билет	Студ_оценка
27711	Иванов	5778	5
27601	Петров	3562	8

Студ\_ном -> Студ\_Фам,

Студ\_ном -> Студ\_билет

Атрибут Студ\_ном – детерминант данного отношения

Однако данном отношении можно выделить еще один потенциальный ключ отношения: Студ\_билет

НФ БК учитывает все потенциальные ключи, которые входят в отношения.

Если отношение имеет единственный потенциальный ключ, то 3-я НФ и НФ БК – эквивалентны.

Потенциальным (возможным) ключом отношения называется набор атрибутов отношения, который полностью и однозначно (функционально полно) определяет значения всех остальных атрибутов отношения, то есть возможный ключ — это набор атрибутов, также однозначно определяющий кортеж отношения.

Студ_ном	Студ_Фам	Студ_билет	Студ_оценка
27711	Иванов	5778	5
27601	Петров	3562	8

Отношение находится в нормальной форме Бойса—Кодда, если оно находится в третьей нормальной форме и каждый детерминант отношения является возможным ключом отношения.

Рассмотрим отношение, моделирующее сдачу студентом текущих экзаменов.

Ном_Зач_КН	Идентификатор_Студ	Дисц-на	Дата	Оценка
Б-2345	2345	БД	14.05.13	9

Возможными (составными) ключами отношения являются:

Нонер\_зач.кн, Дисциплина, Дата и Идентификатор\_студента, Дисциплина, Дата.

(только они однозначно определяют кортежи этого отношения)

Какие функциональные зависимости у нас имеются?

### Функциональные зависимости:

- 1. Номер\_зач.кн, Дисциплина. Дата -> Оценка;
- 2. Идентификатор\_студента, Дисциплина. Дата -> Оценка;
- 3. Номер зач.кн. -> Идентификатор\_студента;
- 4. Идентификатор студента -> Номер зач.кн.
- Но зависимости 3 и 4 избыточные, так как это **детерминанты**, которые <u>не являются возможными ключами</u> отношений в данном отношении.
- Действительно, если оставить в данном отношении ключом только Номер зач.кн., мы не сможем однозначно выделить кортеж по отдельному предмету с конкретной оценкой.

То же самое и при использовании ключа Идентификатор\_студента

Для приведения отношения к нормальной форме Бойса—Кодда надо разделить исходное отношение, например, на два со следующими схемами: (Идентификатор\_студента. Дисциплина. Дата. Оценка) (Идентификатор\_студента. Номер зач.кн.) или наоборот:

(Номер зач.кн., Дисциплина. Дата, Оценка) (Номер зач.кн.. Идентификатор\_студента)

Эти схемы равнозначны с точки зрения теории нормализации, поэтому выбирать проектировщикам следует исходя из некоторых дополнительных рассуждений.

# Нормальные формы высших порядков 4NF и 5NF (PJ/NF)

Четвертая нормальная форма устраняет **нетривиальные многозначные** зависимости.

Отношение находится в 4НФ, если оно находится в **BCNF** и в нем **отсутствуют** нетривиальные многозначные зависимости.

#### Определение:

В отношении R (A, B, C) существует многозначная зависимость (multi valid dependence, MVD) R.A -» R.B в том и только в том случае, если множество значений B, соответствующее паре значений A и C, зависит только от A и не зависит от C. Различают тривиальные и нетривиальные многозначные зависимости.

# Нормальные формы высших порядков 4NF и 5NF (PJ/NF)

Для случая трех атрибутов X, Y, Z многозначная зависимость

X –» Y|Z будет тривиальной, если не существует функциональных зависимостей X –» Y и X –» Z.

Другими словами, многозначная зависимость является нетривиальной, если наблюдаемые многозначные зависимости X —» Y и X —» Z фактически являются функциональными зависимостями от первичного ключа отношения.

Тривиальная многозначная зависимость не нарушает 4НФ, а **нетривиальная** требует дальнейшей декомпозиции отношения, причем чаще всего сразу на три отношения.

Последней нормальной формой является пятая нормальная форма 5NF, которая связана с анализом нового вида зависимостей, зависимостей «проекции соединения» (project-join зависимости, обозначаемые как PJ-зависимости).

Этот вид зависимостей <u>является в некотором роде</u> обобщением многозначных зависимостей.

Отношение R (X, Y, ..., Z) удовлетворяет зависимости соединения (X, Y, ..., Z) в том и только в том случае, когда R восстанавливается без потерь путем соединения своих проекций на X, Y, ..., Z. Здесь X, Y, ..., Z — наборы атрибутов отношения R.

Отношение R находится в пятой нормальной форме (нормальной форме проекции-соединения — PJ/NF) в том и только в том случае, когда любая зависимость соединения в R следует из существования некоторого возможного ключа в R.

Пятая нормальная форма редко используется на практике. В большей степени она является теоретическим исследованием.

## Спасибо за внимание!